ECGEB352 ÉCONOMÉTRIE · TRAVAIL DE GROUPE 2026-2027

Résolution commentée du travail

Les 41 questions de l’énoncé : la réponse, le raisonnement expliqué depuis zéro, les résultats, le code R et une rédaction possible.

1. Communes belges
Revenus et prix des maisons. Régression, logarithmes, indicatrices, interactions.

2. Mères américaines
Enfants et travail. Variables instrumentales, 2SLS, tests de validité.

3. Localités burkinabè
Électrification. Double différence, effets fixes, erreurs-types groupées.

Novembre 2026 · accompagne le script travail_ecgeb352.R

Avant de commencer

Comment lire ce document

Les 41 questions de l'énoncé sont traitées dans l'ordre. Chaque sous-question suit le même plan.

Bloc	Ce qu'il contient
Énoncé	La question, telle qu'elle est posée.
Réponse	Ce qu'il faut pouvoir dire en deux ou trois phrases, chiffres compris.
Explication	Le raisonnement pas à pas, sans prérequis : d'où vient l'idée, pourquoi cette méthode, comment lire le résultat.
Résultats et **Code R**	Les tableaux produits par R, puis les lignes du script qui les donnent, commentées.
Rédaction possible	Une ou plusieurs formulations pour le rapport, quand la question laisse un choix. À réécrire avec tes mots.
À retenir, **oral**	En fin de question : l'essentiel, et les questions probables à l'oral avec leur réponse.

D'où viennent les chiffres

Tous les résultats sortent du script `travail_ecgeb352.R`, fourni avec ce document. Il a été exécuté du début à la fin sur les quatre fichiers du travail (R 4.3.3, 66 secondes, aucune erreur) et enregistre 91 fichiers dans le dossier `resultats`. Les **graphiques demandés par l'énoncé** sont ceux du script. Les **schémas explicatifs** viennent des outils de l'atelier interactif, figés dans leur état initial : quand le texte invite à manipuler un outil, c'est à l'atelier qu'il renvoie. « Les deux corrigés » désigne les versions de ChatGPT et de Claude que tu m'as transmises.

Ce que tu dois vérifier toi-même

✓ QUATRE POINTS QUE JE N'AI PAS PU CONTRÔLER

- **La colonne « DiD : TWFE » du tableau 4 de Schmidt et Moradi** (question 3.4 c) : l'article est en accès payant. Lis le coefficient, l'erreur-type et le nombre d'observations dans ta copie.
- **Les autres résultats de cet article** (question 3.9 b) : la liste donnée concorde avec l'énoncé, mais ne remplace pas la lecture des sections 1 à 4.
- **Le chiffre de −11,3 points du tableau 7 d'Angrist et Evans** (question 2.13) : il ne figure pas dans l'énoncé.
- **La raison pour laquelle Anvers a gardé son code INS** (question 1.1 d) : plausible, non confirmée à la source.

Trois points à connaître avant de commencer

- **La session R doit être en UTF-8.** Sinon R ne lit qu'une ligne de chaque fichier Statbel, avec un simple avertissement, et le script échoue plus loin. Le contrôle : `dim(immo_raw)` doit afficher 286 120 lignes. Sous Windows, utilise R 4.2 ou plus récent.
- **La fusion de Bastogne et Bertogne a pris effet le 2 décembre 2024**, et non le 1er.
- **L'effet sur les écoles électrifiées est fragile** (questions 3.5 et 3.8) : il vient d'une baisse dans le groupe de comparaison, et il n'est plus significatif avec des erreurs-types groupées.

L'énoncé précise que l'usage d'outils d'intelligence artificielle n'est pas autorisé pour le travail remis et qu'un examen oral suit la remise : ce document sert à comprendre et à vérifier, et ce que tu remets reste ta décision.

Sommaire

Partie 1 — Revenus et prix des maisons dans les communes belges

1.1 Construire la base : 565, 581, puis 551 communes 5
1.2 Ce que mesurent vraiment prix et rev_hab 15
1.3 Rouvroy et Charleroi : la précision d'une médiane 17
1.4 Décrire les données : tableaux, histogrammes, logarithmes 21
1.5 Le nuage de points 26
1.6 Quatre modèles, quatre façons de lire une pente 30
1.7 Variations prédites : approximation ou valeur exacte ? 33
1.8 Peut-on choisir un modèle à son R^2 ? 36
1.9 Ajouter la région : des droites parallèles 37
1.10 Changer de référence à la main 40
1.11 Vérifier avec relevel() 42
1.12 Pourquoi l'élasticité change : le biais de variable omise 43
1.13 Une élasticité par région 48
1.14 La variance des erreurs est-elle constante ? 57
1.15 Ajouter la population et la part d'appartements 64
1.16 Un contrôle problématique 66
1.17 L'élasticité dans les quatre spécifications 68
1.18 Une hausse du revenu fait-elle monter les prix ? 70

Partie 2 — Enfants et travail des mères

2.1 Décrire l'échantillon 77
2.2 La régression par les MCO et son biais 79
2.3 Un instrument valide ? 82
2.4 La première étape 86
2.5 Les quatre compositions de la fratrie 88
2.6 Forme réduite et variables instrumentales 92
2.7 Variables de contrôle : MCO contre VI 97
2.8 Les doubles moindres carrés avec deux instruments 100
2.9 Pourquoi ces résultats ? Les mécanismes 103
2.10 Un instrument à la fois 104
2.11 Le test de suridentification 107
2.12 Les variables instrumentales étaient-elles nécessaires ? 110
2.13 Travailler ou non : la marge extensive 113
2.14 Conclure : un effet causal, pour qui ? 115

Partie 3 — Électrification au Burkina Faso

3.1 Décrire le panel 122
3.2 Groupe traité, groupe de comparaison, périodes 124
3.3 Deux comparaisons naïves 127
3.4 La double différence 129
3.5 Trois autres variables de résultat 132
3.6 L'hypothèse des tendances parallèles 136
3.7 Les effets fixes 145
3.8 Les erreurs-types groupées 152
3.9 Plus de lumière, plus d'activité économique ? 157

Annexes

A Valeurs de contrôle 161
B Glossaire 162

PARTIE 1

Revenus et prix des maisons dans les communes belges

Régression, logarithmes, indicatrices

Les communes où les habitants gagnent plus ont-elles des maisons plus chères ? De combien ? Et cette relation est-elle la même en Flandre, en Wallonie et à Bruxelles ?

Ce que tu vas faire

Tu construis d'abord toi-même la base de données, à partir de deux fichiers publics de Statbel qui ne se correspondent pas tout à fait. Puis tu estimes la relation entre le revenu par habitant et le prix médian des maisons, de plusieurs façons, en te demandant à chaque étape ce que le chiffre veut dire.

Étape	Questions	L'idée à retenir
A. Construire et décrire	1.1 à 1.5	Avant d'estimer quoi que ce soit, savoir ce qu'est une ligne et ce que mesurent vraiment les variables.
B. Formes fonctionnelles	1.6 à 1.8	Un coefficient se lit en euros ou en pourcentage selon l'endroit où se trouve le logarithme.
C. Régions	1.9 à 1.12	Ajouter la région change l'élasticité : c'est le biais de variable omise, que tu vérifies au chiffre près.
D. Interaction	1.13	L'élasticité peut différer d'une région à l'autre.
E. Hétéroscédasticité	1.14	La précision des estimations dépend d'une hypothèse sur la dispersion des erreurs.
F. Contrôles et causalité	1.15 à 1.18	Un bon contrôle, un mauvais contrôle, et pourquoi rien de tout cela n'est un effet causal.

Les données

Deux fichiers de Statbel, l'office belge de statistique.

Fichier	Une ligne =	Ce qu'on en tire
`vastgoed_2010_9999.txt`	un territoire × une période × un type de bien	nombre de ventes, prix médian, quartiles
`TF_PSNL_INC_TAX_MUNTY.txt`	une commune × une année de revenus	revenu total net imposable, nombre d'habitants

Les deux se rejoignent par le code INS de la commune. La base finale compte **551 communes** : 281 flamandes, 251 wallonnes et 19 bruxelloises.

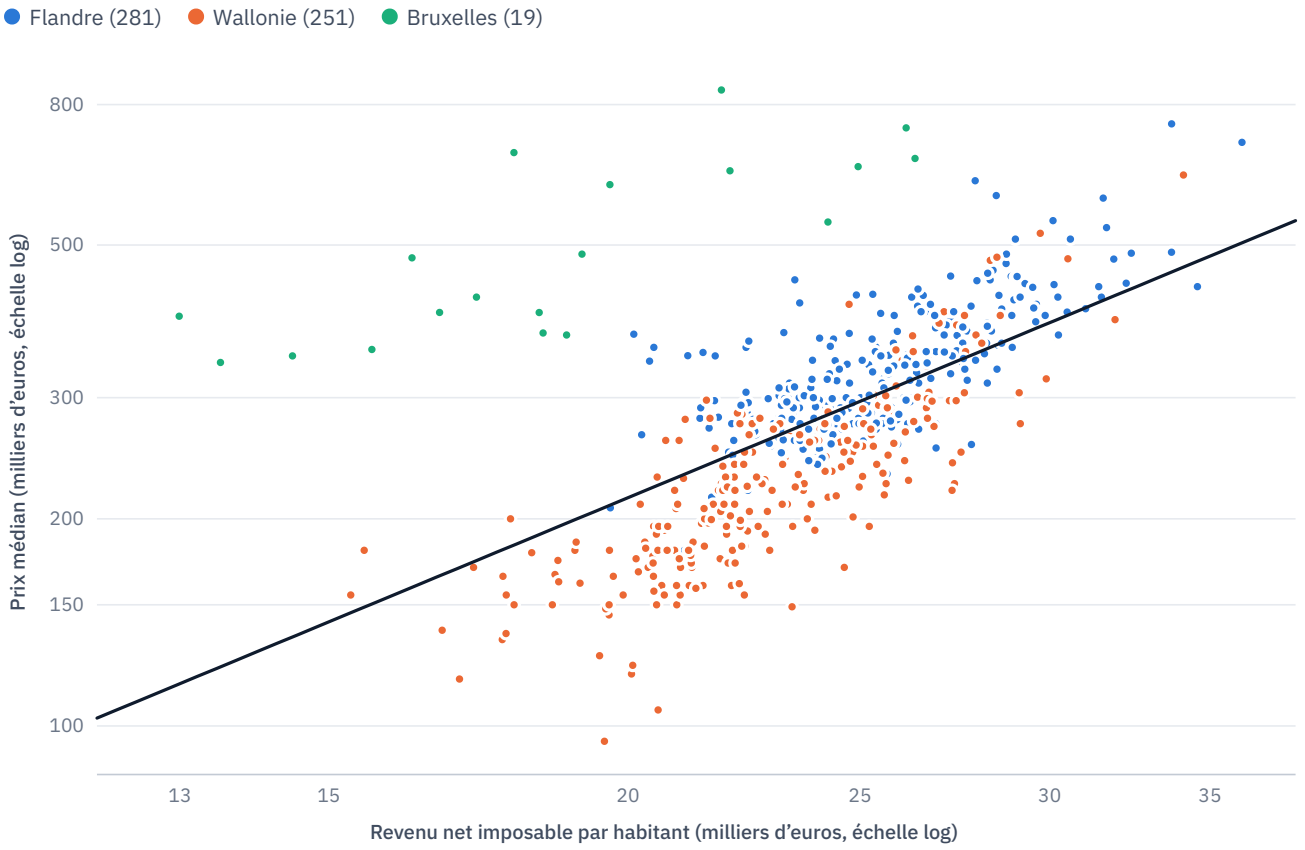
Le résultat en une phrase

À région donnée, une commune dont le revenu par habitant est supérieur de 1 % a un prix médian supérieur d'environ **1,6 %**. À revenu égal, les maisons sont environ 18 % moins chères en Wallonie et 2,4 fois plus chères à

Bruxelles qu'en Flandre. Ce sont des associations entre communes, pas l'effet d'une hausse de revenu.

Le nuage qui résume toute la partie 1

Chaque point est une commune (survole-la pour lire son nom). Change l'échelle et le modèle : la droite, son équation et son R^2 sont **recalculés en direct** sur les vraies données.



ln(prix) = −2,026 + 1,444 × ln(revenu) (R^2 = 0,367, erreur-type HC1 de la pente : 0,149)

En logarithmes, la pente est une **élasticité** : un revenu plus élevé de 1 % va de pair avec un prix plus élevé de 1,44 %. Regarde les couleurs : presque toute la Wallonie est sous la droite, tout Bruxelles au-dessus.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

A. CONSTRUCTION ET DESCRIPTION DE L'ÉCHANTILLON

1.1 Construire la base : 565, 581, puis 551 communes

Cette question est la plus longue du travail, et celle qui fait le plus peur. Elle ne demande pourtant aucune statistique : seulement de comprendre **pourquoi deux fichiers qui décrivent le même pays ne comptent pas le même nombre de communes**, et de réparer cela proprement.

L'outil ci-dessous montre tout le problème d'un coup. Reviens-y à chaque sous-question.

Les 14 fusions : retrouver les mêmes territoires dans les deux fichiers

Choisis une commune fusionnée. À gauche, les codes qui n'existent **que dans le fichier des ventes** (nouvelles communes) ; à droite, ceux qui n'existent **que dans le fichier fiscal** (anciennes communes). C'est exactement ce que renvoient les deux `anti_join()`.

SEULEMENT DANS LES VENTES (13)

Pajottegem 23106 · Wingene 37021 · Tielt 37022 · Nazareth-De Pinte 44086 · Lochristi 44087 · Merelbeke-Melle 44088 · Lokeren 46029 · Beveren-Kruibeke-Zwijndrecht 46030 · Tessenderlo-Ham 71071 · Hasselt 71072 · Bilzen-Hoeselt 73110 · Tongres-Borgloon 73111 · Bastogne 82039

SEULEMENT DANS LE FISCAL (29)

Borsbeek 11007 · Zwijndrecht 11056 · Gammerages 23023 · Gooik 23024 · Herne 23032 · Meulebeke 37007 · Ruiselede 37012 · Tielt 37015 · Wingene 37018 · De Pinte 44012 · Lochristi 44034 · Melle 44040 · Merelbeke 44043 · Moerbeke 44045 · Nazareth 44048 · Wachtebeke 44073 · Beveren 46003 · Kruibeke 46013 · Lokeren 46014 · Hasselt 71022 · Tessenderlo 71057 · Ham 71069 · Bilzen 73006 · Looz 73009 · Hoeselt 73032 · Kortessem 73040 · Tongres 73083 · Bastogne 82003 · Bertogne 82005

Commune	Code INS	Habitants	Revenu total (millions €)	Revenu par habitant
Anvers	11002	544 759	11 097,0	20 370 €
Borsbeek	11007	11 379	257,1	22 597 €
Anvers (somme)	**11002**	**556 138**	**11 354,1**	**20 416 €**

Le bon calcul : on additionne les revenus totaux et les habitants des anciennes communes, puis on divise : 11 354,1 millions € / 556 138 habitants = **20 416 €** par habitant.

L'erreur à éviter : faire la moyenne simple des revenus par habitant donnerait 21 484 € (écart de +1 068 €), car chaque ancienne commune pèserait autant, quelle que soit sa taille.

Le piège d'Anvers : son code 11002 existe dans les *deux* fichiers, donc aucun anti_join ne le signale. Une fusion directe associerait pourtant les ventes d'Anvers + Borsbeek au revenu de la seule ancienne Anvers (20 370 € au lieu de 20 416 €) et à 544 759 habitants au lieu de 556 138.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Compter les communes dans chaque fichier

ÉNONCÉ (A)

Combien de communes le fichier des ventes compte-t-il pour 2023 (ensemble des maisons, niveau communal, année entière) ? Combien de communes le fichier fiscal compte-t-il pour 2023 ?

RÉPONSE

565 communes dans le fichier des ventes, **581** dans le fichier fiscal. L'écart de 16 est le premier signe que les deux fichiers ne découpent pas le pays de la même façon.

EXPLICATION

Le fichier des ventes est un grand tableau « empilé » : la même commune y apparaît des dizaines de fois, pour chaque année, chaque trimestre, chaque type de bien. Pour compter les communes, il faut d'abord ne garder que **les lignes qui nous intéressent**. Quatre filtres :

Variable	Valeurs possibles	Ce qu'on garde	Pourquoi
`CD_YEAR`	2010 à 2026	`2023`	l'année étudiée
`CD_PERIOD`	`Q1` à `Q4` (trimestres), `S1`, `S2` (semestres), `Y` (année)	`"Y"`	l'année entière ; sinon les mêmes ventes seraient comptées plusieurs fois
`CD_niveau_refnis`	1 Belgique, 2 régions, 3 provinces, 4 arrondissements, 5 communes	`5`	le niveau communal
`CD_TYPE_NL`	4 types de biens	« toutes les maisons »	l'énoncé exclut les appartements

Comment savoir que `Y` veut dire « année » et que `5` veut dire « commune » ? Par les métadonnées, et en regardant ce que contient chaque variable avec `table()`. Petit contrôle malin : en 2023, pour un type de bien donné, le niveau 1 compte 1 ligne (la Belgique), le niveau 2 en compte 3 (les régions), le niveau 3 en compte 10 (les provinces), le niveau 4 en compte 43 (les arrondissements) et le niveau 5 en compte 565. C'est bien l'emboîtement administratif belge.

Le fichier fiscal est plus simple : une ligne par commune et par année. Il suffit de garder `CD_YEAR == 2023`.

⚠ LE CODE INS SE LIT COMME DU TEXTE

`colClasses = c(CD_REFNIS = "character")` oblige R à lire le code comme une chaîne de caractères. Sinon `01000` deviendrait le nombre `1000`, et la fusion entre les deux fichiers échouerait sans message d'erreur.

RÉSULTATS

Fichier	Filtre	Communes
Ventes	2023, année entière, niveau 5, toutes les maisons	**565**
Fiscal	revenus 2023	**581**

CODE R

```r
# Repérer les valeurs utiles avant de filtrer
table(immo_raw$CD_PERIOD)          # Q1..Q4, S1, S2, Y
table(immo_raw$CD_niveau_refnis)   # 1 à 5

ventes23 <- immo_raw %>%
  filter(CD_YEAR == 2023, CD_PERIOD == "Y", CD_niveau_refnis == 5)

maisons23 <- ventes23 %>%
  filter(CD_TYPE_NL == "Alle huizen met 2, 3, 4 of meer gevels (excl. appartementen)") %>%
  transmute(refnis = CD_REFNIS, commune = CD_REFNIS_FR,
            n_ventes = MS_TOTAL_TRANSACTIONS, prix = MS_P_50_median,
            p25 = MS_P_25, p75 = MS_P_75)

fisc23 <- fisc_raw %>% filter(CD_YEAR == 2023)

n_distinct(maisons23$refnis)          # 565
n_distinct(fisc23$CD_MUNTY_REFNIS)    # 581
```

- `filter()` garde les lignes qui vérifient **toutes** les conditions séparées par des virgules.
- `%>%` (le « pipe ») passe le résultat de gauche à la fonction de droite : « prends `immo_raw`, puis filtre ».
- `transmute()` crée de nouvelles colonnes et ne garde qu'elles : c'est ici qu'on donne aux variables les noms demandés par l'énoncé.
- `n_distinct()` compte les valeurs différentes.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Filtrer sur le néerlandais et justifier chaque filtre

Je garde l'année 2023, la période annuelle `Y` (les trimestres et semestres recompteraient les mêmes ventes), le niveau communal 5 et la ligne « toutes les maisons ». Je filtre sur l'intitulé néerlandais, sans accent, pour ne pas dépendre de l'encodage. J'obtiens 565 communes dans les ventes et 581 dans le fichier fiscal.

Filtrer sur l'intitulé français

Même sélection, avec le libellé français du type de bien. Plus lisible pour un lecteur francophone, mais sensible à l'encodage du fichier.

(b) Les communes présentes dans un seul fichier

ÉNONCÉ (B)

Établissez la liste des communes qui ne figurent que dans un seul des deux fichiers (fonction `anti_join()` du package dplyr). Combien y en a-t-il de chaque côté ? Que remarquez-vous dans leurs noms ?

RÉPONSE

13 communes n'existent que dans le fichier des ventes, **29** que dans le fichier fiscal. Les noms des premières sont des assemblages des secondes (Nazareth-De Pinte, Merelbeke-Melle…) : ce sont des **fusions de communes**.

EXPLICATION

`anti_join(x, y)` renvoie les lignes de `x` qui n'ont **aucun correspondant** dans `y`. C'est l'outil qui repère les « orphelins » d'une fusion. On l'appelle deux fois, en inversant les tables.

Regarde les deux listes dans l'outil en haut de la page. Trois choses sautent aux yeux :

- côté ventes, des **noms composés** : Nazareth-De Pinte, Merelbeke-Melle, Tessenderlo-Ham, Bilzen-Hoeselt, Tongres-Borgloon, Beveren-Kruibeke-Zwijndrecht ;
- côté fiscal, **les morceaux** de ces noms : Nazareth, De Pinte, Merelbeke, Melle, Tessenderlo, Ham… ;
- certains noms sont **des deux côtés, avec des codes différents** : Wingene, Tielt, Lochristi, Lokeren, Hasselt, Bastogne. La nouvelle commune a gardé le nom de l'une des anciennes, mais a reçu un nouveau code.

Sur les 29 communes « fiscales », 27 sont flamandes et 2 wallonnes (Bastogne et Bertogne). Les deux listes décrivent donc les mêmes territoires, découpés différemment : 29 anciennes communes sont devenues 13 nouvelles.

LE COMPTE EST-IL BON ?

581 − 29 + 13 = 565. Les 16 communes d'écart de la question (a) sont bien 29 − 13.

CODE R

```r
seulement_ventes <- anti_join(maisons23, fisc23, by = c("refnis" = "CD_MUNTY_REFNIS"))
seulement_fisc   <- anti_join(fisc23, maisons23, by = c("CD_MUNTY_REFNIS" = "refnis"))
nrow(seulement_ventes)   # 13
nrow(seulement_fisc)     # 29
```

`by = c("refnis" = "CD_MUNTY_REFNIS")` dit à R que la colonne `refnis` de la première table correspond à la colonne `CD_MUNTY_REFNIS` de la seconde. On en a besoin parce que la clé ne porte pas le même nom dans les deux fichiers.

(c) D'où vient la différence ?

ÉNONCÉ (C)

La documentation de Statbel n'explique pas cette différence. Consultez la page de Statistiek Vlaanderen « Nieuwe NIS-codes voor gefuseerde gemeenten vanaf 1 januari 2025 ». Expliquez l'origine de la différence entre les deux fichiers, et pourquoi ils ne suivent pas le même découpage communal pour l'année 2023.

RÉPONSE

28 communes flamandes ont fusionné en 13 le **1er janvier 2025**, et Bastogne a absorbé Bertogne le **2 décembre 2024**. Le fichier des ventes décrit toutes ses années, 2023 comprise, avec le **nouveau** découpage (565 communes) ; le fichier fiscal garde l'**ancien** (581 communes).

EXPLICATION

Une commune fusionnée reçoit en principe un nouveau code INS. La page de Statistiek Vlaanderen donne la table de correspondance entre anciens et nouveaux codes pour les fusions flamandes.

Reste la vraie question : pourquoi, **pour la même année 2023**, les deux fichiers n'utilisent-ils pas le même découpage ? Parce que chacun applique **un seul découpage à toute sa série**, mais pas le même. Les données elles-mêmes le montrent.

Fichier	Ce qu'on observe	Ce que ça veut dire
Ventes	565 communes **chaque année** de 2010 à 2025. Pajottegem a des ventes en 2010, alors qu'elle n'existe que depuis 2025.	Statbel a **recalculé tout l'historique** sur le découpage de 2025.
Fiscal	581 communes **chaque année** de 2005 à 2023.	Le fichier utilise le découpage en vigueur avant les fusions.

C'est cohérent : la série des ventes va jusqu'en 2026 et doit donc décrire les nouvelles communes ; les revenus de 2023, eux, ont été déclarés et imposés en 2024, quand les anciennes communes existaient encore.

En une phrase : **chaque fichier est cohérent avec lui-même, mais l'un décrit 2023 avec les communes de 2025, l'autre avec celles de 2023.**

✓ UNE ERREUR DE DATE DANS LES DEUX VERSIONS

ChatGPT et Claude écrivent tous deux que la fusion de Bastogne et Bertogne date du **1er décembre 2024**. La date d'effet est le **2 décembre 2024**, le lundi d'installation du nouveau conseil communal (décret wallon du 19 mai 2023 ; note du Registre national sur les fusions, ibz.rrn.fgov.be). Corrige-la dans ton rapport.

CODE R

```r
# Le fichier des ventes utilise-t-il le même découpage chaque année ?
immo_raw %>%
  filter(CD_PERIOD == "Y", CD_niveau_refnis == 5,
         CD_TYPE_NL == "Alle huizen met 2, 3, 4 of meer gevels (excl. appartementen)") %>%
  group_by(CD_YEAR) %>% summarise(communes = n_distinct(CD_REFNIS))    # 565 partout

fisc_raw %>% group_by(CD_YEAR) %>%
  summarise(communes = n_distinct(CD_MUNTY_REFNIS))                    # 581 partout
```

Ces lignes ne sont dans aucun des deux scripts : ce sont les deux comptages qui prouvent l'explication. `group_by()` puis `summarise()` calcule une ligne par année.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Explication démontrée par les données

Les deux fichiers appliquent chacun un seul découpage à toute leur série. Le fichier des ventes compte 565 communes pour chaque année depuis 2010 : Statbel a recalculé l'historique sur le découpage de 2025 (Pajottegem a des ventes en 2010 alors qu'elle n'existe que depuis 2025). Le fichier fiscal compte 581 communes chaque année : il garde l'ancien découpage, celui dans lequel les revenus de 2023 ont été imposés. Les fusions (28 communes flamandes devenues 13 au 1er janvier 2025, Bastogne et Bertogne au 2 décembre 2024) expliquent l'écart.

Explication courte

Les fusions de communes (1er janvier 2025 en Flandre, décembre 2024 pour Bastogne) ont créé de nouveaux codes. La série des ventes a été recalculée sur le nouveau découpage, alors que la statistique fiscale de 2023 garde l'ancien.

(d) Le piège d'Anvers

ÉNONCÉ (D)

Comparez la liste de cette page avec vos listes de la question (b) : l'une des communes concernées n'apparaît pas parmi les communes du fichier des ventes absentes du fichier fiscal. Laquelle, et pourquoi ? Quelle erreur commettriez-vous pour cette commune en fusionnant simplement les deux fichiers par code INS ?

RÉPONSE

Anvers. Elle a absorbé Borsbeek en **gardant son code 11002**. Ce code existe donc dans les deux fichiers, mais il ne désigne pas le même territoire. Une fusion directe associerait les ventes d'Anvers + Borsbeek au revenu et à la population de la seule ancienne Anvers, **sans aucun message d'erreur**.

EXPLICATION

La page de Statistiek Vlaanderen liste 14 opérations de fusion, mais ton `anti_join` côté ventes ne renvoie que 13 communes. Il en manque une : celle dont le code n'a pas changé.

Toutes les communes fusionnées ont reçu un nouveau code, **sauf Anvers**. Sélectionne-la dans l'outil en haut de la page : Borsbeek (11007) apparaît bien dans la liste « seulement fiscal », mais Anvers n'apparaît nulle part, puisque 11002 se retrouve des deux côtés.

Fichier	Ce que désigne le code 11002	Chiffres 2023
Ventes	Anvers **+ Borsbeek**	2 729 ventes, prix médian 339 000 €
Fiscal	Anvers **seule**	544 759 habitants, 20 370 € par habitant
Fiscal, code 11007	Borsbeek	11 379 habitants, 22 597 € par habitant

L'erreur chiffrée est petite : la population serait sous-estimée de 11 379 habitants (2 %) et le revenu par habitant vaudrait 20 370 € au lieu de 20 416 €. Mais c'est la pire sorte d'erreur : **silencieuse**. Pas de valeur manquante, pas d'avertissement, et Borsbeek disparaît de la base sans laisser de trace.

LA LEÇON GÉNÉRALE

Une fusion de tables par clé ne vérifie que les **codes**, jamais leur **signification**. Deux lignes peuvent se rejoindre parfaitement et parler de deux choses différentes.

(e) Reconstituer les communes fusionnées

ÉNONCÉ (E)

Reconstituez dans le fichier fiscal les communes issues des fusions, de façon à pouvoir les conserver dans votre base. Pourquoi cette reconstitution est-elle possible pour `rev_hab` ? Aurait-elle été possible dans l'autre sens, c'est-à-dire en répartissant entre les anciennes communes les données de ventes des nouvelles communes ?

RÉPONSE

On **additionne** les revenus totaux et les habitants des anciennes communes, puis on **refait la division**. C'est possible parce que `rev_hab` est un rapport de deux totaux. Dans l'autre sens, c'est impossible : une médiane ne se découpe pas sans les prix de chaque vente.

EXPLICATION

Un total s'additionne. Le revenu total de la nouvelle commune est exactement la somme des revenus totaux des anciennes, et de même pour les habitants. Le revenu par habitant de la commune fusionnée est donc :

$$\text{rev_hab}_{\text{fusion}} = \frac{\text{somme des revenus totaux}}{\text{somme des habitants}}$$

Pour Anvers : (11 097,0 + 257,1 millions €) / (544 759 + 11 379) = **20 416 €**.

⚠ NE FAIS PAS LA MOYENNE DES REVENUS PAR HABITANT

La moyenne simple de 20 370 € et 22 597 € donnerait 21 484 €, comme si Borsbeek pesait autant qu'Anvers. Le rapport des sommes est une moyenne **pondérée par la population**, et c'est la seule correcte. L'outil en haut de la page montre l'écart pour chacune des 14 fusions.

Et dans l'autre sens ? Il faudrait retrouver le prix médian de Nazareth seule à partir du prix médian de Nazareth-De Pinte. C'est impossible : la médiane dépend de **tous les prix individuels**, que le fichier ne contient pas. Même le nombre de ventes ne se répartit pas, puisqu'on ne sait pas dans quelle ancienne commune chaque vente a eu lieu.

LA RÈGLE À RETENIR

On peut **agréger** des totaux d'un niveau fin vers un niveau plus large. On ne peut pas **désagréger** sans les données individuelles.

CODE R

```r
# Table de passage : ancien code -> nouveau code (page de Statistiek Vlaanderen)
fusions <- data.frame(
  ancien  = c("11002", "11007", "23023", "23024", "23032" ),   # … 30 lignes en tout
  nouveau = c("11002", "11002", "23106", "23106", "23106" ))

fisc23_new <- fisc23 %>%
  left_join(fusions, by = c("CD_MUNTY_REFNIS" = "ancien")) %>%
  mutate(refnis = ifelse(is.na(nouveau), CD_MUNTY_REFNIS, nouveau)) %>%
  group_by(refnis) %>%
  summarise(rev_tot = sum(MS_TOT_NET_TAXABLE_INC),   # les totaux s'additionnent
            pop     = sum(MS_TOT_RESIDENTS),
            region  = first(region), .groups = "drop") %>%
  mutate(rev_hab = rev_tot / pop)                    # puis on refait le rapport

nrow(fisc23_new)                                       # 565
nrow(anti_join(maisons23, fisc23_new, by = "refnis"))    # 0 : plus aucun orphelin
```

1. `left_join()` colle à chaque commune fiscale son nouveau code, s'il y en a un. Les communes non concernées reçoivent `NA`.

2. `mutate(refnis = ifelse(...))` : si pas de nouveau code, on garde l'ancien.
3. `group_by(refnis)` regroupe les anciennes communes qui partagent le même nouveau code ; `summarise()` les additionne.
4. Les deux dernières lignes sont le **contrôle** : 565 communes, et plus aucun orphelin.

(f) Les 14 communes sans prix médian

ÉNONCÉ (F)

Certaines communes n'ont pas de prix médian. Combien ? Comparez leur nombre de ventes à celui des autres communes. Pourquoi, selon vous, Statbel ne publie-t-il pas de médiane pour ces communes ? Leur exclusion peut-elle affecter vos résultats ?

RÉPONSE

14 communes n'ont pas de prix médian. Elles ont toutes **19 ventes ou moins**, contre 108 en médiane pour les autres. Statbel ne publie les médianes qu'à partir de 16 ventes au prix exploitable, pour des raisons de **fiabilité** et de **confidentialité**. Leur exclusion change peu les résultats (2,5 % des communes, 0,3 % de la population), mais ceux-ci ne valent que pour les communes où il se vend assez de maisons.

EXPLICATION

565 − 14 = **551** : c'est le nombre de contrôle donné par l'énoncé.

Qui sont-elles ? De très petites communes rurales : 10 wallonnes (Ouffet, Tinlot, Amblève, Baelen, Olne, Burg-Reuland, Martelange, Sainte-Ode, Daverdisse, Herbeumont) et 4 flamandes (Biévène, Messines, Horebeke, Herstappe). Herstappe, la plus petite commune du pays (76 habitants), n'a même aucun nombre de ventes renseigné.

Pourquoi pas de médiane ? Deux raisons, qui sont celles que donne la méthodologie de Statbel.

- **Fiabilité.** Une médiane calculée sur cinq ou dix ventes change énormément d'une année à l'autre, au gré des biens vendus. La question 1.3 le chiffre.
- **Confidentialité.** Avec cinq ventes, la médiane et les quartiles sont presque des prix individuels : on pourrait reconnaître une transaction.

Le seuil se voit dans les données :

Ventes de maisons en 2023	Communes sans médiane	Communes avec médiane
15 ou moins	6	0
16	1	0
17 à 19	6	4
20 ou plus	0	547

Entre 17 et 19 ventes, certaines médianes sont publiées et d'autres non. L'explication : le seuil de 16 porte sur les ventes dont **le prix est exploitable**, et le fichier compte aussi des actes sans prix utilisable.

L'exclusion fausse-t-elle les résultats ? Peu en pratique. Sur le principe, c'est une sélection sur la **taille du marché**, pas directement sur le prix : elle ne biaise pas les estimations si la relation entre prix et revenu est la

même dans ces communes qu'ailleurs. Mais on ne peut pas le vérifier, et nos résultats ne décrivent donc que les communes où il se vend au moins une quinzaine de maisons par an.

RÉSULTATS

Groupe	Communes	Ventes (médiane)	Ventes (min – max)	Habitants (moyenne)	Revenu par habitant (moyenne)
Avec prix médian	551	108	17 – 2 729	21 282	24 288 €
Sans prix médian	14	16	5 – 19	2 655	23 296 €

CODE R

```
base_565 <- maisons23 %>%
  inner_join(fisc23_new, by = "refnis") %>%    # garde les communes présentes des deux côtés
  left_join(apparts23, by = "refnis")          # ajoute n_app, NA s'il n'y en a pas

sum(is.na(base_565$prix))                      # 14
base <- base_565 %>% filter(!is.na(prix))      # la base d'analyse
nrow(base)                                     # 551
```

`is.na()` repère les valeurs manquantes ; `!` veut dire « non ». `filter(!is.na(prix))` garde donc les lignes où le prix **n'est pas** manquant.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

La règle, les deux raisons, puis le biais

14 communes n'ont pas de prix médian ; toutes ont 19 ventes ou moins, contre 108 en médiane ailleurs. Statbel ne publie les médianes qu'à partir de 16 ventes au prix exploitable, pour deux raisons : une médiane sur si peu de ventes est trop instable, et elle révélerait presque des prix individuels. Leur exclusion pèse peu (2,5 % des communes, 0,3 % de la population). C'est une sélection sur la taille du marché, qui ne biaise les estimations que si la relation prix-revenu y est différente ; nos résultats valent pour les communes où il se vend assez de maisons.

Mettre l'accent sur la règle de publication

Statbel publie les percentiles à partir de 16 transactions au prix valable. Les 14 communes concernées sont de petits marchés ; si elles sont plus rurales ou moins chères, les résultats sur 551 communes se généralisent moins bien aux 565.

Mettre l'accent sur les raisons et le poids de l'exclusion

Les 14 communes sans médiane sont de très petites communes rurales. Statbel ne publie pas leur médiane parce qu'elle serait peu fiable et presque individuelle. Elles ne représentent que 0,3 % de la population : leur exclusion change peu les estimations.

À RETENIR

- 565 communes dans les ventes (découpage 2025), 581 dans le fiscal (ancien découpage), 13 et 29 orphelins.
- On agrège le fichier fiscal vers le nouveau découpage : somme des totaux, puis rapport.
- Anvers garde son code : le piège silencieux.
- 14 communes sans médiane (moins de 16 prix exploitables) : il reste 551 communes.

QUESTIONS PROBABLES À L'ORAL

Pourquoi lis-tu le code INS comme du texte ?

Pour garder les zéros initiaux (01000 pour la Belgique) et fusionner sur des chaînes strictement identiques. Lu comme un nombre, le code perd ses zéros et la fusion échoue sans prévenir.

Explique en trente secondes pourquoi tu as 551 communes.

Le fichier des ventes compte 565 communes, sur le découpage de 2025. Le fichier fiscal en compte 581, sur l'ancien découpage. Je reconstitue les 14 communes fusionnées dans le fichier fiscal en additionnant revenus et habitants, ce qui donne 565 communes des deux côtés. J'en retire 14 qui n'ont pas de prix médian, faute de ventes suffisantes : il en reste 551.

Que fait `anti_join(x, y)` ?

Il renvoie les lignes de x qui n'ont aucun correspondant dans y. Je l'utilise dans les deux sens pour repérer les communes présentes dans un seul fichier.

Pourquoi ne peut-on pas répartir les ventes d'une nouvelle commune entre les anciennes ?

Parce qu'une médiane dépend de tous les prix individuels, que le fichier ne donne pas. On peut additionner des totaux, pas découper une médiane.

1.2 Ce que mesurent vraiment prix et rev_hab

Avant d'estimer une relation entre deux variables, il faut se demander ce qu'elles mesurent **vraiment**. Aucune des deux ne mesure exactement ce qu'on voudrait. Ces limites reviendront à la question 1.18, quand il faudra dire pourquoi l'élasticité n'est pas un effet causal.

(a) Le prix médian mesure-t-il la valeur des maisons ?

ÉNONCÉ (A)

`prix` est le prix médian des maisons vendues en 2023 dans la commune. Est-ce une mesure de la valeur des maisons de la commune ? Donnez une raison pour laquelle les deux peuvent différer.

RÉPONSE

Non, pas exactement. C'est la médiane des maisons **vendues en 2023**, pas celle de **toutes** les maisons de la commune. Les deux diffèrent dès que les maisons vendues une année donnée ne ressemblent pas au parc existant.

EXPLICATION

Imagine une commune de 5 000 maisons dont 80 se vendent en 2023. `prix` ne décrit que ces 80. Si ce sont surtout de petites maisons mitoyennes, ou des maisons à rénover vendues après une succession, leur prix médian sera plus bas que la valeur médiane des 5 000. C'est un **effet de composition** : l'échantillon des ventes n'est pas tiré au hasard dans le parc.

Deux autres raisons, si tu veux aller plus loin :

- **Qualité et taille.** Le prix médian mélange le prix « d'une maison donnée » et le type de maisons de la commune. Une commune de grandes villas a un prix médian élevé même si le mètre carré y est bon marché.
- **Hasard.** Avec peu de ventes, la médiane dépend des quelques biens vendus cette année-là (question 1.3).

L'énoncé ne demande qu'**une** raison. Donne la première, c'est la plus directe.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Composition des ventes

Non : `prix` est la médiane des maisons vendues en 2023, pas de toutes les maisons de la commune. Si les biens vendus cette année-là ne ressemblent pas au parc (davantage de petites maisons ou de maisons à rénover, par exemple), le prix médian des ventes s'écarte de la valeur médiane des maisons.

Rotation plus forte de certains biens

Non : le prix médian partage en deux les ventes de l'année. Si certains biens, par exemple les maisons rénovées, changent plus souvent de propriétaire, ils sont surreprésentés parmi les ventes par rapport au parc.

(b) Pourquoi rev_hab mesure mal le revenu des ménages

ÉNONCÉ (B)

Donnez deux raisons pour lesquelles `rev_hab` peut mal mesurer le revenu des ménages d'une commune. L'une de ces raisons concerne particulièrement certaines communes bruxelloises : laquelle ?

RÉPONSE

1. On divise par les **habitants**, enfants compris, pas par les ménages : à revenu de ménage égal, une commune de familles nombreuses a un `rev_hab` plus bas.
2. Le revenu **imposable** n'est pas tout le revenu. À Bruxelles, les **fonctionnaires européens et internationaux** ne paient pas l'impôt belge sur leur salaire : leurs revenus élevés manquent, alors qu'ils habitent et achètent dans ces communes.

EXPLICATION

`rev_hab` = revenu total net imposable de la commune ÷ nombre d'habitants. Regarde séparément le haut et le bas de la fraction.

Le dénominateur. On divise par tous les résidents, bébés compris. Deux communes où chaque ménage gagne 60 000 € : dans l'une les ménages comptent deux personnes (`rev_hab` = 30 000 €), dans l'autre quatre (`rev_hab` = 15 000 €). Le pouvoir d'achat immobilier des ménages est pourtant le même.

Le numérateur. Le revenu net imposable est ce qui figure dans la déclaration d'impôt. Il manque :

- les revenus non imposables (les allocations familiales, par exemple) ;
- la plupart des revenus du capital (intérêts, dividendes), taxés à la source et souvent non déclarés ;
- les loyers perçus, taxés sur le revenu cadastral, bien inférieur aux loyers réels ;
- et, pour Bruxelles, les salaires des fonctionnaires européens et internationaux, **exonérés de l'impôt belge**.

Ce dernier point se voit dans les données. Ixelles a le prix médian le plus élevé du pays (840 000 €) pour un revenu par habitant de 21 877 €, **sous la moyenne belge**. Les ménages qui y achètent des maisons sont en partie invisibles dans la statistique fiscale.

POURQUOI C'EST IMPORTANT POUR LA SUITE

À Bruxelles, `rev_hab` sous-estime le revenu réel des acheteurs. Les communes bruxelloises se retrouvent donc à gauche du nuage (revenu apparent faible) et très haut (prix élevés) : c'est ce qui tire vers le bas l'élasticité du modèle sans régions (question 1.12).

QUESTIONS PROBABLES À L'ORAL

Pourquoi les communes bruxelloises ont-elles un revenu par habitant si bas pour des prix si élevés ?

En partie parce que rev_hab y sous-estime le revenu des acheteurs : les fonctionnaires européens et internationaux ne paient pas l'impôt belge sur leur salaire, donc leurs revenus n'apparaissent pas dans la statistique fiscale, alors qu'ils achètent des maisons dans ces communes.

1.3 Rouvroy et Charleroi : la précision d'une médiane

Deux communes au prix médian presque identique, mais l'une repose sur 17 ventes et l'autre sur 1 854. Cette question te fait mesurer ce que cela change, et prépare la question 1.14 sur l'hétéroscédasticité.

(a) Comparer les deux communes

ÉNONCÉ (A)

Comparez les communes de Rouvroy et de Charleroi : nombre de ventes, prix médian, écart interquartile (p75 – p25) et écart interquartile rapporté au prix médian.

RÉPONSE

Prix médians proches (158 500 € et 137 750 €), mais Rouvroy repose sur **109 fois moins de ventes** (17 contre 1 854), et ses prix sont bien plus dispersés : l'écart interquartile y **dépasse le prix médian** (rapport de 1,09, contre 0,65 à Charleroi).

EXPLICATION

L'écart interquartile p75 – p25 est la largeur de la « moitié centrale » des prix : un quart des maisons se vend moins cher que p25, un quart plus cher que p75. Le diviser par le prix médian permet de comparer la dispersion de deux communes qui n'ont pas le même niveau de prix.

À Rouvroy, la moitié centrale des ventes s'étale de 97 500 € à 269 500 € : presque du simple au triple. Dans une petite commune rurale, quelques biens très différents (une fermette, une maison à rénover, une villa récente) suffisent à écarter les quartiles.

RÉSULTATS

Commune	Ventes	Prix médian	p25	p75	Écart interquartile	Écart / prix médian
Charleroi	1 854	137 750 €	95 000 €	185 000 €	90 000 €	0,65
Rouvroy	17	158 500 €	97 500 €	269 500 €	172 000 €	1,09

CODE R

```
tab_1_3 <- base %>%
  filter(commune %in% c("ROUVROY", "CHARLEROI")) %>%
  transmute(commune, n_ventes, prix, p25, p75,
            eiq         = p75 - p25,
            eiq_relatif = (p75 - p25) / prix,
            se_mediane  = 0.93 * (p75 - p25) / sqrt(n_ventes))
```

`%in%` teste l'appartenance à une liste : « la commune est-elle Rouvroy ou Charleroi ? ». Les noms sont en majuscules dans le fichier des ventes.

(b) L'erreur-type de la médiane

ÉNONCÉ (B)

Pour une distribution normale, l'erreur-type de la médiane d'un échantillon de n observations vaut environ 0,93 × (p75 – p25)/√n. Calculez cette erreur-type approximative pour les deux communes et comparez-les.

RÉPONSE

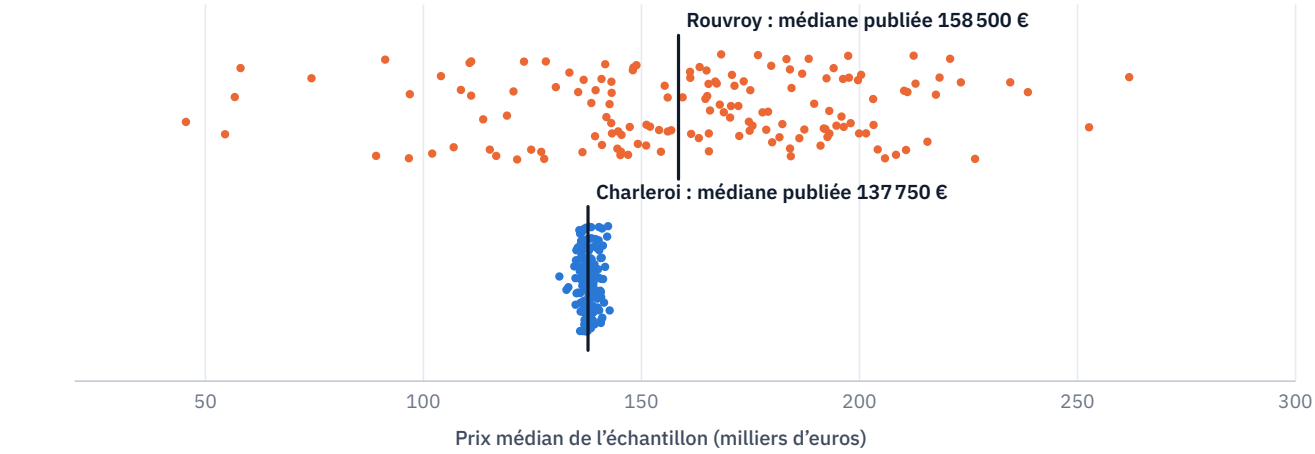
Rouvroy : 38 796 € (24,5 % du prix médian). **Charleroi : 1 944 €** (1,4 %). L'erreur-type est **20 fois plus grande** à Rouvroy.

EXPLICATION

L'erreur-type répond à la question : « si l'on avait observé d'autres ventes, tirées dans la même distribution de prix, de combien la médiane aurait-elle bougé ? ». L'outil ci-dessous le montre.

Une médiane sur 17 ventes, une médiane sur 1 854 ventes

Chaque point est le prix médian qu'on aurait observé une « autre année », si les ventes étaient tirées au hasard dans la même distribution de prix (supposée normale, comme dans l'énoncé). Plus les points s'étalent, moins la médiane publiée est fiable.



Formule de l'énoncé, erreur-type ≈ 0,93 × (p75 – p25) / √n : **Rouvroy 38 796 €** (0,93 × 172 000 / √17), **Charleroi 1 944 €** (0,93 × 90 000 / √1 854), soit un rapport de 20.

Dans la simulation (150 années) : l'écart-type des médianes vaut 39 053 € à Rouvroy et 1 869 € à Charleroi. La formule donne bien l'ordre de grandeur de cette dispersion.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

La formule dit deux choses simples :

$$\text{erreur-type} \approx 0{,}93 \times \frac{p75 - p25}{\sqrt{n}}$$

- **plus les prix sont dispersés** (numérateur), moins la médiane est précise ;
- **plus il y a de ventes** (dénominateur), plus elle est précise, mais seulement comme $\sqrt{n}$: il faut quatre fois plus de ventes pour doubler la précision.

Le calcul : Rouvroy, 0,93 × 172 000 / √17 = 38 796 €. Charleroi, 0,93 × 90 000 / √1 854 = 1 944 €.

D'où vient le facteur 20 ? Il se décompose : le nombre de ventes explique un facteur √(1 854 / 17) = 10,4 ; la dispersion plus forte explique le reste (172 000 / 90 000 = 1,9). Et 10,4 × 1,9 ≈ 20.

> **D'où sort le 0,93 ?**

RÉSULTATS

Commune	Erreur-type	En % du prix médian	Intervalle à 95 % du prix médian
Charleroi	1 944 €	1,4 %	133 900 € – 141 600 €
Rouvroy	38 796 €	24,5 %	82 500 € – 234 500 €

(c) Conséquence pour la régression

ÉNONCÉ (C)

Le prix médian de Rouvroy est-il une mesure aussi fiable du prix d'une maison typique de la commune que celui de Charleroi ? Si `prix` est la variable dépendante d'une régression, quelle hypothèse du modèle linéaire cette différence de précision entre communes peut-elle remettre en cause ? Vous le vérifierez à la question 1.14.

RÉPONSE

Non : la médiane de Rouvroy est bien moins fiable. Comme `prix` est la variable dépendante, cette imprécision entre dans le terme d'erreur, dont la variance dépend alors du nombre de ventes. C'est l'hypothèse d'**homoscédasticité** (variance constante des erreurs) qui est remise en cause.

EXPLICATION

Le raisonnement tient en trois étapes.

1. Le prix qu'on observe est le « vrai » prix typique de la commune, plus une erreur d'échantillonnage : $\text{prix}_{\text{observé}} = \text{prix}_{\text{typique}} + e$.
2. Dans la régression, cette erreur e se retrouve dans le terme d'erreur u, avec tout le reste.
3. La variance de e vaut environ (0,93 × écart interquartile)² / n : elle est **énorme à Rouvroy, minuscule à Charleroi**. La variance de u n'est donc pas la même pour toutes les communes.

Une variance des erreurs qui change d'une observation à l'autre, c'est par définition de l'hétéroscédasticité.

	Ce que ça change
Les coefficients	**Rien** : une erreur de mesure sur y, sans lien avec x, ajoute du bruit mais pas de biais.
Les erreurs-types classiques	Elles deviennent **fausses**. D'où les erreurs-types robustes HC1 imposées par l'énoncé.
L'efficacité	Les MCO ne sont plus les plus précis. Des moindres carrés pondérés par le nombre de ventes le seraient davantage.

RÉDACTION POSSIBLE POUR LE RAPPORT

Nommer l'hypothèse et dérouler le raisonnement

Non : l'erreur-type de la médiane vaut 24,5 % du prix à Rouvroy, contre 1,4 % à Charleroi. Le prix observé est le prix typique plus une erreur d'échantillonnage, qui entre dans le terme d'erreur de la régression. Comme la variance de cette erreur dépend du nombre de ventes, la variance du terme d'erreur n'est pas constante d'une commune à l'autre : l'hypothèse d'homoscédasticité est remise en cause. Les coefficients restent sans biais, mais les erreurs-types classiques ne sont plus valables.

QUESTIONS PROBABLES À L'ORAL

Quelle est la différence entre l'erreur-type de la médiane de Rouvroy et l'erreur-type de l'élasticité ?

La première mesure l'imprécision d'un prix communal : de combien la médiane de Rouvroy aurait pu varier avec d'autres ventes. La seconde mesure l'incertitude sur la relation estimée entre revenu et prix sur l'ensemble des 551 communes.

1.4 Décrire les données : tableaux, histogrammes, logarithmes

On regarde les données avant de les modéliser. Deux enseignements à repérer : Bruxelles est à la fois la région la plus chère et la plus pauvre, et le logarithme ne fait pas la même chose au prix et au revenu.

(a) Statistiques descriptives

ÉNONCÉ (A)

Présentez un tableau des statistiques descriptives (moyenne, médiane, écart-type, minimum, maximum) de `prix`, `rev_hab` et `n_ventes`, pour l'ensemble des communes et par région. Indiquez les communes qui ont les valeurs minimale et maximale de `prix` et de `rev_hab`.

RÉPONSE

Prix médian moyen : **296 148 €** (Flandre 336 156 €, Wallonie 235 028 €, Bruxelles 511 876 €). Revenu par habitant moyen : **24 288 €** (Flandre 25 680 €, Wallonie 23 116 €, Bruxelles 19 199 €). Extrêmes : prix de 95 000 € à **Hastière** à 840 000 € à **Ixelles** ; revenu de 12 987 € à **Saint-Josse-ten-Noode** à 36 091 € à **Sint-Martens-Latem**.

EXPLICATION

Trois choses à commenter dans ce tableau.

- **L'ordre des régions.** La Flandre est plus riche et plus chère que la Wallonie. Bruxelles est à part : **la plus chère et la plus pauvre à la fois**. Une seule droite pour tout le pays aura du mal à décrire cela.
- **Les asymétries.** Pour le prix, la moyenne (296 148 €) dépasse la médiane (285 000 €) ; pour le nombre de ventes, l'écart est énorme (156 contre 108). Quelques très grandes valeurs tirent la moyenne vers le haut : Anvers compte 2 729 ventes.
- **Le revenu.** Moyenne et médiane presque égales (24 288 € et 24 269 €) : la distribution est déjà symétrique.

⚠ UNE MOYENNE ENTRE COMMUNES, PAS ENTRE MAISONS

Ces statistiques donnent le même poids à chaque commune : Rouvroy compte autant que Charleroi. 296 148 € est la moyenne des prix médians communaux, pas le prix moyen d'une maison en Belgique.

RÉSULTATS

Variable	Groupe	Communes	Moyenne	Médiane	Écart-type	Minimum	Maximum
Prix médian (€)	Belgique	551	296 148	285 000	101 888	95 000	840 000
	Flandre	281	336 156	319 000	76 891	180 000	750 000
	Wallonie	251	235 028	225 000	73 493	95 000	632 000
	Bruxelles	19	511 876	479 000	154 953	337 500	840 000
Revenu par habitant (€)	Belgique	551	24 288	24 269	3 264	12 987	36 091
	Flandre	281	25 680	25 521	2 689	19 660	36 091
	Wallonie	251	23 116	22 628	2 934	15 317	34 116

Variable	Groupe	Communes	Moyenne	Médiane	Écart-type	Minimum	Maximum
	Bruxelles	19	19 199	18 429	4 089	12 987	26 354
Nombre de ventes	Belgique	551	156,5	108	216,1	17	2 729
	Flandre	281	195,1	137	250,9	18	2 729
	Wallonie	251	116,7	72	168,5	17	1 854
	Bruxelles	19	110,3	90	73,4	19	276

Extrême	Commune	Région	Valeur
Prix le plus bas	Hastière	Wallonie	95 000 €
Prix le plus élevé	Ixelles	Bruxelles	840 000 €
Revenu le plus bas	Saint-Josse-ten-Noode	Bruxelles	12 987 €
Revenu le plus élevé	Sint-Martens-Latem	Flandre	36 091 €

CODE R

```r
stats_desc <- function(d, groupe) {
  bind_rows(lapply(c("prix", "rev_hab", "n_ventes"), function(v) {
    x <- d[[v]]
    data.frame(groupe = groupe, variable = v, n = length(x),
               moyenne = mean(x), mediane = median(x), ecart_type = sd(x),
               minimum = min(x), maximum = max(x))
  }))
}
tab_1_4 <- bind_rows(stats_desc(base, "Belgique"),
                     stats_desc(filter(base, region == "Flandre"), "Flandre"),
                     stats_desc(filter(base, region == "Wallonie"), "Wallonie"),
                     stats_desc(filter(base, region == "Bruxelles"), "Bruxelles"))

base %>% slice_min(prix, n = 1)    # la commune au prix le plus bas
base %>% slice_max(prix, n = 1)    # … et au prix le plus élevé
```

On écrit une petite fonction `stats_desc()` pour ne pas recopier quatre fois le même calcul. `lapply()` applique la fonction à chacune des trois variables, `bind_rows()` empile les résultats. `slice_min()` et `slice_max()` renvoient la ligne où une variable est minimale ou maximale.

(b) Histogrammes et coefficient d'asymétrie

ÉNONCÉ (B)

Représentez les histogrammes de `prix` et de `rev_hab`, puis ceux de leur logarithme, et calculez le coefficient d'asymétrie de ces quatre variables.

RÉPONSE

Asymétrie : **1,34** pour `prix`, **−0,01** pour ln(prix), **0,01** pour `rev_hab`, **−0,59** pour ln(rev_hab).

EXPLICATION

Un histogramme découpe l'axe en tranches et compte les communes dans chaque tranche. Le coefficient d'asymétrie résume sa forme en un nombre :

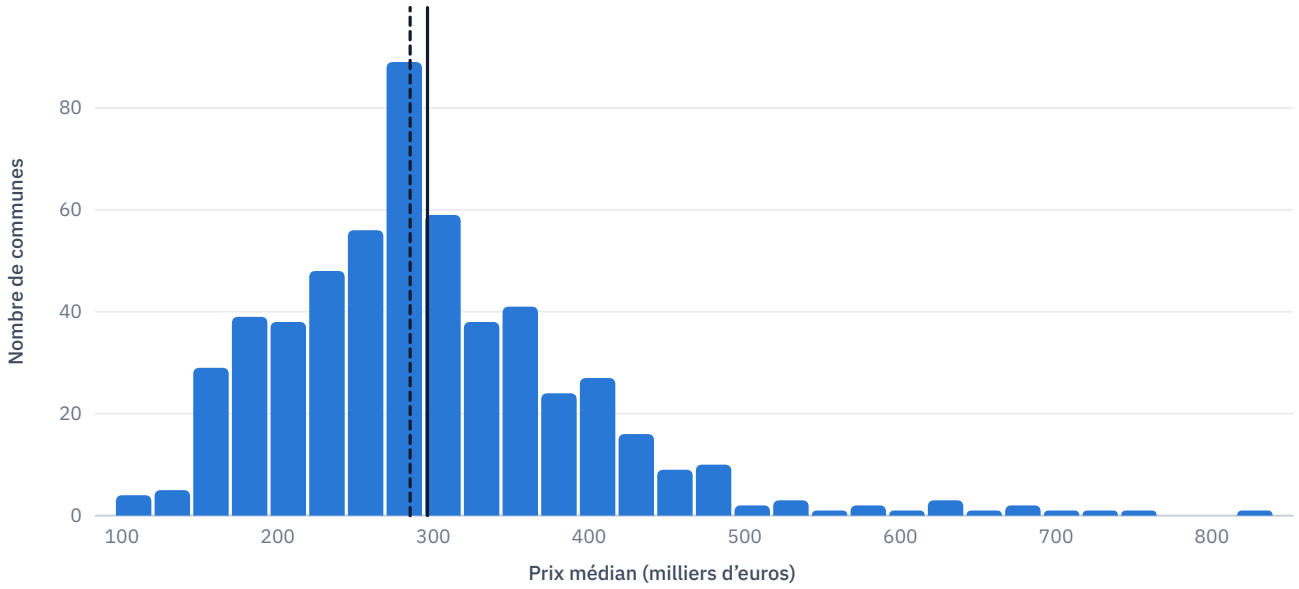
$$\text{asymétrie} = \frac{\frac{1}{n}\,\Sigma\,(x_i - \bar{x})^3}{\left[\frac{1}{n}\,\Sigma\,(x_i - \bar{x})^2\right]^{3/2}}$$

Pas besoin de retenir la formule, seulement sa lecture : les écarts à la moyenne sont mis **au cube**, ce qui garde leur signe et donne beaucoup de poids aux valeurs éloignées.

- **0** : distribution symétrique ;
- **positif** : la queue de droite est plus longue (quelques très grandes valeurs) ;
- **négatif** : la queue de gauche est plus longue.

Distribution du prix et du revenu, en niveau et en logarithme

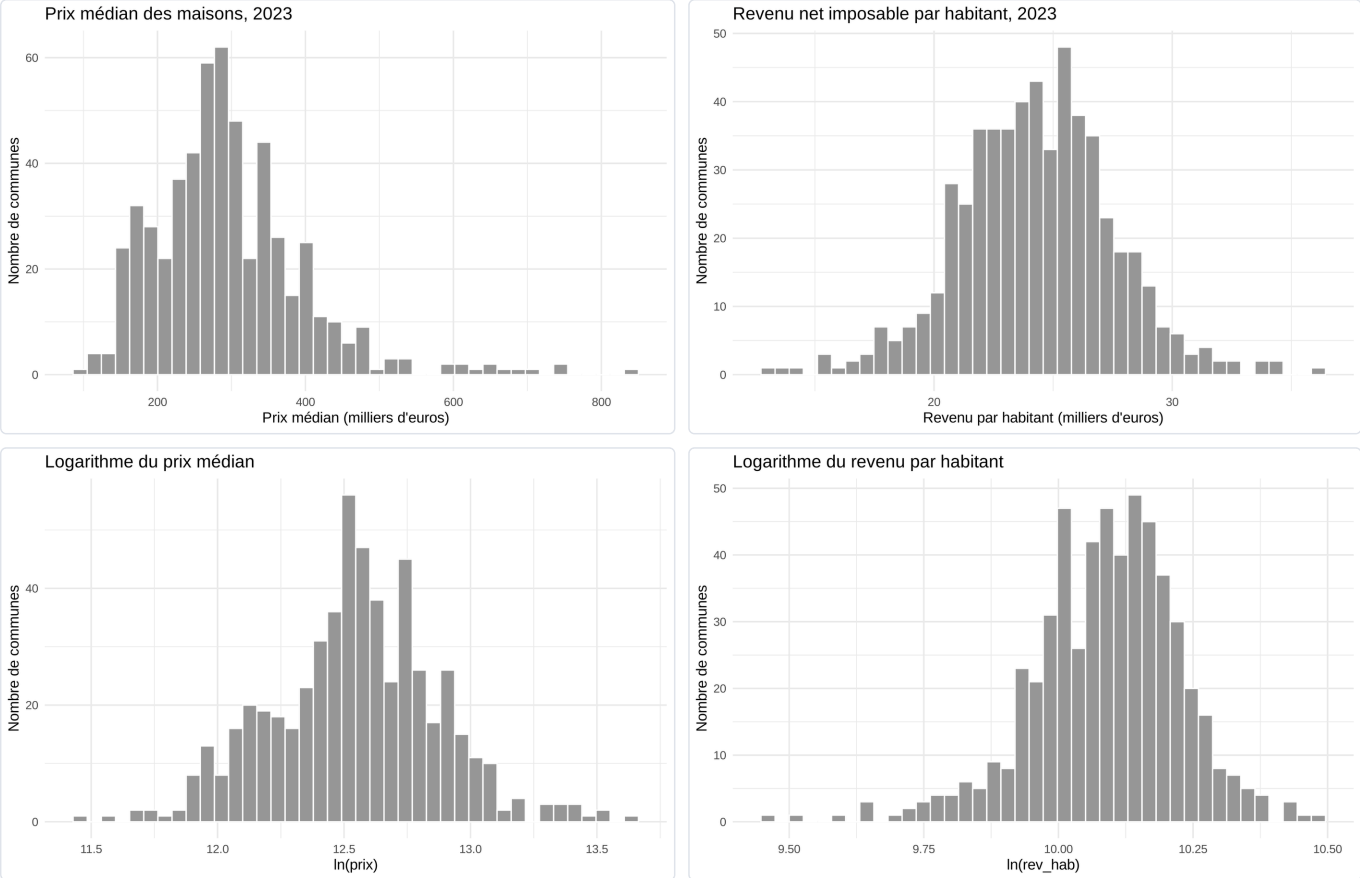
Compare la forme des quatre distributions. Le trait plein est la moyenne, le trait en tirets la médiane : quand ils se séparent, la distribution est asymétrique.



Moyenne 296 148 € (trait plein), médiane 285 000 € (tirets). Coefficient d'asymétrie : **1,34** — queue plus longue à droite (quelques communes très chères tirent la moyenne vers le haut).

Asymétrie de prix	Asymétrie de ln(prix)	Asymétrie de rev_hab	Asymétrie de ln(rev_hab)
1,34	-0,01	0,01	-0,59

Figure tirée de l'outil interactif de l'atelier, dans son état initial.



Histogrammes du prix médian et du revenu par habitant, en niveaux puis en logarithmes (551 communes, 2023). Source : Statbel. Fichiers : fig_1_4_prix.png, fig_1_4_rev.png, fig_1_4_lprix.png, fig_1_4_lrev.png.

CODE R

```r
asymetrie <- function(x) {
  m <- mean(x)
  mean((x - m)^3) / mean((x - m)^2)^1.5
}
asymetrie(base$prix)            #  1,338
asymetrie(log(base$prix))       # -0,007
asymetrie(base$rev_hab)         #  0,012
asymetrie(log(base$rev_hab))    # -0,594

ggplot(base, aes(x = prix / 1000)) +
  geom_histogram(bins = 40, fill = "grey60", colour = "white") +
  labs(x = "Prix médian (milliers d'euros)", y = "Nombre de communes")
```

R n'a pas de fonction d'asymétrie de base : on l'écrit en deux lignes. `log()` est le logarithme naturel.

(c) Ce que fait le logarithme à chaque variable

ÉNONCÉ (C)

Pour laquelle des deux variables la transformation logarithmique rend-elle la distribution plus symétrique ? Que fait-elle à la distribution de l'autre ?

RÉPONSE

Le logarithme rend le **prix** symétrique (asymétrie de 1,34 à −0,01). Il rend au contraire le **revenu**, déjà symétrique, **asymétrique vers la gauche** (de 0,01 à −0,59).

EXPLICATION

Le logarithme **comprime les grandes valeurs et étire les petites**. Ce qu'il produit dépend donc de la forme de départ.

- **Prix** : une longue queue à droite (Ixelles, Knokke, la périphérie riche). Le logarithme la ramène vers le centre : la distribution devient symétrique.
- **Revenu** : déjà symétrique. Le logarithme étire le bas de la distribution et écarte vers la gauche les quelques communes très pauvres (Saint-Josse, Molenbeek) : il **crée** une queue à gauche.

Change de variable et d'échelle dans l'outil de la question (b) pour le voir.

LA LEÇON

Le logarithme n'est pas un remède universel qui « normalise » les données. Il corrige une asymétrie à droite ; sur une variable symétrique, il en crée une à gauche.

(d) Une autre raison de passer en logarithme

ÉNONCÉ (D)

La forme de la distribution est-elle la seule raison de transformer une variable en logarithme dans une régression ? Donnez une autre raison.

RÉPONSE

Non. La raison principale est l'**interprétation** : en logarithme, un coefficient mesure un effet **en pourcentage** (une élasticité), ce qui est plus plausible pour des prix et des revenus qu'un effet constant en euros.

EXPLICATION

Un modèle en niveaux suppose que 1 000 € de revenu en plus ajoutent **le même nombre d'euros** au prix à Hastière (95 000 €) et à Ixelles (840 000 €). Un modèle en logarithmes suppose qu'ils ajoutent **le même pourcentage**. La seconde hypothèse est bien plus crédible.

Autres raisons valables, si on t'en demande davantage :

- un modèle multiplicatif $\text{prix} = A \times \text{rev}^{\beta}$ devient linéaire en logarithmes : $\ln(\text{prix}) = \ln(A) + \beta \ln(\text{rev})$;
- la dispersion augmente souvent avec le niveau : en logarithmes, l'hétéroscédasticité et le poids des valeurs extrêmes diminuent ;
- le coefficient ne dépend plus des unités (euros ou milliers d'euros).

UNE PRÉCISION QUI FAIT BONNE IMPRESSION

La régression linéaire **n'exige pas** que les variables soient normalement distribuées. La symétrie d'un histogramme n'est donc jamais, à elle seule, une raison suffisante de transformer une variable.

RÉDACTION POSSIBLE POUR LE RAPPORT

L'interprétation en pourcentage

Non. La raison principale est l'interprétation : en logarithmes, le coefficient mesure un effet relatif (une élasticité), plus plausible pour des prix et des revenus qu'un effet constant en euros. Une hausse de revenu ne peut pas ajouter le même montant au prix à Hastière et à Ixelles, mais elle peut ajouter le même pourcentage. La régression n'exige d'ailleurs pas que les variables soient normalement distribuées.

QUESTIONS PROBABLES À L'ORAL

Pourquoi mettre le prix en logarithme ?

Surtout pour l'interprétation : le coefficient mesure alors un effet en pourcentage, plus crédible qu'un effet constant en euros entre Hastière et Ixelles. Accessoirement, le logarithme rend la distribution du prix symétrique et réduit le poids des communes très chères.

1.5 Le nuage de points

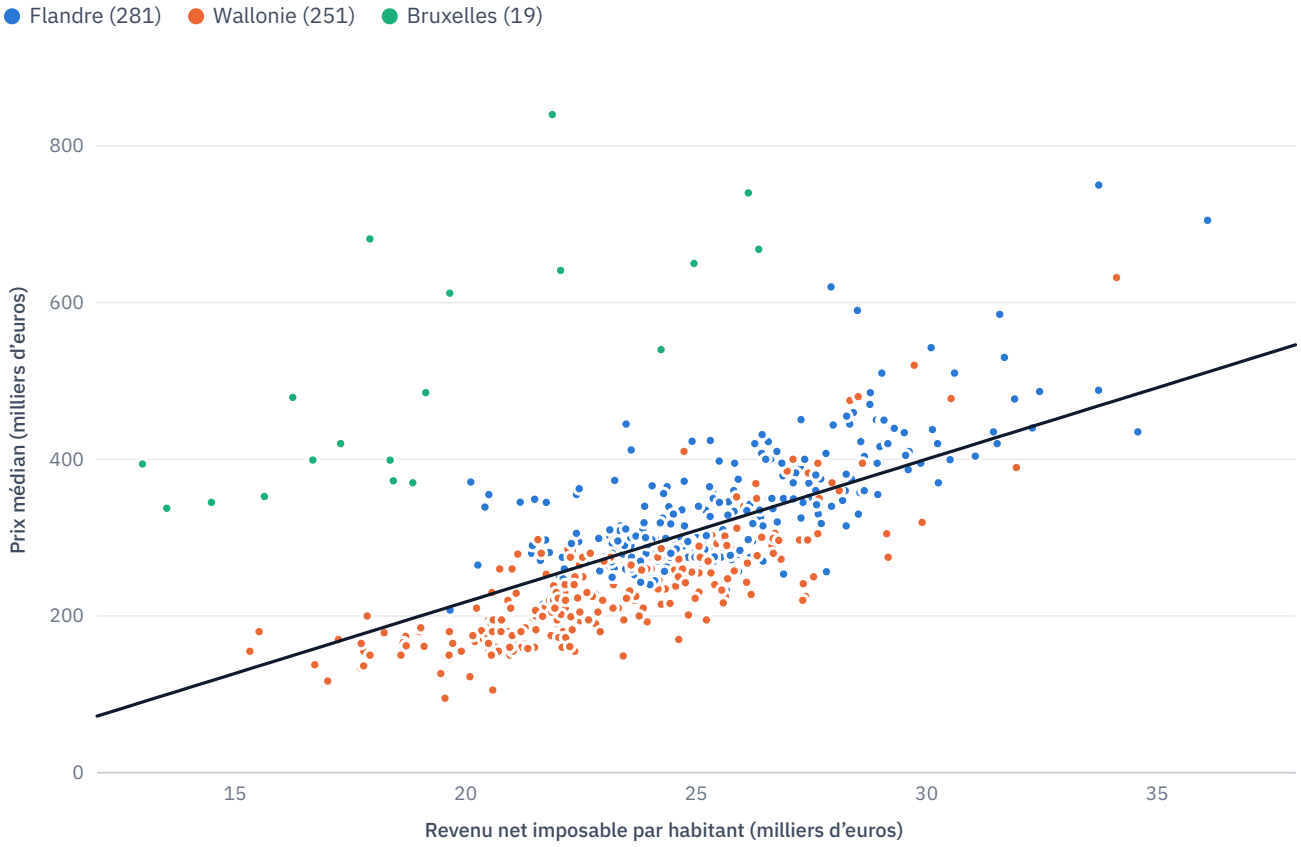
ÉNONCÉ

Représentez `prix` en fonction de `rev_hab`, avec une couleur par région et la droite des MCO estimée sur l'ensemble des communes, d'abord en niveaux, puis avec des échelles logarithmiques.

Un graphique vaut ici tous les tableaux : on y voit d'un coup la relation positive, les trois régions, et le problème que posera Bruxelles. Utilise l'outil pour reproduire les deux graphiques demandés (échelles « Niveaux » puis « Logarithmiques », modèle « Une seule droite »).

Explorateur : 551 communes, prix médian et revenu par habitant

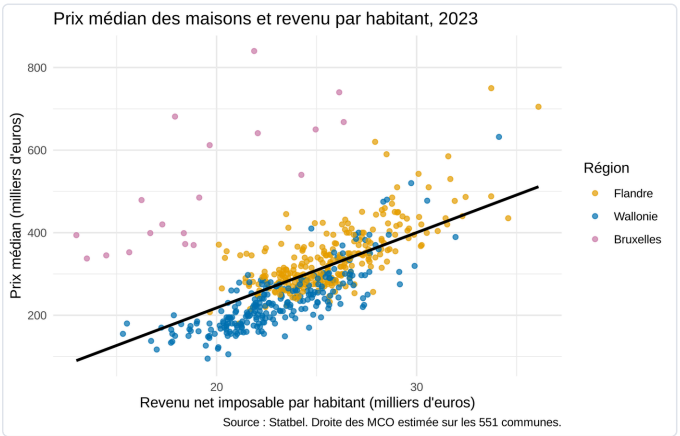
Chaque point est une commune (survole-la pour lire son nom). Change l'échelle et le modèle : la droite, son équation et son R² sont **recalculés en direct** sur les vraies données.

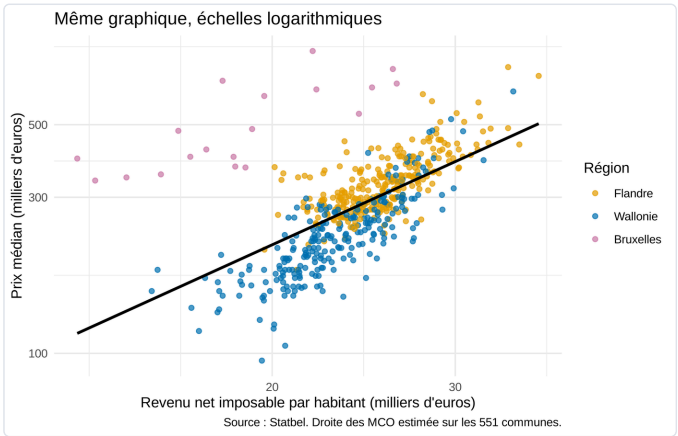


prix = −146,6 + 18,23 × revenu (R² = 0,341, erreur-type HC1 de la pente : 1,67)

En niveaux : 1 000 € de revenu par habitant en plus vont de pair avec 18 229 € de prix médian en plus. Regarde les couleurs : presque toute la Wallonie est sous la droite, tout Bruxelles au-dessus.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.





Prix médian des maisons et revenu par habitant, en niveaux puis en échelles logarithmiques (551 communes, 2023). Source : Statbel. Fichiers : fig_1_5_niveaux.png, fig_1_5_logs.png.

(a) Que représente un point ?

ÉNONCÉ (A)

Que représente un point ?

RÉPONSE

Une commune en 2023. En abscisse, son revenu net imposable par habitant ; en ordonnée, le prix médian des maisons qui y ont été vendues. La couleur indique sa région.

EXPLICATION

C'est la question de l'unité statistique, posée autrement. Réponds toujours par : une observation = quoi, quand, et que lit-on sur chaque axe.

(b) Niveaux ou logarithmes ?

ÉNONCÉ (B)

La relation vous paraît-elle plus proche d'une droite en niveaux ou en logarithmes ?

RÉPONSE

Un peu plus proche d'une droite en logarithmes : en niveaux, le nuage s'incurve vers le haut et s'élargit quand le revenu augmente ; en logarithmes, la dispersion est plus régulière. Mais la différence est modeste : le grand écart à la droite vient des régions, pas de la forme de la courbe.

EXPLICATION

Deux indices à chercher à l'œil.

- **La courbure.** En niveaux, les points flamands et wallons dessinent une courbe qui monte de plus en plus vite. Une droite ne suit pas bien une courbe.
- **L'éventail.** En niveaux, le nuage est étroit à gauche et large à droite : la dispersion des prix augmente avec le revenu. En logarithmes, la bande a une épaisseur plus régulière.

Sois honnête dans ta réponse : la différence n'est pas spectaculaire. Ce qui frappe surtout, dans les deux graphiques, ce sont les trois paquets de couleurs.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Prendre position, puis nuancer

Un peu plus proche d'une droite en logarithmes. En niveaux, le nuage s'incurve vers le haut et s'élargit quand le revenu augmente ; en logarithmes, la dispersion est plus régulière. La différence reste modeste : l'essentiel de l'écart à la droite vient des régions, pas de la forme fonctionnelle.

Insister sur la difficulté de trancher

En logarithmes, les bandes de points sont assez rectilignes à l'intérieur de chaque région et les prix extrêmes pèsent moins. La superposition des trois régions empêche toutefois de trancher nettement à l'œil pour une droite nationale.

(c) Les régions par rapport à la droite

ÉNONCÉ (C)

Comment les communes de chaque région se situent-elles par rapport à la droite ?

RÉPONSE

Bruxelles : les 19 communes sont toutes très au-dessus, à gauche du graphique (revenus faibles, prix élevés). **Wallonie** : la plupart sont en dessous. **Flandre** : la majorité est au-dessus.

EXPLICATION

Être au-dessus de la droite, c'est avoir un prix **plus élevé que ce que le revenu laisse prévoir**. La droite commune est donc un compromis entre trois nuages différents : elle passe trop bas pour Bruxelles et la Flandre, trop haut pour la Wallonie.

C'est le point de départ de toute la suite : les questions 1.9 à 1.13 corrigent ce défaut en donnant à chaque région sa propre droite.

RÉSULTATS

Région	Communes	Au-dessus de la droite en niveaux	Au-dessus de la droite en log-log
Flandre	281	55,9 %	66,9 %
Wallonie	251	13,9 %	17,9 %
Bruxelles	19	100 %	100 %

(d) Ce que le graphique ne montre pas

ÉNONCÉ (D)

Citez deux informations utiles que ce graphique ne permet pas de voir.

RÉPONSE

1. **La précision de chaque point** : Rouvroy (17 ventes) pèse autant à l'œil que Charleroi (1 854 ventes).
2. **Les autres déterminants du prix** : taille et qualité des maisons, distance aux emplois, part d'appartements. Le graphique montre une corrélation, pas l'effet du revenu « toutes choses égales par ailleurs ».

EXPLICATION

Coche « Taille des points = nombre de ventes » dans l'outil : tu vois alors ce que le graphique de base cache. Les gros points sont fiables, les petits beaucoup moins.

On pourrait citer aussi la population des communes (Anvers et une commune de 2 000 habitants valent un point chacune) et l'évolution dans le temps (une seule année).

CODE R

```r
couleurs <- c(Flandre = "#E69F00", Wallonie = "#0072B2", Bruxelles = "#CC79A7")

fig_1_5_niveaux <- ggplot(base, aes(x = rev_k, y = prix_k)) +
  geom_point(aes(colour = region), alpha = 0.7) +                  # couleur par région
  geom_smooth(method = "lm", formula = y ~ x, se = FALSE, colour = "black") +
  scale_colour_manual(values = couleurs) +
  labs(x = "Revenu net imposable par habitant (milliers d'euros)",
       y = "Prix médian (milliers d'euros)", colour = "Région")

fig_1_5_logs <- fig_1_5_niveaux + scale_x_log10() + scale_y_log10()
```

⚠ OÙ PLACER `colour = region`

Il est dans `geom_point()`, pas dans `ggplot()`. Placé dans `ggplot()`, il s'appliquerait aussi à `geom_smooth()`, qui tracerait alors **une droite par région**. L'énoncé demande une seule droite, estimée sur l'ensemble des communes.

Avec `scale_x_log10()` et `scale_y_log10()`, `geom_smooth()` estime la droite sur les logarithmes : c'est exactement le modèle log-log de la question 1.6. ChatGPT obtient le même résultat avec les graphiques de base de R (`plot()` puis `abline()`), en traçant directement ln(prix) contre ln(revenu).

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Précision des points et variables absentes

Le graphique ne montre pas la précision de chaque point : une commune de 17 ventes pèse autant qu'une commune de 1 854 ventes. Il ne montre pas non plus les autres déterminants du prix (taille des maisons, localisation, part d'appartements) : on voit une corrélation, pas l'effet du revenu à caractéristiques égales.

Nombre de ventes et dispersion des prix

Le graphique ne montre ni le nombre de ventes derrière chaque médiane, ni la dispersion des prix de vente à l'intérieur de chaque commune. Un point à Rouvroy et un point à Charleroi ont la même taille malgré des précisions très différentes.

QUESTIONS PROBABLES À L'ORAL

Pourquoi une seule droite ne convient-elle pas à ce nuage ?

Parce qu'elle fait un compromis entre trois nuages : toutes les communes bruxelloises sont au-dessus, la plupart des wallonnes en dessous. Les erreurs de prédiction ne sont pas dues au hasard, elles dépendent de la région.

B. FORMES FONCTIONNELLES

1.6 Quatre modèles, quatre façons de lire une pente

ÉNONCÉ

Estimez par les MCO les quatre modèles suivants, en exprimant `prix` et `rev_hab` en milliers d'euros lorsqu'ils sont en niveau : niveau-niveau, log-log, log-niveau, niveau-log. Présentez-les dans un tableau unique (coefficients, erreurs-types, R^2, nombre d'observations). Interprétez le coefficient de pente de chaque modèle.

Les quatre modèles relient les deux mêmes variables. La seule chose qui change est **l'endroit où l'on met le logarithme**, et cela change complètement la lecture du coefficient. Si la leçon sur les logarithmes n'est pas fraîche,

commence par elle.

RÉPONSE

Modèle	Pente (erreur-type HC1)	Lecture
Niveau-niveau	18,229 (1,666)	+1 000 € de revenu ↔ **+18 229 €** de prix
Log-log	1,444 (0,149)	+1 % de revenu ↔ **+1,44 %** de prix (élasticité)
Log-niveau	0,0642 (0,0051)	+1 000 € de revenu ↔ **+6,4 %** de prix
Niveau-log	401,17 (45,97)	+1 % de revenu ↔ **+4 012 €** de prix

EXPLICATION

La règle, en deux lignes.

- La variable **dépendante** est en log ? L'effet se lit **en pourcentage**. Sinon, dans l'unité de y (ici des milliers d'euros).
- Le **régresseur** est en log ? L'effet se lit « **pour une hausse de 1 %** de x ». Sinon, pour une hausse d'une unité (ici 1 000 €).

Applique-la mécaniquement aux quatre cas.

Niveau-niveau (18,229). Rien en log : unités contre unités. Une commune dont le revenu par habitant est supérieur de 1 000 € a, en moyenne, un prix médian supérieur de 18,229 milliers d'euros, soit 18 229 €.

Log-log (1,444). Tout en log : pourcentage contre pourcentage. Un revenu supérieur de 1 % va de pair avec un prix supérieur de 1,44 %. C'est une élasticité. Elle dépasse 1 : le prix augmente **plus que proportionnellement** au revenu.

Log-niveau (0,0642). Seul y est en log : pourcentage contre unité. On multiplie par 100 : 1 000 € de revenu en plus vont de pair avec un prix supérieur d'environ 6,4 %. C'est une semi-élasticité. Valeur exacte : 100 × (exp(0,0642) − 1) = 6,6 %.

Niveau-log (401,17). Seul x est en log : unité contre pourcentage. On **divise** par 100 : un revenu supérieur de 1 % va de pair avec un prix supérieur de 401,17 / 100 = 4,01 milliers d'euros, soit environ 4 000 €.

⚠ LE VOCABULAIRE QUI COÛTE DES POINTS

On compare des communes entre elles, la même année. Écris « va de pair avec », « est associé à », « une commune dont le revenu est plus élevé a… ». N'écris pas « une hausse du revenu fait monter le prix » : ce serait une affirmation causale, que la question 1.18 te demandera justement de refuser.

Pourquoi « en milliers d'euros » ? Uniquement pour obtenir des coefficients lisibles. Diviser une variable par 1 000 multiplie ou divise son coefficient par 1 000, sans rien changer d'autre. Dans un logarithme, changer d'unité ne déplace que la constante : c'est pourquoi les logs peuvent être pris sur les montants en euros.

RÉSULTATS

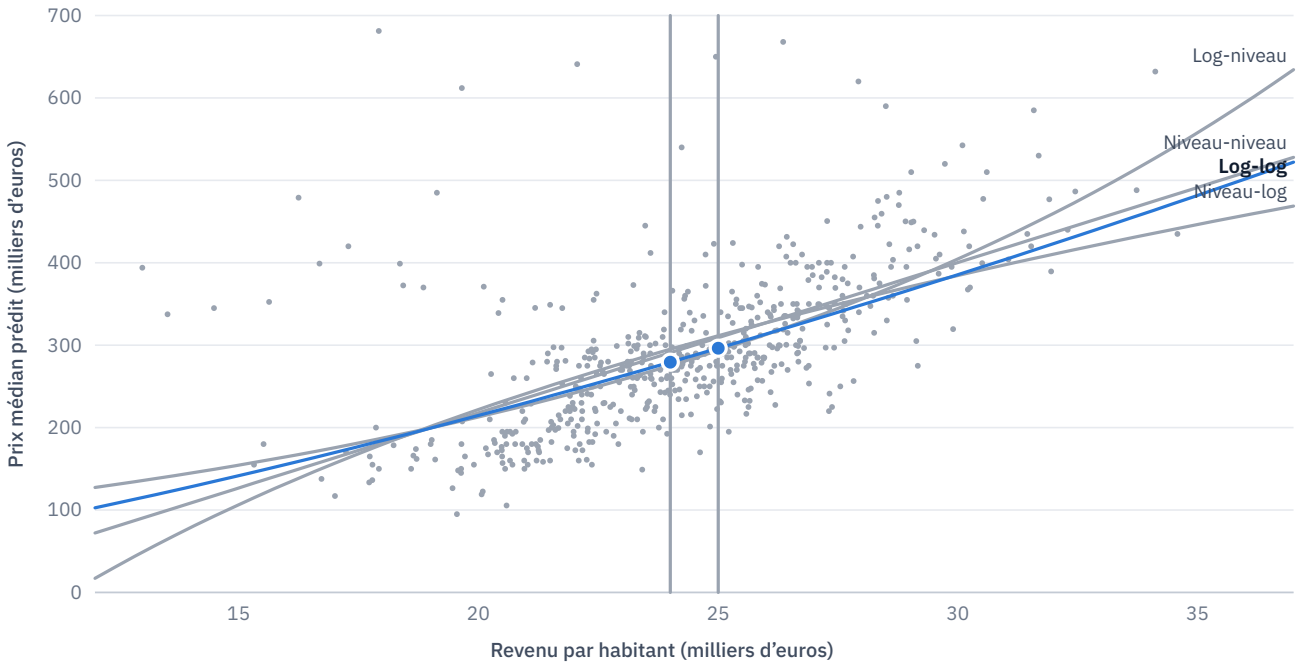
	Niveau-niveau	Log-log	Log-niveau	Niveau-log
Variable dépendante	prix (k€)	ln(prix)	ln(prix)	prix (k€)

	Niveau-niveau	Log-log	Log-niveau	Niveau-log
Régresseur	rev_hab (k€)	ln(rev_hab)	rev_hab (k€)	ln(rev_hab)
Pente	**18,229** (1,666)	**1,444** (0,149)	**0,0642** (0,0051)	**401,17** (45,97)
Constante	−146,61 (41,70)	−2,026 (1,513)	10,984 (0,131)	−3 751,0 (464,9)
R^2	0,341	0,367	0,403	0,297
Observations	551	551	551	551

Erreurs-types robustes HC1 entre parenthèses. Les quatre pentes sont très significatives (t entre 8,7 et 12,5). Source : Statbel, 2023.

Quatre formes fonctionnelles, quatre prédictions

Les quatre modèles de la question 1.6, estimés sur les mêmes 551 communes. Déplace le revenu de départ et d'arrivée : le tableau refait les calculs de la question 1.7.



Le revenu passe de 24 000 € à 25 000 € : +1 000 €, soit +4,17 %.

Écart entre approximation et valeur exacte : **0,06 point** pour le log-log, **0,21 point** pour le log-niveau. La variation est petite : l'approximation suffit.

Modèle	Prix prédit au départ	Variation en €	Approximation usuelle	Variation exacte
Niveau-niveau	290 889 €	+18 229 €	—	+6,27 %
Log-log	279 371 €	+16 967 €	+6,02 %	+6,07 %
Log-niveau	275 281 €	+18 256 €	+6,42 %	+6,63 %
Niveau-log	295 099 €	+16 377 €	—	+5,55 %

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

CODE R

```r
base <- base %>%
  mutate(prix_k = prix / 1000, rev_k = rev_hab / 1000,   # en milliers d'euros
         lprix = log(prix), lrev = log(rev_hab))          # logarithmes

reg_1_6_nn <- lm(prix_k ~ rev_k, data = base)   # niveau-niveau
reg_1_6_ll <- lm(lprix  ~ lrev,  data = base)   # log-log
reg_1_6_ln <- lm(lprix  ~ rev_k, data = base)   # log-niveau
reg_1_6_nl <- lm(prix_k ~ lrev,  data = base)   # niveau-log

rob <- function(m) coeftest(m, vcov = vcovHC(m, type = "HC1"))
rob(reg_1_6_ll)                    # coefficients et erreurs-types robustes
summary(reg_1_6_ll)$r.squared      # R²
nobs(reg_1_6_ll)                   # nombre d'observations
```

- `lm(y ~ x, data = base)` estime y sur x par les MCO, constante comprise.
- `rob()` est un raccourci défini une fois au début du script, pour ne pas réécrire soixante fois la même ligne. `coeftest()` vient du package `lmtest`, `vcovHC()` du package `sandwich`.
- On aurait pu écrire directement `lm(log(prix) ~ log(rev_hab))` : le résultat est le même.

QUESTIONS PROBABLES À L'ORAL

Pourquoi 1,44 % et pas 1,44 € ?

Parce que le logarithme est des deux côtés : la pente relie une variation en pourcentage du revenu à une variation en pourcentage du prix. C'est une élasticité.

Que se passe-t-il si tu exprimes le revenu en euros plutôt qu'en milliers d'euros ?

Dans les modèles où le revenu est en niveau, la pente est divisée par 1 000. Dans ceux où il est en logarithme, seule la constante change. Rien d'autre ne bouge : ni les t, ni le R^2, ni les prédictions.

1.7 Variations prédites : approximation ou valeur exacte ?

ÉNONCÉ

Pour une commune dont le revenu par habitant est de 24 000 euros, calculez la variation du prix prédite par chacun des quatre modèles pour (a) une hausse du revenu de 1 000 euros. Faites de même pour (b) un passage de 20 000 à 30 000 euros. Pour les modèles dont la variable dépendante est en logarithme, donnez l'approximation usuelle et la variation exacte. Pourquoi l'écart entre approximation et variation exacte grandit-il de (a) à (b) ? Quel type de relation chacun des quatre modèles impose-t-il aux données ?

Cette question fait calculer la même chose de deux façons, pour montrer **quand la lecture rapide d'un coefficient en logarithme cesse d'être fiable**. L'outil de la question 1.6 refait tous ces calculs : règle le revenu de départ et d'arrivée.

RÉPONSE

(a) De 24 000 à 25 000 € : les quatre modèles prédisent **+16 400 à +18 300 €**, soit +5,5 à +6,6 %, et l'approximation est presque exacte. (b) De 20 000 à 30 000 € : **+163 000 à +192 000 €**, et l'approximation se trompe lourdement (64 % au lieu de 90 % pour le log-niveau). L'approximation est une formule valable pour de **petites** variations ; son erreur croît comme le carré de la variation.

EXPLICATION

Les formules. Le revenu passe de r_0 à r_1 (en milliers d'euros).

Modèle	Approximation usuelle	Variation exacte
Niveau-niveau	—	$\Delta\text{prix} = \beta_1 \, (r_1 - r_0)$
Log-log	$\%\Delta\text{prix} \approx \beta_1 \times \%\Delta\text{rev}$	$\%\Delta\text{prix} = 100 \times [(r_1 \, / \, r_0)^{\beta_1} - 1]$
Log-niveau	$\%\Delta\text{prix} \approx 100 \times \beta_1 \, (r_1 - r_0)$	$\%\Delta\text{prix} = 100 \times [\exp(\beta_1 \, (r_1 - r_0)) - 1]$
Niveau-log	—	$\Delta\text{prix} = \beta_1 \times [\ln(r_1) - \ln(r_0)]$

Les modèles en niveau n'ont pas d'« approximation » : leur variable dépendante est en euros, le calcul est direct.

Un exemple entièrement détaillé : le log-log, cas (b). Le revenu augmente de 50 %.

- Approximation usuelle : 1,444 × 50 % = **72,2 %**.
- Calcul exact : le modèle dit $\ln(\text{prix}) = \beta_0 + 1{,}444 \times \ln(\text{rev})$. La variation de ln(prix) vaut donc 1,444 × ln(30 000 / 20 000) = 1,444 × 0,4055 = 0,5856. Pour revenir à un pourcentage : 100 × (exp(0,5856) − 1) = **79,6 %**.

Pourquoi l'écart grandit-il ? L'approximation repose sur deux raccourcis : $\exp(z) - 1 \approx z$ et $\ln(1 + g) \approx g$. Ils remplacent une courbe par sa tangente. Près du point de départ, la tangente colle à la courbe ; plus on s'éloigne, plus elle s'en écarte. L'erreur est de l'ordre de $z^2 \, / \, 2$: elle croît comme le **carré** de la variation.

	(a)	(b)
Variation du log-prix dans le log-niveau (z)	0,064	0,642
Erreur de l'approximation	0,2 point	25,8 points

Une variation dix fois plus grande donne une erreur environ cent fois plus grande.

Quel type de relation chaque modèle impose-t-il ?

Modèle	Ce qui est constant	Forme de la courbe prix-revenu
Niveau-niveau	l'effet **en euros** de 1 000 € de revenu (18 229 €)	une droite
Log-log	l'**élasticité** (1,44)	convexe : en euros, l'effet de 1 000 € grandit avec le revenu
Log-niveau	la **semi-élasticité** (+6,4 % par 1 000 €)	exponentielle, convexe elle aussi
Niveau-log	l'effet en euros de **1 %** de revenu (4 012 €)	concave : l'effet de 1 000 € diminue quand le revenu monte

Le nuage de la question 1.5 s'incurve vers le haut : les modèles convexes (log-log, log-niveau) lui conviennent mieux que le modèle concave (niveau-log), qui a d'ailleurs le plus petit R².

RÉSULTATS

(a) De 24 000 à 25 000 € (+1 000 €, soit +4,17 %)

Modèle	Prix prédit à 24 000 €	Variation en €	Approximation	Variation exacte
Niveau-niveau	290 889 €	+18 229 €	—	+6,27 %

Modèle	Prix prédit à 24 000 €	Variation en €	Approximation	Variation exacte
Log-log	279 371 €	+16 967 €	+6,02 %	+6,07 %
Log-niveau	275 281 €	+18 256 €	+6,42 %	+6,63 %
Niveau-log	295 099 €	+16 377 €	—	+5,55 %

(b) De 20 000 à 30 000 € (+10 000 €, soit +50 %)

Modèle	Prix prédit à 20 000 €	Variation en €	Approximation	Variation exacte
Niveau-niveau	217 973 €	+182 291 €	—	+83,6 %
Log-log	214 695 €	+170 914 €	+72,2 %	+79,6 %
Log-niveau	212 927 €	+191 739 €	+64,2 %	+90,0 %
Niveau-log	221 957 €	+162 660 €	—	+73,3 %

Pour exprimer en euros les modèles dont la variable dépendante est en log, on part du prix prédit $\exp(\beta_0 + \beta_1 x)$. Pour les modèles en niveau, le pourcentage rapporte la variation au prix prédit de départ.

⚠ LE PIÈGE

Dans le cas (b), ne lis pas le coefficient du log-niveau « à la volée » : 0,0642 × 10 = 0,642 ne veut **pas** dire +64 %. La variation exacte est de +90 %. Dès que le produit dépasse 0,1 environ, passe à la formule avec l'exponentielle.

CODE R

```r
b_ll <- coef(reg_1_6_ll)[2]              # la pente du log-log
r0 <- 20; r1 <- 30                       # en milliers d'euros

b_ll * (r1 - r0) / r0 * 100              # approximation : 72,2 %
100 * ((r1 / r0)^b_ll - 1)               # exacte : 79,6 %

b_ln <- coef(reg_1_6_ln)[2]              # la pente du log-niveau
100 * b_ln * (r1 - r0)                   # approximation : 64,2 %
100 * (exp(b_ln * (r1 - r0)) - 1)        # exacte : 90,0 %
```

`coef(m)` renvoie le vecteur des coefficients ; `[2]` prend le deuxième, la pente (le premier est la constante). `exp()` est l'exponentielle, l'opération inverse du logarithme.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Une approximation par modèle, erreur en z²

Je donne pour le log-log l'approximation $\beta_1 \times \%\Delta rev$ et pour le log-niveau $100 \times \beta_1 \times \Delta rev$, puis la variation exacte. L'écart passe de 0,2 point en (a) à 26 points en (b) pour le log-niveau, parce que l'approximation remplace exp(z) − 1 par z : l'erreur est de l'ordre de $z^2/2$ et croît comme le carré de la variation.

Deux approximations pour les modèles en log

Je donne l'approximation locale (β × %Δrev) et la lecture directe de 100 × Δln(prix) comme un pourcentage, puis la variation exacte. Les trois s'écartent davantage sur un grand intervalle car le logarithme et l'exponentielle sont courbes.

QUESTIONS PROBABLES À L'ORAL

Pourquoi l'approximation est-elle bonne en (a) et mauvaise en (b) ?

Parce qu'elle remplace exp(z) − 1 par z, ce qui n'est juste que pour un petit z. En (a), z vaut 0,06 et l'erreur est de 0,2 point ; en (b), z vaut 0,64 et l'erreur atteint 26 points. L'erreur croît comme le carré de la variation.

1.8 Peut-on choisir un modèle à son R^2 ?

ÉNONCÉ

Un·e collègue retient le modèle log-log parce que son R^2 est plus élevé que celui du modèle niveau-niveau. Discutez cet argument. Quels critères utiliseriez-vous pour choisir, à la lumière des questions 1.4 à 1.7 ? Dans la suite, on retient le modèle log-log.

RÉPONSE

L'argument ne tient pas. Le R^2 du log-log (0,367) est la part expliquée de la variance de **ln(prix)** ; celui du niveau-niveau (0,341), la part expliquée de la variance de **prix**. Ce sont deux variables différentes : les deux R^2 ne sont pas comparables. On choisit le log-log pour son **interprétation** (une élasticité), la **symétrie** de ln(prix) et la **forme du nuage**, pas pour son R^2.

EXPLICATION

Le R^2 est une proportion : « quelle part de la dispersion de y le modèle explique-t-il ? ». Changer y, c'est changer la dispersion à expliquer. Comparer 0,367 et 0,341 revient à comparer une note sur 20 et une note sur 100 sans regarder le barème.

Les comparaisons qui, elles, sont valables.

- **Même variable dépendante.** Sur ln(prix), le log-niveau (0,403) fait mieux que le log-log (0,367). Sur prix, le niveau-niveau (0,341) fait mieux que le niveau-log (0,297).
- **Même échelle.** On ramène les prédictions du log-log en euros, puis on calcule le carré de leur corrélation avec le prix observé : 0,357, contre 0,341 pour le niveau-niveau. Le log-log reste un peu meilleur, mais l'écart est faible.

Les critères à utiliser, avec ce que les questions précédentes ont montré.

1. **L'interprétation économique.** Un effet proportionnel (une élasticité) est plus plausible pour des prix et des revenus, et il ne dépend pas des unités. Le niveau-niveau prédirait d'ailleurs un prix **négatif** pour un revenu inférieur à 8 043 € (146,61 / 18,229).
2. **La distribution (question 1.4).** ln(prix) est symétrique, ce qui limite le poids des communes très chères.
3. **La forme du nuage (question 1.5).** En niveaux, relation convexe et dispersion croissante ; en logarithmes, bande plus régulière.
4. **La qualité d'ajustement**, mais seulement entre modèles comparables.

CE QU'IL FAUT SAVOIR RÉPONDRE SI ON INSISTE

« Votre log-niveau a un R^2 plus élevé que votre log-log, pourquoi ne pas le prendre ? » Entre ces deux-là, la comparaison est légitime, et le log-niveau s'ajuste un peu mieux. On garde le log-log pour son interprétation en élasticité et parce que l'énoncé l'impose pour la suite ; l'écart de R^2 (0,403 contre 0,367) est modeste.

CODE R

```r
# R² du log-log recalculé sur l'échelle des prix
cor(base$prix_k, exp(fitted(reg_1_6_ll)) / 1000)^2    # 0,357
summary(reg_1_6_nn)$r.squared                         # 0,341
```

`fitted(m)` renvoie les valeurs ajustées, ici des ln(prix) prédits. `exp()` les ramène en euros. Le carré de la corrélation entre le prix observé et ce prix prédit est un R² comparable à celui du modèle en niveaux.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Deux R² non comparables, puis quatre critères

L'argument ne tient pas : les deux R² mesurent la part expliquée de deux variables différentes, ln(prix) et prix. Ramené sur l'échelle des prix, le log-log explique 35,7 % de la variance contre 34,1 % pour le niveau-niveau : il reste un peu meilleur, mais ce n'est pas un argument décisif. Je choisis le log-log pour son interprétation (une élasticité, plus plausible qu'un effet constant en euros), pour la symétrie de ln(prix) et pour la forme du nuage, plus régulière en logarithmes.

Deux R² non comparables, critère de prévision

Les deux R² portent sur des dispersions différentes et ne se comparent pas. Je retiens le log-log pour son élasticité et la forme du nuage. Pour départager des modèles sur leur qualité de prédiction, il faudrait comparer leurs erreurs sur une même échelle.

QUESTIONS PROBABLES À L'ORAL

Pourquoi avoir retenu le log-log si ce n'est pas pour son R² ?
Pour son interprétation : la pente est une élasticité, un effet proportionnel plus crédible qu'un effet constant en euros entre une commune à 95 000 € et une à 840 000 €. S'y ajoutent la symétrie de ln(prix) et un nuage plus régulier en logarithmes.

C. RÉGIONS

1.9 Ajouter la région : des droites parallèles

ÉNONCÉ

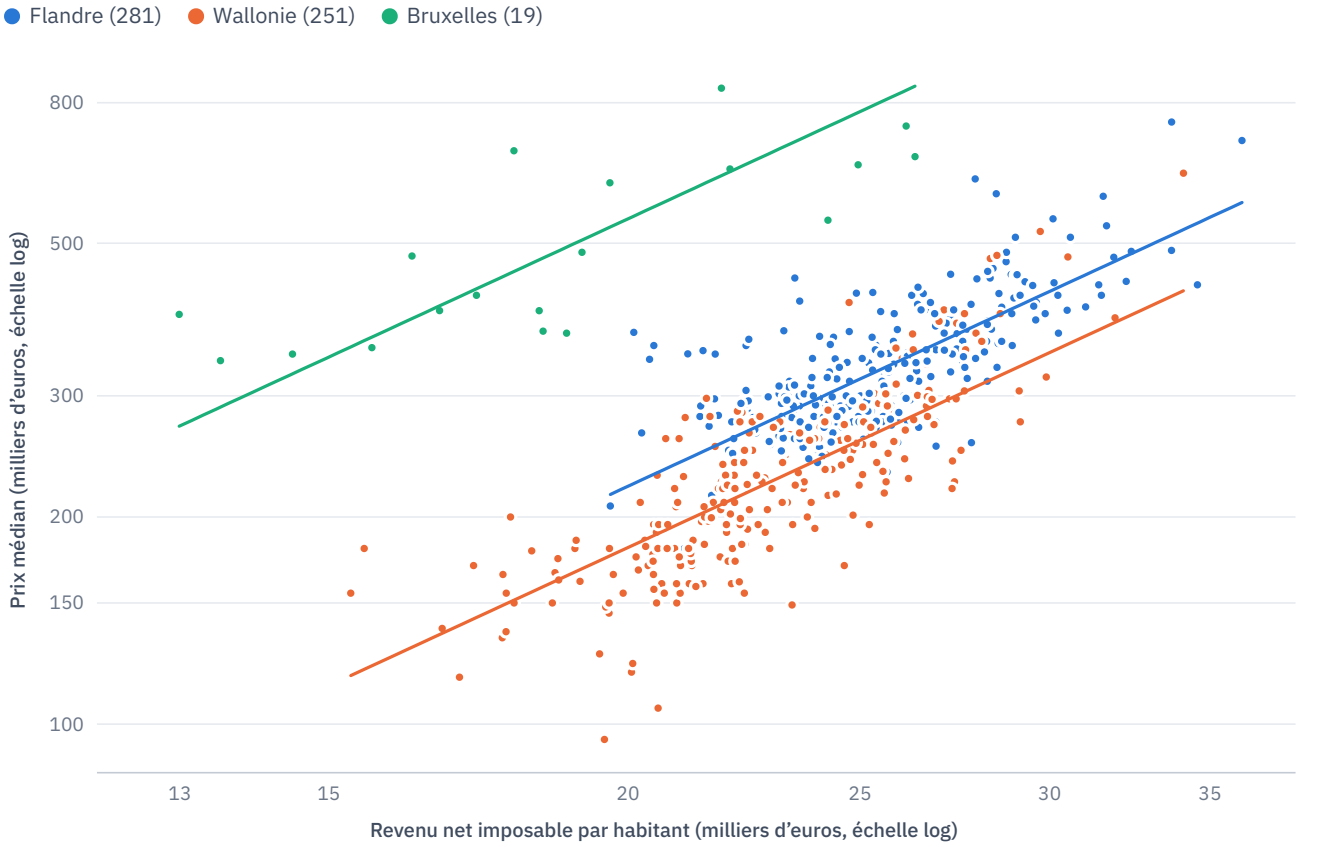
Ajoutez au modèle log-log des indicatrices de région, avec la Flandre comme catégorie de référence.

Le nuage de la question 1.5 montrait trois paquets de couleurs. On donne maintenant à chaque région **sa propre hauteur**, tout en gardant une pente commune.

$$\ln(\text{prix}_i) = \beta_0 + \beta_1 \ln(\text{rev_hab}_i) + \delta_W \,\text{Wallonie}_i + \delta_B \,\text{Bruxelles}_i + u_i$$

Le modèle 1.9 : trois droites parallèles

Chaque point est une commune (survole-la pour lire son nom). Change l'échelle et le modèle : la droite, son équation et son R^2 sont **recalculés en direct** sur les vraies données.



ln(prix) = −3,614 + 1,608 × ln(revenu) − 0,205 × Wallonie + 0,895 × Bruxelles (R^2 = 0,757)

Même pente pour tous, mais une hauteur propre à chaque région (la Flandre sert de référence). À revenu égal, le prix est −18,5 % en Wallonie et +144,7 % à Bruxelles par rapport à la Flandre.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Interpréter les deux indicatrices

ÉNONCÉ (A)

Interprétez les coefficients des deux indicatrices.

RÉPONSE

Wallonie : −0,205. À revenu par habitant égal, le prix médian d'une commune wallonne est inférieur de **18,5 %** à celui d'une commune flamande. **Bruxelles : +0,895.** À revenu égal, il est supérieur de **145 %**, soit 2,45 fois plus élevé.

EXPLICATION

Une commune flamande a `Wallonie = 0` et `Bruxelles = 0` : c'est la catégorie de référence. Écris l'équation pour chaque région.

Région	Équation de sa droite	Hauteur
Flandre	$\ln(\text{prix}) = \beta_0 + \beta_1 \ln(\text{rev})$	−3,614
Wallonie	$\ln(\text{prix}) = (\beta_0 + \delta_W) + \beta_1 \ln(\text{rev})$	−3,819
Bruxelles	$\ln(\text{prix}) = (\beta_0 + \delta_B) + \beta_1 \ln(\text{rev})$	−2,719

Même pente (1,608), hauteurs différentes : **trois droites parallèles**. Le coefficient d'une indicatrice est l'écart vertical entre la droite de cette région et celle de la Flandre.

Passer du coefficient au pourcentage. L'écart est mesuré en logarithmes. Pour une indicatrice, la variation n'est pas « petite » : on passe d'un coup de 0 à 1. Il faut donc la formule exacte :

$$\text{écart en \%} = 100 \times (\exp(\delta) - 1)$$

- Wallonie : 100 × (exp(−0,205) − 1) = **−18,5 %**. Ici l'approximation (−20,5 %) n'était pas loin.
- Bruxelles : 100 × (exp(0,895) − 1) = **+144,7 %**. L'approximation aurait donné +89,5 % : complètement faux.

Remarque au passage le R^2 : il passe de 0,367 à **0,757**. Les régions expliquent une grande partie des écarts de prix entre communes.

RÉSULTATS

	Coefficient	Erreur-type HC1	t
Constante	−3,614	0,752	−4,8
ln(rev_hab)	1,608	0,074	21,7
Wallonie	−0,205	0,017	−12,3
Bruxelles	0,895	0,055	16,4

R^2 = 0,757 ; 551 communes.

CODE R

```
base$region <- factor(base$region, levels = c("Flandre", "Wallonie", "Bruxelles"))
reg_1_9 <- lm(lprix ~ lrev + region, data = base)
rob(reg_1_9)

100 * (exp(coef(reg_1_9)[c("regionWallonie", "regionBruxelles")]) - 1)   # -18,5 et +144,7
```

Quand un régresseur est un **facteur**, R crée tout seul une indicatrice par catégorie, sauf la première, qui sert de référence. L'ordre donné dans `levels = c(...)` décide donc de la référence : ici la Flandre. Les coefficients s'appellent `regionWallonie` et `regionBruxelles` (nom de la variable collé à celui de la catégorie).

(b) Pourquoi pas trois indicatrices et la constante ?

ÉNONCÉ (B)

Pourquoi ne peut-on pas inclure dans le modèle les trois indicatrices de région et la constante ?

RÉPONSE

Parce que, pour chaque commune, Flandre + Wallonie + Bruxelles = 1, exactement comme la colonne de la constante. Les régresseurs seraient **parfaitement colinéaires** : les MCO n'auraient pas de solution unique. C'est le **piège des variables indicatrices**.

EXPLICATION

Trois régions, trois hauteurs à estimer. Avec la constante et trois indicatrices, on aurait **quatre** nombres pour décrire **trois** hauteurs : il y a un nombre de trop.

Concrètement, on pourrait ajouter n'importe quelle valeur c à la constante et retrancher c aux trois indicatrices sans changer une seule prédiction :

	Constante	Flandre	Wallonie	Bruxelles	Hauteur Flandre	Hauteur Wallonie
Solution 1	−3,614	0	−0,205	0,895	−3,614	−3,819
Solution 2	0	−3,614	−3,819	−2,719	−3,614	−3,819
Solution 3	10	−13,614	−13,819	−12,719	−3,614	−3,819

Une infinité de jeux de coefficients donnent exactement le même modèle : les données ne peuvent pas choisir entre eux. Mathématiquement, la matrice $X'X$ n'est pas inversible ; l'hypothèse d'**absence de colinéarité parfaite** est violée.

R ne plante pas : il détecte le problème, retire une variable et affiche `NA` pour son coefficient.

QUESTIONS PROBABLES À L'ORAL

Comment lis-tu un coefficient d'indicatrice dans un modèle dont la variable dépendante est en logarithme ?
C'est un écart en logarithmes par rapport à la catégorie de référence, toutes choses égales par ailleurs. Je le convertis en pourcentage avec 100 × (exp(δ) − 1), parce que l'approximation 100 × δ n'est valable que pour un petit δ.

1.10 Changer de référence à la main

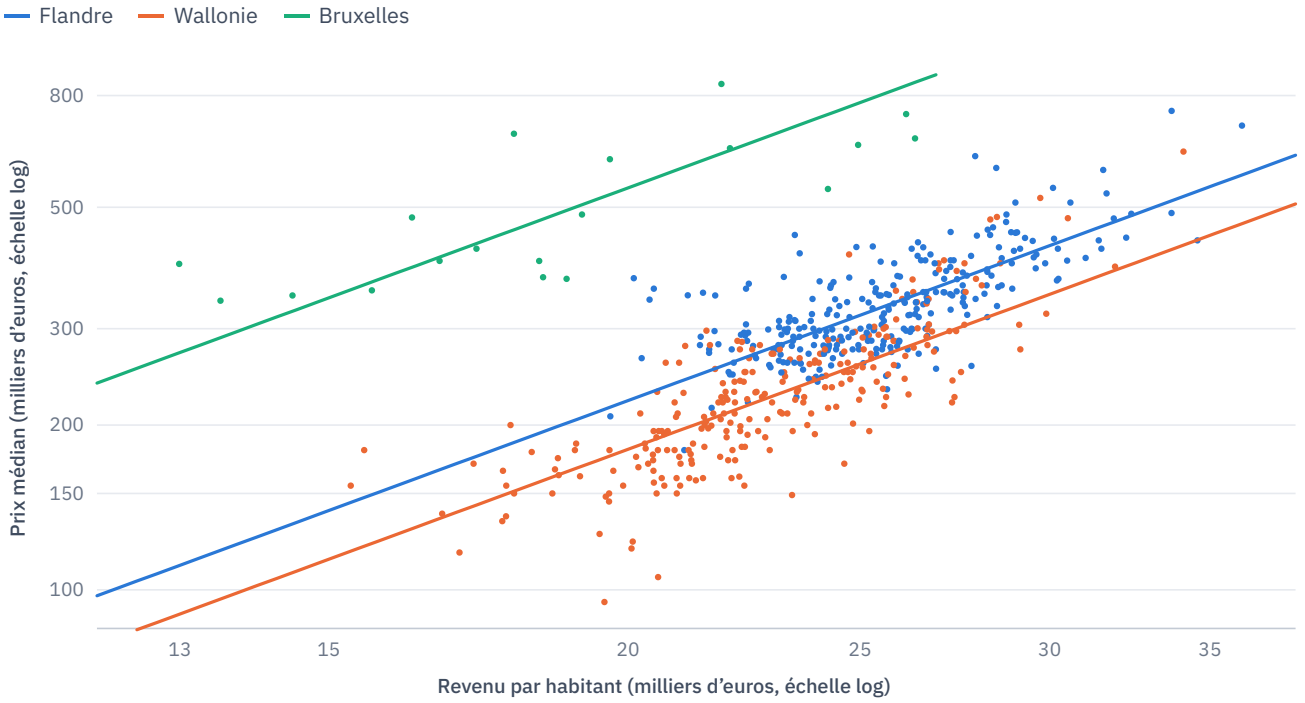
ÉNONCÉ

Sans réestimer le modèle, calculez à partir des coefficients de la question 1.9 la valeur de tous les coefficients (constante, élasticité, indicatrices) que vous obtiendriez avec la Wallonie comme catégorie de référence. Détaillez chaque calcul. Interprétez le coefficient de l'indicatrice Bruxelles.

Changer de catégorie de référence ne change pas le modèle : ce sont les mêmes trois droites, décrites depuis un autre point de vue. L'outil ci-dessous fait le calcul pour les trois références possibles.

Changer de région de référence sans réestimer

Le modèle 1.9 trace trois droites parallèles. Choisis la région de référence : les droites ne bougent pas, seuls changent la constante et le sens des indicatrices.



Référence : **Flandre** (trait épais). La constante est la hauteur de *sa* droite ; chaque indicatrice mesure l'écart vertical entre la droite d'une autre région et celle-ci. Les valeurs ajustées, les résidus, le R^2 (0,757) et l'élasticité (1,608) sont identiques dans les trois écritures.

Coefficient	Calcul à partir du modèle 1.9	Valeur	Erreur-type HC1	Écart exact en %
Constante	$\beta_0 = -3{,}614$	−3,614	0,752	—
ln(rev_hab)	β_1 (pente commune, inchangée)	1,608	0,074	—
Indicatrice Wallonie	$(\beta_0 + \delta_W) - (\beta_0) = -3{,}819 - (-3{,}614)$	−0,205	0,017	−18,5 %
Indicatrice Bruxelles	$(\beta_0 + \delta_B) - (\beta_0) = -2{,}719 - (-3{,}614)$	+0,895	0,055	+144,7 %

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

RÉPONSE

Nouveau coefficient	Calcul	Valeur
Constante	−3,614 + (−0,205)	**−3,819**
Élasticité	inchangée	**1,608**
Indicatrice Flandre	−(−0,205)	**+0,205**
Indicatrice Bruxelles	0,895 − (−0,205)	**+1,100**

À revenu égal, le prix médian d'une commune bruxelloise est **trois fois** celui d'une commune wallonne (+200 %).

EXPLICATION

Pars de la seule chose qui ne dépend pas de la référence : **la hauteur de chaque droite**.

Région	Hauteur de sa droite
Flandre	$\beta_0 = -3{,}614$
Wallonie	$\beta_0 + \delta_W = -3{,}614 - 0{,}205 = -3{,}819$
Bruxelles	$\beta_0 + \delta_B = -3{,}614 + 0{,}895 = -2{,}719$

Avec la Wallonie en référence, deux règles suffisent :

- la **nouvelle constante** est la hauteur de la droite de la **nouvelle référence** : −3,819 ;
- chaque **indicatrice** est la hauteur de sa région **moins** celle de la référence.

Donc : Flandre = −3,614 − (−3,819) = **+0,205** (le même écart qu'avant, signe inversé). Bruxelles = −2,719 − (−3,819) = **+1,100**.

L'**élasticité** ne bouge pas : les trois droites ont la même pente, quel que soit le point de vue.

Interprétation de Bruxelles. À revenu par habitant égal, le prix médian d'une commune bruxelloise dépasse celui d'une commune wallonne de 100 × (exp(1,100) − 1) = **+200 %** : il est trois fois plus élevé.

⚠ DEUX ERREURS FRÉQUENTES

- Écrire « +110 % » en lisant 1,100 directement. La valeur exacte est +200 %.
- Additionner les pourcentages (18,5 % + 144,7 %). Les écarts s'additionnent **en logarithmes** (0,205 + 0,895 = 1,100), pas en pourcentages.

QUESTIONS PROBABLES À L'ORAL

Comment retrouves-tu les coefficients sans réestimer ?

Chaque région a une hauteur de droite, qui ne dépend pas de la référence. La nouvelle constante est la hauteur de la nouvelle référence, et chaque indicatrice est la différence entre la hauteur de sa région et celle de la référence. La pente est commune, donc inchangée.

1.11 Vérifier avec relevel()

ÉNONCÉ

Réestimez le modèle avec la Wallonie comme catégorie de référence (fonction `relevel()`) et comparez aux valeurs calculées à la question 1.10. Qu'est-ce qui change, et qu'est-ce qui ne change pas ?

RÉPONSE

R redonne **exactement** les valeurs calculées à la main (−3,819 ; 1,608 ; +0,205 ; +1,100). **Changent** : la constante et les indicatrices (valeur, sens et erreur-type), donc les hypothèses testées. **Ne changent pas** : l'élasticité et son erreur-type, les valeurs ajustées, les résidus, le R^2 (0,757).

EXPLICATION

C'est le même modèle, écrit autrement. Tout ce qui décrit **l'ajustement** est identique ; tout ce qui décrit **un écart à la référence** est redéfini.

	Ne change pas	Change
Coefficients	l'élasticité (1,608)	la constante, les indicatrices
Erreurs-types	celle de l'élasticité (0,074)	celles de la constante et des indicatrices
Ajustement	valeurs ajustées, résidus, R^2, nombre d'observations	—
Ce qu'on teste	—	Bruxelles **contre la Wallonie**, et non plus contre la Flandre

Un détail qui montre que tu as compris : l'erreur-type de Bruxelles passe de 0,055 à 0,052. Ce n'est plus la même quantité. Avant, on mesurait l'écart Bruxelles-Flandre (δ_B) ; maintenant l'écart Bruxelles-Wallonie ($\delta_B - \delta_W$), dont la précision dépend de la covariance entre les deux estimateurs. L'écart Flandre-Wallonie, lui, garde la même erreur-type (0,017) : seul son signe s'inverse.

RÉSULTATS

	Référence Flandre (1.9)	Référence Wallonie (1.11)
Constante	−3,614 (0,752)	−3,819 (0,743)
ln(rev_hab)	1,608 (0,074)	1,608 (0,074)
Wallonie	−0,205 (0,017)	—
Flandre	—	+0,205 (0,017)
Bruxelles	+0,895 (0,055)	+1,100 (0,052)
R^2	0,757	0,757

CODE R

```
base$region_w <- relevel(base$region, ref = "Wallonie")
reg_1_11 <- lm(lprix ~ lrev + region_w, data = base)
rob(reg_1_11)

all.equal(fitted(reg_1_9), fitted(reg_1_11))    # TRUE : mêmes valeurs ajustées
```

`relevel()` déplace une catégorie en première position du facteur, donc en référence. `all.equal()` vérifie que deux objets sont égaux, à une erreur d'arrondi près : c'est la preuve que les deux écritures décrivent le même modèle.

QUESTIONS PROBABLES À L'ORAL

Changer de catégorie de référence change-t-il les conclusions ?

Non. Les prédictions, les résidus, le R^2 et l'élasticité sont identiques. Seule change la question que posent les indicatrices : un écart par rapport à la Wallonie au lieu d'un écart par rapport à la Flandre.

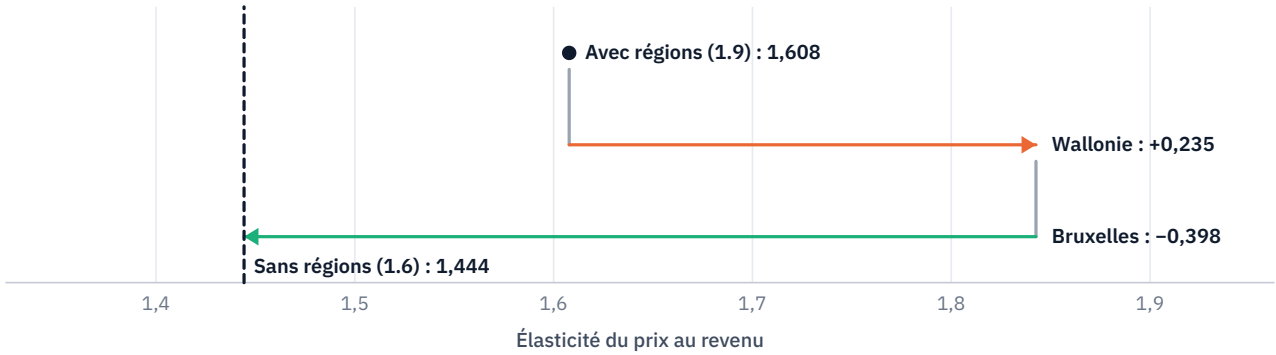
1.12 Pourquoi l'élasticité change : le biais de variable omise

L'élasticité valait 1,444 sans les régions (question 1.6) et vaut 1,608 avec (question 1.9). Cette question explique pourquoi, puis te fait retrouver l'un des deux chiffres à partir de l'autre, **à la quatrième décimale**. C'est la

démonstration la plus élégante du travail.

De 1,608 à 1,444 : la formule du biais de variable omise

Le modèle « court » (sans régions) a une élasticité différente du modèle « long » (avec régions). La différence se décompose exactement : pour chaque région omise, **son effet sur le prix × son lien avec le revenu**.



1,6078 + 0,2348 − 0,3983 = 1,4443, exactement l'élasticité du modèle sans régions (1,4443) : ce n'est pas une approximation, c'est une identité des MCO (551 communes).

La Wallonie (plus pauvre *et* moins chère à revenu égal) gonfle la pente ; Bruxelles (plus pauvre *mais* beaucoup plus chère) l'écrase davantage. Essaie « Sans Bruxelles » : l'écart change de signe.

Région omise	Effet sur ln(prix) à revenu égal (δ)	Pente de l'indicatrice sur ln(rev_hab) (π)	Contribution δ × π
Wallonie	−0,2049	−1,1457	**+0,2348**
Bruxelles	+0,8949	−0,4451	**−0,3983**

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Pourquoi deux élasticités différentes ?

ÉNONCÉ (A)

L'élasticité estimée à la question 1.9 diffère de celle du modèle log-log de la question 1.6. Pourquoi ces deux coefficients sont-ils différents ?

RÉPONSE

Parce que le modèle 1.6 **omet la région**, qui influence le prix **et** est corrélée au revenu. Son élasticité (1,444) mélange deux choses : la relation entre prix et revenu **à l'intérieur** des régions, et les différences de prix et de revenu **entre** régions. C'est un biais de variable omise.

EXPLICATION

Dans le modèle 1.6, tout ce qui n'est pas le revenu se retrouve dans le terme d'erreur, région comprise. Or la région remplit les deux conditions qui créent un biais :

1. elle **influence le prix** : à revenu égal, on paie moins cher en Wallonie et beaucoup plus cher à Bruxelles ;
2. elle est **liée au revenu** : les communes wallonnes et bruxelloises ont en moyenne des revenus plus faibles.

Le coefficient du revenu « ramasse » alors une partie de l'effet de la région. Le modèle 1.9 retire cet effet : son élasticité (1,608) compare des communes **d'une même région**.

(b) Retrouver exactement 1,444

ÉNONCÉ (B)

Estimez la régression de l'indicatrice Wallonie sur log(rev_hab), puis celle de l'indicatrice Bruxelles sur log(rev_hab). À l'aide des coefficients de ces deux régressions et de ceux de la question 1.9, retrouvez exactement l'élasticité de la question 1.6. Détaillez le calcul.

RÉPONSE

$$1{,}6078 + (-0{,}2049) \times (-1{,}1457) + 0{,}8949 \times (-0{,}4451) = 1{,}6078 + 0{,}2348 - 0{,}3983 = 1{,}4443$$

C'est exactement l'élasticité de la question 1.6.

EXPLICATION

La formule du biais de variable omise, avec deux variables omises :

$$\text{élasticité courte} = \text{élasticité longue} + \delta_W \times \pi_W + \delta_B \times \pi_B$$

Chaque variable omise ajoute un terme, qui est le produit de deux nombres :

- δ : **son effet sur le prix** dans le modèle long (question 1.9) ;
- π : **son lien avec le revenu**, c'est-à-dire la pente de la régression de l'indicatrice sur ln(rev_hab).

Les deux régressions « auxiliaires » donnent les π :

Régression	Pente sur ln(rev_hab)	Lecture
Wallonie ~ ln(rev_hab)	π_W = −1,1457 (0,169)	plus le revenu est élevé, moins la commune a de chances d'être wallonne
Bruxelles ~ ln(rev_hab)	π_B = −0,4451 (0,107)	idem pour Bruxelles

Le calcul, terme à terme :

Terme	Calcul	Valeur
Élasticité du modèle long (1.9)	β_1	1,6078
Contribution de la Wallonie	(−0,2049) × (−1,1457)	+0,2348
Contribution de Bruxelles	0,8949 × (−0,4451)	−0,3983
Somme		**1,4443**
Élasticité du modèle court (1.6)		1,4443

« EXACTEMENT », PAS « À PEU PRÈS »

L'égalité est une propriété algébrique des MCO, vraie sur n'importe quel échantillon, pas une approximation statistique. C'est pour cela que l'énoncé écrit « retrouvez exactement ». Garde quatre décimales dans ton rapport pour le montrer.

CODE R

```r
base <- base %>% mutate(wallonie  = as.numeric(region == "Wallonie"),
                        bruxelles = as.numeric(region == "Bruxelles"))
reg_1_12_w <- lm(wallonie  ~ lrev, data = base)     # pente π_W
reg_1_12_b <- lm(bruxelles ~ lrev, data = base)     # pente π_B

b <- coef(reg_1_9)
b["lrev"] + b["regionWallonie"]  * coef(reg_1_12_w)[2] +
            b["regionBruxelles"] * coef(reg_1_12_b)[2]      # 1,4443
coef(reg_1_6_ll)["lrev"]                                    # 1,4443
```

`as.numeric(region == "Wallonie")` fabrique l'indicatrice à la main : la comparaison renvoie `TRUE` ou `FALSE`, que `as.numeric()` transforme en 1 ou 0. On accède à un coefficient par son nom : `b["lrev"]`.

(c) Le signe de chaque contribution

ÉNONCÉ (C)

Expliquez le signe de la contribution de chaque région, en vous aidant du graphique de la question 1.5.

RÉPONSE

Wallonie : (–) × (–) = +0,235. Les communes wallonnes sont plus pauvres *et* moins chères à revenu égal : elles tirent le bas de la droite vers le bas, ce qui la rend plus pentue. **Bruxelles : (+) × (–) = –0,398.** Les communes bruxelloises sont plus pauvres *mais* beaucoup plus chères : elles relèvent le bas de la droite, ce qui l'aplatit. L'effet bruxellois l'emporte.

EXPLICATION

Le signe d'une contribution est le produit de deux signes : **effet de la région sur le prix** × **lien de la région avec le revenu**.

Regarde le nuage (modèle « Une seule droite ») en te demandant où se trouve chaque région.

- **Wallonie** : à gauche (revenus faibles) et sous la droite (prix bas). Une droite qui veut passer près de ces points doit descendre à gauche : elle devient **plus raide**. Omettre la Wallonie *gonfle* l'élasticité.
- **Bruxelles** : à gauche aussi, mais très au-dessus (prix élevés). Une droite attirée par ces points doit remonter à gauche : elle devient **plus plate**. Omettre Bruxelles *écrase* l'élasticité.

Les deux effets vont en sens contraire. Le bruxellois (−0,398) est plus fort que le wallon (+0,235) : au total, l'élasticité sans régions **sous-estime** de 0,163 celle qui vaut à l'intérieur des régions.

Vérifie-le avec l'outil en haut de la page : choisis « Sans Bruxelles », l'écart change de signe.

(d) « 1.9 est la bonne, 1.6 est biaisée » ?

ÉNONCÉ (D)

Un·e collègue affirme que l'élasticité de la question 1.9 est « la bonne » et que celle de la question 1.6 est « biaisée ». Êtes-vous d'accord ?

RÉPONSE

Pas entièrement : tout dépend de la question posée. Pour comparer des communes d'une même région, 1.9 est la bonne mesure, et 1.6 est biaisée de −0,16 *pour ce paramètre-là*. Pour décrire l'association sur l'ensemble de la Belgique, 1.6 répond correctement à cette autre question. Et **aucune des deux n'est un effet causal**.

EXPLICATION

« Biaisé » n'a de sens que par rapport à ce qu'on cherche à mesurer.

Ce qu'on veut savoir	La bonne élasticité
« Si je prends deux communes **de la même région**, de combien leurs prix diffèrent-ils quand leurs revenus diffèrent de 1 % ? »	1.9 (1,608)
« Si je ne connais **que le revenu** d'une commune belge, quel prix prédire ? »	1.6 (1,444)
« Si le revenu des habitants **augmentait**, de combien le prix monterait-il ? »	Aucune des deux

Le collègue a raison sur un point : 1.6 est une mauvaise estimation de la relation *à région donnée*. Il a tort de croire que 1.9 est « la » bonne : elle peut elle-même être biaisée par d'autres variables omises, à l'intérieur des régions cette fois (localisation, qualité des logements). Ajouter un contrôle retire **un** biais, pas tous les biais.

À RETENIR

- Omettre une variable crée un biais égal à (son effet sur y) × (son lien avec x).
- Wallonie : (−) × (−) = +0,235. Bruxelles : (+) × (−) = −0,398.
- 1,608 + 0,235 − 0,398 = 1,444, exactement.
- « Biaisé » se dit toujours par rapport à un paramètre précis.

QUESTIONS PROBABLES À L'ORAL

Pourquoi l'élasticité passe-t-elle de 1,44 à 1,61 quand tu ajoutes les régions ?

Par biais de variable omise : la région influence le prix et est corrélée au revenu. La Wallonie, pauvre et bon marché, gonfle la pente de 0,23 ; Bruxelles, pauvre mais chère, l'écrase de 0,40. L'effet bruxellois domine, et la formule 1,608 + 0,235 − 0,398 redonne exactement 1,444.

Alors 1,61 est-elle la vraie élasticité ?

C'est la bonne mesure de l'association entre communes d'une même région. Mais ce n'est pas un effet causal : d'autres variables omises, comme la localisation, sont liées à la fois au revenu et au prix.

1.13 Une élasticité par région

ÉNONCÉ

Estimez un modèle log-log dans lequel l'élasticité peut différer d'une région à l'autre, en ajoutant l'interaction entre log(rev_hab) et les indicatrices de région.

Le modèle 1.9 imposait la même pente aux trois régions. On relâche cette contrainte : chaque région a maintenant sa hauteur **et** sa pente.

$$\ln(\text{prix}) = \beta_0 + \beta_1 \ln(\text{rev}) + \delta_W W + \delta_B B + \theta_W (W \times \ln(\text{rev})) + \theta_B (B \times \ln(\text{rev})) + u$$

Le modèle 1.13 : une droite par région

Chaque point est une commune (survole-la pour lire son nom). Change l'échelle et le modèle : la droite, son équation et son R² sont **recalculés en direct** sur les vraies données.



Une droite par région (R² = 0,765). Élasticités : **Flandre 1,440**, **Wallonie 1,838**, **Bruxelles 1,072**.

La pente wallonne est la plus forte ; celle de Bruxelles ne repose que sur 19 communes.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) L'élasticité de chaque région et son erreur-type

ÉNONCÉ (A)

Donnez l'élasticité estimée dans chaque région et son erreur-type. Pour les régions autres que la référence, l'élasticité est la somme de deux coefficients : calculez son erreur-type à partir de la matrice de variance-covariance, ou réestimez le modèle en changeant de catégorie de référence.

RÉPONSE

Région	Calcul	Élasticité	Erreur-type HC1	IC à 95 %
Flandre	β_1	**1,440**	0,108	[1,23 ; 1,65]
Wallonie	$\beta_1 + \theta_W$	**1,838**	0,109	[1,62 ; 2,05]
Bruxelles	$\beta_1 + \theta_B$	**1,072**	0,138	[0,80 ; 1,34]

EXPLICATION

Lire les élasticités. Remplace W et B par leurs valeurs pour chaque région et regarde ce qui multiplie ln(rev).

- Flandre (W = 0, B = 0) : il reste β_1 = 1,440.
- Wallonie (W = 1) : $\beta_1 + \theta_W$ = 1,440 + 0,398 = 1,838.
- Bruxelles (B = 1) : $\beta_1 + \theta_B$ = 1,440 − 0,368 = 1,072.

Le coefficient d'une interaction est donc la **différence de pente** avec la région de référence.

L'erreur-type d'une somme. C'est le piège de la question. On n'additionne **pas** les deux erreurs-types. La variance d'une somme fait intervenir la covariance :

$$\mathrm{Var}(\hat{\beta}_1 + \hat{\theta}_W) = \mathrm{Var}(\hat{\beta}_1) + \mathrm{Var}(\hat{\theta}_W) + 2\,\mathrm{Cov}(\hat{\beta}_1, \hat{\theta}_W)$$

Ici la covariance est fortement négative (quand la pente flamande est surestimée, la différence avec la Wallonie est sous-estimée d'autant), ce qui explique que l'erreur-type de la somme (0,109) soit **plus petite** que celle de l'interaction seule (0,153).

La seconde méthode, plus simple. Mets la Wallonie en catégorie de référence : le coefficient de ln(rev) devient directement l'élasticité wallonne, avec la bonne erreur-type. Les deux méthodes donnent 1,838 (0,109).

UNE VÉRIFICATION QUI RASSURE

Dans un modèle où tout est interagi avec la région, les élasticités sont exactement celles qu'on obtiendrait en estimant **une régression séparée dans chaque région**.

RÉSULTATS

	Coefficient	Erreur-type HC1
Constante	−1,909	1,097
ln(rev_hab)	1,440	0,108

	Coefficient	Erreur-type HC1
Wallonie	−4,219	1,550
Bruxelles	4,465	1,744
ln(rev_hab) × Wallonie	0,398	0,153
ln(rev_hab) × Bruxelles	−0,368	0,175

CODE R

```r
reg_1_13 <- lm(lprix ~ lrev * region, data = base)    # * = effets principaux + interactions
rob(reg_1_13)

V  <- vcovHC(reg_1_13, type = "HC1")                  # matrice de variance-covariance robuste
bi <- coef(reg_1_13)

bi["lrev"] + bi["lrev:regionWallonie"]                                  # 1,838
sqrt(V["lrev", "lrev"] + V["lrev:regionWallonie", "lrev:regionWallonie"] +
     2 * V["lrev", "lrev:regionWallonie"])                              # 0,109

# Vérification : la Wallonie en référence
rob(lm(lprix ~ lrev * region_w, data = base))["lrev", ]                 # 1,838 (0,109)
```

- `lrev * region` est un raccourci pour `lrev + region + lrev:region`. Le `:` désigne l'interaction seule.
- `vcovHC()` renvoie un tableau carré : sur la diagonale, les variances des coefficients ; ailleurs, leurs covariances. `V["a", "b"]` lit la case à la ligne `a`, colonne `b`.
- `sqrt()` est la racine carrée : l'erreur-type est la racine de la variance.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Formule de la variance d'une somme, puis vérification

En Flandre, l'élasticité est β_1 = 1,440 (0,108). En Wallonie et à Bruxelles, c'est β_1 plus le coefficient d'interaction : 1,838 et 1,072. L'erreur-type d'une somme se calcule avec la matrice de variance-covariance robuste, $\sqrt{\text{Var}(\beta_1) + \text{Var}(\theta) + 2\,\text{Cov}(\beta_1, \theta)}$: 0,109 et 0,138. Je vérifie en mettant la Wallonie en référence : le coefficient de ln(rev) vaut alors directement 1,838 (0,109).

Fonction de contraste générale

Je calcule chaque élasticité régionale comme une combinaison linéaire des coefficients, L'b, et son erreur-type comme √(L'VL) avec la matrice HC1, puis l'intervalle avec le quantile de Student.

(b) Flandre et Wallonie ont-elles la même élasticité ?

ÉNONCÉ (B)

Testez l'égalité des élasticités flamande et wallonne.

RÉPONSE

On rejette l'égalité. $H_0 : \theta_W = 0$. Statistique t = 0,398 / 0,153 = **2,59** ; p = **0,0097**. L'élasticité est significativement plus forte en Wallonie (1,84) qu'en Flandre (1,44), au seuil de 5 % et même de 1 %.

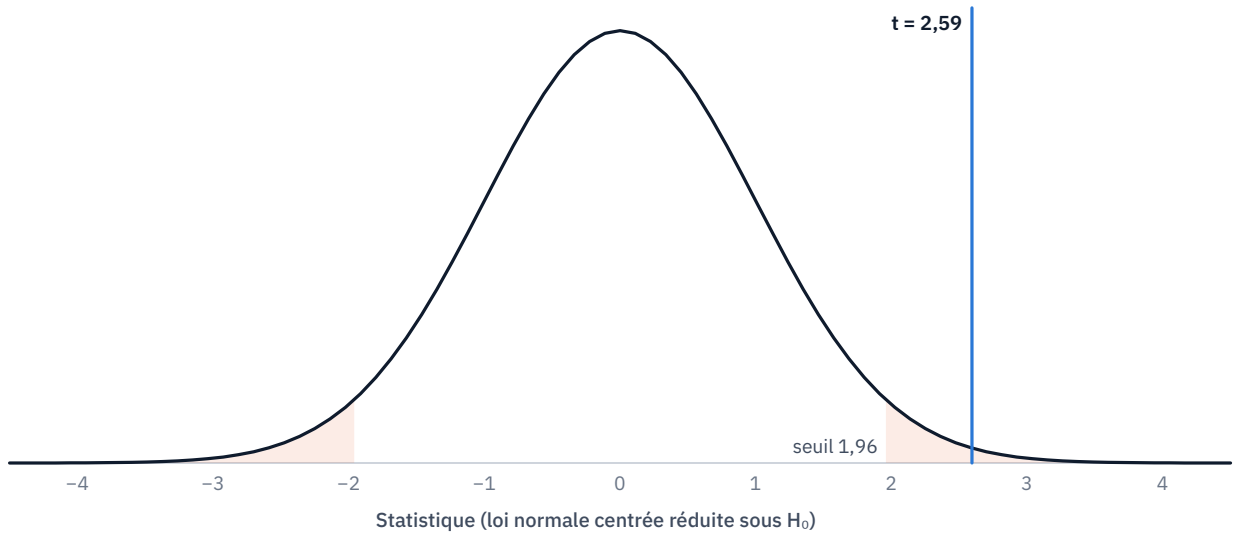
EXPLICATION

L'élasticité wallonne vaut $\beta_1 + \theta_W$, la flamande β_1. Elles sont égales si et seulement si $\theta_W = 0$. Tester l'égalité des deux élasticités, c'est donc tester **un seul coefficient**, qui figure déjà dans la sortie de la régression.

1. **Hypothèses.** $H_0 : \theta_W = 0$ (même élasticité). $H_1 : \theta_W \neq 0$.
2. **Statistique.** t = coefficient / erreur-type robuste = 0,398 / 0,153 = 2,59.
3. **Loi sous H_0.** Normale centrée réduite (grand échantillon). Valeur critique à 5 % : 1,96.
4. **Décision.** 2,59 > 1,96, p = 0,0097 : on rejette H_0.

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : θ_W = 0 : même élasticité en Flandre et en Wallonie.

Statistique 2,59, valeur critique à 5 % : 1,96 (en valeur absolue). La **p-valeur** est de 0,0095 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 0,9 % des cas.

On rejette H_0 au seuil de 5 %.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Les écarts de prix entre communes wallonnes suivent donc davantage les écarts de revenu que ce n'est le cas en Flandre.

⚠ LE TEST QU'IL NE FAUT PAS FAIRE

Tester séparément « l'élasticité flamande est non nulle » et « l'élasticité wallonne est non nulle » répond à une autre question. Et comparer deux intervalles de confiance qui se chevauchent ne dit rien non plus : ici [1,23 ; 1,65] et [1,62 ; 2,05] se chevauchent un peu, et pourtant la différence est significative.

CODE R

```
linearHypothesis(reg_1_13, "lrev:regionWallonie = 0", vcov. = V, test = "F")
# F = 6,73 ; p = 0,0097   (et F = t² : 2,594² = 6,73)
```

`linearHypothesis()` (package `car`) teste une ou plusieurs restrictions sur les coefficients. `vcov. = V` lui fait utiliser la matrice robuste HC1. Avec une seule restriction, sa statistique F est le carré du t lu dans `rob(reg_1_13)`.

(c) Bruxelles : 19 communes

ÉNONCÉ (C)

Sur combien de communes repose l'estimation bruxelloise ? Qu'en concluez-vous ?

RÉPONSE

Sur **19 communes** seulement. L'estimation (1,07) est **fragile** : quelques communes atypiques suffisent à déplacer la pente, et les erreurs-types robustes sont peu fiables sur un si petit groupe. On ne peut pas conclure grand-chose sur l'élasticité bruxelloise.

EXPLICATION

Trois raisons de se méfier.

- **Le poids de chaque point.** Avec 19 observations, deux ou trois communes atypiques commandent la pente : Ixelles (840 000 € pour 21 877 € de revenu), Saint-Gilles (681 250 € pour 17 920 €).
- **La validité des erreurs-types.** Les erreurs-types robustes sont justifiées pour de **grands** échantillons. Sur 19 points, l'approximation est mauvaise : l'intervalle [0,80 ; 1,34] est sans doute trop optimiste.
- **Un marché particulier.** À Bruxelles, 80 % des ventes de logements sont des appartements : les maisons vendues y sont un sous-ensemble peu représentatif. Et `rev_hab` y mesure mal le revenu des acheteurs (question 1.2).

L'écart de pente entre Bruxelles et la Flandre (−0,368) a une p-valeur de 0,036 : à la limite du seuil, et peu robuste pour les mêmes raisons.

(d) Pourquoi l'indicatrice Wallonie vaut maintenant −4,2

ÉNONCÉ (D)

Le coefficient de l'indicatrice Wallonie a fortement changé par rapport à la question 1.9. Que mesure-t-il dans ce modèle ? Est-il interprétable tel quel ?

RÉPONSE

Il mesure l'écart entre la Wallonie et la Flandre **quand ln(rev_hab) = 0**, c'est-à-dire pour un revenu de **1 € par habitant**. C'est une extrapolation absurde, très loin des données (le revenu minimum est de 12 987 €) : **non, il n'est pas interprétable tel quel.**

EXPLICATION

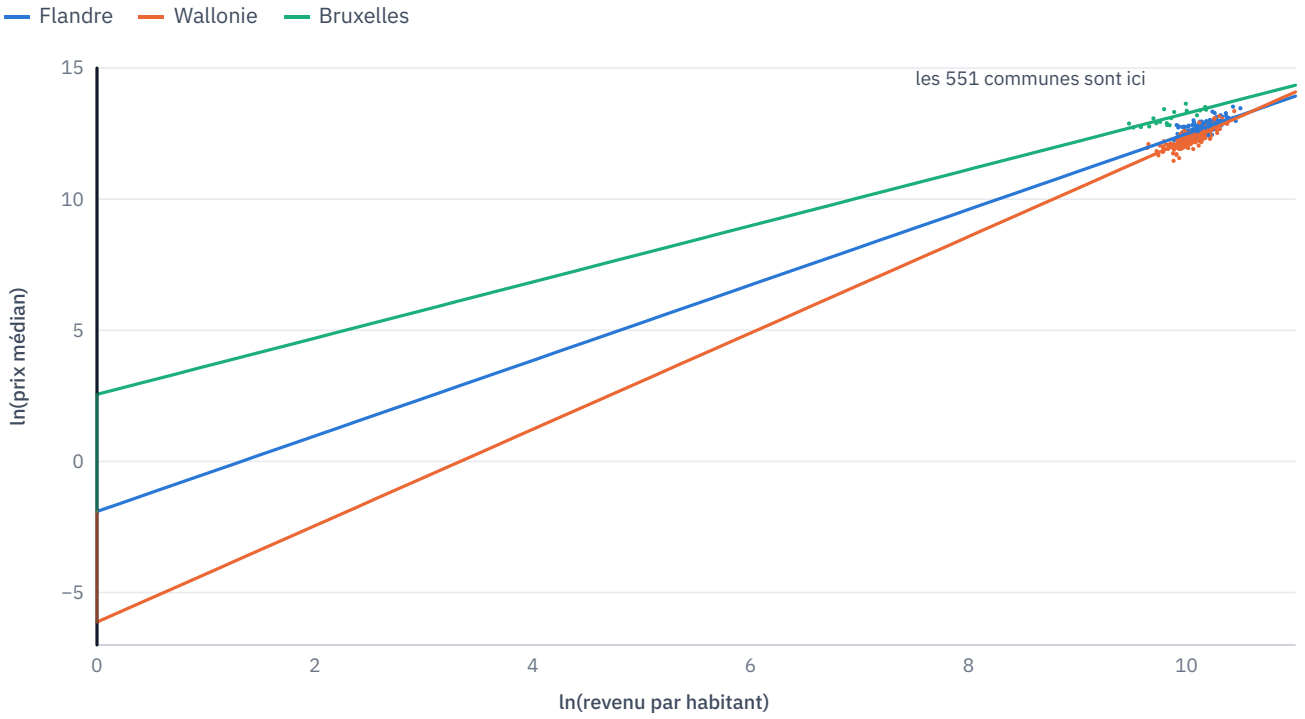
Avec des pentes différentes, les droites ne sont plus parallèles : l'écart entre deux régions **dépend du revenu** auquel on le mesure.

$$\text{écart Wallonie} - \text{Flandre au revenu } r = \delta_W + \theta_W \times \ln(r)$$

Le coefficient δ_W est la valeur de cette expression quand le second terme s'annule, donc quand ln(r) = 0, soit r = 1 €. L'outil ci-dessous prolonge les droites jusque-là.

Où mesure-t-on l'écart entre régions ? Le rôle du centrage

Avec des pentes différentes, l'écart entre deux régions dépend du revenu auquel on le mesure. Le coefficient de l'indicatrice donne cet écart là où le régresseur vaut **zéro**. Déplace ce point zéro.



Point zéro : un revenu de **1 €** par habitant. On est très loin des données (le revenu le plus faible observé est de 12 987 €) : l'écart de −4,22 mesure la distance entre deux droites *prolongées* jusque-là. C'est un artefact d'extrapolation, pas un écart de prix réel. Les pentes, elles, ne changent jamais : déplacer l'origine d'un axe ne fait pas tourner une droite.

Coefficient du modèle centré	Formule	Valeur	Lecture
Constante	$\beta_0 + \beta_1 \times \ln(c)$	−1,909	extrapolation
lrev_c (élasticité flamande)	β_1, inchangé	1,440	—
Indicatrice Wallonie	$\delta_W + \theta_W \times \ln(c)$	−4,219	non interprétable
Indicatrice Bruxelles	$\delta_B + \theta_B \times \ln(c)$	+4,465	non interprétable
Interactions	θ_W et θ_B, inchangées	+0,398 et −0,368	—

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

À un revenu réaliste, l'écart redevient raisonnable. À 25 000 € : −4,219 + 0,398 × ln(25 000) = −4,219 + 0,398 × 10,127 = **−0,189**.

LA RÈGLE GÉNÉRALE

Dans un modèle avec interaction, le coefficient d'une indicatrice est l'écart mesuré **là où l'autre variable de l'interaction vaut zéro**. Si zéro est loin des données, ce coefficient n'a aucun sens concret.

(e) Centrer le revenu sur 25 000 €

ÉNONCÉ (E)

Créez `lrev_c` = ln(rev_hab) − ln(25 000) et réestimez le modèle en remplaçant log(rev_hab) par `lrev_c`. Quels coefficients changent, lesquels restent identiques, et pourquoi ? Interprétez le nouveau coefficient de l'indicatrice Wallonie et la nouvelle constante.

RÉPONSE

Inchangés : les pentes (élasticité 1,440 et interactions 0,398 et −0,368), leurs erreurs-types, le R^2, les valeurs ajustées. **Modifiés** : la constante (12,672) et les indicatrices (Wallonie −0,189, Bruxelles 0,738), désormais mesurées à 25 000 € au lieu de 1 €. Pour un revenu de 25 000 € par habitant, le prix médian wallon est inférieur de **17,2 %** au flamand, et le prix flamand prédit est de **318 600 €**.

EXPLICATION

Centrer, c'est déplacer le point zéro du régresseur. `lrev_c` vaut 0 quand le revenu vaut 25 000 €, une valeur proche du revenu moyen (24 288 €). La règle de la question (d) fait le reste : les indicatrices mesurent maintenant l'écart **à 25 000 €**.

	Modèle 1.13	Modèle centré
Constante	−1,909 (1,097)	12,672 (0,009)
ln(rev_hab) ou lrev_c	1,440 (0,108)	1,440 (0,108)
Wallonie	−4,219 (1,550)	−0,189 (0,017)
Bruxelles	4,465 (1,744)	0,738 (0,060)
Interaction Wallonie	0,398 (0,153)	0,398 (0,153)
Interaction Bruxelles	−0,368 (0,175)	−0,368 (0,175)

Pourquoi les pentes ne bougent pas. Déplacer l'origine d'un axe ne fait pas tourner une droite. C'est toujours le même modèle, avec les mêmes prédictions.

Pourquoi les erreurs-types de la constante et des indicatrices s'effondrent (de 1,550 à 0,017 pour la Wallonie). On n'extrapole plus : on estime un écart au cœur du nuage, là où il y a beaucoup de données.

Les interprétations.

- **Nouvelle constante (12,672)** : ln(prix) prédit pour une commune **flamande** à 25 000 € par habitant, soit exp(12,672) ≈ 318 600 €.
- **Nouvelle indicatrice Wallonie (−0,189)** : à 25 000 € de revenu par habitant, le prix médian wallon est inférieur de 100 × (exp(−0,189) − 1) = −17,2 % au prix flamand.

CODE R

```r
base$lrev_c <- base$lrev - log(25000)
reg_1_13e <- lm(lprix ~ lrev_c * region, data = base)
rob(reg_1_13e)
exp(coef(reg_1_13e)[1])    # 318 575 € : le prix flamand prédit à 25 000 €
```

(f) Les trois droites et leurs intervalles de confiance

ÉNONCÉ (F)

Représentez les relations estimées dans chaque région, avec leurs intervalles de confiance à 95 %, sur le nuage de points.

RÉPONSE

Trois droites de pentes différentes sur le nuage en échelles logarithmiques, chacune entourée d'une bande. La droite wallonne est la plus pentue et se rapproche de la flamande pour les communes riches ; la droite bruxelloise est très au-dessus, avec une bande large. Les bandes s'élargissent aux extrémités, où il y a peu de communes.

EXPLICATION

Reprends l'outil en haut de la page (modèle « Une pente par région ») pour voir les trois droites.

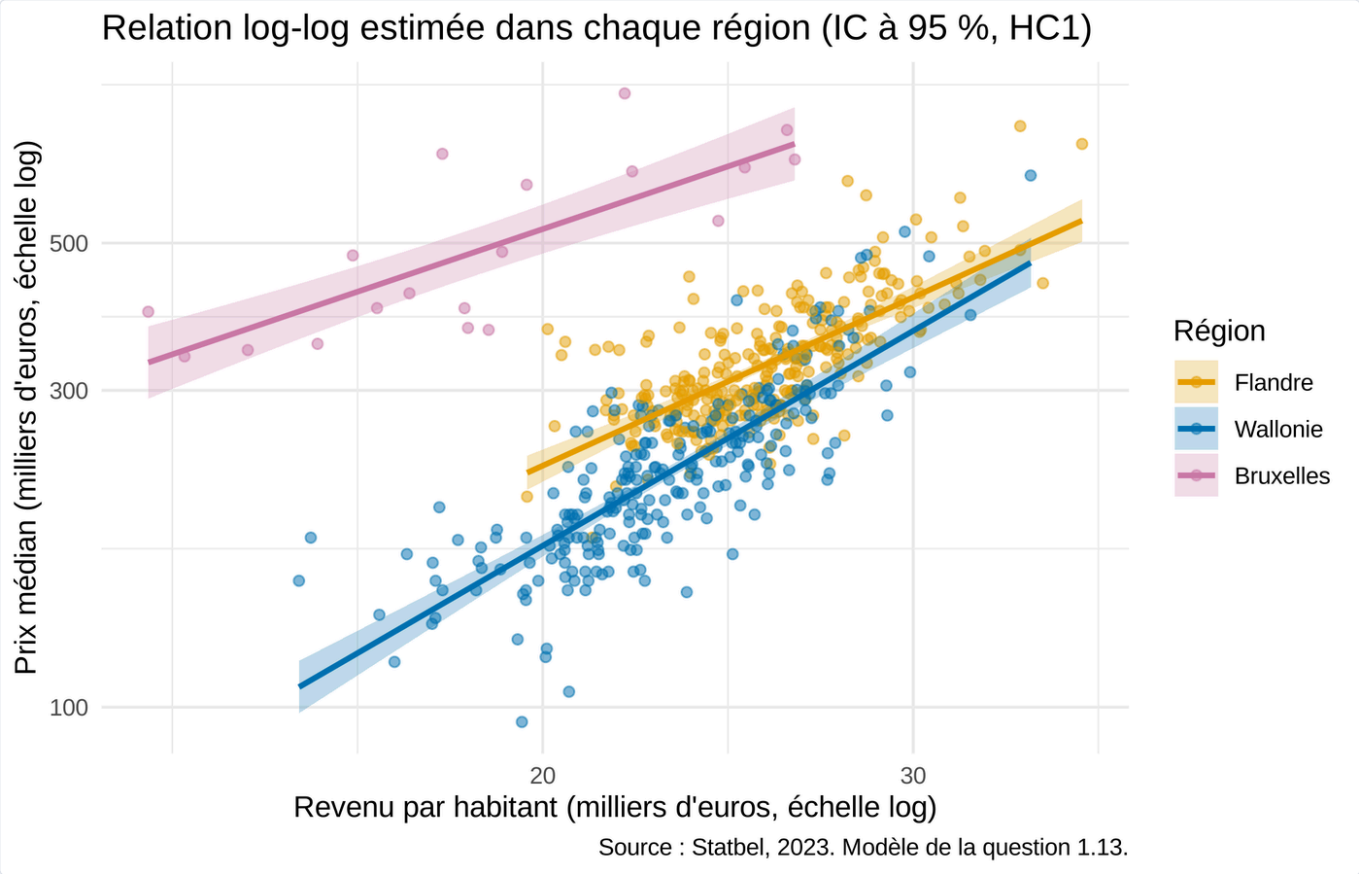
Comment se construit la bande. Pour chaque région et chaque niveau de revenu, on calcule la prédiction $x'b$, puis son erreur-type robuste $\sqrt{x'\mathrm{V}x}$, où x est le vecteur des régresseurs pour cette région et ce revenu, et V la matrice HC1. La bande va de prédiction − 1,96 × erreur-type à prédiction + 1,96 × erreur-type.

Ce qu'il faut commenter.

- L'écart Wallonie-Flandre **se réduit quand le revenu augmente** : −17 % à 25 000 €, environ −11 % à 30 000 €.
- La bande de Bruxelles est large : 19 communes.
- Les bandes s'évasent aux extrémités : on est moins sûr d'une droite là où il y a peu de points.

⚠ CE QUE LA BANDE NE DIT PAS

C'est un intervalle de confiance sur le prix **moyen** prédit, pas un intervalle où tomberait le prix d'une commune donnée. La plupart des communes sont en dehors de la bande, et c'est normal.



Relation log-log estimée dans chaque région, avec intervalles de confiance à 95 % (erreurs-types HC1). Fichier : fig_1_13f.png.

CODE R

```r
# Une grille de revenus observés dans chaque région
grille <- bind_rows(lapply(levels(base$region), function(r) {
  x <- base$lrev[base$region == r]
  data.frame(region = r, lrev = seq(min(x), max(x), length.out = 50))
}))
grille$region <- factor(grille$region, levels = levels(base$region))

X <- model.matrix(~ lrev * region, data = grille)    # les régresseurs pour chaque point de la grille
grille$fit <- as.vector(X %*% bi)                    # prédiction x'b
grille$se  <- sqrt(rowSums((X %*% V) * X))           # erreur-type robuste sqrt(x'Vx)
grille <- grille %>% mutate(bas = fit - 1.96 * se, haut = fit + 1.96 * se)
```

On trace ensuite `geom_ribbon()` (la bande) et `geom_line()` (la droite) par-dessus `geom_point()`. `predict(..., se.fit = TRUE)` donnerait des erreurs-types **classiques** : il faut faire le calcul à la main pour rester en HC1, comme le demande l'énoncé. `%*%` est le produit matriciel.

QUESTIONS PROBABLES À L'ORAL

Pourquoi l'indicatrice Wallonie passe-t-elle de −0,205 à −4,219 ?

Dans le modèle avec interaction, elle mesure l'écart entre les deux régions quand ln(rev) vaut zéro, soit un revenu de 1 €. C'est une extrapolation sans aucun sens. En centrant le revenu sur 25 000 €, elle devient −0,189 et se lit : à ce revenu, les maisons wallonnes sont 17 % moins chères.

Que change le centrage, et que ne change-t-il pas ?

Il ne change ni les pentes, ni les prédictions, ni le R^2 : c'est le même modèle. Il change la constante et les indicatrices, parce qu'elles sont mesurées au point zéro du régresseur, qu'on a déplacé de 1 € à 25 000 €.

1.14 La variance des erreurs est-elle constante ?

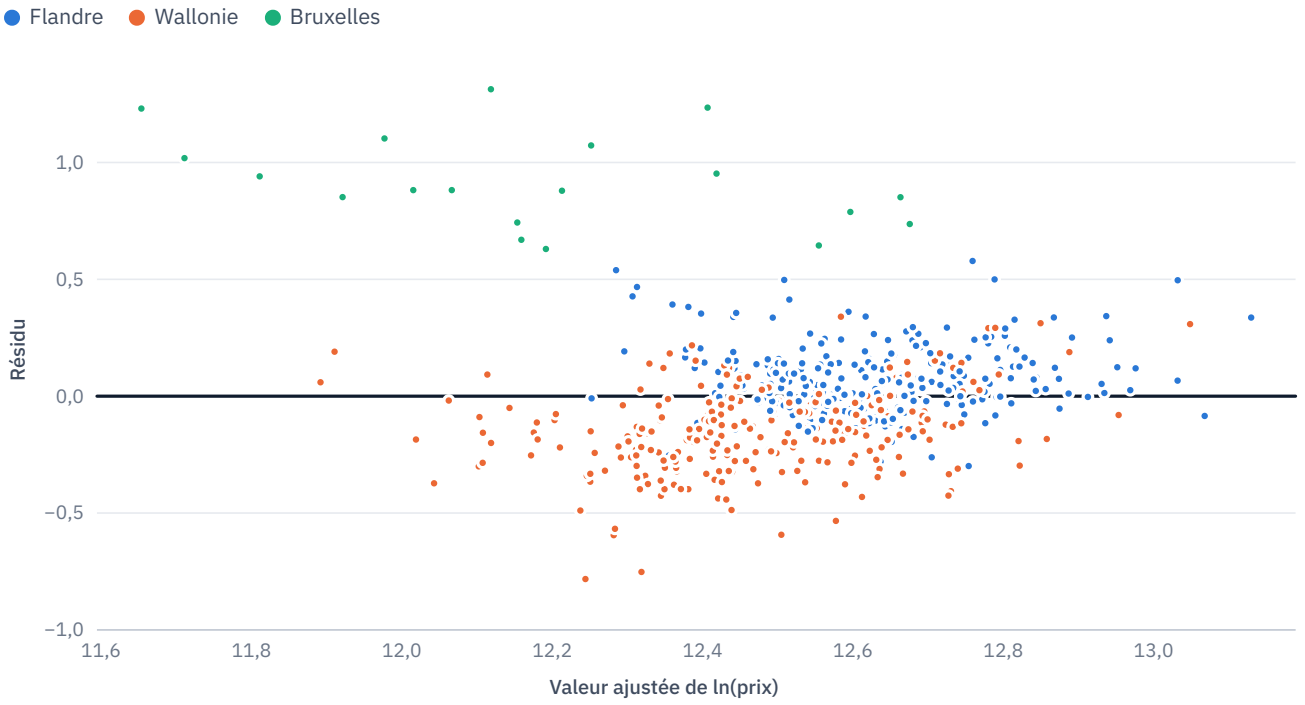
ÉNONCÉ

Pour le modèle log-log de la question 1.6 et pour le modèle avec indicatrices de région de la question 1.9 : (a) représentez les résidus en fonction des valeurs ajustées, puis en fonction de log(n_ventes) ; (b) effectuez un test de Breusch-Pagan sur les régresseurs du modèle, puis sur log(n_ventes) ; (c) comparez les erreurs-types classiques et robustes de l'élasticité.

La question 1.3 annonçait un problème : le prix médian est bien moins précis dans les petites communes, donc la variance des erreurs ne devrait pas être la même partout. On le vérifie de trois façons, puis on en tire les conséquences.

Les résidus des modèles 1.6 et 1.9

Un résidu = ln(prix) observé − ln(prix) prédit. Si la variance des erreurs était constante, le nuage formerait une bande horizontale d'épaisseur régulière, centrée sur zéro, quelle que soit la région.



Modèle 1.6 : les résidus ne sont pas centrés par région. Résidu moyen : Flandre +0,07, Wallonie −0,15, **Bruxelles +0,92**. Ce modèle se trompe systématiquement selon la région : la « variance non constante » vient surtout de variables oubliées.

Élasticité	Erreur-type classique	Erreur-type robuste HC1	Breusch-Pagan, régresseurs	Breusch-Pagan, ln(ventes)
1,444	0,081	0,149	82,62	4,86
		rapport 1,85	khi²(1), p < 0,0001	khi²(1), p 0,027

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Les graphiques de résidus

ÉNONCÉ (A)

Représentez les résidus en fonction des valeurs ajustées, puis en fonction de log(n_ventes).

RÉPONSE

Modèle 1.6 : les résidus ne sont pas centrés par région (tous positifs à Bruxelles, de +0,6 à +1,3 ; surtout négatifs en Wallonie) et sont bien plus dispersés aux faibles valeurs ajustées. **Modèle 1.9** : un nuage centré sur zéro, d'épaisseur assez régulière, un peu plus large pour les communes qui comptent peu de ventes.

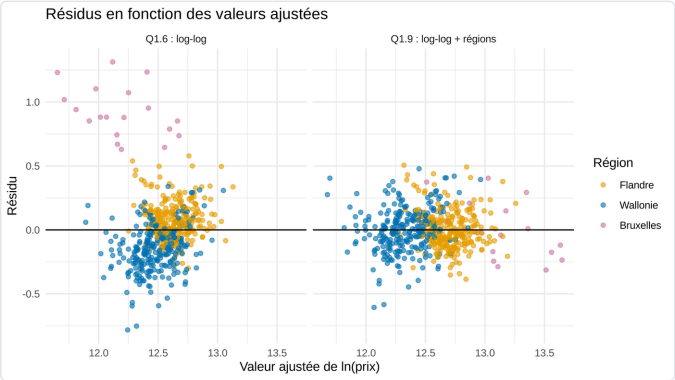
EXPLICATION

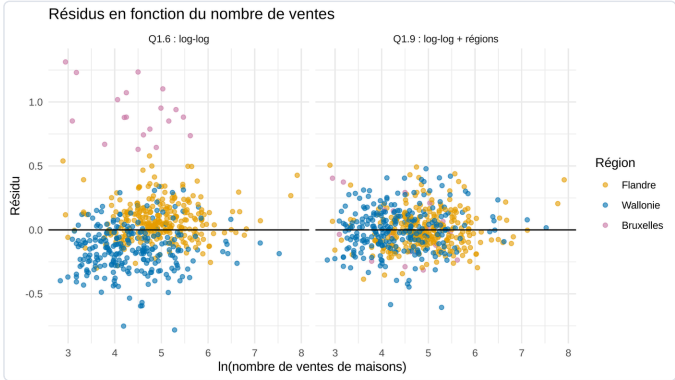
Un résidu est l'erreur de prédiction : ln(prix) observé moins ln(prix) prédit. Si tout va bien, le nuage des résidus est une **bande horizontale**, centrée sur zéro, de même épaisseur partout.

Deux défauts possibles, à ne pas confondre :

- une bande dont **l'épaisseur varie** : c'est l'hétéroscédasticité ;
- une bande qui **n'est pas centrée sur zéro** pour certains groupes : le modèle se trompe systématiquement, il lui manque une variable.

Dans le modèle 1.6, les deux se voient, et le second domine : les 19 communes bruxelloises ont toutes un résidu très positif. Passe au modèle 1.9 dans l'outil : les couleurs se mélangent, la bande se resserre.





Résidus des modèles 1.6 et 1.9 en fonction des valeurs ajustées, puis du nombre de ventes. Fichiers : fig_1_14_ajuste.png, fig_1_14_ventes.png.

CODE R

```
base$lventes <- log(base$n_ventes)
d14 <- data.frame(ajuste = fitted(reg_1_9), residu = resid(reg_1_9),
                  lventes = base$lventes, region = base$region)

ggplot(d14, aes(x = ajuste, y = residu, colour = region)) +
  geom_point(alpha = 0.6) + geom_hline(yintercept = 0)
```

`fitted()` donne les valeurs ajustées, `resid()` les résidus. `geom_hline(yintercept = 0)` trace la ligne zéro.

(b) Le test de Breusch-Pagan

ÉNONCÉ (B)

Effectuez un test de Breusch-Pagan sur les régresseurs du modèle, puis sur log(n_ventes).

RÉPONSE

Modèle	Variables testées	Statistique	ddl	p-valeur	Décision à 5 %
1.6	ln(rev_hab)	82,6	1	$1{,}0 \times 10^{-19}$	rejet
1.6	ln(n_ventes)	4,86	1	0,027	rejet
1.9	ln(rev_hab), régions	9,26	3	0,026	rejet (pas à 1 %)
1.9	ln(n_ventes)	0,48	1	0,487	non-rejet

EXPLICATION

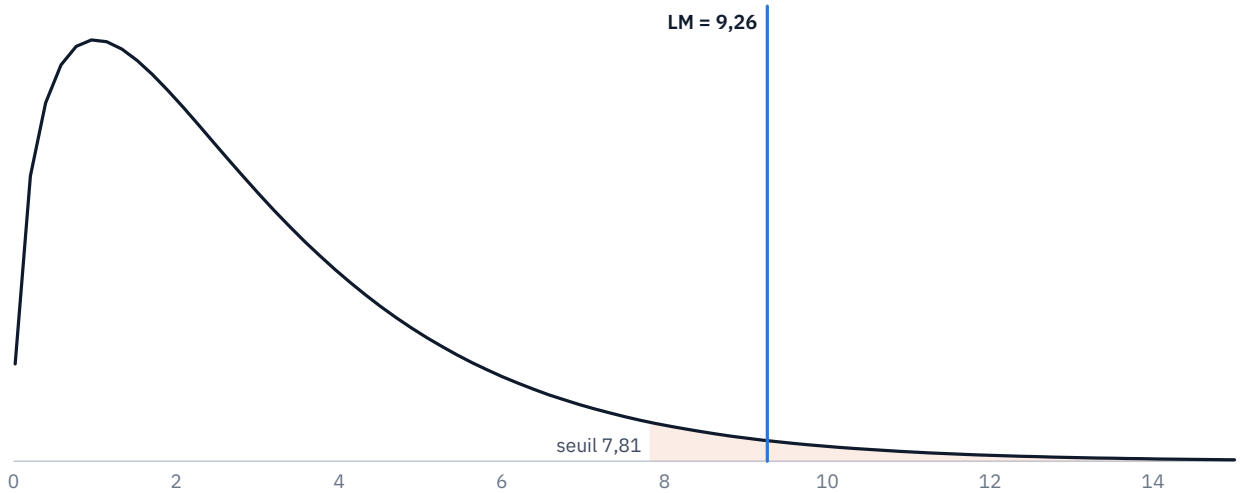
Le test de Breusch-Pagan formalise ce qu'on cherche à l'œil : **l'épaisseur du nuage des résidus dépend-elle de certaines variables ?**

1. **Hypothèses.** H_0 : la variance de l'erreur est constante (homoscédasticité). H_1 : elle dépend des variables z choisies.
2. **Régression auxiliaire.** On régresse les résidus **au carré** sur les variables z. Un résidu au carré est grand quand le point est loin de la droite : si z aide à prédire ces carrés, c'est que la dispersion dépend de z.
3. **Statistique.** LM = n × R^2 de cette régression. Sous H_0, elle suit un khi-deux dont le nombre de degrés de liberté est le nombre de variables z.
4. **Décision.** On rejette H_0 si $p < 0{,}05$.

Le test dépend donc des variables z qu'on lui donne : c'est pourquoi l'énoncé le demande deux fois, avec les régresseurs du modèle puis avec ln(n_ventes).

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : variance des erreurs constante (homoscédasticité).

Statistique 9,26, valeur critique à 5 % : 7,81. La **p-valeur** est de 0,0260 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 2,6 % des cas.

On rejette H_0 au seuil de 5 %.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Lecture. Le modèle 1.6 est fortement hétéroscédastique. Le modèle 1.9 l'est beaucoup moins : le test global rejette encore à 5 % (pas à 1 %), et celui sur le nombre de ventes ne rejette pas.

CODE R

```
bptest(reg_1_6_ll)                          # z = les régresseurs du modèle
bptest(reg_1_6_ll, ~ lventes, data = base)  # z = ln(n_ventes)
bptest(reg_1_9)
bptest(reg_1_9, ~ lventes, data = base)
```

`bptest()` (package `lmtest`) utilise par défaut la version « studentisée » de Koenker, valable même si les erreurs ne suivent pas une loi normale. Le second argument, une formule commençant par `~`, donne les variables z.

(c) Erreurs-types classiques et robustes

ÉNONCÉ (C)

Comparez les erreurs-types classiques et robustes de l'élasticité.

RÉPONSE

Modèle	Élasticité	Erreur-type classique	Erreur-type HC1	Rapport
1.6	1,444	0,081	0,149	**1,85**
1.9	1,608	0,058	0,074	**1,27**

EXPLICATION

Les deux erreurs-types mesurent la même chose (l'imprécision de l'élasticité), mais avec deux formules. La classique **suppose** l'homoscédasticité ; la robuste n'en a pas besoin. Quand l'hypothèse est vraie, les deux sont proches. Leur écart est donc un **thermomètre** de l'hétéroscédasticité.

Dans le modèle 1.6, la formule classique sous-estime l'incertitude de presque la moitié : l'intervalle à 95 % serait [1,29 ; 1,60] au lieu de [1,15 ; 1,74].

CODE R

```
sqrt(diag(vcov(reg_1_9)))["lrev"]                  # classique : 0,058
sqrt(diag(vcovHC(reg_1_9, type = "HC1")))["lrev"]   # robuste   : 0,074
```

`vcov()` est la matrice de variance-covariance classique, `vcovHC()` la robuste. `diag()` extrait la diagonale (les variances), `sqrt()` en prend la racine.

(d) La question 1.3 se confirme-t-elle ?

ÉNONCÉ (D)

Vos résultats confirment-ils ce que la question 1.3 laissait attendre ?

RÉPONSE

En partie seulement. On voit bien un peu plus de dispersion dans les petites communes (écart-type des résidus de 0,20 sous 30 ventes, contre 0,16 ailleurs, dans le modèle 1.9). Mais le test sur ln(n_ventes) ne rejette pas l'homoscédasticité dans ce modèle (p = 0,49) : l'erreur d'échantillonnage de la médiane n'est qu'une **petite partie** du bruit total.

EXPLICATION

La question 1.3 prédisait : moins de ventes, médiane moins précise, donc résidus plus dispersés. Le tableau montre que c'est vrai, mais surtout pour les très petites communes.

Ventes de maisons	Communes	Écart-type des résidus (1.6)	Écart-type des résidus (1.9)	Erreur-type relative de la médiane
Moins de 30	34	0,419	0,201	12,2 %
30 à 49	62	0,179	0,154	9,5 %
50 à 99	156	0,278	0,165	6,7 %
100 à 199	186	0,247	0,161	4,3 %
200 et plus	113	0,225	0,157	3,0 %

Pourquoi le test ne le détecte-t-il pas ? Compare deux ordres de grandeur.

- Pour la plupart des communes, l'erreur d'échantillonnage de la médiane vaut 3 à 7 % du prix, soit une variance d'environ $0{,}05^2 = 0{,}0025$.
- La variance totale des résidus du modèle 1.9 est d'environ $0{,}163^2 = 0{,}027$: **dix fois plus**.

L'imprécision de la médiane est noyée dans tout le reste (qualité des logements, localisation…). Elle ne pèse vraiment que pour une trentaine de petites communes, et un test qui cherche une relation régulière avec ln(n_ventes) manque de puissance pour la voir.

Et dans le modèle 1.6 ? Le test sur ln(n_ventes) rejette (p = 0,027), mais pour une mauvaise raison : le nombre de ventes est lié aux régions, dont l'effet est resté dans les résidus.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Tableau par classes de ventes et ordres de grandeur

En partie. Dans le modèle 1.9, l'écart-type des résidus vaut 0,20 dans les communes de moins de 30 ventes, contre environ 0,16 ailleurs : la dispersion est bien plus forte là où la médiane est imprécise. Mais le test de Breusch-Pagan sur ln(n_ventes) ne rejette pas (p = 0,49), parce que l'erreur d'échantillonnage de la médiane (variance d'environ 0,0025) ne représente qu'un dixième de la variance des résidus (0,027).

Signe de la relation entre résidus au carré et ventes

Partiellement. La relation entre les résidus au carré et ln(n_ventes) est négative, comme attendu, dans le modèle simple, mais elle devient proche de zéro une fois les régions prises en compte. L'imprécision de la médiane existe, mais elle n'explique pas à elle seule la variance de l'erreur.

(e) Pourquoi l'écart est-il plus grand dans le modèle 1.6 ?

ÉNONCÉ (E)

Pourquoi l'écart entre erreurs-types classiques et robustes est-il plus grand dans le modèle de la question 1.6 ? Qu'est-ce que cela suggère sur ce modèle ?

RÉPONSE

Parce que l'omission des régions crée de **très grands résidus aux revenus les plus faibles** : toutes les communes bruxelloises (résidus d'environ +0,9) et les communes wallonnes pauvres se trouvent à gauche du nuage. Cela suggère que le modèle 1.6 est **mal spécifié** : il lui manque des variables.

EXPLICATION

L'erreur-type robuste donne à chaque résidu au carré un poids proportionnel à $(x - \bar{x})^2$: les observations **éloignées du revenu moyen** comptent le plus. Elle s'écarte donc de la classique quand les grands résidus se concentrent aux extrémités du revenu.

C'est exactement le cas du modèle 1.6. Les communes bruxelloises sont pauvres (à l'extrémité gauche) et mal prédites (résidus énormes). La formule classique, qui suppose la même dispersion partout, ne voit pas ce cumul.

Ce qu'on appelle ici « hétéroscédasticité » est en grande partie autre chose : une **moyenne mal modélisée**. La preuve, c'est qu'il suffit d'ajouter les régions pour que tout s'améliore d'un coup.

	Modèle 1.6	Modèle 1.9
R^2	0,367	0,757
Breusch-Pagan (régresseurs)	82,6	9,3

	Modèle 1.6	Modèle 1.9
Rapport HC1 / classique	1,85	1,27

(f) Ce que l'hétéroscédasticité change et ne change pas

ÉNONCÉ (F)

Qu'est-ce que l'hétéroscédasticité change, et qu'est-ce qu'elle ne change pas, à vos estimations et à vos conclusions ?

RÉPONSE

Elle ne change pas les coefficients, qui restent sans biais, ni le R^2, ni les valeurs ajustées. **Elle change** les erreurs-types : la formule classique devient fausse, donc aussi les tests et les intervalles de confiance. Avec les erreurs-types HC1, nos conclusions tiennent : l'élasticité reste très significative (t = 21,7 dans le modèle 1.9), seuls les intervalles s'élargissent.

EXPLICATION

	Avec hétéroscédasticité
Coefficients estimés	**inchangés et sans biais** : l'absence de biais ne demande que $E(u \mid x) = 0$
R^2, valeurs ajustées, résidus	inchangés
Erreurs-types classiques	**fausses**
Tests t, tests F, intervalles de confiance classiques	**faux**
Efficacité des MCO	perdue : des moindres carrés pondérés par le nombre de ventes seraient plus précis

Le remède est déjà en place : les erreurs-types robustes HC1, que l'énoncé impose partout. Elles ne modifient aucun coefficient ; elles donnent seulement une mesure honnête de l'incertitude.

⚠ LA PHRASE À NE JAMAIS PRONONCER

« L'hétéroscédasticité biaise les coefficients. » C'est faux. Elle fausse les erreurs-types classiques, rien d'autre.

QUESTIONS PROBABLES À L'ORAL

Qu'est-ce que l'hétéroscédasticité, et pourquoi en attendais-tu ici ?

C'est une variance des erreurs qui n'est pas la même pour toutes les observations. J'en attendais parce que le prix médian est beaucoup moins précis dans les communes où il y a peu de ventes : cette erreur d'échantillonnage entre dans le terme d'erreur.

Que fait HC1 ?

Il calcule les erreurs-types sans supposer que la variance des erreurs est constante. Les coefficients ne changent pas. HC1 est la version de White multipliée par n / (n − k), une petite correction pour les échantillons finis.

1.15 Ajouter la population et la part d'appartements

On ajoute deux variables de contrôle au modèle 1.9. La première sous-question est un petit travail de détective sur une valeur manquante ; la seconde, un exercice d'interprétation.

(a) Que signifient les 25 valeurs manquantes ?

ÉNONCÉ (A)

Vingt-cinq communes de votre base ont une valeur manquante pour le nombre de ventes d'appartements. Que signifie, selon vous, cette valeur manquante ? Comment la traitez-vous ? (Indice : examinez les plus petites valeurs de `n_app` dans le fichier.)

RÉPONSE

Elle signifie **« aucune vente d'appartement »**. La plus petite valeur de `n_app` est 1 et le fichier entier ne contient **aucun zéro** : Statbel n'écrit pas les lignes à zéro vente. On remplace donc ces valeurs manquantes par **0**, au lieu de supprimer les communes.

EXPLICATION

Suis l'indice. Trois observations suffisent.

1. La plus petite valeur de `n_app` est **1**. Il n'y a jamais de 0.
2. Dans **tout** le fichier des ventes (toutes années, tous niveaux, tous types de biens), la variable `MS_TOTAL_TRANSACTIONS` ne vaut jamais 0.
3. Les 25 communes concernées sont de petites communes rurales (Biévène, Pepingen, Glabbeek, Lo-Reninge…), où il est tout à fait plausible qu'aucun appartement ne se soit vendu.

Conclusion : une cellule vide veut dire « zéro ».

Pourquoi ce n'est pas un secret statistique ? On pourrait croire que Statbel masque les petits nombres pour protéger la confidentialité. Mais 37 communes ont exactement **1** vente d'appartement et 21 en ont **2**, et ces chiffres sont publiés. Un seuil de confidentialité aurait masqué ceux-là en premier.

Pourquoi remplacer par 0 plutôt que supprimer ? Supprimer ces 25 communes écarterait justement celles où `part_app` vaut 0 : une sélection systématique, qui fausserait le coefficient de `part_app`.

⚠ CETTE RÈGLE NE VAUT QUE POUR UN COMPTAGE

Un nombre de ventes manquant peut vouloir dire zéro. Un **prix médian** manquant ne veut pas dire « prix nul » : les 14 communes de la question 1.1 (f) restent exclues.

CODE R

```r
sum(is.na(base$n_app))                                  # 25
sort(base$n_app)[1:10]                                  # 1 1 1 1 … : jamais 0
sum(immo_raw$MS_TOTAL_TRANSACTIONS == 0, na.rm = TRUE)  # 0 : aucun zéro dans tout le fichier

base <- base %>%
  mutate(n_app    = ifelse(is.na(n_app), 0, n_app),
         part_app = n_app / (n_app + n_ventes),
         lpop     = log(pop))
```

`ifelse(condition, valeur si vrai, valeur si faux)` remplace les `NA` par 0. `na.rm = TRUE` demande d'ignorer les valeurs manquantes dans le calcul.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Les deux preuves, le codage à zéro, puis le test de sensibilité

La valeur manquante signifie qu'aucun appartement n'a été vendu : la plus petite valeur de n_app est 1 et le fichier ne contient aucun zéro, donc Statbel n'écrit pas les zéros. Ce n'est pas un masquage de confidentialité, puisque des communes à 1 ou 2 ventes sont publiées. Je remplace ces 25 valeurs par 0 plutôt que de supprimer les communes, ce qui écarterait justement celles où la part d'appartements est nulle. En les retirant à titre de vérification, l'élasticité passe de 1,637 à 1,634 : le choix ne change pas le résultat.

Aucun zéro dans le fichier, donc NA = 0

La plus petite valeur de n_app est 1 et aucune ligne du fichier ne vaut 0 : une cellule vide signifie zéro vente. Je remplace par 0 pour ne pas exclure les communes sans appartement.

Zéro comme hypothèse, vérifiée par sensibilité

Le plus petit compte publié vaut 1 et des comptes de 1 ou 2 sont fréquents : la confidentialité n'explique pas ces absences. Je pose zéro comme hypothèse de travail et vérifie que retirer ces 25 communes ne change pas l'élasticité (1,6335 contre 1,6367).

(b) Interpréter les deux nouveaux coefficients

ÉNONCÉ (B)

Ajoutez au modèle avec indicatrices de région le logarithme de la population et la part des appartements dans les ventes de logements, `part_app` = `n_app` / (`n_app` + `n_ventes`). Interprétez les coefficients de ces deux variables.

RÉPONSE

ln(pop) : 0,018, non significatif (p = 0,13). C'est une élasticité : une commune 10 % plus peuplée a des prix supérieurs de 0,18 % seulement. **part_app : 0,379**, significatif (t = 5,0). C'est une semi-élasticité : une part d'appartements plus élevée de 10 points va de pair avec des maisons environ **3,9 % plus chères**, toutes choses égales par ailleurs.

EXPLICATION

Applique la règle de la question 1.6. La variable dépendante est ln(prix), donc tout se lit en pourcentage.

ln(pop). Le régresseur est aussi en log : c'est une élasticité. +1 % de population ↔ +0,018 % de prix. L'effet est minuscule et on ne peut pas le distinguer de zéro.

part_app. Le régresseur est en niveau : une semi-élasticité. Attention à l'unité : `part_app` est une proportion **entre 0 et 1**. « Une unité de plus » voudrait dire passer de 0 % à 100 % d'appartements, ce qui n'a pas de sens. On raisonne sur 10 points de pourcentage, soit **0,10** :

- approximation : 100 × 0,379 × 0,10 = 3,8 % ;
- valeur exacte : 100 × (exp(0,379 × 0,10) − 1) = 3,9 %.

Lecture économique : les communes denses, où le terrain est rare, ont à la fois plus d'appartements et des maisons plus chères.

Pour situer : la part d'appartements vaut en moyenne 0,18 (0,20 en Flandre, 0,12 en Wallonie, 0,80 à Bruxelles).

RÉSULTATS

	Coefficient	Erreur-type HC1	p-valeur
Constante	−4,155	0,803	< 0,001
ln(rev_hab)	1,637	0,074	< 0,001
Wallonie	−0,161	0,018	< 0,001
Bruxelles	0,655	0,064	< 0,001
ln(pop)	0,0176	0,0117	0,131
part_app	0,379	0,076	< 0,001

R^2 = 0,785 ; 551 communes.

CODE R

```r
reg_1_15 <- lm(lprix ~ lrev + region + lpop + part_app, data = base)
rob(reg_1_15)
100 * (exp(0.10 * coef(reg_1_15)["part_app"]) - 1)    # +3,9 % pour 10 points de plus
```

QUESTIONS PROBABLES À L'ORAL

Pourquoi remplacer les valeurs manquantes de n_app par 0 ?

Parce que le fichier ne contient aucun zéro et que la plus petite valeur publiée est 1 : Statbel n'écrit pas les lignes sans vente. Une cellule vide veut donc dire zéro vente d'appartement. Supprimer ces communes aurait écarté celles où la part d'appartements est nulle.

1.16 Un contrôle problématique

ÉNONCÉ

L'un de ces deux contrôles vous paraît-il problématique ? Raisonnez sur le sens de la causalité entre cette variable et le prix des maisons, et sur ce que son inclusion change à l'interprétation de l'élasticité et des indicatrices de région.

RÉPONSE

Oui : la part d'appartements. Elle est en partie une **conséquence** du prix des maisons : là où les maisons et le terrain sont chers, on construit et on achète des appartements. C'est une causalité inverse, qui fait d'elle un mauvais contrôle. L'inclure change le sens des autres coefficients : l'écart bruxellois passe de +145 % à +93 %, parce qu'une partie de la « prime bruxelloise » est attribuée à la part d'appartements.

EXPLICATION

Un bon contrôle est une variable qui influence le prix **sans en dépendre**. Demande-toi dans quel sens va la flèche.

Le sens de la causalité. Des maisons chères → construire des appartements devient rentable, et les ménages qui ne peuvent pas s'offrir une maison achètent un appartement → la part d'appartements monte. Le prix **cause** la part d'appartements. On met donc à droite de l'équation une variable qui dépend de ce qu'on a mis à gauche.

Ce que cela change à l'interprétation.

- **L'élasticité** compare désormais des communes qui ont **la même part d'appartements**. Si le revenu agit sur les prix en partie par la densification, on a retiré ce canal. Le chiffre bouge peu ici (de 1,608 à 1,637), mais il ne répond plus à la même question.
- **Les indicatrices de région** changent nettement.

Écart à la Flandre, à revenu égal	Sans contrôle (1.9)	Avec les contrôles (1.15)
Wallonie	−18,5 %	−14,8 %
Bruxelles	+144,7 %	+92,6 %

À Bruxelles, 80 % des ventes sont des appartements. Le modèle 1.15 compare Bruxelles à une Flandre fictive « à part d'appartements égale », une commune flamande qui n'existe pas. Or cette part élevée est elle-même le produit de la rareté du terrain, donc des prix élevés : on a « expliqué » le prix par l'une de ses conséquences.

Et la population ? Elle pose moins de problème : elle tient surtout à l'histoire et à la taille de la commune. Des prix élevés peuvent la freiner à long terme, mais son coefficient est de toute façon négligeable.

LA RÈGLE GÉNÉRALE

On ne contrôle pas une variable qui est une conséquence de la variable dépendante ou du régresseur d'intérêt. Cette règle reviendra à la question 3.7 (f).

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Mauvais contrôle, avec les écarts chiffrés

La part d'appartements est problématique : elle est en partie une conséquence du prix des maisons, car un terrain cher rend la construction d'appartements rentable et pousse les ménages vers eux. L'inclure fait comparer des communes à part d'appartements égale. L'élasticité bouge peu (1,61 à 1,64), mais l'écart bruxellois tombe de +145 % à +93 % : une partie de la prime bruxelloise est attribuée à une variable qui en est elle-même le résultat. La population pose moins de problème et son coefficient est négligeable.

Variable potentiellement endogène

La part d'appartements peut être une conséquence des prix (terrain cher) autant qu'une cause : elle est potentiellement endogène. La fixer retire une voie par laquelle revenu et région se manifestent. Les écarts régionaux passent de −18,5 % à −14,8 % et de +144,7 % à +92,6 %, sans qu'on puisse attribuer ce changement aux seuls appartements.

QUESTIONS PROBABLES À L'ORAL

Pourquoi l'écart entre Bruxelles et la Flandre diminue-t-il quand tu ajoutes part_app ?

Parce qu'une partie de la prime bruxelloise est attribuée à la part d'appartements, qui atteint 80 % à Bruxelles. Mais cette part est elle-même une conséquence de la rareté du terrain et des prix élevés : on compare Bruxelles à une Flandre fictive qui aurait autant d'appartements.

1.17 L'élasticité dans les quatre spécifications

ÉNONCÉ

Représentez dans un seul graphique l'élasticité estimée et son intervalle de confiance à 95 % dans les spécifications des questions 1.6, 1.9, 1.13 (Flandre) et 1.15. Commentez.

RÉPONSE

Les quatre estimations vont de **1,44 à 1,64**, et toutes les bornes inférieures dépassent 1 : le résultat « entre communes, le prix augmente plus que proportionnellement au revenu » est **robuste** au choix de la spécification. Ajouter les régions augmente l'élasticité et divise son erreur-type par deux.

EXPLICATION

L'élasticité dans les quatre spécifications

Chaque ligne : l'estimation (point) et son intervalle de confiance à 95 % (± 1,96 erreur-type HC1). Le trait vertical marque une élasticité de 1 (prix proportionnel au revenu).

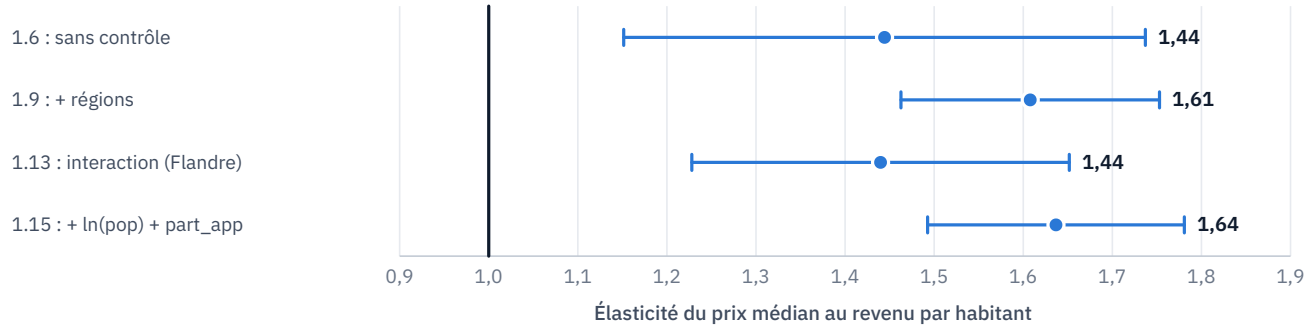
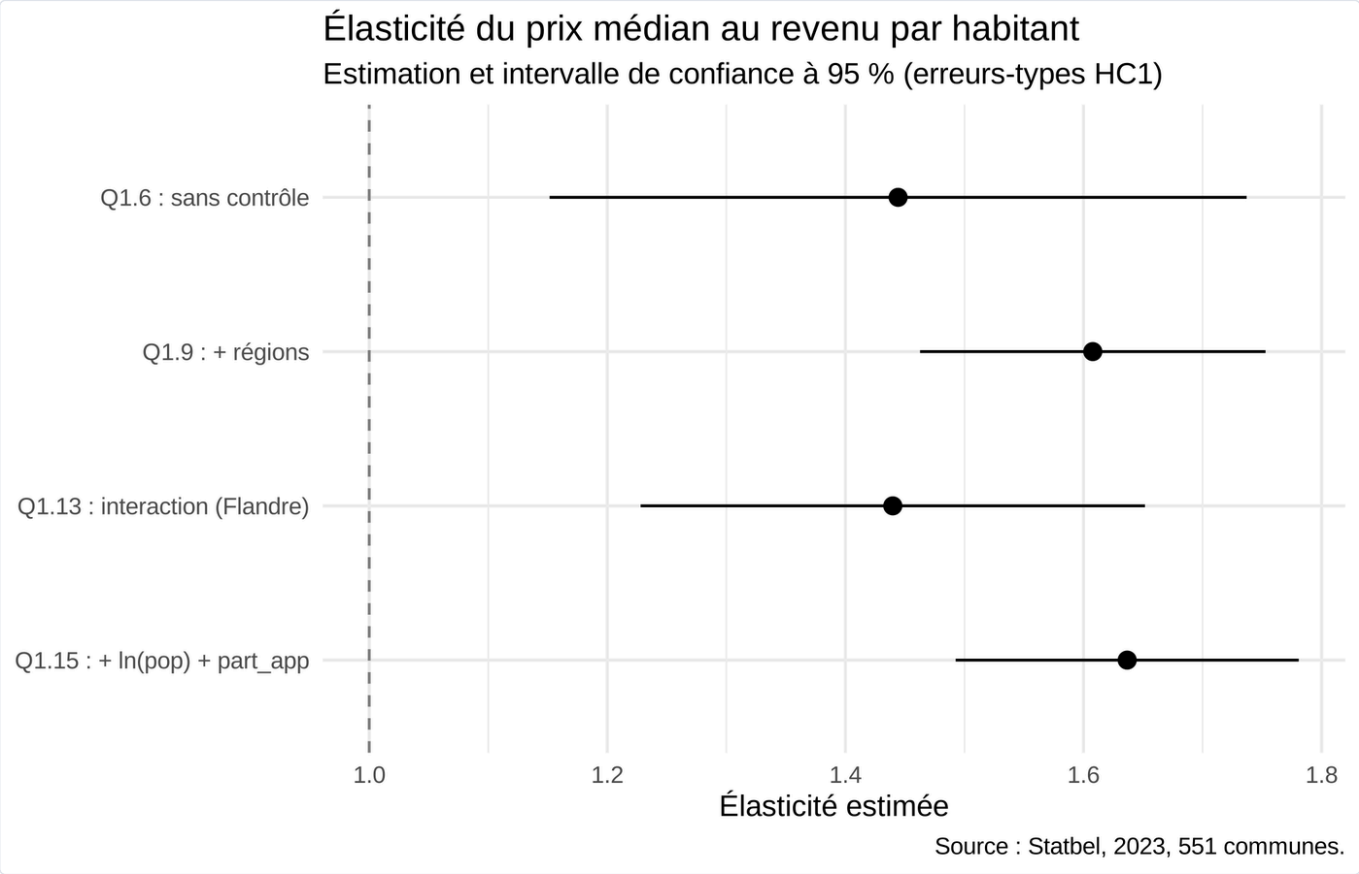


Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Ce qu'il faut commenter, dans l'ordre.

- **Stabilité.** Toutes les estimations sont entre 1,44 et 1,64, et aucun intervalle ne contient 1.
- **De 1.6 à 1.9.** L'élasticité monte (biais de variable omise, question 1.12) et l'intervalle se resserre nettement : les régions absorbent une grande part de la variance des résidus.
- **1.13 (Flandre).** Plus basse (1,44) que l'élasticité commune de 1.9 (1,61), qui fait une moyenne entre la Flandre et la Wallonie, plus pentue.

- **1.15.** Ajouter ln(pop) et part_app change peu l'élasticité, parce que ces variables sont peu corrélées au revenu.
- **La limite.** La stabilité entre spécifications ne prouve pas la causalité (question 1.18).



Élasticité estimée et intervalle de confiance à 95 % dans les quatre spécifications. Fichier : fig_1_17.png.

RÉSULTATS

Spécification	Élasticité	Erreur-type HC1	IC à 95 %
1.6 : sans contrôle	1,444	0,149	[1,15 ; 1,74]
1.9 : + régions	1,608	0,074	[1,46 ; 1,75]
1.13 : interaction, Flandre	1,440	0,108	[1,23 ; 1,65]
1.15 : + ln(pop) + part_app	1,637	0,074	[1,49 ; 1,78]

CODE R

```
ligne_elast <- function(m, nom) {
  ct <- rob(m)
  data.frame(specification = nom, elasticite = ct["lrev", 1], se = ct["lrev", 2])
}
tab_1_17 <- bind_rows(ligne_elast(reg_1_6_ll, "1.6 : sans contrôle"),
                      ligne_elast(reg_1_9,    "1.9 : + régions"),
                      ligne_elast(reg_1_13,   "1.13 : interaction (Flandre)"),
                      ligne_elast(reg_1_15,   "1.15 : + ln(pop) + part_app")) %>%
  mutate(ic_bas = elasticite - 1.96 * se, ic_haut = elasticite + 1.96 * se)

ggplot(tab_1_17, aes(x = elasticite, y = specification)) +
  geom_vline(xintercept = 1, linetype = "dashed") +
  geom_pointrange(aes(xmin = ic_bas, xmax = ic_haut))
```

`ct["lrev", 1]` lit, dans le tableau renvoyé par `rob()`, la ligne `lrev` et la première colonne (le coefficient) ; la colonne 2 est l'erreur-type. `geom_pointrange()` trace un point et son intervalle.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Repère à 1 : plus que proportionnel

Les quatre élasticités vont de 1,44 à 1,64 et tous les intervalles sont au-dessus de 1 : le prix augmente plus que proportionnellement au revenu, quelle que soit la spécification. Les régions augmentent l'élasticité (biais de variable omise) et divisent son erreur-type par deux. L'élasticité flamande est plus basse que l'élasticité commune, tirée vers le haut par la Wallonie. Cette stabilité ne prouve pas un effet causal.

Repère à 0 : relation positive et significative

Toutes les estimations sont positives et leurs intervalles excluent zéro, de 1,440 à 1,637. Les régions resserrent nettement l'intervalle. Le chevauchement d'intervalles de modèles estimés sur les mêmes données n'est pas un test d'égalité.

QUESTIONS PROBABLES À L'ORAL

Que montre ce graphique, et que ne montre-t-il pas ?
Il montre que l'élasticité est stable, entre 1,44 et 1,64, et toujours supérieure à 1 : le résultat ne dépend pas de la spécification. Il ne montre pas que cette élasticité est un effet causal : des variables omises peuvent biaiser les quatre estimations de la même façon.

1.18 Une hausse du revenu fait-elle monter les prix ?

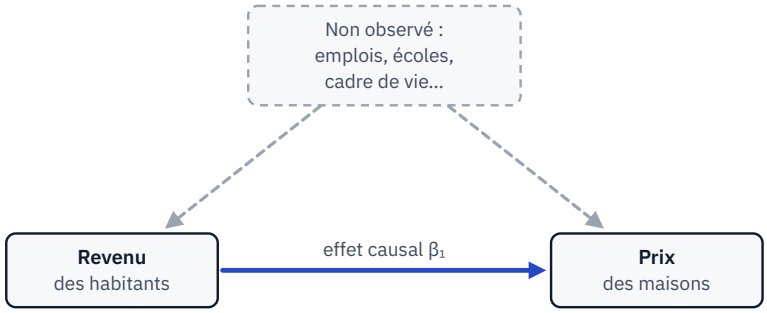
ÉNONCÉ

Peut-on conclure de vos résultats qu'une hausse du revenu des habitant·es fait monter le prix des maisons d'une commune ?

C'est la question qui donne son sens à toute la partie. La réponse courte est **non** : on a mesuré une association entre communes, pas l'effet d'une hausse de revenu. Les quatre sous-questions te font construire cette réponse proprement.

Qui cause quoi ? Le schéma à avoir en tête

Chaque flèche se lit « agit sur ». Change de schéma pour voir ce que chaque hypothèse autorise ou interdit.



On veut la flèche **X → Y**. Mais un facteur non observé U agit à la fois sur X et sur Y : comparer les valeurs de Y selon X mélange l'effet de X et celui de U. C'est un **facteur de confusion** ; l'estimateur des MCO est biaisé.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) L'hypothèse nécessaire

ÉNONCÉ (A)

Énoncez l'hypothèse qui serait nécessaire pour interpréter l'élasticité de la question 1.9 comme un effet causal.

RÉPONSE

L'**exogénéité** du revenu, à région donnée : $E(u \mid \ln(\text{rev_hab}), \text{région}) = 0$. En mots : à l'intérieur d'une région, tout ce qui détermine le prix des maisons en dehors du revenu est sans lien avec le revenu des habitants. Ni variable omise corrélée au revenu, ni causalité inverse.

EXPLICATION

Le terme d'erreur u contient toutes les autres causes du prix : la localisation, la qualité des logements, les écoles, les transports. L'hypothèse dit que, parmi les communes d'une même région, celles qui ont un revenu élevé ne sont **en moyenne ni mieux ni moins bien loties** sur tous ces autres points.

Dis-le ainsi à l'oral : « il faudrait que le revenu des communes soit distribué comme s'il avait été tiré au sort à l'intérieur de chaque région ». Posé comme cela, on voit tout de suite que ce n'est pas crédible.

(b) Deux mécanismes qui la mettent en défaut

ÉNONCÉ (B)

Décrivez deux mécanismes concrets qui mettent cette hypothèse en défaut, et le sens du biais qui en résulterait.

RÉPONSE

1. **Les atouts locaux omis** (proximité des emplois, cadre vert, bonnes écoles, gare) font monter les prix **et** attirent les ménages aisés : biais **vers le haut**.
2. **Le tri des ménages (causalité inverse)** : des maisons chères empêchent les ménages modestes de s'installer, donc le revenu est en partie une conséquence du prix : biais **vers le haut** aussi.

EXPLICATION

Utilise la règle du signe : **biais = (effet sur le prix) × (lien avec le revenu)**.

Mécanisme 1 : une variable omise. Une commune proche de Bruxelles, verte, bien desservie.

- Effet sur le prix : **positif** (les gens paient pour y vivre).
- Lien avec le revenu : **positif** (ce sont les ménages aisés qui s'y installent).
- (+) × (+) : le coefficient du revenu absorbe l'effet de ces atouts. L'élasticité **surestime** l'effet du revenu. Exemples : Sint-Martens-Latem, Kraainem, Lasne.

Mécanisme 2 : la causalité inverse. Le prix des maisons détermine **qui peut s'installer**. Une commune chère filtre les ménages modestes ; son revenu par habitant est élevé *parce que* ses maisons sont chères. La flèche va du prix vers le revenu. Là encore l'association est plus forte que l'effet causal : biais vers le haut.

Un troisième mécanisme, de sens contraire. `rev_hab` mesure mal le revenu des ménages (question 1.2). Une erreur de mesure sur le régresseur tire le coefficient **vers zéro** : c'est le biais d'atténuation. Les biais ne vont donc pas tous dans le même sens, et on ne peut pas dire de combien l'élasticité s'écarte du vrai effet.

RÉDACTION POSSIBLE POUR LE RAPPORT

Atouts locaux et tri des ménages, avec la règle du signe

Premier mécanisme : des atouts locaux non observés (proximité des emplois, cadre de vie, écoles) augmentent les prix et attirent les ménages aisés ; le revenu est alors corrélé positivement au terme d'erreur et l'élasticité surestime l'effet du revenu. Second mécanisme : la causalité inverse par le tri des ménages ; une commune chère n'est accessible qu'aux ménages aisés, donc le revenu des habitants est en partie une conséquence du prix. Biais vers le haut également.

(c) La conclusion en trois phrases

ÉNONCÉ (C)

Formulez en trois phrases au plus la conclusion que vos résultats permettent réellement de tirer.

RÉPONSE

En 2023, à région donnée, les communes belges dont le revenu par habitant est supérieur de 1 % ont des maisons vendues environ 1,6 % plus cher, et cette relation résiste aux changements de spécification. À revenu égal, les maisons sont environ 18 % moins chères en Wallonie et 2,4 fois plus chères à Bruxelles qu'en Flandre. Cette élasticité décrit une association entre communes, pas l'effet d'une hausse de revenu, car le revenu des habitants et le prix des maisons dépendent tous deux de la localisation et s'influencent mutuellement.

EXPLICATION

Une bonne conclusion en trois phrases suit toujours le même plan :

1. **le résultat principal, chiffré**, avec l'unité et le périmètre (où, quand, qui) ;
2. **le résultat secondaire** qui le nuance ou le complète ;
3. **la limite** : ce qu'on n'a pas le droit de dire.

Écris-la avec tes propres chiffres arrondis et tes propres mots : c'est le passage que le correcteur lira le plus attentivement.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Conclusion chiffrée

En 2023, à région donnée, les communes belges dont le revenu par habitant est supérieur de 1 % ont des maisons vendues en moyenne 1,4 à 1,6 % plus cher, une relation forte et robuste. À revenu égal, les maisons sont environ 18 % moins chères en Wallonie et 2,4 fois plus chères à Bruxelles qu'en Flandre. Cette élasticité décrit une association entre communes, pas l'effet d'une hausse de revenu : revenu et prix dépendent tous deux de la localisation et s'influencent mutuellement.

Conclusion qualitative

En 2023, les communes à revenu fiscal plus élevé ont généralement des prix médians de maisons plus élevés, y compris au sein des régions. L'intensité de cette association varie selon la région. Ces données en coupe ne permettent pas d'attribuer la différence de prix à une hausse exogène du revenu.

(d) Quelle variation faudrait-il observer ?

ÉNONCÉ (D)

Quel type de variation des revenus faudrait-il observer pour estimer un effet causal ?

RÉPONSE

Une variation du revenu **sans lien avec l'attractivité de la commune** : idéalement des changements de revenu **au cours du temps dans les mêmes communes**, provoqués par une cause extérieure qui n'agit sur les prix **que par le revenu**.

EXPLICATION

Il faut une source de variation qui casse les deux mécanismes de la question (b).

- **Suivre les mêmes communes dans le temps** (un panel avec effets fixes de commune) élimine tout ce qui est fixe : la localisation, le cadre de vie.
- **Un choc extérieur** élimine la causalité inverse : le revenu change pour une raison qui ne vient pas du marché immobilier local.

Des exemples concrets :

- l'évolution des salaires au Grand-Duché de Luxembourg, qui fait varier le revenu des communes belges selon leur part de travailleurs frontaliers ;
- une réforme fiscale qui modifie le revenu net plus fortement dans certaines communes, pour des raisons étrangères au logement ;

- l'évolution nationale des salaires par secteur, appliquée à la structure d'emploi initiale de chaque commune.

On comparerait alors l'évolution des prix dans les communes touchées et dans des communes semblables non touchées : par **double différence** ou par **variables instrumentales**. Ce sont exactement les outils des parties 2 et 3.

À RETENIR

- L'élasticité de 1,6 est une association entre communes, robuste aux spécifications.
- Pour un effet causal, il faudrait E(u | revenu, région) = 0.
- Deux mécanismes la violent, avec un biais vers le haut : atouts locaux omis et tri des ménages.
- Il faudrait une variation du revenu extérieure au marché du logement : c'est le rôle des outils des parties 2 et 3.

QUESTIONS PROBABLES À L'ORAL

Peux-tu dire qu'une hausse de revenu fait monter les prix ?

Non. J'ai comparé des communes différentes, la même année. Les communes riches sont aussi mieux situées, et des maisons chères sélectionnent des habitants aisés. Mon élasticité est une association ; pour un effet causal, il faudrait une variation du revenu sans lien avec l'attractivité de la commune.

Quelle hypothèse faudrait-il pour que ce soit causal ?

L'exogénéité du revenu à région donnée : que tout ce qui détermine le prix en dehors du revenu soit sans lien avec le revenu. Ce n'est pas crédible ici.

PARTIE 2

Enfants et travail des mères

Variables instrumentales

Les mères de trois enfants travaillent moins que les mères de deux enfants. Est-ce le troisième enfant qui les fait moins travailler, ou sont-ce d'autres femmes ?

Le problème

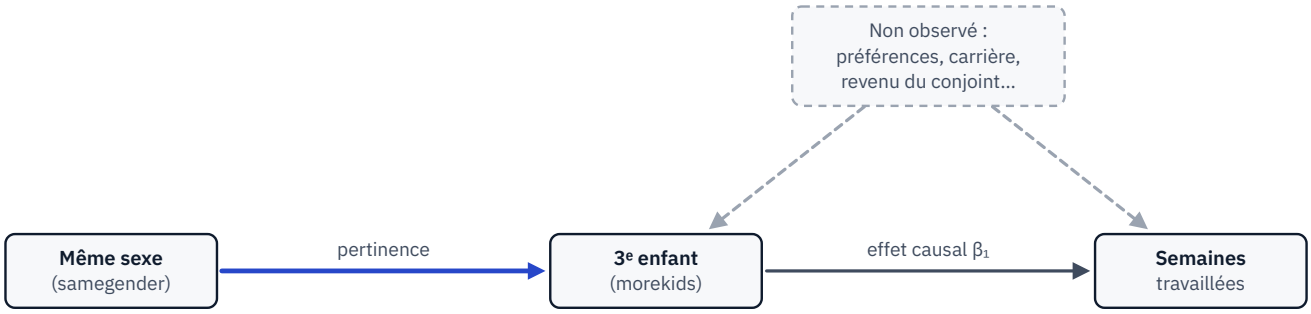
Les mères de plus de deux enfants ont travaillé 5,4 semaines de moins en 1979 que les mères de deux enfants. Mais avoir un troisième enfant est un **choix**. Les femmes qui le font peuvent être aussi celles qui, de toute façon, auraient moins travaillé : parce qu'elles tiennent moins à leur carrière, ou que leur conjoint gagne bien sa vie. Comparer les deux groupes mélange l'effet de l'enfant et ces différences entre femmes.

L'idée d'Angrist et Evans (1998)

Beaucoup de parents souhaitent un garçon **et** une fille. Ceux dont les deux premiers enfants sont de même sexe ont donc plus souvent un troisième enfant. Or le sexe d'un enfant est dû au hasard. On tient là une variable qui fait varier le nombre d'enfants **sans être un choix** : un instrument.

Qui cause quoi ? Le schéma à avoir en tête

Chaque flèche se lit « agit sur ». Change de schéma pour voir ce que chaque hypothèse autorise ou interdit.



L'instrument Z fait varier X (**pertinence**) sans être lié à U (**indépendance**) et sans agir sur Y autrement que par X (**exclusion**). La part de X provoquée par Z est donc « propre » : on n'utilise qu'elle.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Les données

`Fertility.RData` : 254 654 femmes mariées de 21 à 35 ans, mères d'au moins deux enfants, au recensement américain de 1980.

Variable	Ce qu'elle mesure
`work`	semaines travaillées par la mère en 1979 (0 à 52)
`morekids`	la mère a plus de deux enfants (yes / no)
`gender1`, `gender2`	sexe du premier et du deuxième enfant
`age`	âge de la mère au recensement
`afam`, `hispanic`, `other`	origine de la mère (yes / no)

Le chemin

Étape	Questions	L'idée à retenir
A. Le problème	2.1, 2.2	Les MCO comparent deux groupes qui ne sont pas comparables.
B. L'instrument	2.3 à 2.6	Conditions de validité, première étape, forme réduite, et la division qui donne l'effet.
C. Contrôles et 2SLS	2.7 à 2.9	Ce que font les contrôles, et deux instruments au lieu d'un.
D. Tester	2.10 à 2.12	Les instruments sont-ils cohérents ? Fallait-il vraiment instrumenter ?
E. Conclure	2.13, 2.14	Arrêt du travail ou réduction, et pour quelles mères l'effet vaut.

Le résultat en une phrase

Un troisième enfant réduit le travail de la mère d'environ **5,5 semaines par an** (intervalle de confiance : 3 à 8 semaines), surtout parce que certaines mères cessent complètement de travailler. Ce chiffre vaut pour les mères qui ont eu ce troisième enfant *à cause* du sexe des deux premiers.

L'effet d'un troisième enfant selon la méthode

Effet estimé de `morekids` sur les semaines travaillées, avec intervalle de confiance à 95 %. Les MCO sont très précis (intervalle minuscule) ; les variables instrumentales le sont beaucoup moins.

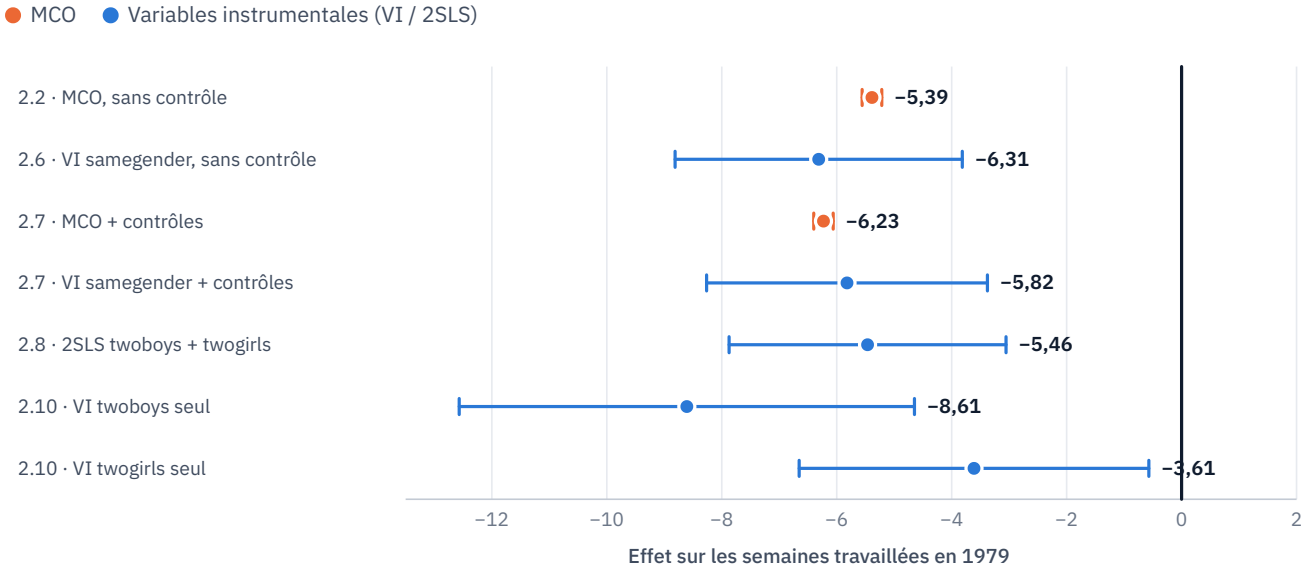


Figure tirée de l'outil interactif de l'atelier, dans son état initial.

2.1 Décrire l'échantillon

ÉNONCÉ

Décrivez l'échantillon : unité statistique, nombre d'observations et au plus quatre statistiques descriptives utiles pour la suite, dont vous justifierez le choix. Représentez la distribution de `work` et commentez-la.

RÉPONSE

Unité statistique : une femme mariée de 21 à 35 ans, mère d'au moins deux enfants, au recensement américain de 1980. **254 654 observations.** Quatre statistiques : 19,0 semaines travaillées en moyenne, 47,2 % des mères n'ont pas travaillé du tout, 38,1 % ont plus de deux enfants, 50,6 % ont deux premiers enfants de même sexe. La distribution de `work` a **deux pics**, à 0 et à 52 semaines.

EXPLICATION

Avant tout : transformer les facteurs. Dans le fichier, `morekids`, `afam`, `hispanic` et `other` valent `"yes"` ou `"no"`. Une régression a besoin de nombres : on les recode en 1 et 0.

Quatre statistiques, chacune choisie pour une raison. L'énoncé demande de **justifier** le choix : chaque chiffre doit servir à quelque chose plus loin.

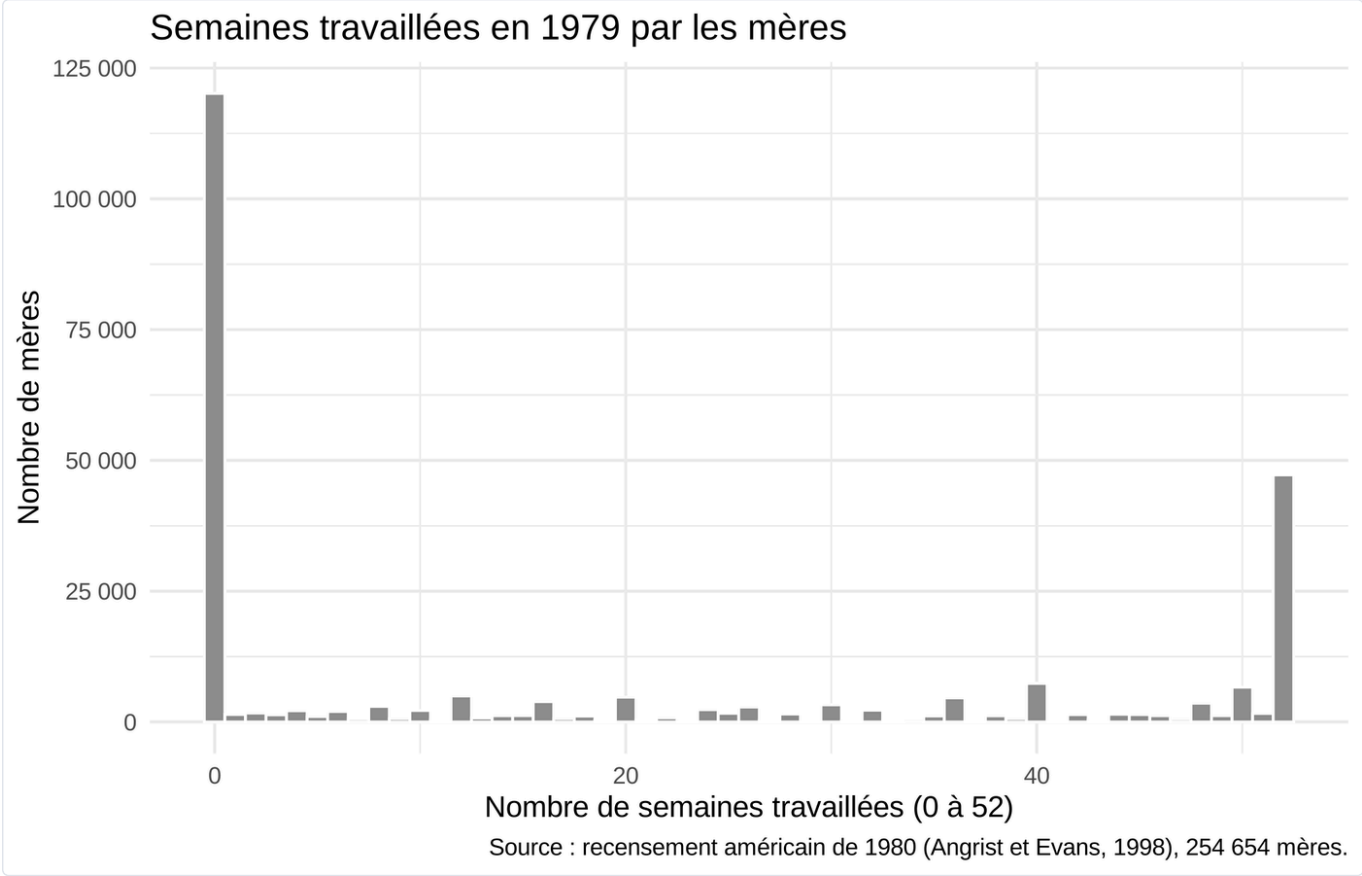
Statistique	Valeur	À quoi elle sert dans la suite
Semaines travaillées, moyenne	19,0	L'échelle pour juger les effets : −5 semaines, c'est plus d'un quart de la moyenne.
Mères sans aucune semaine travaillée	47,2 %	Près d'une mère sur deux est à zéro : l'effet peut passer par l'arrêt complet du travail (question 2.13).
Mères de plus de deux enfants	38,1 %	La taille des deux groupes comparés : 96 912 et 157 742 mères.
Deux premiers enfants de même sexe	50,6 %	L'instrument est réparti moitié-moitié, comme on l'attend si le sexe est dû au hasard.

La distribution de `work`. Elle ne ressemble pas du tout à une cloche. Un pic à **0** (47,2 % des mères), un second à **52** (18,5 %, l'année entière), et entre les deux des valeurs éparpillées avec de petits pics aux chiffres ronds (40, 48, 50). La moyenne (19,0) est très éloignée de la médiane (5).

Ce que cela implique : une régression sur `work` mélange deux décisions différentes, **travailler ou non** (la marge extensive) et **combien de semaines** (la marge intensive). La question 2.13 les séparera.

⚠ LE PIÈGE DE `as.numeric()` SUR UN FACTEUR

`as.numeric(morekids)` appliqué directement au facteur renvoie ses codes internes, **1 et 2**, pas 0 et 1. Il faut écrire `as.numeric(morekids == "yes")` : la comparaison donne vrai ou faux, que `as.numeric()` transforme en 1 ou 0.



Semaines travaillées en 1979 par les 254 654 mères. Source : recensement américain de 1980 (Angrist et Evans, 1998). Fichier : fig_2_1.png.

CODE R

```r
load(file.path(dossier, "Fertility.RData"))      # crée le data frame Fertility

fert <- Fertility %>%
  mutate(morekids   = as.numeric(morekids == "yes"),       # facteur yes/no -> 1/0
         afam       = as.numeric(afam == "yes"),
         hispanic   = as.numeric(hispanic == "yes"),
         other      = as.numeric(other == "yes"),
         boy1st     = as.numeric(gender1 == "male"),
         samegender = as.numeric(gender1 == gender2),
         twoboys    = as.numeric(gender1 == "male"   & gender2 == "male"),
         twogirls   = as.numeric(gender1 == "female" & gender2 == "female"),
         travaille  = as.numeric(work > 0))

nrow(fert)                # 254 654
mean(fert$work)           # 19,0
mean(fert$work == 0)      # 0,472
mean(fert$morekids)       # 0,381
mean(fert$samegender)     # 0,506

ggplot(fert, aes(x = work)) +
  geom_histogram(binwidth = 1, boundary = -0.5, fill = "grey55", colour = "white")
```

- `load()` charge un fichier `.RData` et recrée les objets qu'il contient.
- La moyenne d'une variable 0/1 est une **proportion** : `mean(fert$morekids)` donne la part des mères de plus de deux enfants.
- `&` veut dire « et ». On crée dès maintenant toutes les variables des questions suivantes.
- `binwidth = 1` : une barre par nombre de semaines.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Moyenne, zéros, morekids, samegender

L'unité est une femme mariée de 21 à 35 ans, mère d'au moins deux enfants, au recensement américain de 1980 ; l'échantillon en compte 254 654. Je retiens : la moyenne de work (19,0 semaines), qui donne l'échelle des effets ; la part des mères à zéro (47,2 %), qui annonce le rôle de l'arrêt complet du travail ; la part de morekids (38,1 %), qui donne la taille des groupes comparés ; et la part de samegender (50,6 %), conforme à un sexe dû au hasard. La distribution de work a deux pics, à 0 et à 52 semaines.

Moyenne, morekids, participation, année complète

Je retiens la part de mères de plus de deux enfants (38,1 %), la moyenne des semaines travaillées (19,0), la part ayant travaillé au moins une semaine (52,8 %) et la part ayant travaillé toute l'année (18,5 %). Les deux dernières décrivent les deux pics de la distribution.

QUESTIONS PROBABLES À L'ORAL

Pourquoi la moyenne de work décrit-elle mal la mère « typique » ?

Parce que la distribution a deux pics : près de la moitié des mères sont à 0 semaine, près d'une sur cinq à 52. Très peu de mères travaillent 19 semaines. La médiane n'est que de 5.

2.2 La régression par les MCO et son biais

ÉNONCÉ

Estimez par les MCO le modèle $\text{work}_i = \beta_0 + \beta_1 \, \text{morekids}_i + u_i$.

C'est la comparaison la plus simple possible : les mères de plus de deux enfants contre les mères de deux enfants. La question te fait dire, pas à pas, pourquoi elle ne mesure pas un effet.

(a) Interpréter le coefficient

ÉNONCÉ (A)

Que vous apprend le coefficient estimé de `morekids` ? Interprétez-le.

RÉPONSE

−5,39 (erreur-type 0,087). Les mères de plus de deux enfants ont travaillé en moyenne **5,4 semaines de moins** en 1979 que les mères de deux enfants : 15,7 semaines contre 21,1, soit 26 % de moins.

EXPLICATION

Avec un seul régresseur qui vaut 0 ou 1, la régression ne fait que **comparer deux moyennes**.

Coefficient	Ce qu'il est	Valeur
Constante β_0	moyenne de `work` quand `morekids` = 0 (mères de deux enfants)	21,07
Pente β_1	écart entre les deux moyennes	−5,39
$\beta_0 + \beta_1$	moyenne de `work` quand `morekids` = 1	15,68

L'estimation est extrêmement précise (t = −62) : avec 254 654 observations, presque tout est estimé avec précision. **Précis ne veut pas dire juste** : c'est tout l'enjeu des questions suivantes.

RÉSULTATS

	Coefficient	Erreur-type HC1	t
Constante	21,068	0,056	375,8
morekids	−5,387	0,087	−61,8

CODE R

```
reg_2_2 <- lm(work ~ morekids, data = fert)
rob(reg_2_2)

fert %>% group_by(morekids) %>% summarise(work_moyen = mean(work), n = n())
#  morekids  work_moyen       n
#         0        21,1  157742
#         1        15,7   96912
```

La seconde commande vérifie que la pente est bien la différence des deux moyennes : 15,68 − 21,07 = −5,39.

(b) Est-ce l'effet d'un troisième enfant ?

ÉNONCÉ (B)

Peut-on y voir l'effet d'un troisième enfant sur le travail de la mère ?

RÉPONSE

Non. On compare des femmes qui ont **choisi** d'avoir un troisième enfant à des femmes qui ne l'ont pas fait. Ces deux groupes diffèrent par bien d'autres choses que le nombre d'enfants, et ces différences jouent aussi sur le travail.

EXPLICATION

Pour que −5,39 soit un effet causal, il faudrait que les deux groupes soient identiques en tout, sauf le troisième enfant. Formellement : $E(u \mid \text{morekids}) = 0$, c'est-à-dire que tout ce qui influence le travail en dehors du nombre d'enfants soit réparti de la même façon dans les deux groupes.

Rien ne le garantit. Personne n'a tiré au sort qui aurait un troisième enfant.

(c) Dans quelle direction ?

ÉNONCÉ (C)

Si non, dans quelle direction l'estimation risque-t-elle de s'écarter de l'effet réel, et pourquoi ? Appuyez votre raisonnement sur une variable précise contenue dans le terme d'erreur.

RÉPONSE

Prenons le **niveau d'études** de la mère. Les femmes plus diplômées travaillent davantage (effet positif sur `work`) et ont moins souvent un troisième enfant (lien négatif avec `morekids`). Le biais est (+) × (−) = **négatif** : le coefficient des MCO serait **trop négatif**, il exagérerait la baisse du travail due à un enfant.

EXPLICATION

La question impose une méthode : nommer **une** variable du terme d'erreur, puis appliquer la règle du signe.

$$\text{biais} = (\text{effet de la variable omise sur work}) \times (\text{son lien avec morekids})$$

Variable omise	Effet sur `work`	Lien avec `morekids`	Biais
Niveau d'études	+ (les diplômées travaillent plus)	− (elles ont moins souvent un 3e enfant)	**négatif**
Attachement à la carrière	+	−	**négatif**
Revenu du conjoint	− (moins besoin d'un second salaire)	+ (un enfant de plus est plus abordable)	**négatif**

Dans les trois cas, les MCO attribuent au troisième enfant une baisse du travail qui vient en réalité du type de femmes qui ont trois enfants. Le vrai effet serait **moins négatif** que −5,39.

LA NUANCE QUI TE SERVIRA AUX QUESTIONS 2.6 ET 2.7

D'autres variables omises jouent en sens **inverse**. L'âge, par exemple : les mères plus âgées ont plus souvent trois enfants (lien +) et travaillent davantage, leurs enfants étant plus grands (effet +). Biais positif. Le sens du biais **total** n'est donc pas garanti, et tu verras que le résultat de la question 2.6 surprend.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Le niveau d'études

Prenons le niveau d'études de la mère, contenu dans le terme d'erreur. Les femmes plus diplômées travaillent davantage (effet positif sur work) et ont moins souvent un troisième enfant (lien négatif avec morekids). Le biais est donc négatif : les MCO exagèrent la baisse du travail due à un troisième enfant. D'autres variables omises, comme l'âge, jouent en sens inverse ; le sens du biais total n'est pas certain.

La préférence pour la carrière

Supposons qu'une forte préférence pour la carrière augmente les semaines travaillées et diminue la probabilité d'un enfant supplémentaire. Cette variable omise est liée positivement à work et négativement à morekids : la pente est tirée vers le bas, donc potentiellement trop négative. D'autres déterminants peuvent agir en sens opposé.

(d) Le nom du mécanisme

ÉNONCÉ (D)

D'un point de vue théorique, comment nomme-t-on le mécanisme qui engendre un tel écart par rapport à l'effet réel ? Quelle est sa source ici ?

RÉPONSE

C'est un **biais d'endogénéité** : le régresseur `morekids` est corrélé au terme d'erreur, ce qui viole l'hypothèse d'exogénéité $E(u \mid X) = 0$. Sa source, ici : un **biais de variable omise** (ou de sélection). La décision d'avoir un troisième enfant est prise en fonction de préférences et de contraintes non observées qui influencent aussi le travail.

EXPLICATION

Deux niveaux de réponse, que la question sépare.

- **Le mécanisme général** : l'endogénéité. Un régresseur est endogène quand il est corrélé au terme d'erreur ; l'estimateur des MCO est alors biaisé, quelle que soit la taille de l'échantillon.
- **Sa source ici** : des **variables omises**. Les femmes se « sélectionnent » elles-mêmes dans le groupe des familles nombreuses, selon des caractéristiques qu'on n'observe pas.

Une autre source est possible, la **causalité inverse** : une femme qui ne travaille pas pour d'autres raisons supporte un coût plus faible pour un enfant de plus. Le travail influencerait alors la fécondité, et non l'inverse.

Les trois sources classiques d'endogénéité, à connaître : variable omise, causalité inverse (ou simultanéité), erreur de mesure du régresseur.

QUESTIONS PROBABLES À L'ORAL

Pourquoi les MCO sont-ils biaisés ici ?

Parce qu'avoir un troisième enfant est un choix, lié à des facteurs non observés qui jouent aussi sur le travail, comme le niveau d'études ou le revenu du conjoint. morekids est corrélé au terme d'erreur : c'est un biais d'endogénéité, dont la source est une variable omise.

B. L'INSTRUMENT : LE SEXE DES DEUX PREMIERS ENFANTS

2.3 Un instrument valide ?

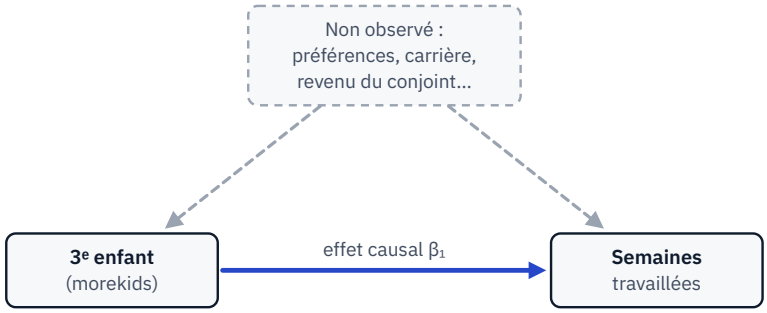
ÉNONCÉ

Construisez `samegender`, qui vaut 1 si les deux premiers enfants sont du même sexe, 0 sinon. On propose de l'utiliser comme instrument de `morekids`.

Un instrument est une variable qui fait varier le régresseur endogène « de l'extérieur ». Cette question pose les deux conditions qu'il doit remplir. Retiens surtout laquelle se vérifie dans les données et laquelle ne se vérifie pas.

Qui cause quoi ? Le schéma à avoir en tête

Chaque flèche se lit « agit sur ». Change de schéma pour voir ce que chaque hypothèse autorise ou interdit.



On veut la flèche **X → Y**. Mais un facteur non observé U agit à la fois sur X et sur Y : comparer les valeurs de Y selon X mélange l'effet de X et celui de U. C'est un **facteur de confusion** ; l'estimateur des MCO est biaisé.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Les conditions de validité

ÉNONCÉ (A)

Quelles conditions une variable doit-elle remplir pour être un instrument valide de `morekids` ? Énoncez-les formellement et en mots.

RÉPONSE

Condition	Formellement	En mots
Pertinence	$\text{Cov}(Z, \text{morekids}) \neq 0$	Le sexe des deux premiers enfants doit réellement modifier la probabilité d'un troisième enfant.
Exogénéité	$\text{Cov}(Z, u) = 0$	Il ne doit être lié à rien de ce qui, dans le terme d'erreur, détermine le travail de la mère.

EXPLICATION

Le modèle est $\text{work} = \beta_0 + \beta_1 \text{morekids} + u$ et l'instrument $Z =$ `samegender`.

La pertinence est la condition « facile » : elle porte sur deux variables observées, donc elle **se teste** (question 2.4).

L'exogénéité est la condition « difficile » : elle porte sur u, qu'on n'observe pas. Elle **ne se teste pas directement**. Elle regroupe deux idées, qu'il faut savoir séparer à l'oral.

- **L'indépendance** : Z est « comme tiré au sort », sans lien avec les caractéristiques des mères. C'est plausible : le sexe d'un enfant est dû au hasard.
- **La restriction d'exclusion** : Z n'agit sur le travail de la mère **que par le troisième enfant**, sans effet direct. C'est le point fragile.

Change de schéma dans l'outil en haut de la page pour voir ce que chaque violation ajouterait.

Une troisième hypothèse, la **monotonie**, servira à la question 2.14 : personne ne fait l'inverse (avoir un troisième enfant avec une fratrie mixte, mais pas avec deux enfants de même sexe).

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Pertinence et exogénéité

Un instrument Z doit remplir deux conditions. Pertinence, Cov(Z, morekids) ≠ 0 : le sexe des deux premiers enfants doit modifier la probabilité d'un troisième enfant. Exogénéité, Cov(Z, u) = 0 : il ne doit être lié à aucun déterminant non observé du travail de la mère. Cette seconde condition suppose que Z soit comme tiré au sort (indépendance) et qu'il n'agisse sur le travail que par le troisième enfant (exclusion).

Pertinence, indépendance, exclusion

Trois conditions : la pertinence (Z modifie morekids), l'indépendance (Z est sans lien avec les déterminants du travail et de la fécondité) et l'exclusion (Z n'agit sur le travail que par morekids). Pour une interprétation locale, on ajoute la monotonie.

(b) Un mécanisme qui violerait l'exclusion

ÉNONCÉ (B)

Donnez un exemple concret de mécanisme par lequel le sexe des deux premiers enfants pourrait modifier le nombre de semaines travaillées par la mère sans passer par la naissance d'un troisième enfant. Quelle condition serait alors violée ?

RÉPONSE

Deux enfants de même sexe peuvent partager une chambre, des vêtements et des jouets : les élever **coûte moins cher**, le ménage a moins besoin d'un second revenu, et la mère peut travailler moins, **même sans troisième enfant**. L'instrument aurait alors un effet direct sur le travail : c'est la **restriction d'exclusion** (donc l'exogénéité) qui serait violée.

EXPLICATION

On cherche une flèche qui va **directement** de Z à Y, sans passer par X. Deux exemples classiques.

- **Les économies d'échelle** : chambre, vêtements et jouets partagés entre enfants de même sexe. Le budget du ménage est moins serré.
- **Le partage des tâches** : un père peut s'investir davantage auprès de ses fils. Dans une famille de deux garçons, la mère aurait alors plus de temps pour travailler. C'est l'exemple que cite l'article.

Dans les deux cas, cet effet direct de Z se retrouve dans u : $\mathrm{Cov}(Z, u) \neq 0$. Choisis l'outil « Exclusion violée » dans le schéma pour le voir.

CE QU'IL FAUT BIEN DISTINGUER

L'instrument peut être parfaitement aléatoire (indépendance respectée) **et** violer l'exclusion. Le hasard garantit que les mères se ressemblent au départ ; il ne garantit pas que le sexe des enfants n'a pas d'autre conséquence.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Les économies de coût

Deux enfants de même sexe peuvent partager chambre, vêtements et jouets : ils coûtent moins cher, le ménage a moins besoin d'un second revenu et la mère peut travailler moins, même sans troisième enfant. L'instrument agit alors directement sur le travail : la restriction d'exclusion, donc l'exogénéité, est violée.

L'implication du père

Si un père s'occupe davantage de ses enfants quand ce sont des garçons, la mère de deux garçons peut travailler davantage à nombre d'enfants donné. Le sexe des enfants a alors un effet direct sur le travail, ce qui viole l'exclusion, même si le sexe est aléatoire.

(c) Les mères se ressemblent-elles selon samegender ?

ÉNONCÉ (C)

Comparez l'âge et l'origine des mères selon la valeur de `samegender`. Que vous apprend cette comparaison, et que ne peut-elle pas vous apprendre ?

RÉPONSE

Les deux groupes sont **quasi identiques** : 30,40 et 30,38 ans, mêmes proportions d'origines, et aucune différence n'est significative malgré 254 654 observations. C'est ce qu'on attend si le sexe des enfants est dû au hasard : cela soutient l'**indépendance**. Mais la comparaison ne dit **rien** des caractéristiques non observées, ni surtout de la **restriction d'exclusion**.

EXPLICATION

Si l'instrument est « comme tiré au sort », les deux groupes qu'il forme doivent se ressembler sur tout ce qui a été fixé avant. C'est le même principe que la vérification d'un tirage au sort dans un essai clinique.

Caractéristique	Sexes différents	Même sexe	Différence	Erreur-type	p-valeur
Âge (années)	30,404	30,383	−0,021	0,013	0,11
Afro-américaine	5,23 %	5,11 %	−0,12 pt	0,09 pt	0,16
Hispanique	7,43 %	7,42 %	−0,01 pt	0,10 pt	0,92
Autre origine	5,66 %	5,60 %	−0,06 pt	0,09 pt	0,51

L'écart d'âge est de 0,021 an : **une semaine**. Avec un échantillon aussi grand, la moindre différence réelle serait détectée ; aucune ne l'est.

Ce que la comparaison ne peut pas apprendre.

- L'équilibre sur les caractéristiques **non observées** (préférences, ambition). On ne teste que ce qu'on observe, même si le hasard rend cet équilibre probable.
- **Rien sur l'exclusion.** Un effet direct du sexe des enfants sur le travail (question b) ne créerait aucune différence d'âge ou d'origine entre les mères. Les deux groupes peuvent être parfaitement comparables au départ et l'instrument quand même invalide.

CODE R

```r
rob(lm(age ~ samegender, data = fert))     # idem pour afam, hispanic, other
```

Régresser une caractéristique sur `samegender` compare sa moyenne entre les deux groupes : la constante est la moyenne du groupe « sexes différents », la pente est l'écart, avec son erreur-type robuste et sa p-valeur.

QUESTIONS PROBABLES À L'ORAL

Quelles sont les conditions d'un bon instrument, et laquelle peux-tu tester ?
La pertinence : l'instrument fait varier le nombre d'enfants, ce qui se teste avec la première étape. L'exogénéité : il n'est lié à rien d'autre qui influence le travail et n'agit que par le troisième enfant. Elle ne se teste pas directement, elle se défend par des arguments.

2.4 La première étape

ÉNONCÉ

Estimez la régression de `morekids` sur `samegender`.

La première étape vérifie la condition de pertinence : l'instrument fait-il vraiment varier le nombre d'enfants ?

(a) Le lien entre samegender et le troisième enfant

ÉNONCÉ (A)

Que dit-elle du lien entre `samegender` et la décision d'avoir un troisième enfant ? Interprétez le coefficient.

RÉPONSE

+0,0675 (erreur-type 0,0019). Les mères dont les deux premiers enfants sont de même sexe ont une probabilité d'avoir un troisième enfant supérieure de **6,75 points de pourcentage** : 41,4 % contre 34,6 %. Ce sont exactement les chiffres de l'article.

EXPLICATION

`morekids` vaut 0 ou 1. Une régression linéaire sur une telle variable s'appelle un modèle de probabilité linéaire : ses coefficients se lisent en **points de probabilité**.

- Constante : 0,3464. Parmi les mères dont les deux premiers enfants sont de sexes différents, 34,6 % ont un troisième enfant.
- Pente : 0,0675. Avec deux enfants de même sexe, la part monte à 34,6 + 6,75 = 41,4 %.

⚠ POINTS DE POURCENTAGE OU POURCENTS ?

+6,75 **points** (de 34,6 % à 41,4 %), et non +6,75 **%**. En pourcentage relatif, la hausse est de 6,75 / 34,6 ≈ 19 %.

RÉSULTATS

	Coefficient	Erreur-type HC1	t
Constante	0,3464	0,0013	258,3
samegender	0,0675	0,0019	35,2

CODE R

```
reg_2_4 <- lm(morekids ~ samegender, data = fert)
rob(reg_2_4)
```

(b) Le lien est-il suffisant ?

ÉNONCÉ (B)

Quel indicateur permet de juger si ce lien est suffisant ? Que conclut-il ?

RÉPONSE

La **statistique F de la première étape**, qui teste que le coefficient de l'instrument est nul. Avec un seul instrument, F = t² = 35,2² = **1 238**. La règle usuelle demande F > 10 : l'instrument est **très fort**.

EXPLICATION

Un instrument qui ne déplace presque pas `morekids` est un instrument faible : l'estimation par variables instrumentales devient alors très imprécise et peut même être biaisée. On mesure la force de l'instrument avec la statistique F du test « les coefficients des instruments sont tous nuls » dans la première étape.

Le repère habituel (Staiger et Stock) : **F supérieur à 10**. Ici 1 238 : aucun souci.

Remarque intéressante : l'instrument est très fort *statistiquement*, alors qu'il n'explique presque rien de `morekids` (R^2 de la première étape : 0,48 %). Ce n'est pas contradictoire. Avec 254 654 observations, un écart de 6,75 points est mesuré avec une précision extrême. La question 2.6 (d) montrera ce que ce petit R^2 coûte.

CODE R

```
rob(reg_2_4)["samegender", "t value"]^2      # F robuste = t² = 1 238
summary(reg_2_4)$r.squared                    # 0,0048
```

(c) Ce que cette étape vérifie

ÉNONCÉ (C)

Parmi les conditions de la question 2.3, laquelle cette étape permet-elle de vérifier ? Laquelle ne permet-elle pas de vérifier ?

RÉPONSE

Elle vérifie la **pertinence**. Elle ne peut pas vérifier l'**exogénéité** (indépendance et exclusion), qui porte sur le lien entre l'instrument et le terme d'erreur, non observé.

EXPLICATION

La première étape relie Z à X : deux variables qu'on a sous les yeux. L'exogénéité relie Z à u : on ne peut pas régresser quoi que ce soit sur une variable invisible. Elle se défend par le raisonnement (le sexe est dû au hasard) et par des indices indirects (l'équilibre de la question 2.3 c).

Une première étape très forte ne dit donc **rien** de la validité de l'instrument. Un instrument peut être très fort et parfaitement invalide.

QUESTIONS PROBABLES À L'ORAL

Une première étape très forte valide-t-elle l'instrument ?

Non. Elle établit seulement la pertinence. L'exogénéité ne se teste pas ainsi : si le sexe des enfants agit directement sur le travail de la mère, l'instrument est invalide même avec un F de 1 238.

2.5 Les quatre compositions de la fratrie

ÉNONCÉ

Construisez `boy1st` (binaire égale à 1 si le premier enfant est un garçon), `twoboys` (= 1 si les deux premiers enfants sont des garçons) et `twogirls` (= 1 si ce sont deux filles).

`samegender` mettait dans le même panier « deux garçons » et « deux filles ». On les sépare, ce qui donnera deux instruments au lieu d'un à partir de la question 2.8.

(a) Les quatre proportions et leurs intervalles

ÉNONCÉ (A)

Calculez la proportion de mères ayant plus de deux enfants pour chacune des quatre compositions possibles des deux premiers enfants (garçon-garçon, garçon-fille, fille-garçon, fille-fille) et représentez ces proportions avec un intervalle de confiance à 95 %.

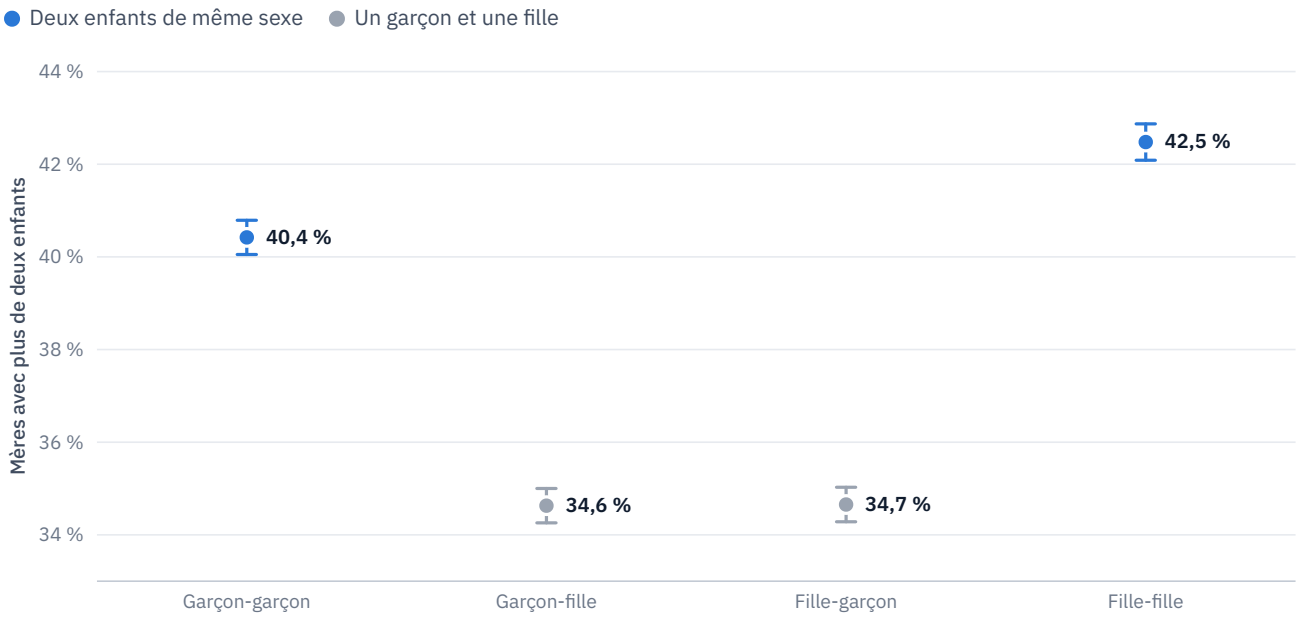
RÉPONSE

Composition	Mères	Plus de deux enfants	IC à 95 %
Garçon-garçon	67 799	**40,4 %**	[40,1 ; 40,8]
Garçon-fille	63 185	**34,6 %**	[34,3 ; 35,0]
Fille-garçon	62 724	**34,7 %**	[34,3 ; 35,0]
Fille-fille	60 946	**42,5 %**	[42,1 ; 42,9]

EXPLICATION

Qui a un troisième enfant ? Les quatre compositions

Part des mères ayant plus de deux enfants selon le sexe des deux premiers (dans l'ordre des naissances), avec l'intervalle de confiance à 95 %.



Les deux compositions mixtes sont au même niveau (34,6 % et 34,7 %) : l'ordre garçon-fille ou fille-garçon ne change rien. Deux garçons ajoutent +5,8 points, deux filles +7,8 points : l'effet existe dans les deux cas, mais il est plus fort après deux filles.

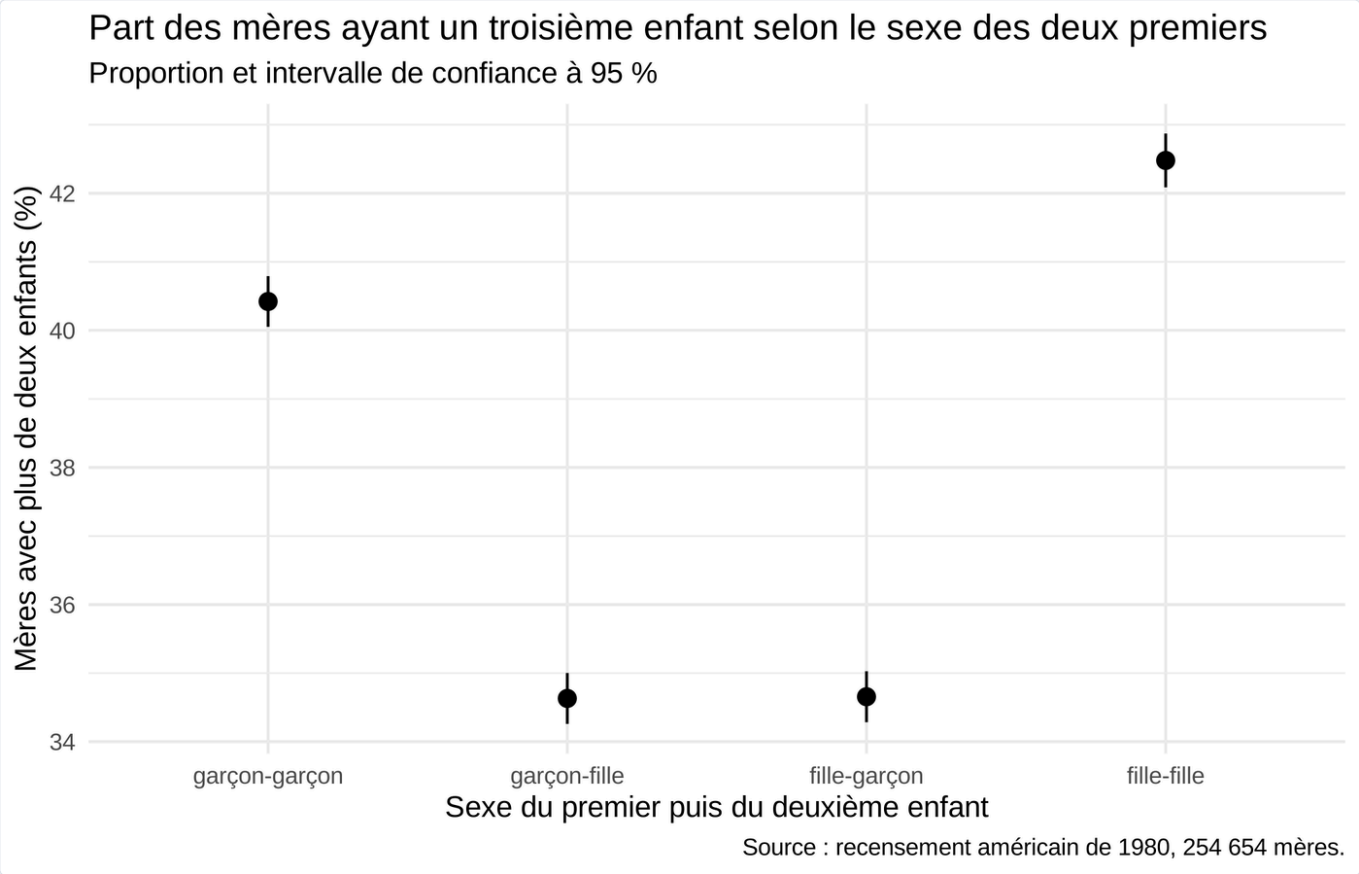
Figure tirée de l'outil interactif de l'atelier, dans son état initial.

L'intervalle de confiance d'une proportion. Pour une proportion p estimée sur n mères :

$$p \pm 1{,}96 \times \sqrt{\frac{p\,(1-p)}{n}}$$

Exemple pour garçon-garçon : 0,4042 ± 1,96 × √(0,4042 × 0,5958 / 67 799) = 0,4042 ± 0,0037.

Les intervalles sont minuscules (moins d'un demi-point de chaque côté) : chaque groupe compte plus de 60 000 mères.



Part des mères ayant un troisième enfant selon le sexe des deux premiers, avec intervalles de confiance à 95 %. Fichier : fig_2_5.png.

CODE R

```
tab_2_5a <- fert %>%
  mutate(composition = case_when(twoboys == 1 ~ "garçon-garçon",
                                 boy1st == 1 & twoboys == 0 ~ "garçon-fille",
                                 boy1st == 0 & twogirls == 0 ~ "fille-garçon",
                                 twogirls == 1 ~ "fille-fille")) %>%
  group_by(composition) %>%
  summarise(n = n(), p = mean(morekids), .groups = "drop") %>%
  mutate(se = sqrt(p * (1 - p) / n),
         ic_bas = p - 1.96 * se, ic_haut = p + 1.96 * se)

ggplot(tab_2_5a, aes(x = composition, y = 100 * p)) +
  geom_pointrange(aes(ymin = 100 * ic_bas, ymax = 100 * ic_haut))
```

`case_when()` est un « si… sinon si… » : il donne à chaque mère l'étiquette de la première condition vraie.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Formule usuelle

Je calcule chaque intervalle avec p ± 1,96 × √(p(1 − p)/n). Les quatre intervalles ont une demi-largeur inférieure à 0,4 point : chaque groupe compte plus de 60 000 mères.

Intervalle de Wilson

Je calcule des intervalles binomiaux de Wilson à 95 %. Ils coïncident ici avec la formule usuelle, la taille des groupes étant très grande.

(b) La régression et le test

ÉNONCÉ (B)

Estimez la régression de `morekids` sur `twoboys`, `twogirls` et `boy1st`. Testez l'égalité des coefficients de `twoboys` et de `twogirls`. Le sexe du premier enfant a-t-il un effet propre sur la probabilité d'avoir un troisième enfant ?

RÉPONSE

Deux garçons : **+5,8 points** ; deux filles : **+7,8 points**. On **rejette** l'égalité des deux coefficients ($F = 28{,}0$; $p = 1{,}2 \times 10^{-7}$) : l'effet est plus fort après deux filles. Le sexe du premier enfant, à lui seul, n'a **aucun effet** : −0,02 point, $p = 0{,}93$.

EXPLICATION

Quatre groupes, une constante et trois indicatrices : le modèle est **saturé**, il reproduit exactement les quatre proportions de la question (a). Chaque coefficient est une différence entre deux groupes. Pour le voir, écris ce que valent les trois indicatrices pour chaque composition.

Composition	twoboys	twogirls	boy1st	Probabilité prédite
Fille-garçon	0	0	0	constante
Garçon-fille	0	0	1	constante + boy1st
Garçon-garçon	1	0	1	constante + boy1st + twoboys
Fille-fille	0	1	0	constante + twogirls

Coefficient	Ce qu'il compare	Valeur	Erreur-type HC1
Constante	P(fille-garçon)	0,3465	0,0019
boy1st	P(garçon-fille) − P(fille-garçon)	−0,0002	0,0027
twoboys	P(garçon-garçon) − P(garçon-fille)	0,0579	0,0027
twogirls	P(fille-fille) − P(fille-garçon)	0,0782	0,0028

Le test d'égalité. H_0 : coefficient de `twoboys` = coefficient de `twogirls`. L'écart vaut −0,0203 (erreur-type 0,0038), soit $t = -5{,}29$ et $F = t^2 = 28{,}0$. $p = 1{,}2 \times 10^{-7}$: on rejette.

Le sexe du premier enfant. Le coefficient de `boy1st` compare les deux compositions **mixtes**, qui ne diffèrent que par l'ordre. Il est nul. Ce qui compte, c'est la composition de la paire, pas le sexe de l'aîné.

CODE R

```
reg_2_5 <- lm(morekids ~ twoboys + twogirls + boy1st, data = fert)
rob(reg_2_5)
linearHypothesis(reg_2_5, "twoboys = twogirls", vcov. = vcovHC(reg_2_5, type = "HC1"))
```

`linearHypothesis()` accepte une restriction écrite en toutes lettres, avec les noms des coefficients.

(c) Ce que la question 2.4 ne montrait pas

ÉNONCÉ (C)

Que montrent ce graphique et cette régression que la régression de la question 2.4 ne montre pas ?

RÉPONSE

Trois choses. L'effet existe **pour les deux** compositions de même sexe, ce qui soutient l'explication par la préférence pour la mixité. Il est **asymétrique** : plus fort après deux filles (+7,8 points) qu'après deux garçons (+5,8), ce qui suggère en plus une préférence pour les garçons. Et le sexe du premier enfant, **à lui seul**, ne change rien.

EXPLICATION

`samegender` donnait un seul chiffre moyen (+6,75 points). En le décomposant, on apprend que cette moyenne cache deux effets de tailles différentes, et que les deux ordres mixtes sont équivalents.

Cela a deux conséquences pratiques : on dispose de **deux instruments** (`twoboys` et `twogirls`) au lieu d'un, et il faudra contrôler `boy1st` quand on les utilisera (question 2.8 c).

QUESTIONS PROBABLES À L'ORAL

Pourquoi dis-tu que le sexe du premier enfant n'a pas d'effet propre ?

Parce que le coefficient de boy1st compare garçon-fille à fille-garçon, deux fratries mixtes qui ne diffèrent que par l'ordre. Il vaut −0,02 point avec une p-valeur de 0,93. C'est la composition de la paire qui compte.

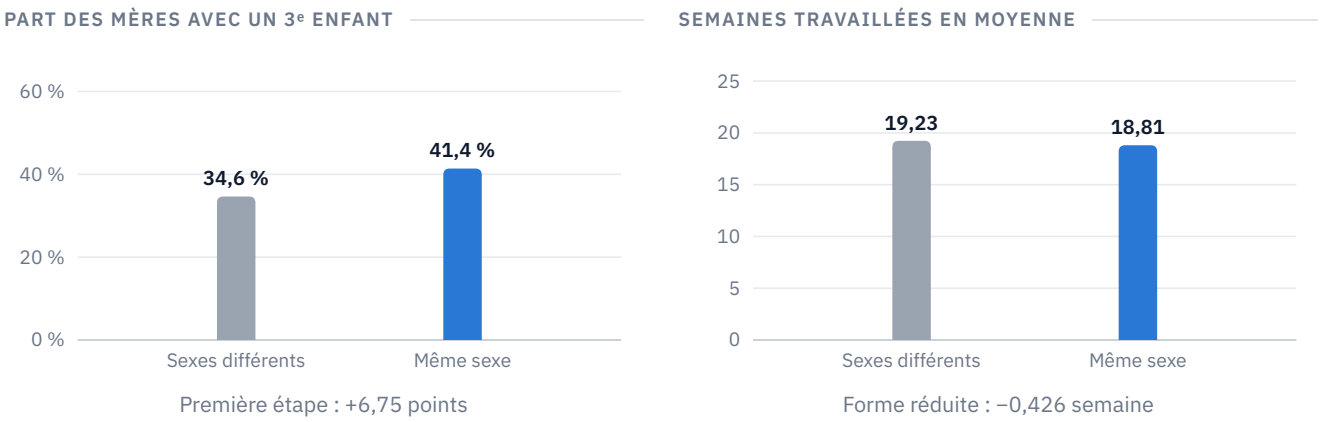
2.6 Forme réduite et variables instrumentales

Tout est prêt pour l'estimation par variables instrumentales. Elle se résume à **une division**, que l'outil ci-dessous te fait refaire.

L'estimateur de Wald : une division

Compare les mères selon le sexe de leurs deux premiers enfants. Le sexe change **un peu** la probabilité d'un troisième enfant (première étape) et **un peu** le travail (forme réduite). Le rapport des deux donne l'effet d'un troisième enfant.

● Sexes différents (125 909 mères) ● Même sexe (128 745 mères)



$$\frac{\text{forme réduite}}{\text{première étape}} = \frac{-0{,}4263}{0{,}0675} = \mathbf{-6{,}31 \text{ semaines}}$$

Prends 100 mères de chaque groupe. Dans le groupe « même sexe », il y a **6,75 troisièmes enfants de plus**, et ces 100 mères travaillent au total **42,6 semaines de moins**. Si toute la baisse vient de ces enfants supplémentaires (c'est la restriction d'exclusion), chacun « coûte » 42,6 / 6,75 = **6,3 semaines**.

Ce sont les vraies valeurs : on retrouve exactement l'estimation par variables instrumentales de la question 2.6 (−6,31).

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) La forme réduite

ÉNONCÉ (A)

Estimez la régression de `work` sur `samegender` (forme réduite) et interprétez le coefficient.

RÉPONSE

−0,426 (erreur-type 0,087). Les mères dont les deux premiers enfants sont de même sexe ont travaillé **0,43 semaine de moins** en 1979 (18,81 contre 19,23). Comme le sexe des enfants est dû au hasard, c'est l'effet causal d'avoir deux enfants de même sexe sur le travail.

EXPLICATION

La forme réduite saute l'intermédiaire : elle relie directement l'instrument Z au résultat Y.

0,43 semaine, c'est trois jours par an : très peu. C'est normal. Avoir deux enfants de même sexe ne change la décision d'avoir un troisième enfant que pour une petite partie des familles (6,75 %). L'effet sur **l'ensemble** des mères est donc dilué.

Si la restriction d'exclusion est vraie, toute cette différence de travail passe par le troisième enfant. C'est ce qui permet le calcul de la question (c).

RÉSULTATS

	Coefficient	Erreur-type HC1	t
Constante	19,234	0,062	311,4
samegender	−0,426	0,087	−4,9

CODE R

```
reg_2_6a <- lm(work ~ samegender, data = fert)
rob(reg_2_6a)
```

(b) L'estimation par variables instrumentales

ÉNONCÉ (B)

Estimez le modèle de la question 2.2 par variables instrumentales, avec `samegender` comme instrument de `morekids`. Interprétez le coefficient de `morekids` et confrontez-le à l'estimation MCO de la question 2.2. La différence va-t-elle dans le sens que vous aviez prévu ?

RÉPONSE

−6,31 (erreur-type 1,275 ; IC à 95 % : [−8,81 ; −3,82]). Un troisième enfant réduit le travail de la mère d'environ 6,3 semaines par an. **Non, ce n'est pas le sens prévu** : on attendait des MCO plus négatifs que la VI, c'est l'inverse (−5,39 contre −6,31). Mais l'écart (0,93) est petit par rapport à l'erreur-type de la VI (1,27) : il n'est pas significatif.

EXPLICATION

Interprétation. Pour les mères dont le troisième enfant est dû à la composition de la fratrie, cet enfant réduit le travail de 6,3 semaines par an.

La confrontation avec les MCO. À la question 2.2 (c), on prévoyait que les MCO **exagéraient** l'effet. La VI, censée corriger ce biais, devrait donc être moins négative. Elle est plus négative. Sois honnête dans ton rapport : la prédiction ne se vérifie pas ici. Deux explications.

	MCO (2.2)	VI (2.6)
morekids	−5,387 (0,087)	−6,314 (1,275)
IC à 95 %	[−5,56 ; −5,22]	[−8,81 ; −3,82]

1. **L'écart n'est pas significatif.** L'intervalle de la VI contient largement −5,39. On ne peut pas affirmer que les deux estimations diffèrent.
2. **Les MCO sans contrôle subissent des biais de sens opposés.** L'âge et l'origine les tirent vers zéro (voir l'astuce de la question 2.2 c). Une fois ces contrôles ajoutés, à la question 2.7, les MCO deviennent **plus** négatifs que la VI, comme prévu et comme dans l'article.

CODE R

```
reg_2_6b <- ivreg(work ~ morekids | samegender, data = fert)
rob(reg_2_6b)
```

`ivreg()` vient du package `AER`. La formule se lit en deux parties, séparées par une barre verticale : à gauche l'équation qu'on veut estimer, à droite la liste des instruments.

(c) Le rapport de deux coefficients

ÉNONCÉ (C)

Montrez que l'estimation obtenue en (b) est égale au rapport de deux coefficients que vous avez déjà estimés. Expliquez pourquoi.

RÉPONSE

$$\hat{\beta}_{\text{VI}} = \frac{\text{forme réduite}}{\text{première étape}} = \frac{-0{,}4263}{0{,}06753} = -6{,}314$$

C'est l'estimateur de Wald : l'effet de l'instrument sur le travail, divisé par son effet sur le nombre d'enfants.

EXPLICATION

L'intuition. Les mères « même sexe » travaillent 0,43 semaine de moins et ont 0,0675 troisième enfant de plus par mère. Si toute la différence de travail vient de ces enfants supplémentaires, chacun « coûte » 0,43 / 0,0675 = 6,3 semaines.

La démonstration. Avec un seul instrument et sans contrôle, l'estimateur par variables instrumentales s'écrit :

$$\hat{\beta}_{\text{VI}} = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, X)}$$

Divise le haut et le bas par $\text{Var}(Z)$:

$$\hat{\beta}_{\text{VI}} = \frac{\text{Cov}(Z, Y) \,/\, \text{Var}(Z)}{\text{Cov}(Z, X) \,/\, \text{Var}(Z)} = \frac{\text{pente de Y sur Z}}{\text{pente de X sur Z}}$$

Le numérateur est la pente de la forme réduite (question a), le dénominateur celle de la première étape (question 2.4).

CODE R

```r
coef(reg_2_6a)["samegender"] / coef(reg_2_4)["samegender"]    # -6,314
coef(reg_2_6b)["morekids"]                                    # -6,314
```

(d) Pourquoi une erreur-type quinze fois plus grande ?

ÉNONCÉ (D)

Pourquoi l'erreur-type de l'estimation par variables instrumentales est-elle beaucoup plus grande que celle des MCO ?

RÉPONSE

Parce que la VI n'utilise que la part des variations de `morekids` **provoquée par l'instrument**, et que cette part est minuscule : 0,48 % de sa variance. L'erreur-type est multipliée par environ $1 / \sqrt{0{,}0048} \approx 14$; on observe 1,275 / 0,087 = **14,6**.

EXPLICATION

Les MCO utilisent **toutes** les différences de nombre d'enfants entre mères, bonnes et mauvaises. La VI n'en garde qu'une petite fraction, celle qui vient du sexe des deux premiers enfants : la seule dont on est sûr qu'elle n'est pas un choix. Moins d'information utilisée, moins de précision.

Une approximation à connaître :

$$\mathrm{Var}(\hat{\beta}_{\mathrm{VI}}) \approx \frac{\mathrm{Var}(\hat{\beta}_{\mathrm{MCO}})}{\rho^2_{XZ}}$$

où ρ^2_{XZ} est le carré de la corrélation entre `morekids` et `samegender`, c'est-à-dire le R^2 de la première étape (0,0048).

Autre façon de le voir, avec la division de Wald : on divise par 0,0675, un nombre petit. Toute imprécision sur le numérateur (la forme réduite) est multipliée par 1 / 0,0675 ≈ 15.

LE COMPROMIS À RETENIR

On échange du **biais** contre de l'**imprécision**. Les MCO donnent une réponse très précise à une mauvaise question ; la VI donne une réponse imprécise à la bonne.

À RETENIR

- Première étape : +6,75 points de probabilité d'un 3e enfant (F = 1 238).
- Forme réduite : −0,43 semaine.
- VI = forme réduite / première étape = −6,31 semaines.
- Erreur-type 15 fois plus grande que celle des MCO : le prix de la crédibilité.

QUESTIONS PROBABLES À L'ORAL

Comment obtiens-tu −6,31 semaines ?

Je compare les mères selon le sexe de leurs deux premiers enfants. Celles dont les enfants sont de même sexe travaillent 0,43 semaine de moins et ont 6,75 points de plus de chances d'avoir un troisième enfant. Le rapport, −0,426 / 0,0675, donne −6,3 semaines par enfant supplémentaire, à condition que le sexe des enfants n'agisse sur le travail que par le troisième enfant.

Pourquoi l'erreur-type de la VI est-elle si grande ?

Parce qu'elle n'utilise que la variation du nombre d'enfants due au sexe des deux premiers, soit 0,5 % de sa variance. On gagne en crédibilité ce qu'on perd en précision.

2.7 Variables de contrôle : MCO contre VI

On ajoute l'âge et l'origine de la mère aux deux estimations. La question porte moins sur les chiffres que sur une observation : les contrôles déplacent beaucoup les MCO et presque pas la VI. Comprendre pourquoi, c'est comprendre ce qu'est un instrument.

(a) Contrôle ou instrument ?

ÉNONCÉ (A)

Qu'est-ce qu'une variable de contrôle ? En quoi son rôle diffère-t-il de celui d'un instrument ?

RÉPONSE

Une **variable de contrôle** est une variable qu'on ajoute à l'équation du résultat pour tenir constant un facteur qui influence le travail **et** qui est lié au nombre d'enfants. Un **instrument** n'a, lui, **aucun effet direct** sur le résultat : il est exclu de l'équation du travail et ne sert qu'à faire varier `morekids`.

EXPLICATION

	Contrôle	Instrument
Figure dans l'équation de `work` ?	**Oui** : il a son propre effet sur le travail	**Non** : c'est la restriction d'exclusion
Figure dans la première étape ?	Oui	Oui
Son rôle	Neutraliser un facteur de confusion	Isoler une variation « propre » de `morekids`
Dans `ivreg(y ~ x + w | z + w)`	des deux côtés de la barre	seulement à droite de la barre

Un moyen simple de s'en souvenir : le contrôle répond à « **comparons des mères semblables** » ; l'instrument répond à « **trouvons un tirage au sort caché** ».

(b) Ce que contrôle chaque variable

ÉNONCÉ (B)

Ajoutez `age`, `afam`, `hispanic` et `other` comme variables de contrôle, d'abord dans la régression MCO de la question 2.2, puis dans l'estimation par variables instrumentales de la question 2.6 (`samegender` reste le seul instrument). Pour chacune de ces variables, expliquez ce qu'elle contrôle : quelle différence entre mères neutralise-t-elle, et pourquoi cette différence pourrait-elle fausser la comparaison entre mères de deux enfants et mères de plus de deux enfants ?

RÉPONSE

Avec les contrôles : MCO **−6,23** (0,086) ; VI **−5,82** (1,246). Chaque contrôle neutralise une différence liée à la fois au nombre d'enfants et au travail. L'**âge** : une mère plus âgée a eu plus de temps pour avoir un troisième enfant *et* travaille davantage. L'**origine** : en 1980, les mères afro-américaines et hispaniques ont plus souvent trois enfants, et les premières travaillent beaucoup plus.

EXPLICATION

Pour dire ce que neutralise un contrôle, il faut deux informations : **son lien avec** `morekids` et **son effet sur** `work`. Les deux se lisent dans les régressions.

Contrôle	Effet sur la probabilité d'un 3e enfant	Effet sur les semaines travaillées	Ce qu'il neutralise
`age`	+1,5 point par année	+0,84 semaine par année	Une mère plus âgée a eu plus de temps pour avoir un 3e enfant, et ses enfants plus grands lui laissent plus de temps pour travailler.
`afam`	+10,0 points	+11,7 semaines	En 1980, les mères afro-américaines ont plus d'enfants et travaillent nettement plus.
`hispanic`	+15,1 points	+0,5 semaine	Les mères hispaniques ont bien plus souvent trois enfants, sans travailler beaucoup plus.
`other`	+2,7 points	+2,1 semaines	Même logique, plus faible.

Applique la règle du signe à l'âge : effet positif sur le travail, lien positif avec `morekids` : biais **positif**. Sans ces contrôles, le groupe « plus de deux enfants » contient davantage de mères âgées et afro-américaines, qui travaillent plus pour d'autres raisons. La comparaison brute attribuait donc au troisième enfant une baisse **trop faible** : les MCO étaient tirés vers zéro. C'est l'inverse du biais envisagé à la question 2.2 (c), et c'est ce qui expliquait la surprise de la question 2.6.

⚠ CE QUE CES COEFFICIENTS NE DISENT PAS

Les coefficients des indicatrices d'origine décrivent des écarts moyens entre groupes aux États-Unis en 1980, à âge et nombre d'enfants donnés. Ils ne disent rien de leurs causes.

RÉSULTATS

Effet de `morekids`	Sans contrôle	Avec contrôles
MCO	−5,387 (0,087)	−6,230 (0,086)
VI (`samegender`)	−6,314 (1,275)	−5,821 (1,246)

CODE R

```
reg_2_7_mco <- lm(work ~ morekids + age + afam + hispanic + other, data = fert)
reg_2_7_vi  <- ivreg(work ~ morekids + age + afam + hispanic + other |
                       samegender + age + afam + hispanic + other, data = fert)
rob(reg_2_7_mco); rob(reg_2_7_vi)

rob(lm(morekids ~ age + afam + hispanic + other, data = fert))     # lien des contrôles avec morekids
```

Dans `ivreg()`, les contrôles sont écrits **des deux côtés** de la barre : ils sont exogènes, ils servent donc à la fois de régresseurs et d'instruments pour eux-mêmes. Seul `morekids` est absent à droite, remplacé par `samegender`.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Deux chiffres par contrôle

Pour chaque contrôle, je donne son lien avec morekids et son effet sur work. L'âge : +1,5 point de probabilité d'un troisième enfant et +0,84 semaine de travail par année. Afro-américaine : +10 points et +11,7 semaines. Hispanique : +15 points et +0,5 semaine. Sans ces contrôles, le groupe des mères de plus de deux enfants compte davantage de mères âgées et afro-américaines, qui travaillent plus pour d'autres raisons : la comparaison brute sous-estimait la baisse due au troisième enfant.

Description qualitative de chaque contrôle

L'âge neutralise le temps écoulé pour avoir un autre enfant et le stade de la carrière ; les indicatrices d'origine, des différences moyennes de contexte socio-économique et d'accès à l'emploi. Si ces caractéristiques sont liées à la fécondité et au travail, leur omission fausse la comparaison des MCO.

(c) Pourquoi les contrôles déplacent les MCO et pas la VI

ÉNONCÉ (C)

Comment les estimations de l'effet de `morekids` évoluent-elles ? Comment expliquez-vous que l'ajout des contrôles modifie peu l'estimation VI, alors qu'il modifie davantage l'estimation MCO ?

RÉPONSE

Les MCO passent de −5,39 à **−6,23** (un déplacement de dix erreurs-types) ; la VI de −6,31 à **−5,82** (0,4 erreur-type). Les MCO utilisent toute la variation de `morekids`, fortement liée aux contrôles. La VI n'utilise que la variation due à `samegender`, qui n'est liée à **aucun** contrôle : pour elle, ce ne sont pas des facteurs de confusion.

EXPLICATION

	Sans contrôle	Avec contrôles	Variation	En erreurs-types
MCO	−5,39	−6,23	−0,84	environ 10
VI `samegender`	−6,31	−5,82	+0,49	environ 0,4

Pour les MCO. Les quatre contrôles prédisent très significativement un troisième enfant. Les omettre créait un biais de variable omise ; les ajouter le retire.

Pour la VI. Rappelle-toi la question 2.3 (c) : les mères sont **identiques** en âge et en origine selon `samegender`. Si l'on régresse `samegender` sur les quatre contrôles, aucun coefficient n'est significatif. Or un contrôle ne corrige un biais que s'il est lié à la source de variation qu'on utilise. Ici il ne l'est pas : il n'y a rien à corriger. Le petit déplacement de la VI (0,49) n'est que du bruit d'échantillonnage.

C'est exactement ce qu'on attend d'un instrument « comme tiré au sort » : dans une expérience aléatoire, ajouter des contrôles ne change pas l'estimation, cela la rend seulement un peu plus précise (l'erreur-type passe de 1,275 à 1,246).

CE QUE CETTE QUESTION DÉMONTRE

La stabilité de la VI quand on ajoute des contrôles est un **argument en faveur de l'instrument**. La sensibilité des MCO est le signe qu'ils restent exposés à d'autres variables omises, celles qu'on n'observe pas.

Remarque enfin l'ordre des estimations : avec les contrôles, les MCO (−6,23) sont **plus** négatifs que la VI (−5,82). C'est le sens prévu à la question 2.2 (c), et celui de l'article.

CODE R

```
rob(lm(samegender ~ age + afam + hispanic + other, data = fert))    # aucun coefficient significatif
```

QUESTIONS PROBABLES À L'ORAL

Qu'est-ce qu'une variable de contrôle, par opposition à un instrument ?
Un contrôle a son propre effet sur le résultat et figure dans l'équation : on l'ajoute pour comparer des mères semblables. Un instrument n'a pas d'effet direct sur le résultat : il est exclu de l'équation et ne sert qu'à faire varier le nombre d'enfants.

2.8 Les doubles moindres carrés avec deux instruments

ÉNONCÉ

Estimez par les doubles moindres carrés (2SLS) le modèle $\text{work} = \beta_0 + \beta_1\,\text{morekids} + \beta_2\,\text{age} + \beta_3\,\text{afam} + \beta_4\,\text{hispanic} + \beta_5\,\text{other} + \beta_6\,\text{boy1st} + u$ en utilisant `twoboys` et `twogirls` (question 2.5) comme instruments de `morekids`.

On passe d'un instrument à deux. La division de Wald ne suffit plus : il faut la méthode générale, les doubles moindres carrés.

Le principe en deux étapes.

1. **Première étape** : on régresse `morekids` sur les instruments et les contrôles, et on calcule sa valeur prédite. Cette prédiction ne contient que la variation de `morekids` expliquée par des variables exogènes.
2. **Seconde étape** : on régresse `work` sur cette prédiction et sur les contrôles.

`ivreg()` fait les deux étapes d'un coup et calcule les bonnes erreurs-types.

(a) Les rôles, la première étape et la force des instruments

ÉNONCÉ (A)

Dans cette estimation, quelle variable est endogène, lesquelles sont des instruments, lesquelles sont des contrôles ? Écrivez l'équation de la première étape, estimez-la et jugez de la force des instruments.

RÉPONSE

Endogène : `morekids`. **Instruments** : `twoboys`, `twogirls`. **Contrôles** : `age`, `afam`, `hispanic`, `other`, `boy1st`. Dans la première étape, deux garçons ajoutent 5,9 points et deux filles 7,9 points à la probabilité d'un troisième enfant. Le F robuste des deux instruments vaut **657,9**, très au-dessus de 10 : les instruments sont **forts**.

EXPLICATION

L'équation de la première étape : le régresseur endogène, expliqué par **tous** les exogènes (instruments et contrôles).

$$\text{morekids} = \pi_0 + \pi_1\,\text{twoboys} + \pi_2\,\text{twogirls} + \pi_3\,\text{age} + \pi_4\,\text{afam} + \pi_5\,\text{hispanic} + \pi_6\,\text{other} + \pi_7\,\text{boy1}$$

La force des instruments. On teste $H_0 : \pi_1 = \pi_2 = 0$, c'est-à-dire « les instruments n'expliquent rien une fois les contrôles pris en compte ». Il y a deux restrictions : c'est un test **F conjoint**, et non plus un simple t². Résultat : F = 657,9.

⚠ SUR QUOI PORTE LE F DE PREMIÈRE ÉTAPE

Sur les **instruments seulement**, pas sur l'ensemble de la régression. Le F global affiché par `summary()` teste tous les régresseurs, contrôles compris : ce n'est pas le bon.

RÉSULTATS

Première étape	Coefficient	Erreur-type HC1
twoboys	0,0586	0,0026
twogirls	0,0785	0,0027
boy1st	−0,0007	0,0027
age	0,0154	0,0003
afam	0,1004	0,0044
hispanic	0,1511	0,0041
other	0,0276	0,0046

CODE R

```
reg_2_8_fs <- lm(morekids ~ twoboys + twogirls + age + afam + hispanic + other + boy1st,
                 data = fert)
rob(reg_2_8_fs)
linearHypothesis(reg_2_8_fs, c("twoboys = 0", "twogirls = 0"),
                 vcov. = vcovHC(reg_2_8_fs, type = "HC1"))      # F = 657,9

reg_2_8 <- ivreg(work ~ morekids + age + afam + hispanic + other + boy1st |
                   twoboys + twogirls + age + afam + hispanic + other + boy1st, data = fert)
rob(reg_2_8)
```

`linearHypothesis()` reçoit ici **deux** restrictions dans un vecteur `c(...)` : il les teste ensemble.

(b) L'effet estimé et son évolution

ÉNONCÉ (B)

Comment l'effet estimé de `morekids` évolue-t-il par rapport aux questions 2.2, 2.6 et 2.7 ? Interprétez-le.

RÉPONSE

−5,46 (erreur-type 1,23 ; IC à 95 % : [−7,87 ; −3,05]). Un troisième enfant réduit le travail de la mère d'environ **5,5 semaines par an**, soit 29 % de la moyenne. C'est moins négatif que les MCO avec contrôles (−6,23), dans le sens prévu, et très proche de l'article (−5,40 et −5,16).

EXPLICATION

Question	Méthode	Effet de `morekids`	Erreur-type HC1
2.2	MCO, sans contrôle	−5,39	0,09
2.6	VI `samegender`, sans contrôle	−6,31	1,27
2.7	MCO + contrôles	−6,23	0,09
2.7	VI `samegender` + contrôles	−5,82	1,25
2.8	**2SLS `twoboys` + `twogirls` + contrôles**	**−5,46**	**1,23**

Trois remarques.

- **Les estimations par instruments restent groupées** entre −5,5 et −6,3, toutes à l'intérieur des intervalles de confiance les unes des autres.
- **Les MCO avec contrôles (−6,23) sont plus négatifs que la 2SLS (−5,46)** : les MCO exagèrent un peu l'effet, comme l'article le conclut.
- **L'interprétation reste locale** : l'effet vaut pour les mères qui ont eu ce troisième enfant à cause de la composition de la fratrie (question 2.14).

Avec deux instruments, la 2SLS combine en réalité deux estimations (celle que donnerait `twoboys` seul et celle de `twogirls` seul), en donnant plus de poids à la plus précise. La question 2.10 les montre séparément.

(c) Pourquoi boy1st, et pourquoi pas trois instruments ?

ÉNONCÉ (C)

Pourquoi faut-il inclure `boy1st` parmi les contrôles ? Pourquoi ne peut-on pas utiliser `samegender`, `twoboys` et `twogirls` ensemble comme instruments ?

RÉPONSE

`boy1st` : parce que `twoboys` ne peut valoir 1 que si l'aîné est un garçon, et `twogirls` que si c'est une fille. Sans ce contrôle, un effet propre du sexe du premier enfant serait attribué au troisième enfant. **Trois instruments** : impossible, car `samegender` = `twoboys` + `twogirls` pour chaque mère. Les trois sont parfaitement colinéaires.

EXPLICATION

Pourquoi `boy1st`. Les deux instruments sont, par construction, liés au sexe de l'aîné. Avec `boy1st` en contrôle, chaque instrument compare des familles **dont le premier enfant est du même sexe** :

- `twoboys` compare garçon-garçon à garçon-fille ;
- `twogirls` compare fille-fille à fille-garçon.

Dans chaque comparaison, la seule chose qui change est le sexe du **deuxième** enfant, tiré au sort. Sans `boy1st`, si le sexe de l'aîné avait un effet direct sur le travail de la mère (un père plus investi auprès d'un fils aîné, par exemple), cet effet passerait par les instruments et violerait l'exclusion.

En pratique, le coefficient de `boy1st` est nul dans l'équation du travail (−0,01 semaine) : le contrôle est une précaution, qui ne change rien au résultat.

Pourquoi pas trois instruments. C'est le piège de la colinéarité parfaite de la question 1.9 (b), dans un autre décor. `samegender` est la somme exacte des deux autres : il n'apporte **aucune information nouvelle**, et la première étape ne peut pas estimer trois coefficients distincts.

CODE R

```r
all(fert$samegender == fert$twoboys + fert$twogirls)    # TRUE pour les 254 654 mères
```

QUESTIONS PROBABLES À L'ORAL

Pourquoi contrôles-tu boy1st ?

Pour que twoboys et twogirls comparent des familles dont l'aîné est du même sexe. Sinon, un effet propre du sexe du premier enfant sur le travail de la mère serait attribué au troisième enfant.

Que veut dire la barre dans ivreg(y ~ x + w | z + w) ?

À gauche, l'équation du résultat. À droite, toutes les variables exogènes : les contrôles w, qui sont des deux côtés, et l'instrument z, seulement à droite. x, absent à droite, est le régresseur endogène.

2.9 Pourquoi ces résultats ? Les mécanismes

ÉNONCÉ

Proposez au moins deux mécanismes, économiques ou liés aux préférences des parents, qui pourraient expliquer vos résultats de la question 2.5. L'un d'eux pourrait-il aussi agir directement sur le travail de la mère ? Quelle condition de validité des instruments serait alors violée ?

RÉPONSE

1. **La préférence pour la mixité** : les parents veulent un garçon et une fille, donc réessaient après deux enfants de même sexe. 2. **La préférence pour les garçons** : elle explique que l'effet soit plus fort après deux filles (+7,8 points) qu'après deux garçons (+5,8). 3. **Les économies d'échelle** : deux enfants de même sexe coûtent moins cher (chambre, vêtements), ce qui rend un troisième plus abordable. Ce troisième mécanisme peut agir **directement** sur le travail de la mère, et violerait alors la **restriction d'exclusion**.

EXPLICATION

La question 2.5 a montré deux faits : les deux compositions de même sexe augmentent la probabilité d'un troisième enfant, et l'effet est plus fort après deux filles. Chaque mécanisme doit expliquer l'un ou l'autre.

Mécanisme	Type	Ce qu'il explique	Effet direct sur le travail ?
Préférence pour la mixité	préférences	les deux compositions de même sexe augmentent la probabilité	non

Mécanisme	Type	Ce qu'il explique	Effet direct sur le travail ?
Préférence pour les garçons	préférences	l'asymétrie : +7,8 après deux filles, +5,8 après deux garçons	non, a priori
Économies d'échelle	économique	un 3e enfant est plus abordable après deux enfants de même sexe	**oui**

Le mécanisme gênant. Si deux enfants de même sexe coûtent moins cher, la famille a aussi **moins besoin d'un second salaire**, troisième enfant ou pas. Le sexe des enfants influence alors le travail de la mère par un autre chemin que le nombre d'enfants. C'est précisément ce que la restriction d'exclusion interdit.

La distinction est importante : les deux premiers mécanismes expliquent pourquoi l'instrument est **pertinent** sans menacer sa validité. Le troisième explique aussi la pertinence, mais menace la validité.

RÉDACTION POSSIBLE POUR LE RAPPORT

Trois mécanismes reliés aux résultats

La préférence pour la mixité explique que deux garçons comme deux filles augmentent la probabilité d'un troisième enfant. Une préférence pour les garçons explique que l'effet soit plus fort après deux filles. Les économies d'échelle (chambre, vêtements partagés) rendent un troisième enfant plus abordable ; mais elles réduisent aussi le besoin d'un second salaire, ce qui agirait directement sur le travail de la mère et violerait la restriction d'exclusion.

D. TESTER LES INSTRUMENTS ET L'ENDOGÉNÉITÉ

2.10 Un instrument à la fois

Avec deux instruments, on peut estimer le même effet de deux façons. Si les deux instruments sont valides, les deux réponses devraient se ressembler. C'est l'idée, très simple, qui mène au test de la question 2.11.

Un instrument à la fois, puis les deux ensemble

Effet estimé de `morekids` sur les semaines travaillées, avec intervalle de confiance à 95 %. Les MCO sont très précis (intervalle minuscule) ; les variables instrumentales le sont beaucoup moins.

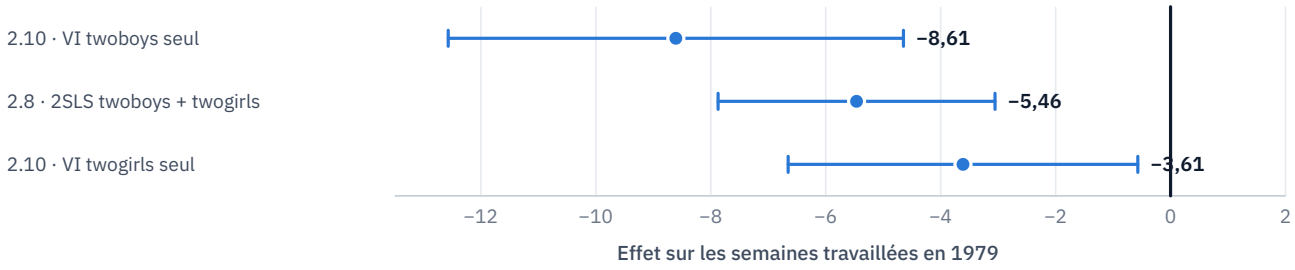


Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Deux estimations du même effet

ÉNONCÉ (A)

Estimez le modèle de la question 2.8 par variables instrumentales en n'utilisant que `twoboys` comme instrument, puis en n'utilisant que `twogirls`. Comparez les deux estimations de l'effet d'un troisième enfant.

RÉPONSE

Avec `twoboys` seul : **−8,61** (erreur-type 2,02). Avec `twogirls` seul : **−3,61** (erreur-type 1,55). Les deux sont négatives, mais la première est plus de deux fois plus grande. L'estimation avec les deux instruments (−5,46) se trouve entre les deux.

RÉSULTATS

Instrument	Effet d'un 3e enfant	Erreur-type HC1	IC à 95 %
`twoboys` seul	−8,61	2,02	[−12,57 ; −4,65]
`twogirls` seul	−3,61	1,55	[−6,65 ; −0,57]
Les deux (2.8)	−5,46	1,23	[−7,87 ; −3,05]

CODE R

```
reg_2_10_boys  <- ivreg(work ~ morekids + age + afam + hispanic + other + boy1st |
                        twoboys  + age + afam + hispanic + other + boy1st, data = fert)
reg_2_10_girls <- ivreg(work ~ morekids + age + afam + hispanic + other + boy1st |
                        twogirls + age + afam + hispanic + other + boy1st, data = fert)
rob(reg_2_10_boys)["morekids", ]; rob(reg_2_10_girls)["morekids", ]
```

Seule la partie droite de la barre change : un seul instrument à la fois, avec les mêmes contrôles.

(b) L'écart est-il important ?

ÉNONCÉ (B)

Si les deux instruments sont valides, que devraient estimer ces deux régressions ? Leur écart vous paraît-il important au regard de leurs erreurs-types ?

RÉPONSE

Si les deux instruments sont valides **et** si l'effet est le même pour toutes les mères, les deux régressions estiment le **même paramètre** et ne devraient différer que par le hasard. L'écart vaut −5,0 semaines pour une erreur-type de 2,55, soit **z = −1,96** : exactement **à la limite** de la significativité à 5 %. Grand en valeur, à peine distinguable du hasard.

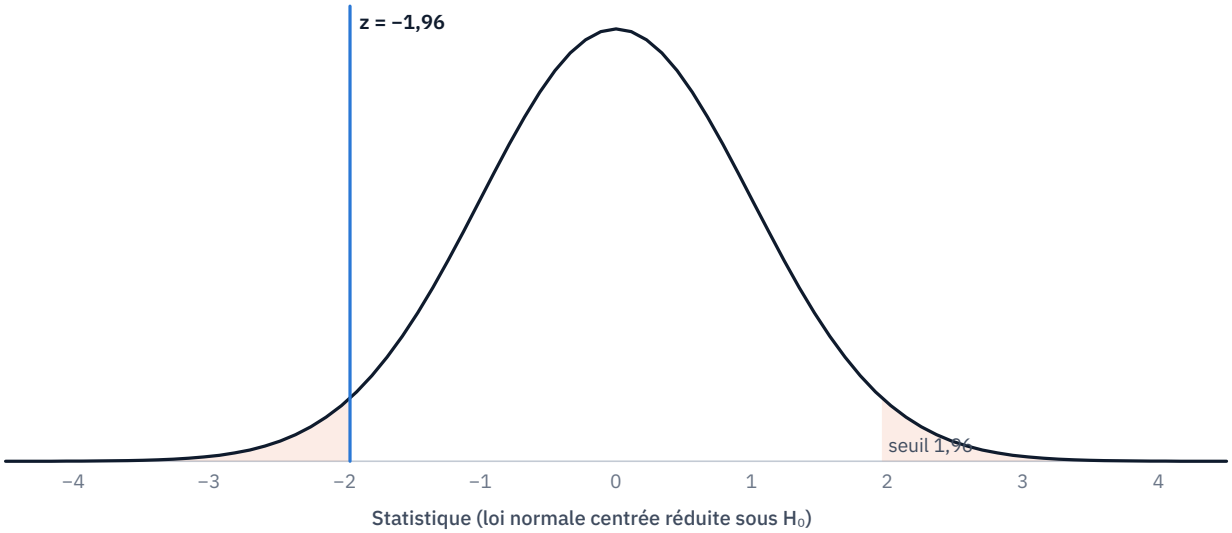
EXPLICATION

Le calcul. Les deux estimations reposent sur des familles différentes : `twoboys` exploite les familles dont l'aîné est un garçon, `twogirls` celles dont l'aînée est une fille. On peut les traiter comme à peu près indépendantes ; la variance de leur différence est alors la somme des deux variances.

$$\text{erreur-type de l'écart} = \sqrt{2{,}02^2 + 1{,}55^2} = 2{,}55 \qquad z = \frac{-8{,}61 - (-3{,}61)}{2{,}55} = -1{,}96$$

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : même effet estimé avec twoboys et avec twogirls.

Statistique −1,96, valeur critique à 5 % : 1,96 (en valeur absolue). La **p-valeur** est de 0,0499 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 5,0 % des cas.

On rejette H_0 au seuil de 5 %.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Comment interpréter un écart « à la limite » ? Deux lectures possibles.

- **L'un des instruments n'est pas valide.** Par exemple, un effet direct sur le travail de la mère qui n'existerait qu'avec deux garçons.
- **Les deux sont valides, mais l'effet n'est pas le même pour toutes les mères.** Chaque instrument mesure l'effet chez ses propres « compliers » : les familles qui ont un troisième enfant à cause de deux garçons ne sont pas les mêmes que celles qui en ont un à cause de deux filles. Les deux nombres peuvent alors différer sans qu'aucun instrument soit fautif.

Les données ne permettent pas de trancher entre ces deux lectures.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Formule simple, justifiée

Si les deux instruments sont valides et l'effet homogène, les deux régressions estiment le même paramètre. L'écart est de −5,0 semaines. Comme les deux estimations exploitent des familles différentes (aîné garçon ou fille), je les traite comme indépendantes : l'erreur-type de l'écart vaut $\sqrt{(2{,}02^2 + 1{,}55^2)} = 2{,}55$ et $z = -1{,}96$, à la limite du seuil de 5 %. L'écart est grand en valeur, mais à peine distinguable du hasard.

Covariance prise en compte

Les deux régressions utilisant les mêmes mères, je calcule l'erreur-type de l'écart en tenant compte de la covariance entre les deux estimateurs : 2,548, d'où $z = -1{,}961$ et $p = 0{,}0499$. L'écart est à la limite du seuil de 5 %.

2.11 Le test de suridentification

Cette question transforme la comparaison de la question 2.10 en un test formel. Avec **plus d'instruments que de variables endogènes**, le modèle est dit suridentifié : on a « un instrument de trop », et on peut s'en servir pour vérifier que les instruments se contredisent ou non.

(a) Le test, étape par étape

ÉNONCÉ (A)

Votre modèle de la question 2.8 compte plus d'instruments que de variables endogènes. Comment pouvez-vous en tirer parti pour évaluer la validité des instruments ? Mettez cette vérification en œuvre étape par étape (hypothèses, statistique, loi sous l'hypothèse nulle, décision) et concluez.

RÉPONSE

C'est le **test de suridentification** (test de Sargan, ou test J). H_0 : tous les instruments sont exogènes. Statistique : n × R^2 de la régression des résidus 2SLS sur tous les exogènes = **3,856**. Loi sous H_0 : khi-deux à 2 − 1 = **1** degré de liberté (valeur critique à 5 % : 3,84). p = **0,0496** : on **rejette H_0 à 5 %, de justesse**, mais pas à 1 %. Indice faible que les deux instruments ne racontent pas la même histoire.

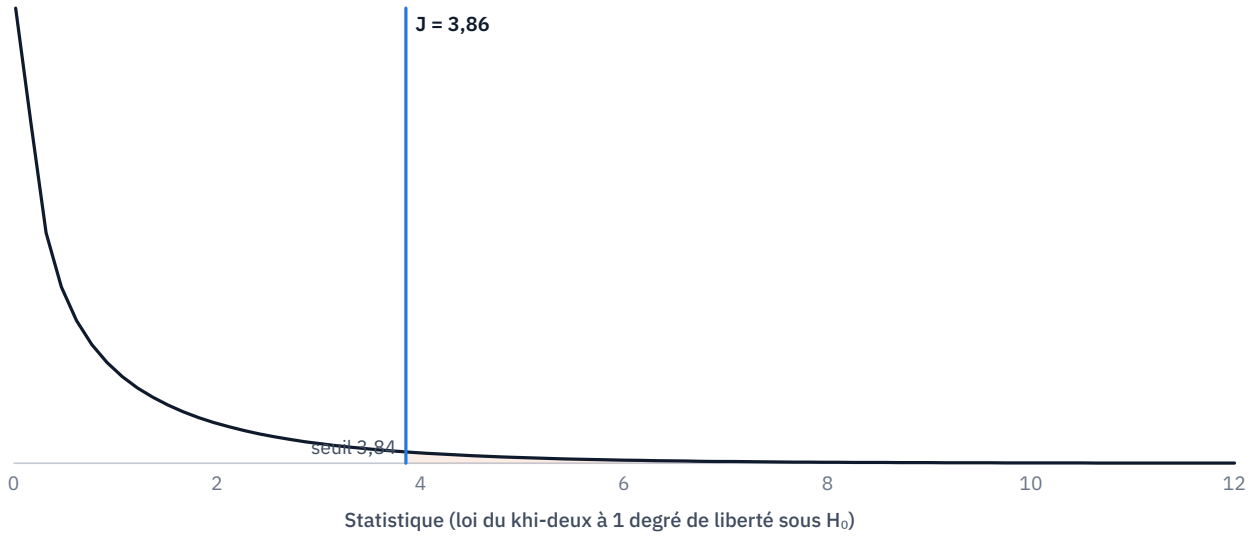
EXPLICATION

L'idée. Si les instruments sont valides, ils ne sont pas liés au terme d'erreur. Les résidus de la 2SLS, qui estiment ce terme d'erreur, ne devraient donc pas pouvoir être « expliqués » par les instruments.

1. **Hypothèses.** H_0 : tous les instruments sont exogènes. H_1 : au moins un instrument ne l'est pas.
2. **Résidus.** On estime la 2SLS et on calcule ses résidus, $\hat{u} = \text{work} - X\hat{\beta}$, avec le **vrai** `morekids` (pas sa prédiction).
3. **Régression auxiliaire.** On régresse $\hat{u}$ sur tous les exogènes : les deux instruments et les cinq contrôles.
4. **Statistique.** $S = n \times R^2$ de cette régression = 254 654 × 0,00001514 = **3,856**. (Le manuel de Stock et Watson l'écrit $J = m \times F$, où F teste les deux instruments dans cette régression : on obtient 3,856 aussi.)
5. **Loi sous H_0.** Khi-deux à $m - k$ degrés de liberté : nombre d'instruments (2) moins nombre de variables endogènes (1) = **1**.
6. **Décision.** Valeur critique à 5 % : 3,84. Or 3,856 > 3,84, et p = 0,0496 < 0,05 : on rejette H_0 à 5 %.

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : tous les instruments sont exogènes.

Statistique 3,86, valeur critique à 5 % : 3,84. La **p-valeur** est de 0,0496 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 5,0 % des cas.

On rejette H_0 au seuil de 5 %.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Comment conclure quand p = 0,0496 ? Avec honnêteté : on rejette au seuil de 5 %, mais de si peu que la conclusion basculerait avec un échantillon à peine différent. Ce n'est pas un verdict, c'est une **alerte**. Soit un instrument est invalide, soit l'effet diffère entre les mères concernées par chaque instrument (question 2.10 b).

⚠ NE PAS ARRONDIR AVANT DE DÉCIDER

Si tu arrondis la p-valeur à 0,05, tu ne sais plus de quel côté du seuil elle se trouve. Écris 0,0496.

CODE R

```r
fert$u_2sls <- resid(reg_2_8)                 # résidus 2SLS (avec le vrai morekids)
aux_2_11 <- lm(u_2sls ~ twoboys + twogirls + age + afam + hispanic + other + boy1st,
               data = fert)
sargan <- nrow(fert) * summary(aux_2_11)$r.squared     # 3,856
1 - pchisq(sargan, df = 1)                             # p = 0,0496
qchisq(0.95, df = 1)                                   # valeur critique : 3,84

summary(reg_2_8, diagnostics = TRUE)                   # même résultat, ligne "Sargan"
```

- `resid()` appliqué à un modèle `ivreg` renvoie les bons résidus, calculés avec le vrai `morekids`.
- `pchisq(x, df)` donne la probabilité qu'un khi-deux soit inférieur à `x` ; `1 - pchisq()` est donc la p-valeur.
- `summary(..., diagnostics = TRUE)` affiche d'un coup les trois diagnostics : force des instruments, Wu-Hausman (question 2.12) et Sargan.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Sargan par régression auxiliaire

H_0 : tous les instruments sont exogènes. Je régresse les résidus de la 2SLS sur les instruments et les contrôles ; $n \times R^2 = 3{,}856$ suit sous H_0 un khi-deux à $2 - 1 = 1$ degré de liberté. La valeur critique à 5 % est 3,84 et $p = 0{,}0496$: je rejette H_0 à 5 %, de justesse, mais pas à 1 %. C'est un indice faible que les deux instruments ne donnent pas la même réponse, à lire avec prudence ; ce test suppose l'homoscédasticité, et sa version robuste donne la même valeur.

J de Hansen robuste

Je calcule le test J de Hansen, robuste à l'hétéroscédasticité, par GMM en deux étapes : $J = 3{,}856$ avec un degré de liberté, $p = 0{,}0496$. On rejette tout juste à 5 %, pas à 1 %. Le Sargan classique donne la même valeur.

(b) Pourquoi impossible avec samegender seul ?

ÉNONCÉ (B)

Pourquoi cette vérification n'était-elle pas réalisable avec `samegender` comme seul instrument ?

RÉPONSE

Avec un instrument pour une variable endogène, le modèle est **juste identifié** : $m - k = 1 - 1 = \mathbf{0}$ degré de liberté. L'estimateur choisit le coefficient de façon que les résidus soient exactement non corrélés à l'instrument : il ne reste rien à tester.

EXPLICATION

Un seul instrument donne **une seule** estimation de l'effet. On n'a aucune autre estimation à laquelle la comparer.

Techniquement, l'estimateur par variables instrumentales est construit pour que la covariance entre l'instrument et les résidus soit **exactement nulle**. La régression auxiliaire aurait donc un R^2 de 0 par construction, et la statistique vaudrait toujours 0.

LA LIMITE DE FOND

On ne peut **jamais** tester l'exogénéité d'un instrument sans supposer qu'un autre instrument est valide. Le test de suridentification ne vérifie pas que les instruments sont valides : il vérifie qu'ils sont **cohérents entre eux**.

(c) Ce que le test peut et ne peut pas détecter

ÉNONCÉ (C)

`twoboys` et `twogirls` exploitent-ils des sources de variation réellement distinctes ? Qu'en déduisez-vous sur ce que cette vérification peut détecter et ne peut pas détecter ?

RÉPONSE

Oui et non. Ils portent sur deux groupes de familles distincts, mais ils exploitent **le même type** de variation : une fratrie de même sexe. Le test peut donc détecter une violation **propre à un seul** instrument, pas une violation **commune aux deux**. Un non-rejet ne prouverait jamais la validité des instruments.

EXPLICATION

- **Distinctes** : `twoboys` oppose garçon-garçon à garçon-fille parmi les familles dont l'aîné est un garçon ; `twogirls` oppose fille-fille à fille-garçon parmi les autres. Ce sont deux ensembles de familles disjoints.
- **Pas vraiment distinctes** : les deux reposent sur la même idée. Ils sont donc exposés aux **mêmes** violations. Les économies de chambre et de vêtements valent pour deux garçons comme pour deux filles.

Situation	Les deux instruments donnent…	Le test…
Effet direct seulement avec deux garçons	des estimations différentes	peut le détecter
Effet direct identique pour les deux compositions	la **même** estimation, fausse	**ne voit rien**

Si les deux instruments sont biaisés de la même façon, ils sont d'accord entre eux, et le test les déclare « cohérents ». C'est pourquoi il faut toujours défendre les instruments par un raisonnement, pas seulement par ce test.

QUESTIONS PROBABLES À L'ORAL

Que conclus-tu du test de Sargan ?

Il vérifie que les deux instruments donnent la même réponse. Il rejette de justesse à 5 %, avec une p-valeur de 0,0496, mais pas à 1 %. C'est un indice faible : soit un instrument est invalide, soit l'effet diffère selon les mères. Et il ne peut de toute façon pas détecter une violation commune aux deux instruments.

2.12 Les variables instrumentales étaient-elles nécessaires ?

Les MCO avec contrôles donnent −6,23 et la 2SLS −5,46. La différence est-elle réelle, ou n'est-elle que du bruit ? Si `morekids` est en fait exogène, les MCO sont justes **et** beaucoup plus précis : on aurait instrumenté pour rien.

(a) Le test d'endogénéité et l'estimateur retenu

ÉNONCÉ (A)

Au vu de vos résultats, le recours aux variables instrumentales était-il réellement nécessaire ? Proposez une procédure permettant de le vérifier formellement, mettez-la en œuvre étape par étape pour le modèle de la question 2.8 et indiquez quel estimateur vous retenez.

RÉPONSE

C'est le **test d'endogénéité de Hausman**. H_0 : `morekids` est exogène. On ajoute à la régression MCO le résidu de la première étape ; son coefficient vaut **−0,771** (erreur-type 1,232), t = **−0,63**, p = **0,53**. On **ne rejette pas** l'exogénéité : statistiquement, les MCO (−6,23) et la 2SLS (−5,46) ne se distinguent pas. Le choix de l'estimateur demande ensuite un jugement (voir les options ci-dessous).

EXPLICATION

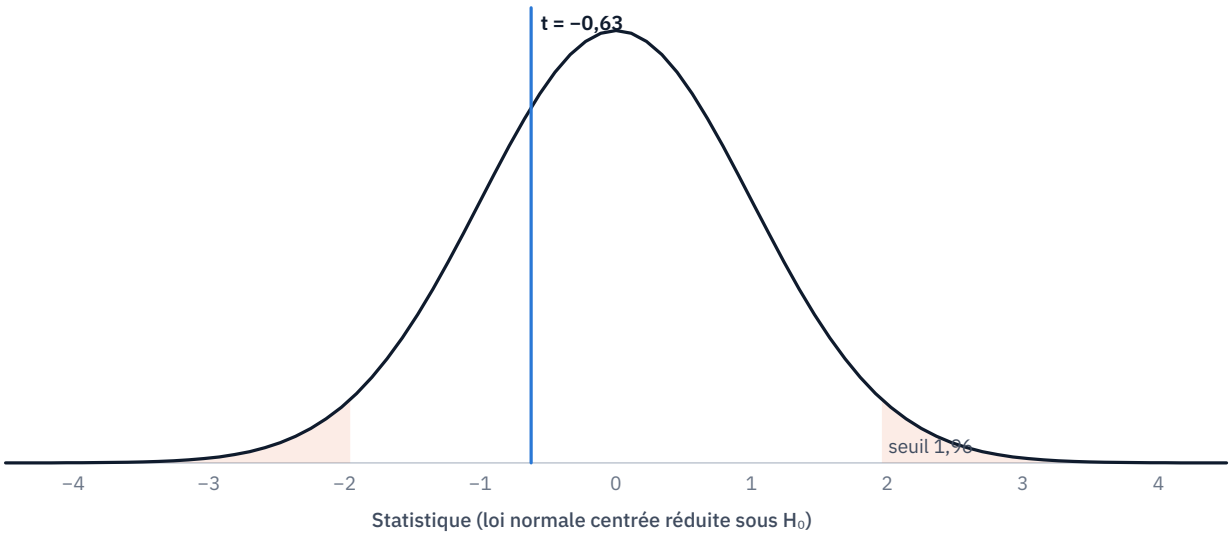
L'idée. Si `morekids` est exogène, MCO et 2SLS estiment tous deux le vrai effet, et ne diffèrent que par le hasard. S'il est endogène, seule la 2SLS est juste et les deux s'écartent. Le test demande donc : **l'écart entre −6,23 et −5,46 est-il plus grand que ce que le hasard explique ?**

La procédure (version « régression »).

1. **Hypothèses.** H_0 : `morekids` est exogène, $\text{Cov}(\text{morekids}, u) = 0$. H_1 : il est endogène.
2. **Première étape.** On reprend la régression de `morekids` de la question 2.8 et on garde ses **résidus** $\hat{v}$: la part de `morekids` que les instruments et les contrôles n'expliquent pas. C'est la partie « suspecte ».
3. **Régression augmentée.** On ajoute $\hat{v}$ à la régression MCO de `work`.
4. **Statistique.** Le t du coefficient de $\hat{v}$, avec erreur-type HC1. Sous H_0, il suit une loi normale.
5. **Résultat.** Coefficient −0,771, erreur-type 1,232, t = −0,63, p = 0,53.
6. **Décision.** On ne rejette pas H_0.

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : morekids est exogène (MCO et 2SLS estiment la même chose).

Statistique −0,63, valeur critique à 5 % : 1,96 (en valeur absolue). La **p-valeur** est de 0,53 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 53 % des cas.

On ne rejette pas H_0 au seuil de 5 %. Attention : ne pas rejeter ne prouve pas que H_0 est vraie, seulement que les données ne la contredisent pas assez.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Remarque que −0,771 est exactement l'écart entre les deux estimations : −6,231 − (−5,463) = −0,77.

Quel estimateur retenir ? C'est ici que les deux corrigés divergent, et qu'il te faut choisir.

- **L'argument pour les MCO.** Le test ne rejette pas l'exogénéité. Sous H_0, les MCO sont justes et **14 fois plus précis** (erreur-type 0,09 contre 1,23).
- **Les arguments pour la 2SLS.** Le test est **peu puissant** : avec une erreur-type de 1,23, il ne détecterait qu'un écart d'au moins 2,4 semaines. Ne pas rejeter l'exogénéité ne la prouve pas. Et les MCO sont **sensibles aux**

contrôles (−5,39 sans, −6,23 avec, −8,05 dans l'article, qui contrôle aussi l'âge à la première naissance), alors que la VI reste stable (−6,31, −5,82, −5,46).

Les deux positions se défendent. L'important est d'en choisir une, de la justifier, et de rester cohérent avec ta conclusion de la question 2.14 (d).

CODE R

```r
fert$v_hat <- resid(reg_2_8_fs)                # résidus de la première étape
reg_2_12 <- lm(work ~ morekids + age + afam + hispanic + other + boy1st + v_hat, data = fert)
rob(reg_2_12)["v_hat", ]                       # -0,771 (1,232), t = -0,63, p = 0,53

summary(reg_2_8, diagnostics = TRUE)           # ligne "Wu-Hausman" : F = 0,39 = t², p = 0,53
```

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Retenir la 2SLS, malgré le non-rejet

Le test de Hausman ne rejette pas l'exogénéité de morekids (t = −0,63, p = 0,53) : statistiquement, les MCO (−6,23) et la 2SLS (−5,46) ne se distinguent pas. Je retiens néanmoins la 2SLS, pour deux raisons : le test est peu puissant (il ne détecterait qu'un écart d'environ 2,4 semaines), et les MCO varient fortement selon les contrôles (de −5,4 à −8,1 dans l'article) alors que la VI reste stable. Le non-rejet ne prouve pas l'exogénéité.

Retenir les MCO, comme le veut le test

Le test de Hausman ne rejette pas l'exogénéité de morekids (t = −0,63, p = 0,53). Sous cette hypothèse, les MCO sont convergents et bien plus précis : je retiens les MCO avec contrôles (−6,23 semaines, erreur-type 0,09), en signalant que la 2SLS donne un ordre de grandeur proche (−5,46).

Rapporter les deux, en disant ce que chacune mesure

Le test ne rejette pas l'exogénéité (p = 0,53) : rien n'oblige statistiquement à préférer la 2SLS. Je présente donc les deux estimations. Les MCO (−6,23) décrivent précisément l'écart entre mères à caractéristiques égales ; la 2SLS (−5,46) est la seule qui repose sur une variation due au hasard, au prix d'une forte imprécision.

(b) Sur quelle hypothèse repose la conclusion ?

ÉNONCÉ (B)

Sur quelle hypothèse repose votre conclusion ? Que vous apprend à ce sujet la question 2.11 ?

RÉPONSE

Le test de Hausman suppose que **les instruments sont valides**. Il compare un estimateur juste sous H_0 seulement (les MCO) à un estimateur censé être toujours juste (la 2SLS). Or la question 2.11 jette un doute sur cette validité : le test de suridentification rejette, de justesse, à 5 %. La conclusion du test de Hausman est donc **fragile**.

EXPLICATION

Le test prend la 2SLS comme **étalon**. Si l'étalon est faussé, la comparaison ne veut plus rien dire : un écart nul entre MCO et 2SLS pourrait venir de deux estimateurs biaisés de la même façon.

Test	Ce qu'il suppose	Ce qu'il conclut
Suridentification (2.11)	au moins un instrument valide	rejet de justesse à 5 % : les instruments ne sont peut-être pas cohérents
Hausman (2.12)	**tous** les instruments valides	non-rejet : MCO et 2SLS ne se distinguent pas

Les deux tests ne répondent pas à la même question, et le second repose sur ce que le premier met en doute. S'ajoute un point plus subtil : si l'effet varie d'une mère à l'autre, MCO et 2SLS n'estiment de toute façon pas le même paramètre (la 2SLS mesure l'effet chez les « compliers »).

LA LEÇON À EMPORTER

Aucun test ne valide une stratégie d'identification à lui seul. Chacun repose sur des hypothèses que les données ne peuvent pas toutes vérifier.

QUESTIONS PROBABLES À L'ORAL

Quelle est la différence entre le test de Sargan et le test de Hausman ?
Ils n'ont pas la même hypothèse nulle. Sargan teste si les instruments sont cohérents entre eux, donc leur validité. Hausman teste si le régresseur est exogène, en supposant que les instruments sont valides. Ici, l'un rejette de justesse (p = 0,0496) et l'autre ne rejette pas (p = 0,53).

E. MARGE EXTENSIVE ET CONCLUSION

2.13 Travailler ou non : la marge extensive

Les 5,5 semaines perdues viennent-elles de mères qui travaillent **un peu moins**, ou de mères qui **arrêtent complètement** ? La distribution à deux pics de la question 2.1 laissait deviner la réponse.

(a) Avoir travaillé au moins une semaine

ÉNONCÉ (A)

Créez `travaille`, qui vaut 1 si la mère a travaillé au moins une semaine en 1979 (`work` > 0), 0 sinon. Estimez le modèle de la question 2.8 avec `travaille` comme variable dépendante, par les MCO puis par les doubles moindres carrés (2SLS). Interprétez le coefficient de `morekids` et comparez-le à l'article.

RÉPONSE

MCO : **–0,129** (0,002). 2SLS : **–0,119** (0,028). Selon la 2SLS, un troisième enfant réduit de **11,9 points de pourcentage** la probabilité que la mère ait travaillé (IC à 95 % : 6,4 à 17,4 points). Notre 2SLS est presque identique à celle de l'article (12,0 points) ; nos MCO (12,9 points) sont moins négatifs que les siens (16,7), parce que l'article contrôle aussi l'âge de la mère à la première naissance.

EXPLICATION

`travaille` vaut 0 ou 1 : c'est un modèle de probabilité linéaire, et le coefficient se lit en **points de probabilité**. Pour situer l'ordre de grandeur, 57,2 % des mères de deux enfants ont travaillé en 1979 : une baisse de 12 points est considérable.

	Nos estimations	Article (Angrist et Evans)
MCO	−0,129 (0,002)	−0,167
2SLS	−0,119 (0,028)	−0,120

Pourquoi nos MCO diffèrent de ceux de l'article, et pas notre 2SLS ? L'article contrôle l'âge à la première naissance, absent de notre fichier. À âge donné, une mère qui a commencé tôt a des enfants plus grands : elle travaille davantage **et** a plus souvent un troisième enfant. Omettre cette variable tire nos MCO vers zéro. La VI n'est pas touchée, puisque l'instrument est indépendant de l'âge à la première naissance.

C'est la leçon de la question 2.7, une troisième fois : **la VI est robuste au choix des contrôles, pas les MCO.**

CODE R

```
reg_2_13_mco <- lm(travaille ~ morekids + age + afam + hispanic + other + boy1st, data = fert)
reg_2_13_vi  <- ivreg(travaille ~ morekids + age + afam + hispanic + other + boy1st |
                        twoboys + twogirls + age + afam + hispanic + other + boy1st, data = fert)
rob(reg_2_13_mco)["morekids", ]; rob(reg_2_13_vi)["morekids", ]
```

Même modèle qu'à la question 2.8 : seule la variable dépendante change.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Comparer aux deux chiffres de l'énoncé

Selon la 2SLS, un troisième enfant réduit de 11,9 points la probabilité que la mère ait travaillé en 1979 (IC à 95 % : 6,4 à 17,4), à rapprocher des 57 % de mères de deux enfants qui ont travaillé. C'est presque exactement le résultat de l'article (12,0 points). Nos MCO (12,9 points) sont moins négatifs que les siens (16,7) parce que nous ne pouvons pas contrôler l'âge à la première naissance ; la VI n'en est pas affectée.

Comparer aux trois chiffres du tableau 7

La baisse est de 12,85 points en MCO et de 11,90 points en 2SLS. Le tableau 7 de l'article donne −16,7 points en MCO, −12,0 avec samegender et −11,3 avec les deux instruments. (À vérifier dans l'article avant de citer −11,3.)

(b) Quelle part vient de l'arrêt complet du travail ?

ÉNONCÉ (B)

Combien de semaines les mères de deux enfants qui ont travaillé en 1979 ont-elles travaillé en moyenne ? Combinez ce chiffre avec votre estimation 2SLS en (a) pour évaluer approximativement quelle part de l'effet sur les semaines travaillées (question 2.8) s'explique par des mères qui cessent complètement de travailler. Quelle hypothèse faites-vous dans ce calcul ?

RÉPONSE

Les mères de deux enfants qui ont travaillé l'ont fait **36,8 semaines** en moyenne. Semaines perdues par l'arrêt complet : 0,119 × 36,8 = **4,38**. Rapportées à l'effet total de 5,46 semaines : environ **80 %**. Hypothèse : les mères qui arrêtent à cause du troisième enfant auraient sinon travaillé autant que la moyenne des mères actives de deux enfants.

EXPLICATION

L'effet total sur les semaines (−5,46) a deux composantes.

- **La marge extensive** : des mères passent de « travaille » à « ne travaille plus ». Chacune perd toutes ses semaines.
- **La marge intensive** : des mères continuent de travailler, mais moins de semaines.

Le calcul de la première :

Étape	Valeur
Semaines moyennes des mères de deux enfants qui ont travaillé	36,8
Effet 2SLS sur la probabilité de travailler	−0,119
Semaines perdues par l'arrêt complet : 0,119 × 36,8	−4,38
Effet 2SLS total sur les semaines (question 2.8)	−5,46
Part due à l'arrêt complet : 4,38 / 5,46	**80 %**

Lecture : sur 100 mères « poussées » vers un troisième enfant, environ 12 cessent de travailler. Si chacune travaillait 36,8 semaines, cela fait 4,4 semaines perdues par mère en moyenne, sur les 5,5 au total. Les 20 % restants viennent de mères qui continuent à travailler, mais moins.

L'hypothèse, et pourquoi elle est discutable. On suppose que les mères qui arrêtent auraient travaillé 36,8 semaines, comme la mère active moyenne. Or ce sont justement les mères « à la marge », sans doute **moins attachées au travail** que la moyenne : elles auraient probablement travaillé moins. Si c'est le cas, 80 % **surestime** la part de l'arrêt complet : c'est plutôt une borne haute.

CODE R

```
sem_travail <- mean(fert$work[fert$morekids == 0 & fert$work > 0])       # 36,8
coef(reg_2_13_vi)["morekids"] * sem_travail                              # -4,38
coef(reg_2_13_vi)["morekids"] * sem_travail / coef(reg_2_8)["morekids"]  # 0,80
```

`fert$work[condition]` ne garde que les valeurs de `work` pour les mères qui vérifient la condition : deux enfants **et** au moins une semaine travaillée.

QUESTIONS PROBABLES À L'ORAL

Comment arrives-tu à 80 % ?

Je multiplie la baisse de la probabilité de travailler, 0,119, par le nombre de semaines des mères actives de deux enfants, 36,8 : cela donne 4,4 semaines perdues par l'arrêt complet, sur un effet total de 5,5. Je suppose que les mères qui arrêtent auraient travaillé autant que la moyenne des actives, ce qui est sans doute optimiste : 80 % est une borne haute.

2.14 Conclure : un effet causal, pour qui ?

La dernière question rassemble tout. Elle demande ce qu'il faut croire pour lire −5,46 comme un effet causal, ce qui plaide pour et contre, et à qui ce chiffre s'applique.

Pour quelles mères l'effet est-il mesuré ? Les « compliers »

Sous l'hypothèse de monotonie, les mères se répartissent en trois groupes selon leur réaction à l'instrument. La VI ne mesure l'effet que pour le groupe du milieu.



- « Never-takers » : pas de 3e enfant, quel que soit le sexe des deux premiers (58,6 %)
- « Compliers » : un 3e enfant seulement parce que les deux premiers sont de même sexe (6,8 %)
- « Always-takers » : un 3e enfant de toute façon (34,6 %)

Instrument : deux enfants de même sexe. Sans l'instrument, 34,6 % des mères ont un 3e enfant : ce sont les « always-takers ». Avec, 41,4 % : les 58,6 % restants sont les « never-takers ». La différence, **6,8 %**, ce sont les compliers — et c'est aussi la première étape.

L'estimation VI est l'effet moyen *pour ces mères-là* (un effet local, « LATE »). On ne peut pas les identifier une à une, et rien ne garantit que l'effet soit le même pour les autres. Change d'instrument : la part et la composition des compliers changent, ce qui peut expliquer que `twoboys` et `twogirls` ne donnent pas la même estimation.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

(a) Les conditions d'une interprétation causale

ÉNONCÉ (A)

Rappelez les conditions sous lesquelles votre estimation de la question 2.8 mesure l'effet causal d'un troisième enfant sur le travail de la mère.

RÉPONSE

1. **Pertinence** : `twoboys` et `twogirls` modifient la probabilité d'un troisième enfant. 2. **Indépendance** : la composition de la fratrie est comme tirée au sort. 3. **Exclusion** : elle n'agit sur le travail de la mère que par le troisième enfant. 4. **Monotonie** : aucune famille ne fait l'inverse (un troisième enfant avec une fratrie mixte, mais pas avec deux enfants de même sexe).

EXPLICATION

Les trois premières sont celles de la question 2.3 : la pertinence, et les deux moitiés de l'exogénéité. La quatrième est nouvelle.

La monotonie. L'instrument doit pousser **tout le monde dans le même sens**, ou ne rien changer. Elle permet d'interpréter l'estimation comme un effet moyen chez les « compliers » (question c). Sans elle, les familles qui réagissent à l'envers brouilleraient la division de Wald.

(b) Pour et contre, condition par condition

ÉNONCÉ (B)

Pour chacune, rassemblez les éléments qui plaident pour et contre, en vous appuyant sur vos résultats et sur les éléments de l'article présentés au début de cette partie.

RÉPONSE

La **pertinence** est établie (F = 658). L'**indépendance** est très plausible (le sexe est dû au hasard, les mères se ressemblent, la VI ne bouge pas avec les contrôles). L'**exclusion** est le point faible (économies de coût, implication du père, test de Sargan à p = 0,0496), même si l'article ne trouve qu'un écart de 2 % en tenant compte du sexe de chaque enfant. La **monotonie** est plausible.

EXPLICATION

Condition	Pour	Contre
Pertinence	F de première étape = 658 ; +5,8 et +7,8 points pour deux garçons et deux filles ; mêmes ordres de grandeur que l'article (34,6 % et 41,4 %).	Rien de sérieux. L'instrument explique peu de variance (0,5 %), mais il est fort vu la taille de l'échantillon.
Indépendance	Le sexe à la naissance est dû au hasard ; âge et origine équilibrés (2.3 c) ; la VI bouge à peine avec les contrôles (2.7 c) ; l'article trouve aussi le même âge à la première naissance et les mêmes études.	L'échantillon ne garde que des femmes **mariées**. Si le sexe des enfants influence le divorce, les mères encore mariées sont sélectionnées selon la composition de la fratrie.
Exclusion	L'article : tenir compte du sexe de chaque enfant ne change les résultats que de 2 % au plus ; pratiquement aucun effet sur le travail des pères ; `boy1st` n'a aucun effet propre (−0,01 semaine).	Économies de chambre et de vêtements, implication du père auprès des garçons (2.3 b, 2.9) ; le test de Sargan rejette à 5 % (p = 0,0496) ; les deux instruments donnent −8,6 et −3,6 semaines.
Monotonie	La préférence pour la mixité pousse toujours dans le même sens ; les deux premières étapes sont positives.	Quelques parents qui voudraient deux enfants du même sexe pourraient faire l'inverse ; ce cas semble rare, et une moyenne positive ne l'exclut pas.

Pour chaque ligne, tu dois pouvoir citer **un résultat à toi** et **un élément de l'article**. C'est ce que demande l'énoncé.

(c) Pour quelles mères ?

ÉNONCÉ (C)

Pour quelles mères l'effet est-il estimé ? Peut-on l'étendre à toutes les mères, ou à d'autres pays et d'autres époques ?

RÉPONSE

Pour les **« compliers »** : les mères qui ont eu un troisième enfant *parce que* les deux premiers étaient de même sexe, et qui ne l'auraient pas eu sinon (environ 7 % des mères). C'est un **effet local** (LATE). On ne peut l'étendre à toutes les mères que par hypothèse, et à d'autres pays ou époques qu'avec prudence.

EXPLICATION

L'outil en haut de la page montre les trois groupes.

- Les **« always-takers »** auraient eu un troisième enfant de toute façon : l'instrument ne change rien pour elles.
- Les **« never-takers »** n'en auraient eu en aucun cas : idem.
- Les **« compliers »** sont les seules dont le comportement change avec l'instrument. La VI ne « voit » que celles-là.

Peut-on généraliser ?

- **À toutes les mères** : pas sans hypothèse supplémentaire. Les mères qui veulent de toute façon une grande famille sont sans doute moins attachées au marché du travail ; l'effet peut être différent pour elles. L'article trouve d'ailleurs un effet plus faible chez les plus diplômées et chez celles dont le mari gagne le plus.
- **À d'autres pays ou époques** : avec prudence. Ce sont des mères américaines **mariées**, de 21 à 35 ans, en 1979, dans un pays où une mère sur deux ne travaillait pas, sans congé parental généralisé et avec peu de garde d'enfants subventionnée. En Belgique aujourd'hui, l'effet pourrait être plus faible, ou passer davantage par une réduction du temps de travail que par l'arrêt complet.
- **À d'autres naissances** : c'est l'effet d'un **troisième** enfant, pas d'un premier ou d'un deuxième.

(d) L'estimation retenue et la conclusion

ÉNONCÉ (D)

Quelle estimation retenez-vous, et que concluez-vous, en trois phrases au plus ?

RÉPONSE

Je retiens l'estimation **2SLS** : un troisième enfant réduit le travail de la mère d'environ **5,5 semaines par an** (IC à 95 % : 3 à 8 semaines) et sa probabilité de travailler de 12 points, l'essentiel de l'effet venant de mères qui cessent complètement de travailler. Les MCO donnent un ordre de grandeur proche (−6,2 semaines), mais seule la VI repose sur une variation due au hasard, et elle reste stable quand on ajoute des contrôles. Cette conclusion vaut pour les mères américaines de 1980 qui ont eu un troisième enfant à cause du sexe des deux premiers, et le test de suridentification, à la limite du seuil, invite à la lire comme un ordre de grandeur.

EXPLICATION

Même plan que pour la conclusion de la partie 1 : **le résultat chiffré**, **ce qui le rend crédible**, **ses limites**.

Vérifie la cohérence avec ta réponse à la question 2.12 (a). Si tu y as retenu les MCO, ta conclusion doit commencer par −6,2 semaines et dire que la 2SLS confirme l'ordre de grandeur. Si tu y as retenu la 2SLS, garde la version ci-dessus.

Pourquoi la 2SLS, alors que le test de Hausman ne rejetait pas ? Parce que ce test, peu puissant, ne prouve pas l'exogénéité, et que les MCO varient de −5,4 à −8,1 selon les contrôles alors que la VI ne bouge presque pas. Suivre strictement le test et retenir les MCO se défend aussi : l'essentiel est de justifier ton choix et d'en donner les limites.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

2SLS, avec ses raisons et ses limites

Je retiens l'estimation 2SLS : un troisième enfant réduit le travail de la mère d'environ 5,5 semaines par an (IC à 95 % : 3 à 8 semaines) et sa probabilité de travailler de 12 points, l'essentiel venant de mères qui cessent complètement de travailler. Les MCO donnent un ordre de grandeur proche (−6,2 semaines), mais seule la VI repose sur une variation due au hasard et reste stable quand on ajoute des contrôles. Cette conclusion vaut pour les mères américaines de 1980 qui ont eu un troisième enfant à cause du sexe des deux premiers, et le test de suridentification, à la limite du seuil, invite à la lire comme un ordre de grandeur.

2SLS de référence, MCO en parallèle

Je retiens −5,46 semaines (IC à 95 % : −7,87 à −3,05) comme estimation de référence pour les familles dont la décision réagit aux instruments, sous les hypothèses de validité. La baisse de la probabilité de travailler atteint 11,9 points. Le rejet limite du test de suridentification et le non-rejet du test d'endogénéité invitent à présenter aussi les MCO ajustés (−6,23) et à rester prudent sur l'interprétation causale.

À RETENIR

- Quatre conditions : pertinence (testée), indépendance (plausible), exclusion (le point faible), monotonie.
- L'effet est local : il vaut pour les compliers, environ 7 % des mères.
- 2SLS : −5,5 semaines et −12 points de probabilité de travailler ; environ 80 % de l'effet passe par l'arrêt complet.
- Sargan rejette de justesse (p = 0,0496), Hausman ne rejette pas (p = 0,53) : aucun des deux n'est une preuve.

QUESTIONS PROBABLES À L'ORAL

Qui sont les compliers ?

Les mères qui ont eu un troisième enfant parce que les deux premiers étaient de même sexe, et qui ne l'auraient pas eu avec un garçon et une fille. Elles représentent environ 7 % de l'échantillon. La VI mesure l'effet pour elles seulement.

Si tu devais résumer la partie 2 en une phrase ?

Un troisième enfant réduit le travail de la mère d'environ cinq semaines et demie par an, surtout par l'arrêt complet du travail ; ce chiffre repose sur l'hypothèse que le sexe des deux premiers enfants n'agit sur le travail que par le troisième enfant, et ne vaut que pour les mères dont la décision dépend de ce sexe.

PARTIE 3

Électrification au Burkina Faso

Différences-en-différences

Raccorder un village au réseau électrique coûte cher, et très peu de ménages s'y branchent. Le réseau change-t-il quand même quelque chose pour la localité tout entière ?

Le contexte

Au Burkina Faso, en 2014, seuls 4,7 % des ménages ruraux avaient l'électricité. Si l'on ne regarde que les ménages raccordés, l'extension du réseau paraît peu rentable. Mais une partie des bénéfices peut se situer **au niveau de la communauté** : éclairage public, écoles électrifiées, pompes à eau. Schmidt et Moradi (2026) mesurent ces effets sur un panel de localités raccordées entre 2008 et 2017. Tu répliques ici leur estimation la plus simple.

L'idée de la double différence

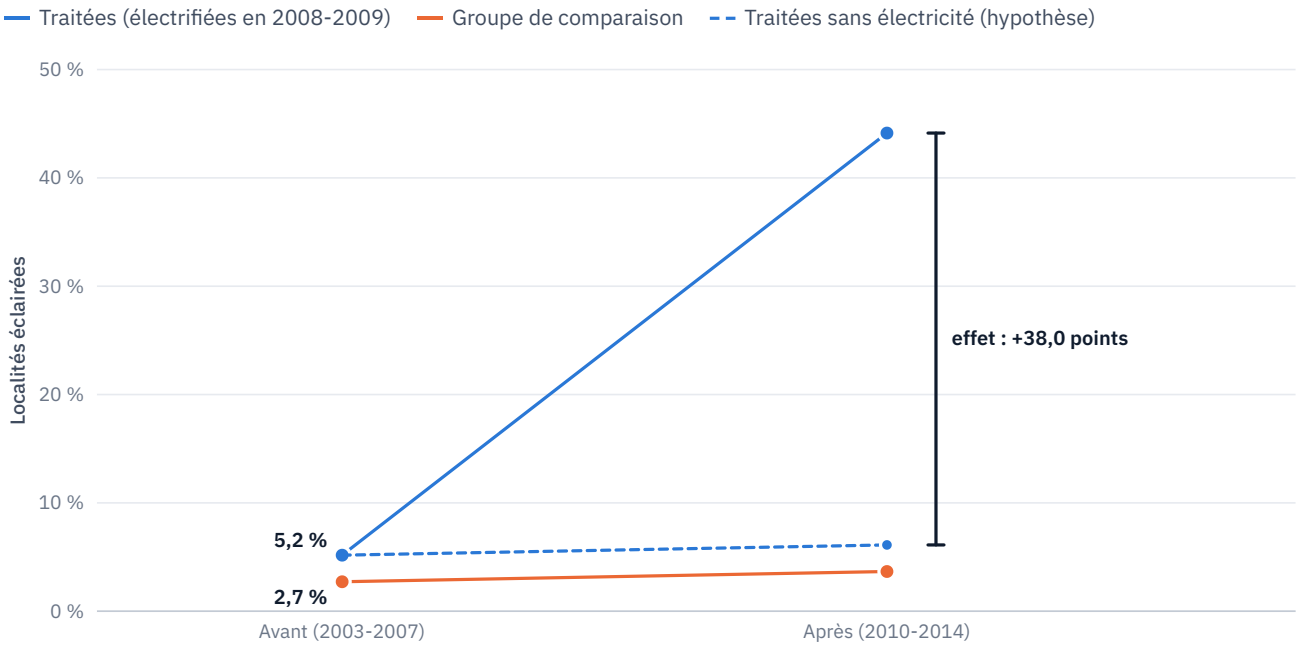
Certaines localités ont été raccordées tôt (2008-2009), d'autres tard (2015-2017). On compare **l'évolution** des premières à celle des secondes entre 2003-2007 et 2010-2014.

$$\text{DD} = (\bar{y}_{T,\,\text{après}} - \bar{y}_{T,\,\text{avant}}) - (\bar{y}_{C,\,\text{après}} - \bar{y}_{C,\,\text{avant}})$$

La première différence retire ce qui distingue durablement les deux groupes. La seconde retire ce qui change pour tout le monde. Il reste ce qui change **seulement pour les localités raccordées, seulement après**.

La double différence, pas à pas

Part des localités dont la lumière est détectée par satellite (`nl_extensive`). Passe d'une comparaison naïve à la double différence, puis change le groupe de comparaison pour voir ce qui se passe quand il est mal choisi.



③ **Double différence** : (44,1 − 5,2) − (3,7 − 2,7) = 39,0 − 0,9 = **+38,0 points**. La ligne en tirets est ce qu'auraient fait les traitées sans électricité *si* elles avaient suivi la même évolution que le groupe de comparaison (tendances parallèles) : 6,1 % au lieu des 44,1 % observés.

	Avant (2003-2007)	Après (2010-2014)	Variation
Traitées (59 localités)	5,17 %	44,14 %	+38,97 points
Comparaison (238 localités)	2,72 %	3,66 %	+0,95 point
Écart traitées – comparaison	+2,45 points	+40,47 points	**+38,02 points**

Coefficient de treated × post
0,3802
2 866 observations

Erreur-type robuste HC1
0,0328
t = 11,6

Erreur-type groupée par localité
0,0442
288 localités, t = 8,6

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Les données

`elec_data.dta` : un panel annuel de localités du Burkina Faso.

Variable	Ce qu'elle mesure
`electrific`	identifiant de la localité
`year`	année d'observation
`year_of_el`	année où la localité a été raccordée
`nl_extensive`	1 si une lumière nocturne est détectée par satellite, 0 sinon
`nl_intensive_hat`	quantité de lumière, pour les localités éclairées au moins une fois

Variable	Ce qu'elle mesure
`nschool_elec`	nombre d'écoles primaires ayant l'électricité
`n_students_public`	nombre d'élèves des écoles primaires publiques
`region_num`	région administrative

Le chemin

Étape	Questions	L'idée à retenir
A. Données et groupes	3.1, 3.2	Qui est traité, qui sert de comparaison, quelles années on garde, et pourquoi.
B. De la différence simple à la double	3.3 à 3.5	Chaque comparaison naïve a son biais ; la double différence retire les deux.
C. Tendances parallèles	3.6	L'hypothèse dont tout dépend, et ce qui peut la mettre en défaut.
D. Effets fixes et erreurs-types	3.7, 3.8	La même estimation écrite autrement, et sa vraie précision.
E. Conclusion	3.9	Plus de lumière ne veut pas dire plus d'activité économique.

Le résultat en une phrase

L'arrivée du réseau augmente de **38 points de pourcentage** la part des localités visibles de nuit (de 5 % à 44 %). L'effet estimé sur les écoles électrifiées est positif mais fragile, et rien n'apparaît sur le nombre d'élèves.

A. DONNÉES ET GROUPES

3.1 Décrire le panel

ÉNONCÉ

Ne gardez que les années 2003 à 2014.

(a) Unité statistique et dimensions

ÉNONCÉ (A)

Quelle est l'unité statistique ? Combien de localités différentes contient l'échantillon, et sur combien d'années ?

RÉPONSE

L'unité statistique est **une localité observée une année donnée**. L'échantillon contient **574 localités** suivies pendant **12 ans** (2003-2014), soit 6 888 observations. C'est un panel.

EXPLICATION

Dans les parties 1 et 2, chaque unité n'apparaissait qu'une fois. Ici la même localité revient **douze fois**, une fois par an. On distingue donc :

- le nombre de **lignes** : 6 888 ;
- le nombre de **localités** : 574 ;

- le nombre d'**années** : 12.

574 × 12 = 6 888 : chaque localité a bien une ligne par année. Mais avoir une ligne ne garantit pas que toutes les variables y soient renseignées : `nl_extensive` manque pour 16 à 18 localités selon l'année, et les deux variables scolaires s'arrêtent en 2012.

⚠ LA CONFUSION LA PLUS FRÉQUENTE À L'ORAL

« Combien d'observations ? » et « combien de localités ? » n'appellent pas la même réponse. Plus loin, la régression principale aura 2 866 observations pour 288 localités.

CODE R

```r
elec <- read_dta(file.path(dossier, "elec_data.dta")) %>%
  filter(year >= 2003, year <= 2014)

nrow(elec)                      # 6 888 lignes
n_distinct(elec$electrific)     # 574 localités
n_distinct(elec$year)           # 12 années
```

`read_dta()` (package `haven`) lit un fichier au format Stata. `n_distinct()` compte les valeurs différentes d'une colonne.

(b) Les localités avant l'arrivée du réseau

ÉNONCÉ (B)

Produisez au plus trois statistiques descriptives utiles pour comprendre les caractéristiques des localités avant l'expansion du réseau (avant 2008), et commentez-les.

RÉPONSE

Sur 2003-2007 : seulement **2,1 %** des observations localité-année ont une lumière détectée ; **0,33** école primaire électrifiée par localité en moyenne (médiane 0) ; **44 élèves** en moyenne dans le primaire public (médiane 40). Ce sont de petites localités rurales, presque toutes invisibles de nuit et presque sans électricité.

EXPLICATION

L'énoncé limite à trois statistiques : choisis-en une pour chaque résultat que tu étudieras ensuite.

Statistique, 2003-2007	Moyenne	Médiane	Ce qu'elle apprend
Lumière détectée (`nl_extensive`)	2,1 %	0	Avant 2008, ces localités sont presque toutes invisibles de nuit. Seules 3,8 % sont détectées au moins une fois en cinq ans.
Écoles primaires électrifiées	0,33	0	La variable vaut 0 dans deux observations sur trois : la plupart des localités n'ont aucune école électrifiée.
Élèves du primaire public	43,9	40	Une quarantaine d'élèves : en général une seule petite école.

Pourquoi c'est utile pour la suite : le niveau de départ de la lumière est **quasi nul**. Toute lumière détectée après le raccordement sera donc un changement net, facile à voir. Et un effet de +0,16 école électrifiée (question 3.5) se jugera par rapport à un niveau de départ de 0,33.

Un détail à garder en tête : quelques écoles ont déjà l'électricité **avant** l'arrivée du réseau. La source n'est pas connue (panneaux solaires ou groupes électrogènes, probablement).

✓ UNE CURIOSITÉ DE CETTE VARIABLE, À CONNAÎTRE AVANT LA QUESTION 3.5

La moyenne de 0,33 cache une rupture. De 2003 à 2005, on compte 0,37 à 0,69 école électrifiée par localité ; en 2006, 0,06. La part des localités ayant au moins une école électrifiée passe de 54 % en 2005 à 6 % en 2006.

Une chute aussi brutale, la même année dans tout l'échantillon, ressemble à un changement dans la façon dont la variable est relevée plutôt qu'à une vraie disparition. Aucun des deux corrigés ne le signale. La question 3.5 montre ce que cela change pour l'estimation.

CODE R

```r
avant <- elec %>% filter(year < 2008)
mean(avant$nl_extensive, na.rm = TRUE)         # 0,021
mean(avant$nschool_elec, na.rm = TRUE)         # 0,33
mean(avant$n_students_public, na.rm = TRUE)    # 43,9
median(avant$n_students_public, na.rm = TRUE)  # 40
```

`na.rm = TRUE` demande d'ignorer les valeurs manquantes ; sans cela, la moyenne d'une variable qui contient un seul `NA` vaut `NA`.

QUESTIONS PROBABLES À L'ORAL

Quelle est l'unité statistique de cette partie ?
Une localité observée une année donnée. Les mêmes localités sont suivies chaque année : c'est un panel. Il faut toujours distinguer le nombre d'observations du nombre de localités.

3.2 Groupe traité, groupe de comparaison, périodes

Toute double différence commence par quatre choix : qui est traité, qui sert de comparaison, quelle est la période « avant », quelle est la période « après ». Cette question te fait justifier chacun.

(a) Créer treated et post

ÉNONCÉ (A)

Créez une variable indicatrice de traitement, `treated`, valant 1 si une localité a été électrifiée en 2008 ou 2009, et 0 sinon. Créez également une variable indicatrice de période post-traitement, `post`, valant 1 si `year` > 2009, et 0 sinon.

RÉPONSE

`treated` = 1 pour les localités raccordées en 2008 ou 2009 : elle ne change jamais pour une localité donnée.
`post` = 1 pour les années 2010 et suivantes : elle ne dépend que de l'année.

EXPLICATION

Deux indicatrices de nature différente :

- `treated` décrit **la localité** : elle vaut la même chose sur ses douze lignes ;
- `post` décrit **l'année** : elle vaut la même chose pour toutes les localités une année donnée.

Leur produit `treated × post` vaut 1 uniquement pour une localité traitée, observée après. C'est lui qui portera l'effet.

CODE R

```
elec <- elec %>%
  mutate(treated = as.numeric(year_of_el %in% c(2008, 2009)),
         post    = as.numeric(year > 2009))
```

`%in%` teste l'appartenance à une liste : l'année de raccordement est-elle 2008 ou 2009 ?

(b) Combien de localités par groupe ?

ÉNONCÉ (B)

Ne gardez que les localités électrifiées en 2008 ou 2009 (groupe traité) et celles électrifiées entre 2015 et 2017 (groupe de comparaison), et supprimez les années 2008 et 2009. La période avant couvre donc 2003-2007 et la période après 2010-2014. Combien de localités compte chaque groupe ?

RÉPONSE

59 localités traitées (raccordées en 2008-2009) et **238 localités de comparaison** (raccordées en 2015-2017). Soit 297 localités × 10 années = 2 970 lignes, dont 2 866 avec une valeur de `nl_extensive` .

RÉSULTATS

Groupe	Année de raccordement	Localités	Lignes sur 10 ans	Lignes avec luminosité
Traité (`treated` = 1)	2008 ou 2009	59	590	580
Comparaison (`treated` = 0)	2015 à 2017	238	2 380	2 286

CODE R

```
deux_groupes <- elec %>% filter(treated == 1 | year_of_el %in% 2015:2017)
did <- deux_groupes %>% filter(!(year %in% c(2008, 2009)))

did %>% distinct(electrific, treated) %>% count(treated)    # 238 et 59
nrow(did)                                                   # 2 970
```

- `|` veut dire « ou » : on garde les traitées **ou** les localités raccordées en 2015-2017.
- `!` veut dire « non » : on retire les années 2008 et 2009.
- Pour compter des **localités** et non des lignes, on dédoublonne d'abord avec `distinct()` .

(c) Pourquoi supprimer 2008 et 2009 ?

ÉNONCÉ (C)

Pourquoi supprimer les années 2008 et 2009 ?

RÉPONSE

Parce que ce sont les années où les localités traitées sont **en train d'être raccordées** : elles ne sont ni clairement « avant » ni clairement « après ». Les garder mélangerait des observations traitées et non traitées dans la même période, et tirerait l'estimation vers zéro.

EXPLICATION

Une localité raccordée en décembre 2008 n'a pas d'électricité pendant onze mois de cette année-là. Une localité raccordée en 2009 est encore non traitée en 2008. Et même une fois la ligne arrivée, les premiers branchements et l'éclairage public prennent du temps.

Si l'on classait 2008-2009 dans « après », on y compterait des observations sans électricité : l'effet moyen serait dilué. Si on les classait dans « avant », on y compterait des observations déjà électrifiées : le niveau de départ serait gonflé. Dans les deux cas, l'effet est **sous-estimé**.

En les retirant, on obtient une période avant propre (2003-2007) et une période après propre (2010-2014).

(d) Le choix du groupe de comparaison

ÉNONCÉ (D)

Pourquoi ne pas utiliser comme groupe de comparaison les localités électrifiées entre 2010 et 2014 ? Pourquoi les auteurs n'utilisent-ils pas plutôt des localités jamais électrifiées ?

RÉPONSE

Pas celles de 2010-2014 : elles sont raccordées **pendant** la période « après ». Leur lumière augmente à cause de leur propre électrification ; le groupe de comparaison serait en partie traité et l'effet sous-estimé. **Pas celles jamais électrifiées** : elles diffèrent systématiquement (plus petites, plus isolées), donc leur évolution n'est pas un bon guide. Les localités raccordées en 2015-2017 ont passé la **même sélection** ; seul le calendrier les distingue.

EXPLICATION

Un bon groupe de comparaison doit remplir deux conditions.

1. **Ne pas être traité** pendant la période étudiée.
2. **Ressembler** au groupe traité, au point d'évoluer comme lui en l'absence de traitement.

Candidat	Condition 1	Condition 2
Raccordées en 2010-2014	**Non** : elles s'allument pendant la période « après »	oui
Jamais raccordées	oui	**Non** : l'État a choisi de ne pas les raccorder
Raccordées en 2015-2017	oui : encore sans réseau jusqu'en 2014	oui : retenues par le même programme

Dans l'outil de la page de présentation, choisis « Électrifiées en 2010-2014 » comme groupe de comparaison : la double différence tombe de +38,0 à +20,7 points. Près de la moitié de l'effet a disparu, parce qu'on retranche la hausse de lumière de localités elles-mêmes électrifiées (+18,3 points, au lieu de +0,9 pour le groupe de l'énoncé).

Sur les localités jamais raccordées. L'État a choisi lesquelles raccorder : des pôles de développement, des localités plus grandes ou plus proches du réseau existant. Celles qu'il n'a jamais retenues sont probablement plus petites, plus isolées, plus pauvres. Rien ne dit qu'elles auraient évolué comme les localités traitées.

Les localités « pas encore traitées » sont un choix courant en double différence : elles ont le même profil que les traitées, puisqu'elles finiront par l'être.

QUESTIONS PROBABLES À L'ORAL

Pourquoi ne pas prendre des localités jamais électrifiées comme témoins ?
Parce qu'elles n'ont pas été retenues par le programme : elles sont sans doute plus petites et plus isolées, et rien ne garantit qu'elles auraient évolué comme les traitées. Les localités raccordées en 2015-2017 ont passé la même sélection ; seul le calendrier change.

B. DE LA DIFFÉRENCE SIMPLE À LA DOUBLE DIFFÉRENCE

3.3 Deux comparaisons naïves

ÉNONCÉ

Pour `nl_extensive`, estimez par régression : (a) la différence entre localités traitées et localités de comparaison sur la seule période 2010-2014 ; (b) la différence entre la période après et la période avant pour les seules localités traitées. Interprétez chacune. Peut-on y voir l'effet de l'expansion du réseau électrique ? Pour chacune, décrivez le biais possible.

Avant la double différence, l'énoncé te fait estimer les deux comparaisons qu'on ferait spontanément, pour comprendre ce qui cloche dans chacune. Reprends l'outil de la page de présentation de la partie et passe de ① à ② à ③.

(a) Traitées contre comparaison, après

ÉNONCÉ (A)

La différence entre localités traitées et localités de comparaison sur la seule période 2010-2014.

RÉPONSE

+0,405 (erreur-type 0,030). Sur 2010-2014, la part des observations où la localité est visible de nuit est de 44,1 % chez les traitées, contre 3,7 % dans le groupe de comparaison : **40,5 points** d'écart. Ce n'est pas l'effet pur du réseau : la comparaison inclut les différences qui existaient **déjà avant** entre les deux groupes. C'est un **biais de sélection**.

EXPLICATION

Avec une seule indicatrice comme régresseur, la pente est une différence de moyennes (c'est la leçon de la question 2.2).

Le biais. Les localités raccordées en premier n'ont pas été tirées au sort. Elles sont peut-être plus grandes, plus proches du réseau, déjà un peu plus lumineuses. Et de fait : avant 2008, elles étaient éclairées dans 5,2 % des cas, contre 2,7 % pour les autres. Cet écart de départ de 2,5 points se retrouve dans les 40,5 points et les gonfle.

CODE R

```
reg_3_3a <- lm(nl_extensive ~ treated, data = filter(did, post == 1))
rob(reg_3_3a)
```

`filter(did, post == 1)` ne garde que les années 2010-2014.

(b) Après contre avant, chez les traitées

ÉNONCÉ (B)

La différence entre la période après et la période avant pour les seules localités traitées.

RÉPONSE

+0,390 (erreur-type 0,032). Chez les traitées, la part des observations éclairées passe de 5,2 % à 44,1 % : **+39,0 points**. Ce n'est pas non plus l'effet pur du réseau : la comparaison inclut **tout ce qui a changé avec le temps** pour toutes les localités. C'est un **biais de tendance**.

EXPLICATION

Le biais. Entre 2003-2007 et 2010-2014, beaucoup de choses ont changé au Burkina Faso, réseau ou pas : croissance démographique et économique, diffusion des lampes solaires, et surtout le passage à un satellite plus sensible (VIIRS). Tout cela peut augmenter la lumière détectée partout.

De fait, dans le groupe de comparaison, qui n'a pas reçu le réseau, la part éclairée a augmenté de 0,9 point sur la même période. Cette hausse « de fond » se retrouve dans les 39,0 points.

Les deux biais sont petits ici : 2,5 points pour le premier, 0,9 pour le second. Mais on ne le sait que grâce à la double différence, qui les mesure et les retire tous les deux.

RÉSULTATS

Comparaison	Coefficient	Erreur-type HC1	Ce qu'elle compare	Ce qu'elle contient en trop
(a) Traitées – comparaison, 2010-2014	0,405	0,030	44,1 % contre 3,7 %	l'écart initial entre groupes (2,5 points)
(b) Après – avant, traitées seulement	0,390	0,032	44,1 % contre 5,2 %	la tendance commune (0,9 point)

CODE R

```
reg_3_3b <- lm(nl_extensive ~ post, data = filter(did, treated == 1))
rob(reg_3_3b)
```

QUESTIONS PROBABLES À L'ORAL

Pourquoi 38 points et pas 40,5 ?

40,5 points, c'est l'écart entre les deux groupes après. Mais ils différaient déjà de 2,5 points avant. La double différence retire cet écart de départ : 40,5 – 2,5 = 38,0.

3.4 La double différence

On assemble les deux comparaisons en une seule : d'abord à la main, avec quatre moyennes, puis par une régression qui redonne exactement le même nombre.

(a) Quatre moyennes et une double soustraction

ÉNONCÉ (A)

Calculez les quatre moyennes de `nl_extensive` (groupe × période) et la double différence à partir de ces moyennes.

RÉPONSE

`nl_extensive`	Avant (2003-2007)	Après (2010-2014)	Variation
Traitées	0,0517	0,4414	+0,3897
Comparaison	0,0272	0,0366	+0,0095
Écart	+0,0245	+0,4047	**+0,3802**

Double différence : 0,3897 − 0,0095 = **0,3802**, soit **38,0 points de pourcentage**.

EXPLICATION

La double différence se lit dans les deux sens du tableau, et donne le même résultat.

- **Par lignes** : la variation des traitées moins celle du groupe de comparaison. 0,3897 − 0,0095 = 0,3802.
- **Par colonnes** : l'écart après moins l'écart avant. 0,4047 − 0,0245 = 0,3802.

Le raisonnement contrefactuel. Sans le réseau, qu'auraient fait les localités traitées ? On suppose qu'elles auraient suivi la même évolution que le groupe de comparaison : 5,17 % + 0,95 point = **6,1 %**. On observe 44,1 %. L'écart, 38,0 points, est l'effet attribué au réseau.

C'est la ligne en tirets de l'outil : la trajectoire que les traitées auraient suivie « si rien ne s'était passé ».

CODE R

```
did %>%
  group_by(treated, post) %>%
  summarise(moyenne = mean(nl_extensive, na.rm = TRUE),
            n_obs = sum(!is.na(nl_extensive)), .groups = "drop")

moy <- function(t, p) mean(did$nl_extensive[did$treated == t & did$post == p], na.rm = TRUE)
(moy(1, 1) - moy(1, 0)) - (moy(0, 1) - moy(0, 0))      # 0,3802
```

`group_by(treated, post)` forme les quatre cases ; `summarise()` calcule la moyenne dans chacune. La petite fonction `moy(t, p)` renvoie la moyenne d'une case.

(b) La régression et ses quatre coefficients

ÉNONCÉ (B)

Estimez la régression de `nl_extensive` sur `treated`, `post` et leur interaction. Interprétez chacun des quatre coefficients à l'aide des moyennes calculées en (a).

RÉPONSE

Coefficient	Valeur	Ce qu'il est
Constante β_0	0,0272	moyenne du groupe de comparaison, avant
`treated` β_1	0,0245	écart traitées – comparaison, avant
`post` β_2	0,0095	variation du groupe de comparaison
`treated × post` β_3	**0,3802**	**la double différence**

EXPLICATION

$$\text{nl_extensive} = \beta_0 + \beta_1\,\text{treated} + \beta_2\,\text{post} + \beta_3\,(\text{treated} \times \text{post}) + u$$

Remplace `treated` et `post` par leurs valeurs dans chaque case, comme pour les indicatrices de région.

Case	treated	post	Moyenne prédite
Comparaison, avant	0	0	β_0 = 0,0272
Traitées, avant	1	0	$\beta_0 + \beta_1$ = 0,0517
Comparaison, après	0	1	$\beta_0 + \beta_2$ = 0,0366
Traitées, après	1	1	$\beta_0 + \beta_1 + \beta_2 + \beta_3$ = 0,4414

Quatre cases, quatre coefficients : le modèle reproduit **exactement** les quatre moyennes.

- β_0 : avant 2008, 2,7 % des observations du groupe de comparaison sont éclairées.
- β_1 : avant 2008, les traitées le sont 2,5 points plus souvent. L'écart n'est pas significatif à 5 % (p = 0,08) : les deux groupes sont proches au départ.
- β_2 : dans le groupe de comparaison, la part éclairée augmente de 0,9 point (p = 0,20). C'est la **tendance commune**.
- β_3 : le raccordement augmente de **38 points** la probabilité qu'une localité soit visible de nuit, en moyenne sur 2010-2014 (t = 11,6).

Pourquoi passer par une régression si quatre moyennes suffisent ? Parce qu'elle donne l'**erreur-type** de la double différence, et qu'elle se prête aux extensions (effets fixes, question 3.7).

RÉSULTATS

	Coefficient	Erreur-type HC1	p-valeur
Constante	0,0272	0,0048	< 0,001
treated	0,0245	0,0139	0,077

	Coefficient	Erreur-type HC1	p-valeur
post	0,0095	0,0074	0,199
treated × post	0,3802	0,0328	< 0,001

2 866 observations.

CODE R

```
reg_3_4 <- lm(nl_extensive ~ treated * post, data = did)
rob(reg_3_4)
nobs(reg_3_4)      # 2 866 : R a écarté les 104 lignes sans mesure de lumière
```

`treated * post` développe en `treated + post + treated:post`. Le coefficient d'interaction s'appelle `treated:post` dans la sortie.

(c) Comparer à l'article

ÉNONCÉ (C)

Comparez votre estimation à celle de la colonne « DiD : TWFE » du tableau 4 de l'article.

RÉPONSE

Ton estimation : **0,380** (erreur-type groupée par localité : 0,044 à 0,047, voir la question 3.8). La valeur du tableau 4 est **à lire dans ta copie de l'article** : c'est le seul chiffre du travail que je n'ai pas pu vérifier. La comparaison doit porter sur trois points : le coefficient, l'erreur-type (groupée dans l'article), et les raisons d'un éventuel écart (période, échantillon, effets fixes).

EXPLICATION

✓ UN POINT OÙ LES DEUX CORRIGÉS NE SONT PAS D'ACCORD, ET QUE TU DOIS TRANCHER TOI-MÊME

- **ChatGPT** affirme que la colonne « DiD : TWFE » du tableau 4 donne **0,396 (erreur-type groupée 0,046)**, soit 1,6 point de plus que ton estimation.
- **Claude** dit ne pas avoir pu lire le tableau 4 de la version publiée (accès payant) et cite la version de travail de 2022, dont le tableau 7 (« Simple OLS DiD 2×2 ») donne **0,38 (0,05)** sur 297 localités, 59 traitées et 238 de comparaison.

L'article est derrière un accès payant et je n'ai pas pu lire le tableau non plus. J'ai en revanche essayé de **reproduire 0,396** avec le fichier fourni : avec une période « avant » commençant en 2002 et des effets fixes de localité et d'année, j'obtiens 0,380 avec une erreur-type groupée de 0,046. L'erreur-type coïncide avec celle que cite ChatGPT ; le coefficient, non. Aucune variante simple ne m'a donné 0,396.

Conclusion pratique : **ouvre l'article, lis la ligne « nightlight, extensive margin » de la colonne « DiD : TWFE », et recopie le coefficient, l'erreur-type et le nombre d'observations.** L'énoncé rend cette lecture obligatoire.

Comment rédiger la comparaison, quelle que soit la valeur lue.

1. **Le coefficient.** S'il vaut entre 0,38 et 0,40, ton estimation est très proche : même ordre de grandeur, même signe, même conclusion.

2. **L'erreur-type.** Les auteurs groupent leurs erreurs-types par localité. Compare donc à ton erreur-type **groupée** (0,044 pour le modèle 2×2, 0,047 avec effets fixes), pas à ton erreur-type HC1 (0,033), plus petite.
3. **Les raisons d'un écart.** L'énoncé fait commencer la période en 2003 ; l'article peut utiliser une période ou un échantillon légèrement différents. La colonne « TWFE » utilise des effets fixes de localité et d'année, qui donnent pratiquement le même coefficient que l'interaction (question 3.7).

RÉDACTION POSSIBLE POUR LE RAPPORT

À compléter après lecture du tableau 4

Mon estimation est de 0,380, avec une erreur-type groupée par localité de 0,044. La colonne « DiD : TWFE » du tableau 4 rapporte [valeur lue] ([erreur-type lue]). Les deux estimations sont [très proches / séparées de … point(s)]. Les auteurs utilisent des effets fixes de localité et d'année, qui donnent pratiquement le même coefficient que mon interaction (0,3800 contre 0,3802), et groupent leurs erreurs-types par localité ; un écart résiduel peut venir de la période ou de l'échantillon retenus.

QUESTIONS PROBABLES À L'ORAL

Explique la double différence avec les quatre moyennes.
Les traitées passent de 5,2 % à 44,1 %, soit +39,0 points. Le groupe de comparaison passe de 2,7 % à 3,7 %, soit +0,9 point. La double différence est 39,0 − 0,9 = 38,0 points : la hausse des traitées au-delà de ce qu'ont connu des localités semblables sans réseau.

3.5 Trois autres variables de résultat

ÉNONCÉ

Estimez la régression de la question 3.4 (b) avec, comme variable dépendante, successivement `nl_intensive_hat`, `nschool_elec` et `n_students_public`.

La même double différence, appliquée à trois autres résultats. L'intérêt est dans la comparaison des trois, et dans une habitude à prendre : revenir aux quatre moyennes pour savoir **d'où vient** un coefficient.

(a) Les trois effets

ÉNONCÉ (A)

Interprétez l'effet estimé pour chacune de ces variables.

RÉPONSE

Intensité lumineuse : +0,43 unité (p = 0,002). **Écoles électrifiées** : +0,16 école par localité par rapport à l'évolution du groupe de comparaison (p = 0,045), un résultat fragile. **Élèves** : −6,7, non significatif (p = 0,20) : aucun effet détectable sur le nombre d'élèves.

EXPLICATION

Variable	Double différence	Erreur-type HC1	p-valeur	Observations	Moyenne des traitées avant
`nl_extensive`	0,380	0,033	< 0,001	2 866	0,052
`nl_intensive_hat`	0,429	0,140	0,002	1 390	0,088

Variable	Double différence	Erreur-type HC1	p-valeur	Observations	Moyenne des traitées avant
`nschool_elec`	0,158	0,079	0,045	2 376	0,486
`n_students_public`	−6,73	5,28	0,20	2 376	57,4

Chaque coefficient se lit dans l'unité de sa variable.

- **Intensité** : parmi les localités éclairées au moins une fois, 0,43 unité de lumière en plus sur l'échelle des auteurs.
- **Écoles électrifiées** : +0,16 école par localité. Une moyenne peut être fractionnaire même si chaque localité compte un nombre entier d'écoles. Le résultat est tout juste significatif à 5 %.
- **Élèves** : −6,7 élèves, avec un intervalle de confiance qui va d'environ −17 à +4. On ne peut pas le distinguer de zéro.

« En plus » veut toujours dire : **par rapport à ce qu'aurait donné l'évolution du groupe de comparaison**. Ce n'est pas forcément une hausse observée, comme le montre le cas des écoles.

⚠ POINTS DE POURCENTAGE OU UNITÉS ?

Seule `nl_extensive` vaut 0 ou 1 : son coefficient, multiplié par 100, donne des points de pourcentage. Pour les écoles, 0,158 ne veut **pas** dire « +15,8 % » : c'est 0,158 école.

D'où vient le +0,158 ? Reviens aux quatre moyennes.

Écoles électrifiées par localité	Avant (2003-2007)	Après (2010-2012)	Variation
Traitées	0,4864	0,5000	+0,0136
Comparaison	0,2979	0,1534	−0,1445
Double différence			**+0,1581**

Dans les localités traitées, le nombre d'écoles électrifiées n'a presque pas bougé. La double différence est positive surtout parce qu'il a **baissé** dans le groupe de comparaison. Écrire « le nombre d'écoles électrifiées augmente de 0,16 » est donc un raccourci. La lecture exacte : les traitées ont 0,16 école électrifiée de plus que si elles avaient suivi l'évolution du groupe de comparaison.

✓ VÉRIFIÉ SUR LES DONNÉES, ABSENT DES DEUX CORRIGÉS

La baisse du groupe de comparaison vient de la rupture de 2005-2006 signalée à la question 3.1 (b). Elle touche les deux groupes. Pour la voir, choisis « Écoles électrifiées » dans l'outil de la question 3.6 (b).

Écoles électrifiées	2003	2004	2005	2006	2007	2010	2011	2012
Traitées	0,78	0,95	0,48	0,05	0,17	0,47	0,47	0,56
Comparaison	0,40	0,64	0,34	0,04	0,07	0,12	0,16	0,18

La période « avant » mélange donc deux régimes de mesure. Trois conséquences, que j'ai vérifiées :

- le test placebo de la question 3.6 (c), appliqué aux écoles, **échoue** : −0,26 (p = 0,02). Pour cette variable, les deux groupes n'évoluent pas de la même façon avant 2008 ;
- avec les seules années 2006-2007 comme période avant, la double différence vaut **0,29** (erreur-type groupée 0,08) : presque le double, et nettement significative ;
- avec des erreurs-types groupées par localité (question 3.8), le 0,158 n'est plus significatif (erreur-type 0,117 ; p = 0,18).

Ce que tu peux en dire sans dépasser ce que l'énoncé demande : le signe est positif et cohérent avec l'article, mais la valeur de 0,158 est fragile. Je n'ai pas pu vérifier dans l'article la cause de la rupture.

Les variables scolaires ne sont disponibles que jusqu'en 2012 : pour elles, la période « après » se réduit à 2010-2012.

CODE R

```
reg_3_5_int <- lm(nl_intensive_hat  ~ treated * post, data = did)
reg_3_5_eco <- lm(nschool_elec      ~ treated * post, data = did)
reg_3_5_elv <- lm(n_students_public ~ treated * post, data = did)
rob(reg_3_5_eco)["treated:post", ]
nobs(reg_3_5_int); nobs(reg_3_5_eco)     # 1 390 et 2 376 : pas les mêmes échantillons
```

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Lecture directe, dans l'unité de chaque variable

L'arrivée du réseau augmente l'intensité lumineuse de 0,43 unité parmi les localités éclairées au moins une fois (p = 0,002) et le nombre d'écoles électrifiées de 0,158 école par localité (p = 0,045, proche du seuil de 5 %). L'effet estimé sur le nombre d'élèves, −6,7, n'est pas significatif (p = 0,20).

Lecture par rapport au groupe de comparaison, avec les réserves

Par rapport à l'évolution du groupe de comparaison, les localités raccordées gagnent 0,43 unité d'intensité lumineuse (p = 0,002) et 0,158 école électrifiée (p = 0,045). Ce second effet est fragile : le nombre d'écoles électrifiées est stable chez les traitées (0,49 puis 0,50) et baisse dans le groupe de comparaison (0,30 puis 0,15), et il n'est plus significatif avec des erreurs-types groupées par localité (p = 0,18). L'effet sur le nombre d'élèves (−6,7) ne se distingue pas de zéro (p = 0,20).

(b) Pourquoi moins d'observations pour nl_intensive_hat ?

ÉNONCÉ (B)

Pourquoi l'échantillon est-il plus petit pour `nl_intensive_hat`, et qu'est-ce que cela change à l'interprétation ?

RÉPONSE

Parce que la variable n'est définie que pour les localités **éclairées au moins une fois** : 139 localités sur 297. Or y figurer dépend du traitement lui-même : 75 % des traitées y sont (44 sur 59), contre 40 % des localités de comparaison (95 sur 238). C'est une **sélection sur un résultat** : l'estimation ne vaut que pour ces localités, et les deux groupes n'y sont plus comparables.

EXPLICATION

1 390 observations = 139 localités × 10 années.

Le problème. L'électrification fait entrer dans l'échantillon des localités qui, sans elle, seraient restées invisibles et donc absentes. Parmi les localités de comparaison, seules celles qui s'éclairent **sans réseau** y figurent : des localités particulières, sans doute plus grandes ou plus actives. On compare donc des traitées « ordinaires » à des témoins « exceptionnels ».

Ce que cela change.

- L'estimation décrit les localités éclairées à un moment donné, pas une localité moyenne. Elle ne se généralise pas aux localités toujours sombres.
- Elle mélange deux choses : le passage de l'obscurité à la lumière, et la hausse d'intensité des localités déjà éclairées. Même dans cet échantillon, plus de huit observations sur dix sont des années **sans** lumière.

UN DÉTAIL DE CODAGE, UTILE POUR LA QUESTION 3.6 (E)

Une année sans lumière vaut −0,214 jusqu'en 2011 et 0 à partir de 2012, quand le satellite VIIRS entre dans la série. Le « zéro » de l'échelle change donc avec le capteur, pour toutes les localités.

La règle générale est la même que pour le « mauvais contrôle » de la question 1.16 : **on ne sélectionne pas un échantillon sur une variable que le traitement influence**.

RÉDACTION POSSIBLE POUR LE RAPPORT

Sélection sur un résultat, avec les deux proportions

La variable n'existe que pour les localités éclairées au moins une fois, soit 139 localités sur 297. Or 75 % des traitées y figurent (44 sur 59) contre 40 % des localités de comparaison (95 sur 238) : le traitement fait entrer des localités dans l'échantillon. C'est une sélection sur un résultat. L'estimation ne vaut que pour les localités éclairées à un moment donné, et les deux groupes n'y sont plus comparables.

(c) Ce que les élèves apprennent sur les écoles

ÉNONCÉ (C)

Que vous apprend le résultat obtenu pour `n_students_public` sur l'interprétation du résultat obtenu pour `nschool_elec` ?

RÉPONSE

Que l'effet sur les écoles électrifiées ne s'accompagne d'aucune hausse du nombre d'élèves : il concerne des **écoles existantes** qui ont l'électricité, pas de nouvelles écoles ni un afflux d'élèves. C'est un changement d'**équipement**, pas une expansion de la scolarisation.

EXPLICATION

Deux histoires pouvaient expliquer « plus d'écoles électrifiées ».

- **Histoire 1 : plus d'écoles.** Le réseau attire des familles, on ouvre des classes, et mécaniquement davantage d'écoles sont électrifiées. Dans ce cas, le nombre d'élèves augmenterait.
- **Histoire 2 : les mêmes écoles, mieux équipées.** Les écoles déjà là sont raccordées. Le nombre d'élèves ne bouge pas.

Le nombre d'élèves n'augmente pas : c'est l'histoire 2. Et l'électrification des écoles n'a pas (encore) attiré davantage d'élèves, du moins jusqu'en 2012.

C'est un bon exemple d'utilisation d'un résultat « nul » : il ne mesure pas un effet, mais il permet d'écarter une interprétation.

QUESTIONS PROBABLES À L'ORAL

Le nombre d'écoles électrifiées a-t-il augmenté dans les localités raccordées ?

Presque pas : 0,49 avant, 0,50 après. La double différence de +0,16 vient surtout de la baisse observée dans le groupe de comparaison, de 0,30 à 0,15. C'est un effet par rapport au contrefactuel, pas une hausse observée, et il est fragile : il n'est plus significatif avec des erreurs-types groupées.

Pourquoi la régression sur nl_intensive_hat a-t-elle deux fois moins d'observations ?

Parce que la variable n'est définie que pour les localités éclairées au moins une fois : 139 sur 297. Et le traitement modifie cette appartenance, puisque 75 % des traitées y figurent contre 40 % des autres. C'est une sélection sur un résultat, qui limite la portée de l'estimation.

C. TENDANCES PARALLÈLES

3.6 L'hypothèse des tendances parallèles

La double différence ne mesure un effet causal que sous une hypothèse. Cette question te la fait énoncer (a), regarder ce que les données en disent (b, c), comprendre pourquoi elles ne peuvent pas la prouver (d), puis examiner deux menaces précises : le changement de satellite (e) et la lumière qui déborde chez les voisins (f).

(a) L'hypothèse en une phrase

ÉNONCÉ (A)

Quelle est l'hypothèse centrale de votre stratégie d'identification ? Énoncez-la en une phrase, appliquée aux localités et à la période étudiées.

RÉPONSE

Ce sont les **tendances parallèles** : sans raccordement en 2008-2009, la part de localités éclairées aurait évolué de la même façon, entre 2003-2007 et 2010-2014, dans les 59 localités raccordées en 2008-2009 que dans les 238 localités raccordées en 2015-2017.

EXPLICATION

Trois choses à remarquer dans cette phrase.

1. **Elle parle d'évolutions, pas de niveaux.** Les deux groupes peuvent partir de niveaux différents (5,2 % contre 2,7 %) : la première différence s'en occupe. Ce qu'on exige, c'est qu'ils auraient **évolué** pareil.
2. **Elle parle d'un monde qui n'a pas existé.** « Sans raccordement, les traitées auraient… » : c'est un contrefactuel. On ne l'observera jamais, puisque ces localités ont été raccordées.
3. **Elle est appliquée.** L'énoncé demande les localités et la période : cite les deux groupes et les deux périodes. Une définition générale de manuel ne suffit pas.

En chiffres : on suppose que, sans le réseau, les traitées seraient passées de 5,2 % à 6,1 % (leur niveau de départ plus les 0,9 point du groupe de comparaison). Tout l'effet de 38 points repose là-dessus.

Deux hypothèses d'accompagnement, utiles à l'oral :

- **pas d'anticipation** : les localités ne changent pas avant d'être raccordées ;
- **pas de contamination** : le traitement des unes ne modifie pas le résultat des autres. C'est le sujet du point (f).

(b) Le graphique des moyennes annuelles

ÉNONCÉ (B)

Représentez l'évolution des moyennes annuelles de `nl_extensive` des deux groupes de 2003 à 2014. Que suggère ce graphique au sujet de l'hypothèse ?

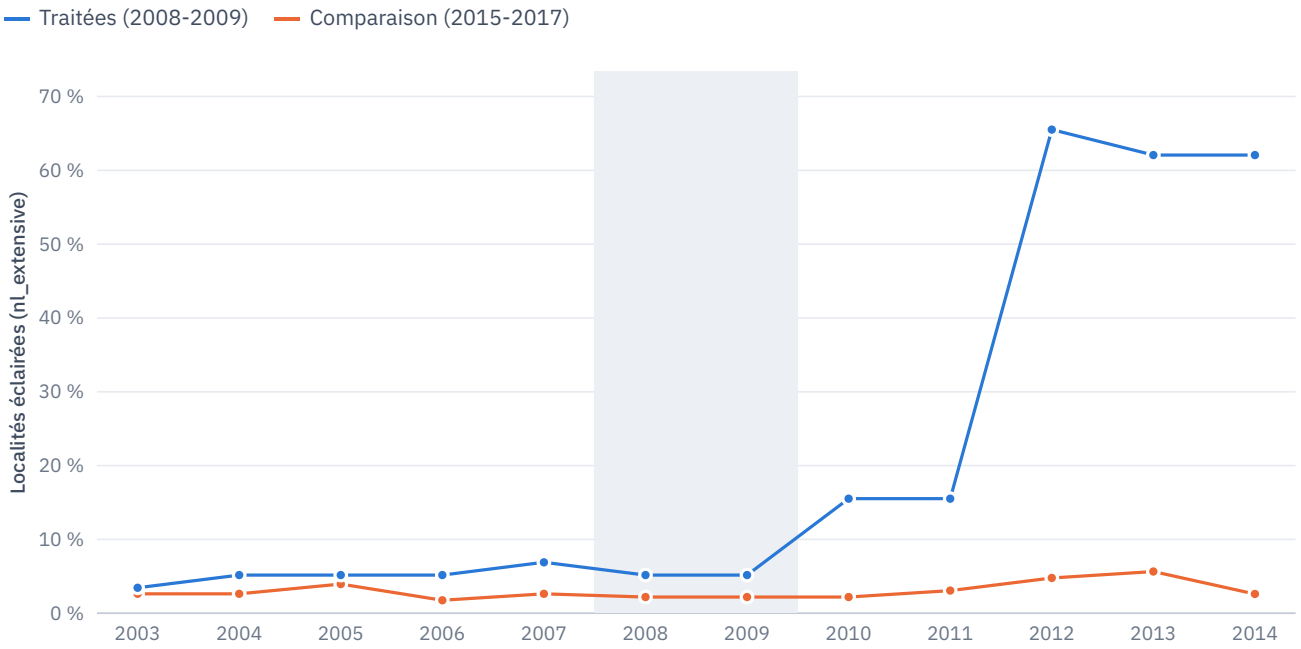
RÉPONSE

Avant 2008, les deux courbes sont basses et presque plates : 3 à 7 % pour les traitées, 2 à 4 % pour le groupe de comparaison, sans divergence nette. C'est **compatible** avec des tendances parallèles. Après, les traitées montent à 15,5 % en 2010-2011 puis à 62-66 % en 2012-2014 ; le groupe de comparaison reste sous 6 %.

EXPLICATION

Les deux groupes année par année

Avant 2008, les deux courbes évoluent-elles de la même façon ? La zone grisée (2008-2009) correspond aux années de raccordement du groupe traité, exclues de l'estimation.



De 2003 à 2007, les deux courbes sont basses et quasi plates : l'écart va de 1 à 4 points, et une localité traitée pèse à elle seule 1,7 point. Après le raccordement, les traitées passent à 15,5 % en 2010, puis bondissent à 65,5 % en 2012, l'année où le satellite VIIRS, plus sensible, entre dans la série. Le groupe de comparaison reste sous 6 %.

Double différence placebo de la part de localités éclairées, sur 2003-2007 seulement, avec une période « après » fictive à partir de 2005 : interaction = **+1,3 point** (erreur-type HC1 2,8 points, t = 0,47, p = 0,64). On ne détecte aucun « effet » à une date où il ne s'est rien passé : les deux groupes évoluaient de façon comparable. C'est le placebo demandé à la question 3.6 (c).

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Localités éclairées (%)	2003	2004	2005	2006	2007	2008	2009	2010	2011	2012	2013	2014
Traitées	3,4	5,2	5,2	5,2	6,9	5,2	5,2	15,5	15,5	65,5	62,1	62,1
Comparaison	2,6	2,6	3,9	1,8	2,6	2,2	2,2	2,2	3,1	4,8	5,7	2,6

Comment lire le graphique. On regarde la période **avant** 2008 et on se demande : l'écart entre les deux courbes reste-t-il à peu près constant ?

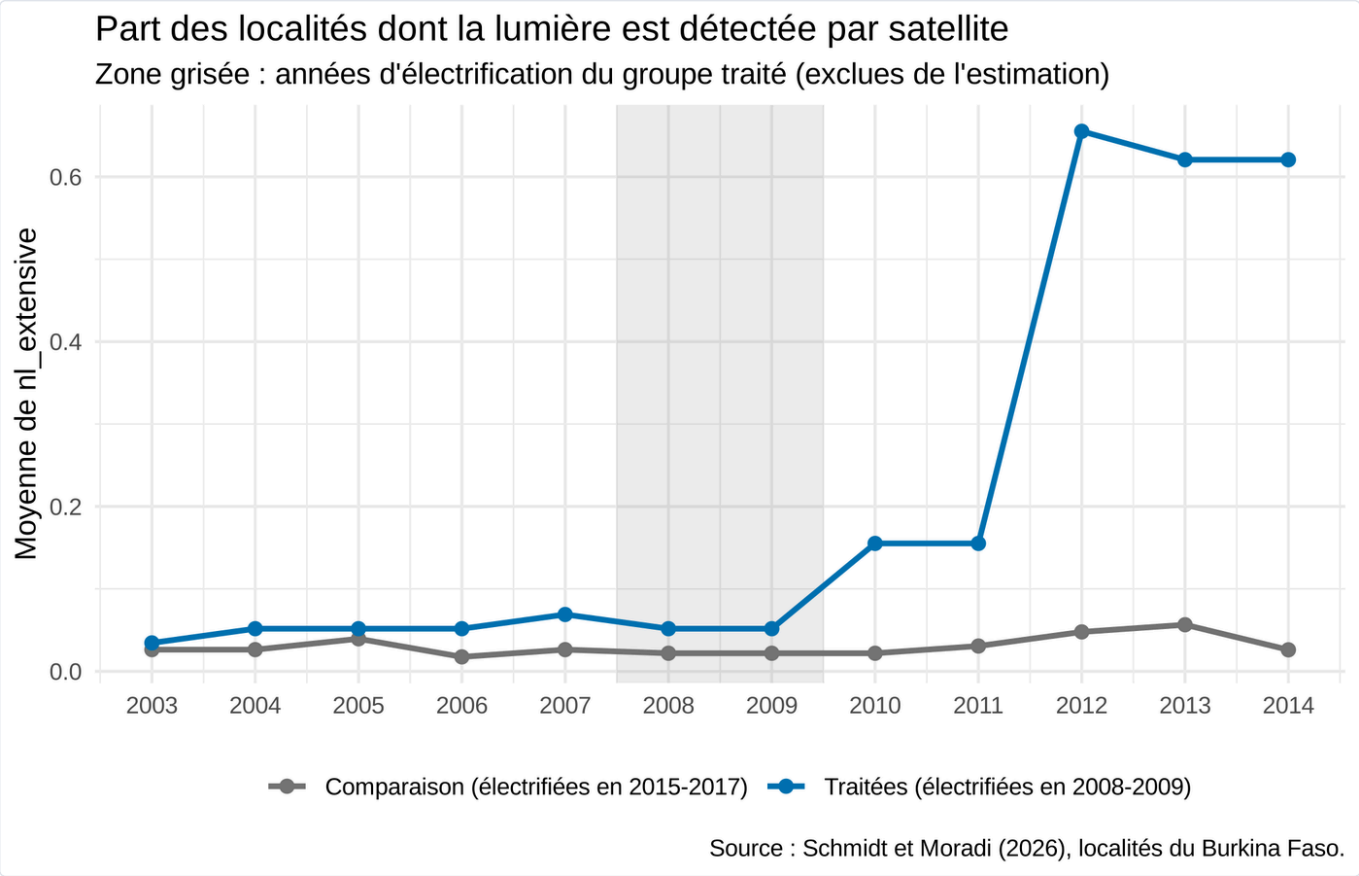
- **Avant 2008.** L'écart varie entre 0,8 et 4,3 points. Il est un peu plus grand à la fin qu'au début, mais garde l'échelle en tête : 58 localités traitées ont des données de lumière, donc **une seule localité pèse 1,7 point**. Les traitées passent de 2 localités éclairées en 2003 à 4 en 2007. Deux localités de plus en quatre ans : rien qui ressemble à un décollage.
- **2008-2009** (zone grisée). Aucun saut visible pendant les années de raccordement : 5,2 %.
- **Après 2009.** Les traitées s'écartent nettement : 15,5 % en 2010-2011, puis 62 à 66 % à partir de 2012. Le groupe de comparaison ne dépasse pas 5,7 %.

Le saut de 2012 coïncide avec l'entrée du satellite VIIRS dans la série : c'est le sujet du point (e).

LE MOT JUSTE

Le graphique est **compatible** avec l'hypothèse, il la rend **plausible**. Il ne la « confirme » pas et ne la « prouve » pas : voir le point (d).

Dans l'outil, change de variable : la même figure pour les écoles électrifiées et pour l'intensité lumineuse est moins rassurante. C'est une bonne raison de présenter `nl_extensive` comme ton résultat principal.



Part des localités dont la lumière est détectée par satellite, par groupe, 2003-2014. Source : Schmidt et Moradi (2026). Fichier : fig_3_6.png.

CODE R

```r
tab_3_6b <- deux_groupes %>%                          # 2003-2014, années 2008-2009 comprises
  group_by(year, groupe = ifelse(treated == 1, "Traitées", "Comparaison")) %>%
  summarise(moyenne = mean(nl_extensive, na.rm = TRUE), .groups = "drop")

ggplot(tab_3_6b, aes(x = year, y = moyenne, colour = groupe)) +
  annotate("rect", xmin = 2007.5, xmax = 2009.5, ymin = -Inf, ymax = Inf, alpha = 0.15) +
  geom_line() + geom_point() +
  scale_x_continuous(breaks = 2003:2014) +
  labs(x = "Année", y = "Part des localités éclairées", colour = NULL)
```

- On part de `deux_groupes`, qui contient encore 2008 et 2009 : l'énoncé demande le graphique de 2003 à 2014.
- `group_by(year, groupe)` puis `summarise()` : une moyenne par année et par groupe, soit 24 points.
- `annotate("rect", …)` dessine la zone grisée des années de raccordement.

(c) La double différence placebo

ÉNONCÉ (C)

Sur la seule période 2003-2007, créez `post_fictif`, qui vaut 1 si `year` ≥ 2005 et 0 sinon, et estimez la double différence « placebo » de `nl_extensive` sur `treated`, `post_fictif` et leur interaction. Interprétez le coefficient d'interaction.

RÉPONSE

L'interaction vaut **+0,013** (erreur-type 0,028 ; p = 0,64), soit 1,3 point. Entre 2003-2004 et 2005-2007, l'écart entre les deux groupes n'a pas changé de façon significative : on ne détecte aucun « effet » à une date où il ne s'est rien passé. C'est compatible avec des tendances parallèles avant le traitement.

EXPLICATION

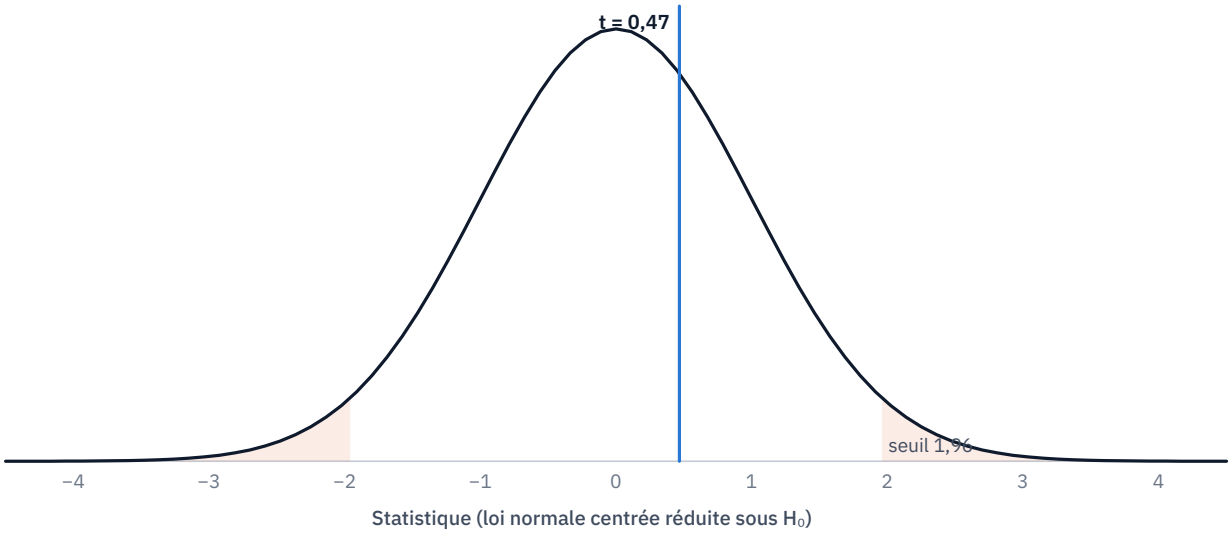
L'idée d'un placebo. En médecine, un placebo est un faux médicament : s'il « guérit », c'est que quelque chose cloche dans l'essai. Ici, on invente un **faux traitement** en 2005, à une date où aucune localité n'a été raccordée, et on applique exactement la même double différence, sur les seules années 2003-2007.

- Si la méthode est saine, on doit trouver **à peu près zéro**.
- Si on trouvait un « effet » significatif, cela voudrait dire que les deux groupes divergeaient déjà avant tout raccordement. Les tendances parallèles seraient alors douteuses.

`nl_extensive`	2003-2004	2005-2007	Variation
Traitées	4,31 %	5,75 %	+1,44
Comparaison	2,63 %	2,78 %	+0,15
Double différence placebo			**+1,29**

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : aucune divergence entre les groupes avant le traitement.

Statistique 0,47, valeur critique à 5 % : 1,96 (en valeur absolue). La **p-valeur** est de 0,64 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême dans 64 % des cas.

On ne rejette pas H_0 au seuil de 5 %. Attention : ne pas rejeter ne prouve pas que H_0 est vraie, seulement que les données ne la contredisent pas assez.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

t = 0,013 / 0,028 = 0,47, bien en dessous de 1,96 : on ne rejette pas H_0 « pas de différence d'évolution entre les groupes avant 2008 ». L'intervalle de confiance à 95 % va de **−4,1 à +6,7 points**.

Dans l'outil du point (b), le curseur « Placebo » déplace la date du faux traitement : essaie 2004, 2006 et 2007.

RÉSULTATS

	Coefficient	Erreur-type HC1	p-valeur
Constante	0,0263	0,0075	< 0,001
treated	0,0168	0,0203	0,41
post_fictif	0,0015	0,0098	0,88
treated × post_fictif	0,0129	0,0277	0,64

1 430 observations (286 localités × 5 années).

CODE R

```
placebo <- did %>%
  filter(year <= 2007) %>%
  mutate(post_fictif = as.numeric(year >= 2005))

reg_3_6c <- lm(nl_extensive ~ treated * post_fictif, data = placebo)
rob(reg_3_6c)
```

(d) Ces vérifications sont-elles une preuve ?

ÉNONCÉ (D)

Les vérifications (b) et (c) permettent-elles de prouver l'hypothèse énoncée en (a) ? Pourquoi ?

RÉPONSE

Non. L'hypothèse porte sur ce qu'auraient fait les traitées **après 2009 sans le réseau** : personne ne l'observe. Les vérifications (b) et (c) montrent seulement que les deux groupes évoluaient de façon semblable **avant** 2008. Cela rend l'hypothèse plausible, pas certaine. Et le placebo est imprécis : son intervalle va de −4 à +7 points.

EXPLICATION

Trois raisons, de la plus fondamentale à la plus technique.

1. Le contrefactuel est inobservable. Des tendances parallèles avant 2008 ne garantissent pas des tendances parallèles après. Exemple : si l'État a construit une route vers les localités traitées en même temps que la ligne électrique, les deux groupes divergent après 2009 pour une raison qui n'est pas l'électricité, et aucun test sur 2003-2007 ne peut le voir.

2. Ne pas rejeter n'est pas prouver. Le placebo ne détecte pas de divergence, mais avec une erreur-type de 2,8 points il ne peut pas exclure un écart de tendance de 5 points. C'est la même logique que pour le test de Hausman de la question 2.12 : un test peu puissant ne rejette presque jamais.

3. Les niveaux de départ sont proches de zéro. Une proportion ne peut pas descendre sous 0 %. Avec 2 à 7 % de localités éclairées, les deux courbes n'ont presque pas la place de diverger avant 2008, même si les localités sont très différentes. Et cinq années, c'est court.

Ce qui rassure quand même. Une différence de tendance qui existerait depuis longtemps creuserait l'écart **progressivement**. Or l'écart est stable jusqu'en 2009, puis s'ouvre brutalement, exactement après le raccordement. Et l'effet est de 38 points, sans commune mesure avec les fluctuations d'avant 2008. La fragilité porte sur la valeur exacte de l'effet, pas sur son existence.

LA FORMULE À RETENIR

Les tests avant traitement peuvent **mettre en doute** les tendances parallèles, jamais les **prouver**.

(e) Le changement de satellite

ÉNONCÉ (E)

Le passage de la série DMSP à la série VIIRS, plus sensible, intervient pendant la période après. À quelle condition ce changement de satellite biaiserait-il votre estimation, et dans quel sens ?

RÉPONSE

À condition qu'il n'affecte pas les deux groupes de la même façon, pour une raison autre que l'électrification. Un capteur plus sensible qui ajoute la même chose partout est retiré par la seconde différence, comme toute évolution commune. **Biais vers le haut** si VIIRS révèle plus de lumières sans rapport avec le réseau chez les traitées ; **vers le bas** s'il en révèle davantage dans le groupe de comparaison.

EXPLICATION

Le raisonnement. Le groupe de comparaison sert à mesurer tout ce qui change avec le temps, satellite compris. Appelle « bonus » ce que le nouveau capteur ajoute à la lumière détectée dans un groupe :

- hausse observée chez les traitées = effet du réseau + bonus des traitées ;
- hausse observée dans le groupe de comparaison = bonus du groupe de comparaison.

La double différence vaut donc : **effet du réseau + (bonus des traitées – bonus du groupe de comparaison)**. Si les deux bonus sont égaux, ils disparaissent. S'ils diffèrent, leur écart s'ajoute à l'effet.

Si VIIRS révèle, en plus de DMSP…	La double différence est…
autant de faibles lumières dans les deux groupes	**non biaisée** : le bonus commun se retranche
plus de lumières chez les traitées (localités plus grandes, autres sources de lumière)	biaisée **vers le haut**
plus de lumières dans le groupe de comparaison (lampes solaires, groupes électrogènes)	biaisée **vers le bas**

Ce que disent tes données. Regarde 2011 et 2012 sur le graphique du point (b).

Localités éclairées	2011 (DMSP)	2012 (VIIRS dans la série)
Traitées	15,5 %	65,5 %
Comparaison	3,1 %	4,8 %

Dans le groupe de comparaison, sans réseau, le nouveau capteur change peu de chose : moins de 2 points. Chez les traitées, la part éclairée est multipliée par quatre. On peut le mesurer en séparant la période après en deux :

Période après	Double différence	Erreur-type HC1
2010-2011 (DMSP)	+10,4 points	3,7
2012-2014 (VIIRS)	+56,4 points	4,0

Le 38,0 de la question 3.4 est la moyenne des deux, pondérée par le nombre d'années : (2 × 10,4 + 3 × 56,4) / 5 = 38,0.

Comment l'interpréter ? Deux lectures, que ces données ne permettent pas de départager.

- Le capteur plus sensible voit enfin la faible lumière **apportée par le réseau** (éclairage public, quelques branchements), que DMSP manquait. Dans ce cas ce n'est pas un biais : c'est le même effet, mieux mesuré.
- Les raccordements montent en puissance avec le temps : il y a réellement plus de lumière en 2012 qu'en 2010.

Dans les deux cas, la conclusion est la même : **l'existence de l'effet est solide, sa valeur exacte dépend du capteur.** « 38 points » est une moyenne entre deux instruments de mesure.

CODE R

```r
did <- did %>%
  mutate(post_dmsp  = as.numeric(year %in% 2010:2011),
         post_viirs = as.numeric(year %in% 2012:2014))

reg_3_6e <- lm(nl_extensive ~ treated + post_dmsp + post_viirs +
                 treated:post_dmsp + treated:post_viirs, data = did)
rob(reg_3_6e)
```

Cette régression n'est pas demandée par l'énoncé. Si tu la gardes, tu dois savoir l'expliquer : elle remplace `post` par deux indicatrices de période, et l'interaction par deux interactions.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

La condition et les deux sens, sans plus

Le changement de satellite ne biaise l'estimation que s'il modifie la lumière détectée différemment dans les deux groupes : un gain de sensibilité commun est retiré par la seconde différence. Si VIIRS révèle davantage de lumières sans rapport avec le réseau dans les localités traitées, l'effet est surestimé ; s'il en révèle davantage dans les localités de comparaison, il est sous-estimé.

La condition, les deux sens, et ce que montrent les données

Le changement de satellite ne biaise l'estimation que s'il modifie la lumière détectée différemment dans les deux groupes : un gain de sensibilité commun est retiré par la seconde différence. Le biais va vers le haut si VIIRS révèle plus de lumières sans rapport avec le réseau chez les traitées, vers le bas dans le cas inverse. Dans nos données, la part de localités traitées éclairées passe de 15,5 % en 2011 à 65,5 % en 2012, année d'entrée de VIIRS, contre 3,1 % à 4,8 % dans le groupe de comparaison : l'ampleur de l'effet dépend donc du capteur, même si son existence ne fait pas de doute.

Avec la régression qui sépare les deux périodes

Le changement de satellite ne biaise l'estimation que s'il modifie la lumière détectée différemment dans les deux groupes, vers le haut si VIIRS révèle plus de lumières sans rapport avec le réseau chez les traitées, vers le bas dans le cas inverse. En séparant la période après, la double différence vaut 10,4 points sur 2010-2011 (DMSP) et 56,4 points sur 2012-2014 (VIIRS). Notre estimation de 38 points est la moyenne des deux : le capteur plus sensible détecte la faible lumière apportée par le réseau, que DMSP manquait. L'ampleur de l'effet est donc à lire avec prudence.

(f) La lumière qui déborde chez les voisins

ÉNONCÉ (F)

La lumière d'une localité électrifiée peut être captée par le satellite dans les localités voisines. Si certaines localités de comparaison sont proches de localités traitées, dans quel sens votre estimation serait-elle biaisée ?

RÉPONSE

Vers le bas : l'effet serait sous-estimé. Si le satellite attribue à une localité de comparaison la lumière d'une voisine traitée, le groupe de comparaison « s'allume » après 2009 à cause du traitement. Sa hausse est gonflée, et comme on la retranche, la double différence est trop petite.

EXPLICATION

La double différence est une soustraction : **hausse des traitées – hausse du groupe de comparaison**.

Le débordement ajoute de la lumière au second terme. On retranche donc trop, et le résultat est trop petit. Exemple : si le débordement allumait 1 point de localités de comparaison en plus, on estimerait 37 points au lieu de 38.

Le principe général. Un groupe de comparaison ne doit pas être touché par le traitement des autres. Quand il l'est, on parle de **contamination** (ou d'effets de débordement). Ici, la contamination rapproche le groupe de comparaison du groupe traité : le biais va **vers zéro**.

Pourquoi ce n'est pas grave pour la conclusion. Un biais vers zéro rend l'estimation prudente : l'effet réel serait d'au moins 38 points. Et il est sans doute petit : le groupe de comparaison n'a gagné que 0,9 point au total entre les deux périodes, débordement compris.

À RETENIR

- Les tendances parallèles portent sur un contrefactuel : on peut les rendre plausibles, pas les prouver.
- Un placebo cherche un effet là où il ne doit pas y en avoir. Trouver zéro est bon signe ; ce n'est pas une preuve.
- Un changement de mesure ne biaise la double différence que s'il touche les deux groupes différemment.
- Une contamination du groupe de comparaison biaise l'effet vers zéro.

QUESTIONS PROBABLES À L'ORAL

Énonce l'hypothèse d'identification de ta double différence.

Sans raccordement en 2008-2009, la part de localités éclairées aurait évolué de la même façon, entre 2003-2007 et 2010-2014, dans les 59 localités traitées que dans les 238 localités raccordées en 2015-2017. Ce sont les tendances parallèles.

Ton graphique et ton placebo prouvent-ils cette hypothèse ?

Non. Ils montrent que les deux groupes évoluaient de façon semblable avant 2008, ce qui rend l'hypothèse plausible. Mais elle porte sur ce qui se serait passé après 2009 sans le réseau, qu'on n'observe pas. Et le placebo est imprécis : son intervalle va de −4 à +7 points.

Pourquoi la part de localités éclairées bondit-elle en 2012 ?

C'est l'année où le satellite VIIRS, plus sensible, entre dans la série. Il détecte de faibles lumières que DMSP manquait. Dans le groupe de comparaison, sans réseau, il change peu de chose ; chez les traitées, la part éclairée passe de 15,5 % à 65,5 %. L'effet moyen de 38 points mélange donc deux instruments de mesure.

D. EFFETS FIXES ET ERREURS-TYPES

3.7 Les effets fixes

La même double différence, écrite autrement. Au lieu d'une indicatrice pour le groupe et d'une pour la période, on donne une constante à **chaque localité** et une à **chaque année**. C'est le modèle « TWFE » (*two-way fixed effects*, effets fixes doubles) de la colonne du tableau 4 de l'article.

(a) Estimer le modèle à effets fixes

ÉNONCÉ (A)

Créez `D` = `treated` × `post`. Estimez la régression de `nl_extensive` sur `D` avec des effets fixes de localité et des effets fixes d'année (`factor(electrific)` et `factor(year)`).

RÉPONSE

Coefficient de `D` : **0,3800** (erreur-type HC1 0,0265), sur 2 866 observations. Pratiquement le même nombre qu'à la question 3.4.

EXPLICATION

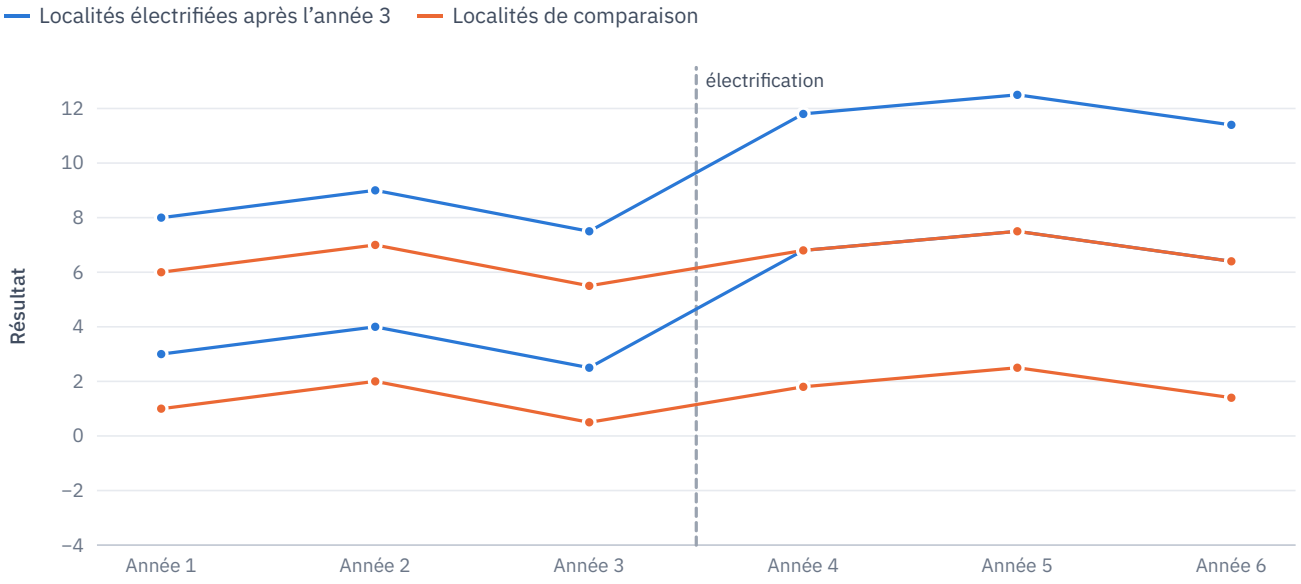
$$\text{nl_extensive}_{it} = \alpha_\text{i} + \gamma_\text{t} + \beta\, D_{it} + u_{it}$$

- i désigne la localité, t l'année.
- α_i : une constante **par localité** (288 localités ont des données de lumière).
- γ_t : une constante **par année** (10 années).
- D_{it} vaut 1 pour une localité traitée observée après 2009, 0 sinon.
- β est l'effet recherché.

Comment R s'y prend. `factor(electrific)` dit à R de traiter l'identifiant comme une **catégorie** et non comme un nombre. R crée alors une indicatrice par localité, exactement comme pour les régions de la question 1.11, mais avec 288 catégories au lieu de 3. Même chose pour `factor(year)`. La régression a 298 coefficients ; un seul nous intéresse.

Ce que retirent les effets fixes

Quatre localités fictives sur six années. Deux sont électrifiées après l'année 3 (effet réel : **+3**). Elles partent de niveaux très différents et subissent les mêmes chocs annuels. Retire les effets fixes un par un.



Données brutes. Les localités ont des niveaux très différents (de 1 à 8) et toutes montent et descendent ensemble au gré des chocs annuels. L'effet de l'électrification est noyé dans ces deux sources de variation.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

Dans l'outil, retire les effets fixes un par un : ce qui reste à la fin, c'est l'écart entre localités électrifiées et non électrifiées, après l'électrification. C'est la double différence.

CODE R

```r
did <- did %>% mutate(D = treated * post)

reg_3_7a <- lm(nl_extensive ~ D + factor(electrific) + factor(year), data = did)
rob(reg_3_7a)["D", ]        # n'afficher que la ligne de D
```

- N'affiche pas `summary(reg_3_7a)` en entier : tu obtiendrais 298 lignes.
- `rob(...)["D", ]` extrait la ligne nommée `D` du tableau de résultats.

(b) Ce que chaque effet fixe neutralise

ÉNONCÉ (B)

Expliquez, dans ce contexte précis, à quoi servent les effets fixes de localité et les effets fixes d'année : quelles différences chacun neutralise-t-il ?

RÉPONSE

- Les **effets fixes de localité** neutralisent tout ce qui distingue durablement une localité des autres : sa taille, sa situation, sa distance au réseau, son niveau de lumière de départ.
- Les **effets fixes d'année** neutralisent tout ce qui touche toutes les localités la même année : conjoncture nationale, météo, et la part **commune** du changement de satellite.

Il ne reste, pour estimer l'effet, que l'évolution de chaque localité dans le temps au-delà des chocs communs : c'est l'idée de la double différence.

EXPLICATION

Effets fixes de localité : chaque localité est comparée à elle-même. À la question 3.4, `treated` donnait un niveau à chaque **groupe**. Ici, chaque **localité** a le sien. Une localité traitée qui a toujours été plus grande, plus proche d'une ville ou déjà un peu éclairée voit tout cela absorbé par sa constante α_i. Peu importe que ces caractéristiques soient observées ou non : il suffit qu'elles ne changent pas dans le temps.

Effets fixes d'année : chaque année a son niveau. À la question 3.4, `post` distinguait deux périodes. Ici, chaque année a sa constante γ_t. Tout ce qui frappe l'ensemble des localités une année donnée y passe : une bonne récolte, une crise, une année nuageuse, un capteur plus sensible.

Ce qu'ils ne neutralisent pas. Tout ce qui change dans le temps **différemment selon les localités** : une route construite en 2010 vers certaines localités traitées, ou un effet du satellite qui ne serait pas le même dans les deux groupes. Les effets fixes ne remplacent donc pas l'hypothèse de tendances parallèles : ils la supposent.

Source de différence	Exemple	Neutralisée par
Fixe dans le temps, propre à la localité	taille, situation géographique	effets fixes de localité
Variable dans le temps, commune à toutes	conjoncture, sensibilité du capteur	effets fixes d'année
Variable dans le temps **et** propre à certaines	route construite en 2010	**rien** : c'est le risque qui reste

RÉDACTION POSSIBLE POUR LE RAPPORT

Les exemples de l'un, la réserve de l'autre

Les effets fixes de localité neutralisent tout ce qui distingue durablement les localités : taille, situation, distance au réseau, niveau de lumière de départ. Les effets fixes d'année neutralisent ce qui touche toutes les localités une même année : conjoncture nationale, couverture nuageuse, part commune du changement de satellite. Ils ne corrigent pas ce qui évolue différemment selon les groupes : l'hypothèse de tendances parallèles reste nécessaire.

(c) Le même coefficient qu'à la question 3.4 ?

ÉNONCÉ (C)

Comparez le coefficient de `D` à celui de l'interaction de la question 3.4. Sont-ils égaux ? Pourquoi ?

RÉPONSE

Presque : 0,38001 contre 0,38020. Ils seraient strictement égaux dans un panel équilibré, où chaque localité est observée les dix années. Ici, deux localités ne sont observées que trois ans : les deux méthodes ne les pondèrent pas de la même façon, d'où un écart de 0,0002.

EXPLICATION

Modèle	Coefficient	Erreur-type HC1	Observations
3.4 : `treated`, `post`, interaction	0,38020	0,0328	2 866
3.7 (a) : effets fixes de localité et d'année	0,38001	0,0265	2 866
3.7 (e) : effets fixes de région et d'année, plus `treated`	0,38040	0,0313	2 866

Pourquoi ils sont égaux dans un panel équilibré. Les effets fixes de localité contiennent toute l'information de `treated`, en plus fin : au lieu de « traitée ou non », ils disent « quelle localité ». Les effets fixes d'année contiennent celle de `post`, en plus fin. Mais `D` ne varie qu'entre **groupes** et entre **périodes**. Le détail supplémentaire (telle localité plutôt que telle autre du même groupe, 2011 plutôt que 2013) n'a aucun lien avec `D` : il ne change pas son coefficient.

La vérification. Sur les 286 localités observées les dix années (2 860 lignes), les trois modèles donnent **0,380006**, identique à la sixième décimale.

Pourquoi un petit écart ici. Sur les 297 localités, 9 n'ont aucune mesure de lumière et 2 n'en ont que pour 2012-2014. Ces deux-là comptent dans la moyenne « comparaison, après » de la question 3.4. Avec des effets fixes de localité, une localité jamais observée avant ne dit rien sur un changement avant-après : elle pèse autrement.

Ce qui change vraiment : l'erreur-type. Elle passe de 0,033 à 0,027, parce que 288 constantes expliquent beaucoup de variation et que le résidu rétrécit. Garde ce gain de précision en tête : la question 3.8 montre qu'il est trompeur.

CODE R

```r
complet <- did %>%
  group_by(electrific) %>%
  filter(sum(!is.na(nl_extensive)) == 10) %>%      # localités observées les 10 années
  ungroup()

coef(lm(nl_extensive ~ treated * post, data = complet))["treated:post"]                 # 0,380006
coef(lm(nl_extensive ~ D + factor(electrific) + factor(year), data = complet))["D"]      # 0,380006
```

(d) Pourquoi treated ne peut pas figurer dans la régression

ÉNONCÉ (D)

Pourquoi `treated` ne peut-il pas figurer dans cette régression ?

RÉPONSE

Parce que `treated` ne change jamais pour une localité donnée : c'est exactement la somme des indicatrices des localités traitées. Il est **parfaitement colinéaire** avec les effets fixes de localité. R ne peut pas séparer les deux et renvoie `NA` .

EXPLICATION

C'est le piège des variables indicatrices de la question 1.11, en plus grand. Là-bas, on ne pouvait pas mettre les trois régions **et** une constante, parce que Bruxelles + Flandre + Wallonie = 1 pour toutes les communes.

Ici : additionne les indicatrices des localités traitées. Tu obtiens une variable qui vaut 1 pour les traitées et 0 pour les autres, c'est-à-dire `treated` . La variable n'apporte **aucune information nouvelle** : chaque constante α_i contient déjà le fait que la localité i est traitée ou non.

De la même façon, `post` est la somme des indicatrices des années 2010 à 2014 : il est absorbé par les effets fixes d'année.

Plus généralement, **aucune caractéristique fixe dans le temps ne peut être estimée avec des effets fixes de localité**. C'est le prix à payer : on neutralise tout ce qui est fixe, donc on ne peut plus rien en dire.

⚠ L'ORDRE DES VARIABLES DANS LA FORMULE

Si tu écris `treated` **après** les effets fixes, R affiche `NA` : c'est le comportement attendu. Si tu l'écris **avant**, R supprime à la place l'indicatrice d'une localité et affiche pour `treated` un nombre (0,110) qui n'a aucun sens. Un coefficient affiché n'est pas forcément un coefficient interprétable.

CODE R

```
m <- lm(nl_extensive ~ D + factor(electrific) + factor(year) + treated, data = did)
coef(m)["treated"]        # NA : colinéarité parfaite
```

(e) Des effets fixes de région à la place

ÉNONCÉ (E)

Remplacez les effets fixes de localité par des effets fixes de région (`factor(region_num)`), en ajoutant `treated` , et réestimez. Le coefficient de `D` change-t-il ? Pourquoi ?

RÉPONSE

Pratiquement pas : 0,3804 contre 0,3800. Pour que la double différence soit correcte, il suffit de tenir compte du **groupe** (`treated`) et du **temps** (effets fixes d'année). La région est une caractéristique fixe de plus, et la double différence retire déjà tout ce qui est fixe. Ce qui change, c'est l'erreur-type : 0,031 au lieu de 0,027.

EXPLICATION

Pourquoi il faut remettre `treated` . Sans effets fixes de localité, plus rien ne tient compte de l'écart de niveau entre les deux groupes. `treated` reprend ce rôle (son coefficient : 0,029, proche du 0,025 de la question 3.4). Si

tu l'oublies, `D` monte à 0,405 : il absorbe l'écart de départ entre les groupes, et tu retombes sur la comparaison naïve de la question 3.3 (a).

Pourquoi `D` ne bouge pas. La région ne change pas dans le temps. Or `D` mesure un **changement** propre aux traitées. Une caractéristique fixe peut expliquer des niveaux, pas un changement : l'ajouter ou la retirer ne déplace pas `D`. Sur le panel équilibré, les trois modèles donnent d'ailleurs exactement 0,380006.

Ce que cela t'apprend. On peut tenir compte des différences fixes à plusieurs niveaux de finesse :

Niveau	Nombre de constantes	Coefficient de D	Erreur-type HC1
Groupe (`treated`)	2	0,3802	0,0328
Région, plus `treated`	13	0,3804	0,0313
Localité	288	0,3800	0,0265

Le coefficient est le même. Plus le niveau est fin, plus le modèle explique de variation, et plus l'erreur-type HC1 diminue.

Les 9 localités sans code de région sont aussi celles qui n'ont aucune mesure de lumière : l'échantillon reste de 2 866 observations.

CODE R

```
reg_3_7e <- lm(nl_extensive ~ D + treated + factor(region_num) + factor(year), data = did)
rob(reg_3_7e)[c("D", "treated"), ]
```

(f) Pourquoi ne pas contrôler nschool_elec

ÉNONCÉ (F)

Pourquoi ne faut-il pas ajouter `nschool_elec` comme variable de contrôle dans la régression de la luminosité ?

RÉPONSE

Parce que `nschool_elec` est lui-même un **résultat** de l'électrification (question 3.5). C'est un mauvais contrôle : le contrôler retirerait de l'effet la part qui passe par les écoles, et ferait comparer des localités qui ne sont plus comparables.

EXPLICATION

Le réseau produit de la lumière par plusieurs chemins : éclairage public, ménages branchés, bâtiments publics, **écoles électrifiées**. Tu cherches l'effet **total** de l'arrivée du réseau.

1. Tu bloquerais un chemin. Contrôler `nschool_elec`, c'est demander : « à nombre d'écoles électrifiées égal, quel est l'effet du réseau sur la lumière ? ». La lumière qui passe par les écoles est exclue de la réponse. Ce n'est plus la question posée.

2. Tu comparerais des localités différentes. Une localité traitée et une localité de comparaison qui ont le même nombre d'écoles électrifiées ne se ressemblent pas : la seconde a obtenu ses écoles électrifiées **sans** réseau. C'est un biais de sélection.

3. Tu perdrais deux années. La variable n'existe pas pour 2013 et 2014 : l'échantillon tomberait de 2 866 à 2 290 observations.

✓ CE QUI SE PASSE SI ON ESSAIE

Avec le contrôle, le coefficient de l'interaction tombe à 0,262. Mais ce n'est pas le contrôle qui le fait baisser : sur les mêmes 2 290 observations, **sans** le contrôle, il vaut déjà 0,264. La baisse vient de la perte de 2013 et 2014, deux des trois années où la lumière est la plus forte. Les raisons 1 et 2 sont des raisons de principe ; dans ces données, c'est la raison 3 qui pèse.

La règle générale, déjà vue à la question 1.16 : on ne contrôle jamais une variable **postérieure au traitement et influencée par lui**.

QUESTIONS PROBABLES À L'ORAL

Qu'est-ce qu'un modèle TWFE ?

Une régression avec deux séries d'effets fixes : une constante par localité, qui neutralise tout ce qui est fixe dans le temps, et une constante par année, qui neutralise tout ce qui est commun à toutes les localités une année donnée. L'effet est estimé par l'évolution de chaque localité au-delà des chocs communs.

Ton coefficient TWFE est-il égal à celui de la question 3.4 ?

Presque : 0,3800 contre 0,3802. Ils seraient identiques dans un panel équilibré ; je l'ai vérifié sur les 286 localités observées dix ans, où les deux valent 0,380006. L'écart vient de deux localités observées seulement de 2012 à 2014.

Pourquoi ne pas contrôler le nombre d'écoles électrifiées ?

Parce que c'est une conséquence de l'électrification. Le contrôler bloquerait un des chemins par lesquels le réseau produit de la lumière : on n'estimerait plus l'effet total. On ne contrôle pas une variable influencée par le traitement.

3.8 Les erreurs-types groupées

Jusqu'ici, les erreurs-types HC1 ont traité les 2 866 observations comme autant d'informations indépendantes. Or ce sont 288 localités observées dix fois. Cette question corrige l'incertitude, pas le coefficient.

(a) HC1 contre erreurs-types groupées

ÉNONCÉ (A)

Estimez à nouveau les modèles des questions 3.4 (b) et 3.7 (a) avec des erreurs-types groupées par localité, et comparez-les aux erreurs-types robustes (HC1).

RÉPONSE

Modèle	Coefficient	HC1	Groupée	Rapport	IC à 95 % (groupée)
3.4 (b) : `treated × post`	0,380	0,033	0,044	1,35	[0,29 ; 0,47]
3.7 (a) : effets fixes	0,380	0,027	0,047	1,76	[0,29 ; 0,47]

Les coefficients ne changent pas. Les erreurs-types augmentent de 35 % et de 76 %.

EXPLICATION

Ce que « grouper » veut dire. Les erreurs-types groupées (en anglais *clustered*) autorisent les erreurs d'une **même localité** à être corrélées entre elles d'une année à l'autre, de n'importe quelle façon. Elles supposent seulement que deux localités **différentes** sont indépendantes.

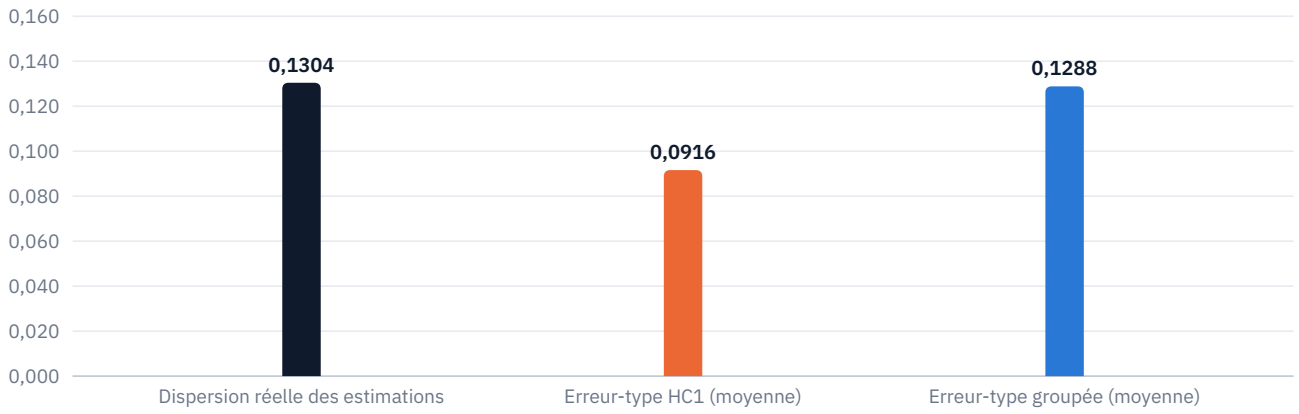
- HC1 : 2 866 informations indépendantes.
- Groupées : 288 blocs indépendants.

Seule l'incertitude change. Le coefficient, lui, est calculé de la même façon.

Un détail qui compte. Avec HC1, le modèle à effets fixes paraissait plus précis que le modèle simple (0,027 contre 0,033). Avec les erreurs-types groupées, les deux se rejoignent (0,047 et 0,044). Le gain de précision apparent des effets fixes était une illusion.

Pourquoi grouper les erreurs-types ? Une simulation sans aucun effet

On simule 600 panels identiques au tien (59 localités traitées, 238 de comparaison, 5 années avant, 5 après), mais où l'électrification n'a **aucun effet**. Les erreurs d'une même localité sont corrélées d'une année à l'autre avec la force que tu choisis.



Avec une corrélation de **0,66** : la vraie dispersion des estimations est de 0,1304. L'erreur-type HC1, qui traite les 2 970 observations comme indépendantes, annonce 0,0916 (70 % de la réalité) ; l'erreur-type groupée par localité annonce 0,1288 (99 %).

Conséquence : alors qu'il n'y a aucun effet, un test à 5 % en « trouve » un dans **16 %** des simulations avec HC1, contre 6 % avec les erreurs groupées (on attend 5 %). Les erreurs persistent : HC1 surestime l'information réellement disponible et annonce une précision qu'on n'a pas.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

CODE R

```
vc_groupee <- vcovCL(reg_3_4, cluster = ~ electrific, type = "HC1")
coeftest(reg_3_4, vcov = vc_groupee)

coeftest(reg_3_7a, vcov = vcovCL(reg_3_7a, cluster = ~ electrific, type = "HC1"))["D", ]
```

- `vcovCL()` (package `sandwich`) calcule la matrice de variance groupée ; `cluster = ~ electrific` désigne la variable qui définit les groupes.
- `coeftest()` refait le tableau de coefficients avec cette matrice. C'est la même mécanique que ta fonction `rob()`, avec `vcovCL` à la place de `vcovHC`.

(b) Pourquoi les erreurs d'une localité sont corrélées

ÉNONCÉ (B)

Expliquez avec vos mots pourquoi les termes d'erreur d'une même localité risquent d'être corrélés d'une année à l'autre dans cette application, et ce que cela implique pour les erreurs-types non groupées.

RÉPONSE

Parce que ce que le modèle n'explique pas dans une localité **persiste** d'une année à l'autre : sa taille, son activité, un marché ou une route à proximité. Une localité plus lumineuse que prévu une année l'est en général aussi l'année suivante. Ses dix observations n'apportent donc pas dix informations indépendantes. Les erreurs-types non groupées font comme si, et sont **trop petites** : les tests rejettent trop souvent et les intervalles sont trop étroits.

EXPLICATION

Une image. Pèse dix fois la même personne : tu n'as pas dix personnes. Tu connais très bien **son** poids, mais tu ne connais pas mieux le poids moyen de la population. Dix années d'une même localité, c'est un peu pareil.

Ce que contient le terme d'erreur d'une localité. Tout ce qui influence sa lumière et n'est pas dans la régression : un marché hebdomadaire, un axe routier, la position exacte de la localité par rapport aux pixels du satellite. Ces facteurs ne changent pas d'une année à l'autre, ou très lentement.

Dans tes données. La corrélation entre le résidu d'une localité et son résidu de l'année précédente vaut **0,66**. Si les erreurs étaient indépendantes, elle serait proche de 0.

Pourquoi c'est pire en double différence. Le régresseur `D` est lui aussi « persistant » : il vaut 1 cinq années de suite dans chaque localité traitée. Quand le régresseur et l'erreur sont tous deux corrélés dans le temps, l'erreur-type naïve peut être très loin de la vérité. C'est un résultat classique (Bertrand, Duflo et Mullainathan, 2004), qui a fait des erreurs-types groupées la norme en double différence.

Et avec les effets fixes ? Ils retirent la partie **permanente** de l'erreur d'une localité, mais pas sa persistance d'une année à l'autre. Le rapport est même plus grand (1,76).

Dans l'outil du point (a), mets la corrélation à 0, puis à 0,66. Sans aucun effet réel, un test à 5 % fondé sur HC1 en « trouve » un dans environ 15 % des simulations : trois fois trop souvent.

(c) Pourquoi grouper par localité

ÉNONCÉ (C)

Pourquoi faut-il grouper au niveau de la localité, et non de l'année ou de la région ?

RÉPONSE

Trois raisons : c'est le niveau où le **traitement est attribué** (on raccorde une localité) ; c'est le niveau où les **erreurs sont corrélées** (dans le temps, au sein d'une localité) ; et il y a **assez de groupes** (288). Par année, il n'y aurait que 10 groupes, et on ignorerait la corrélation dans le temps, qui est le vrai problème. Par région, 13 groupes : trop peu pour une erreur-type fiable.

EXPLICATION

Grouper par…	Nombre de groupes	Corrélation autorisée	Problème
localité	288	entre les années d'une même localité	aucun : c'est le bon niveau
année	10	entre les localités, une même année	ignore la persistance dans le temps ; trop peu de groupes
région	13	entre toutes les observations d'une région	trop peu de groupes

La règle pratique. On groupe au niveau où le traitement est décidé. Ici, le réseau arrive dans une localité : toutes ses années « après » sont traitées ensemble.

Pourquoi le nombre de groupes compte. Une erreur-type groupée est calculée à partir de la dispersion **entre groupes**. Avec 288 localités, cette dispersion est bien mesurée. Avec 10 ou 13 groupes, elle est elle-même très imprécise, et les tests ne sont plus fiables. On cite souvent un minimum de 40 à 50 groupes.

Et la région ? En théorie, grouper par région serait plus prudent encore : cela autoriserait aussi des corrélations entre localités voisines. Mais avec 13 régions, le remède est pire que le mal.

✓ PAR CURIOSITÉ

J'ai essayé : en groupant par année, l'erreur-type de l'interaction vaut 0,107 ; par région, 0,054. L'effet reste significatif dans tous les cas, mais ces deux valeurs reposent sur 10 et 13 groupes : ne les utilise pas pour conclure.

(d) Le sens de l'écart et la conclusion

ÉNONCÉ (D)

Le sens de l'écart observé en (a) est-il celui que vous attendiez ? Que concluez-vous sur l'effet de l'expansion du réseau électrique ?

RÉPONSE

Oui. Avec des erreurs positivement corrélées dans le temps au sein d'une localité, on attend des erreurs-types groupées plus grandes : elles le sont, de 35 % et de 76 %. L'effet reste très significatif : t = 0,380 / 0,044 = **8,6**. L'arrivée du réseau a augmenté de **38 points** la probabilité qu'une localité soit visible de nuit, avec un intervalle de confiance à 95 % de **29 à 47 points**.

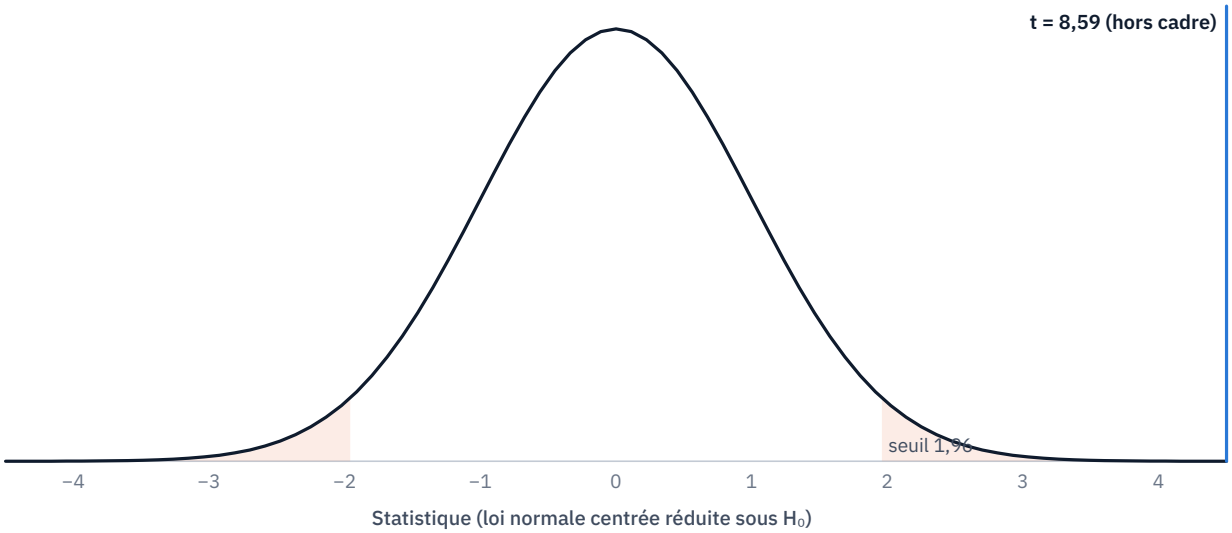
EXPLICATION

Le raisonnement en trois temps.

1. **Ce qu'on attendait.** Corrélation positive (0,66), donc moins d'information qu'il n'y paraît, donc des erreurs-types groupées plus grandes.
2. **Ce qu'on observe.** 0,044 contre 0,033, et 0,047 contre 0,027. Conforme.
3. **Ce que ça change.** L'intervalle s'élargit, de [0,32 ; 0,44] à [0,29 ; 0,47]. La statistique t passe de 11,6 à 8,6. La conclusion ne change pas : l'effet est massif et très loin de zéro.

Où tombe la statistique de test ?

Un test compare un nombre calculé sur tes données (la **statistique**) à ce qu'on obtiendrait par pur hasard **si l'hypothèse nulle H_0 était vraie** (la courbe). Si la statistique tombe dans une zone où le hasard seul l'envoie rarement (zone colorée), on rejette H_0.



H_0 : l'électrification n'a aucun effet sur la lumière.

Statistique 8,59, valeur critique à 5 % : 1,96 (en valeur absolue). La **p-valeur** est inférieure à 0,0001 : si H_0 était vraie, le hasard donnerait une statistique au moins aussi extrême moins d'une fois sur 10 000.

On rejette H_0 au seuil de 5 %.

Figure tirée de l'outil interactif de l'atelier, dans son état initial.

La conclusion à écrire doit rappeler sous quelle hypothèse elle vaut : *sous l'hypothèse de tendances parallèles*, l'arrivée du réseau a augmenté de 38 points (IC à 95 % : 29 à 47) la part de localités visibles de nuit.

✓ ET POUR LES AUTRES RÉSULTATS ? VÉRIFIÉ SUR LES DONNÉES, ABSENT DES DEUX CORRIGÉS

L'énoncé ne demande les erreurs-types groupées que pour la luminosité. Voici ce qu'elles donnent pour les quatre variables de la question 3.5 :

Variable	Double différence	HC1	Groupée	p-valeur (groupée)
`nl_extensive`	0,380	0,033	0,044	< 0,001
`nl_intensive_hat`	0,429	0,140	0,097	< 0,001
`nschool_elec`	0,158	0,079	0,117	0,18
`n_students_public`	−6,73	5,28	5,00	0,18

Deux enseignements.

- **L'effet sur les écoles électrifiées n'est plus significatif** (p = 0,18 au lieu de 0,045). ChatGPT l'avait pressenti en parlant d'une inférence « sensible à la corrélation entre années ».
- **Grouper n'augmente pas toujours l'erreur-type** : pour l'intensité lumineuse, elle diminue. Quand une localité est durablement au-dessus ou en dessous des autres, cet écart permanent s'annule dans la comparaison après − avant. L'erreur-type groupée en tient compte ; HC1, non. Dans l'outil du point (a), pousse la corrélation à 0,95 pour voir l'ordre s'inverser.

À RETENIR

- Effets fixes de localité : tout ce qui est fixe dans le temps. Effets fixes d'année : tout ce qui est commun à tous une année donnée.
- Dans un panel équilibré, TWFE et double différence 2×2 donnent le même coefficient (0,380).
- On ne peut pas estimer l'effet d'une variable fixe dans le temps avec des effets fixes de localité, et on ne contrôle pas un résultat du traitement.
- En panel, on groupe les erreurs-types au niveau où le traitement est attribué : 0,044 au lieu de 0,033.

QUESTIONS PROBABLES À L'ORAL

Pourquoi grouper les erreurs-types par localité ?

Parce que les dix observations d'une localité ne sont pas indépendantes : ce que le modèle n'explique pas chez elle persiste d'une année à l'autre. Dans mes données, la corrélation des résidus d'une année à l'autre est de 0,66. Sans grouper, on surestime l'information disponible et les erreurs-types sont trop petites.

Qu'est-ce que le groupement change à ta conclusion ?

L'erreur-type passe de 0,033 à 0,044 et l'intervalle de confiance s'élargit, de 32-44 points à 29-47 points. L'effet reste très significatif, avec un t de 8,6. La conclusion ne change pas, mais sa précision est plus honnête.

E. CONCLUSION

3.9 Plus de lumière, plus d'activité économique ?

ÉNONCÉ

L'arrivée du réseau augmente mécaniquement la lumière nocturne, par exemple par l'éclairage public, indépendamment de toute activité économique.

La lumière nocturne sert souvent de mesure indirecte de l'activité économique. Mais ici, le traitement **est** de l'électricité. Cette dernière question te demande de séparer ce que tes estimations montrent de ce qu'elles ne montrent pas.

(a) Ton résultat montre-t-il une hausse de l'activité économique ?

ÉNONCÉ (A)

Votre résultat de la question 3.4 montre-t-il une hausse de l'activité économique ?

RÉPONSE

Non. Il montre que les localités raccordées deviennent visibles de nuit, pas qu'elles produisent davantage. Le réseau apporte de la lumière par lui-même : éclairage public, bâtiments publics, quelques ménages branchés. Et `nl_extensive` passe de 0 à 1 dès que quelques lampes dépassent le seuil de détection du satellite.

EXPLICATION

Pourquoi la lumière mesure d'habitude l'activité. Dans un pays où les statistiques locales sont rares, une zone qui s'éclaire est en général une zone où l'on construit, où l'on commerce, où les revenus montent. La lumière est un **indicateur indirect** : on ne s'intéresse pas à elle, mais à ce qu'elle révèle.

Pourquoi ça ne marche plus ici. Un indicateur indirect n'est fiable que si son lien avec ce qu'il mesure reste **stable**. Or l'électrification change ce lien : elle rend la lumière possible et bon marché, à activité inchangée. Un lampadaire devant la mairie allume le pixel sans qu'aucune entreprise ait produit davantage.

Une comparaison : le nombre de parapluies ouverts mesure bien la pluie, sauf le jour où la mairie en distribue gratuitement.

Ce que le résultat montre vraiment. Que le réseau **est utilisé** : il y a de la lumière là où il n'y en avait pas. C'est une condition nécessaire à des effets économiques, pas une preuve de ces effets.

(b) Les autres résultats de l'article

ÉNONCÉ (B)

Quels autres résultats de l'article permettent d'en juger ?

RÉPONSE

Ceux qui portent sur autre chose que la lumière. D'après l'énoncé et les deux corrigés : des effets positifs sur l'**approvisionnement en eau** (systèmes alimentés par le réseau) et sur l'**électrification des écoles**, **pas d'effet sur le nombre d'élèves**, et, du côté des ménages, davantage d'équipements et d'accès aux services financiers, y compris chez les ménages non raccordés. Ce sont des usages concrets et des services collectifs, pas une mesure directe de la production ou des revenus.

EXPLICATION

✓ CETTE RÉPONSE DEMANDE D'AVOIR LU L'ARTICLE

L'énoncé rend obligatoire la lecture des sections 1 à 4 et du tableau 4. Je n'ai pas pu lire l'article (accès payant). Voici ce que je peux garantir.

- **Dit par l'énoncé** : effets positifs importants sur la luminosité, sur l'approvisionnement en eau et sur l'électrification des écoles ; pas d'effet sur le nombre d'élèves ; l'idée que les bénéfices passent par la communauté (éclairage public, écoles, pompes à eau, effets sur les ménages non raccordés).
- **Dit par les deux corrigés, à vérifier dans ta lecture** : équipement des ménages en appareils électriques, accès aux services financiers, absence de croissance démographique significative.

ChatGPT ajoute que, dans la colonne « DiD : TWFE » du tableau 4, les résultats sur l'eau et les écoles sont « plus imprécis » que dans les spécifications principales. C'est cohérent avec ce que tu trouves pour les écoles (question 3.8), mais je n'ai pas pu le contrôler.

Comment classer ces résultats. Demande-toi, pour chacun, s'il parle d'activité économique.

Résultat	Ce qu'il montre	Est-ce de l'activité économique ?
Lumière nocturne	le réseau est utilisé	pas directement
Systèmes d'eau alimentés par le réseau	un service collectif nouveau	non : un équipement
Écoles électrifiées, sans hausse du nombre d'élèves	un équipement amélioré	non

Résultat	Ce qu'il montre	Est-ce de l'activité économique ?
Appareils électriques et services financiers chez les ménages	un changement des conditions de vie	indirectement
Revenus, emploi, entreprises, production	ce qu'il faudrait observer	**oui, et c'est ce qui manque**

Tes propres résultats vont dans le même sens. Question 3.5 : un effet estimé positif sur les écoles électrifiées, aucun sur le nombre d'élèves. Le réseau modifie les équipements ; il ne modifie pas, dans ces données, les comportements mesurés.

RÉDACTION POSSIBLE POUR LE RAPPORT

À ajuster après ta lecture de l'article

L'article rapporte aussi des effets sur l'approvisionnement en eau par des systèmes alimentés par le réseau et sur l'électrification des écoles, sans hausse du nombre d'élèves, ainsi que, pour les ménages, davantage d'appareils électriques et d'accès aux services financiers, y compris chez ceux qui ne sont pas raccordés. Ces résultats décrivent des équipements collectifs et des conditions de vie. Pour conclure à une hausse de l'activité économique, il faudrait des mesures directes : revenus, emploi, création d'entreprises.

(c) La conclusion en trois phrases

ÉNONCÉ (C)

Formulez en trois phrases au plus la conclusion que vos estimations permettent de tirer.

RÉPONSE

Trois phrases, trois fonctions : **le résultat chiffré**, **l'hypothèse dont il dépend**, **ce qu'il ne montre pas**. Choisis ou adapte une des versions proposées plus bas.

EXPLICATION

Une bonne conclusion ne répète pas tous les chiffres. Elle dit ce qu'on a trouvé, à quelle condition c'est crédible, et où s'arrête ce qu'on peut affirmer.

Phrase	Sa fonction	Ce qu'elle doit contenir
1	Le résultat	+38 points, intervalle de 29 à 47, par rapport à quel groupe
2	La condition	tendances parallèles ; ce qui les rend plausibles ; ce qui fragilise l'ampleur (satellite)
3	La limite	lumière et équipements ne sont pas l'activité économique

Trois erreurs à éviter.

- Écrire « l'électrification augmente l'activité économique » : tes estimations ne le montrent pas.
- Donner l'erreur-type HC1 (0,033) comme mesure de précision : c'est l'erreur-type groupée (0,044) qui vaut.
- Écrire que le nombre d'écoles électrifiées « augmente significativement » : l'effet n'est plus significatif avec des erreurs-types groupées, et il vient surtout d'une baisse dans le groupe de comparaison (question 3.5).

L'énoncé dit « trois phrases au plus » : compte-les avant de rendre.

RÉDACTIONS POSSIBLES POUR LE RAPPORT (AU CHOIX)

Version courte

La double différence estime que l'arrivée du réseau a augmenté d'environ 38 points la part de localités visibles de nuit, par rapport aux localités raccordées plus tard. L'équipement scolaire semble s'améliorer, sans hausse discernable du nombre d'élèves. Cette lecture causale dépend de l'hypothèse de tendances parallèles, et la hausse de lumière ne mesure pas à elle seule une hausse de l'activité économique.

Version détaillée, avec intervalle et satellite

Le raccordement au réseau en 2008-2009 a augmenté de 38 points la part de localités visibles de nuit (intervalle de confiance à 95 % avec erreurs-types groupées : 29 à 47 points) par rapport aux localités raccordées en 2015-2017 ; l'effet estimé sur les écoles électrifiées est positif mais fragile, et rien n'apparaît sur le nombre d'élèves. Ce résultat repose sur l'hypothèse de tendances parallèles, compatible avec l'évolution des deux groupes avant 2008, et son ampleur dépend en partie du passage au satellite VIIRS en 2012. Il montre que le réseau apporte de la lumière et des équipements collectifs, mais ne suffit pas à établir une hausse de l'activité économique.

Version intermédiaire, qui commence par l'hypothèse

Sous l'hypothèse de tendances parallèles, que l'évolution des deux groupes avant 2008 rend plausible, l'arrivée du réseau a augmenté de 38 points (intervalle à 95 % : 29 à 47) la part de localités visibles de nuit. L'effet estimé sur les écoles électrifiées est positif mais imprécis, et aucun effet n'apparaît sur le nombre d'élèves. Ces résultats montrent que le réseau est utilisé et modifie les équipements collectifs ; ils ne permettent pas de conclure à une hausse de l'activité économique.

À RETENIR

- +38 points de localités visibles de nuit (IC à 95 % : 29 à 47), sous l'hypothèse de tendances parallèles.
- L'ampleur dépend du capteur : +10 points avec DMSP, +56 avec VIIRS.
- Effet positif mais fragile sur les écoles électrifiées, aucun sur le nombre d'élèves.
- La lumière prouve que le réseau est utilisé, pas que l'activité économique augmente.

QUESTIONS PROBABLES À L'ORAL

En une phrase, que montre ta partie 3 ?

Sous l'hypothèse de tendances parallèles, l'arrivée du réseau a augmenté de 38 points la part de localités visibles de nuit, avec un intervalle de 29 à 47 points ; cela montre que le réseau est utilisé, pas que l'activité économique a augmenté.

Que faudrait-il pour conclure sur l'activité économique ?

Des mesures directes : revenus ou consommation des ménages, emploi, nombre d'entreprises, production agricole. La lumière ne peut pas servir d'indicateur indirect ici, puisque le traitement est justement de l'électricité.

Annexe A — Valeurs de contrôle

Si ton propre code retrouve ces nombres, il est juste. Un écart à la quatrième décimale n'a pas d'importance ; un écart à la première signale une erreur d'échantillon : commence par vérifier nobs(m).

Question	Ce que tu calcules	Valeur attendue
1.1	Lignes et colonnes lues : `dim(immo_raw)` puis `dim(fisc_raw)`	286 120 × 13 puis 11 039 × 49
1.1	Communes dans le fichier des ventes / dans le fichier fiscal	565 / 581
1.1	Communes sans correspondance : ventes seulement / fiscal seulement	13 / 29
1.1	Base d'analyse : communes au total, puis Flandre / Wallonie / Bruxelles	551, puis 281 / 251 / 19
1.3	Erreur-type de la médiane : Rouvroy / Charleroi	38 796 € / 1 944 €
1.4	Asymétrie du prix / de `ln(prix)`	1,338 / −0,007
1.6	Élasticité du modèle log-log (erreur-type HC1)	1,4443 (0,1494)
1.9	Élasticité ; indicatrice Wallonie ; indicatrice Bruxelles	1,6078 ; −0,2049 ; 0,8949
1.13	Élasticités Flandre / Wallonie / Bruxelles	1,440 / 1,838 / 1,072
1.14	Breusch-Pagan sur les régresseurs : modèle 1.6 / modèle 1.9	82,6 / 9,26
1.15	Coefficient de `part_app` (HC1)	0,379 (0,076)
2.1	Nombre de mères	254 654
2.2	MCO : coefficient de `morekids`	−5,387 (0,087)
2.4	Première étape : coefficient de `samegender` ; statistique F	0,0675 ; 1 238
2.6	VI avec `samegender`	−6,314 (1,275)
2.8	2SLS avec `twoboys` et `twogirls` ; F de première étape	−5,463 (1,229) ; 657,9
2.11	Test de suridentification	3,856 (p = 0,0496)
2.12	Hausman : coefficient du résidu de première étape	−0,771 (1,232)
2.13	2SLS sur la probabilité de travailler	−0,119 (0,028)
3.1	Localités ; lignes de 2003 à 2014	574 ; 6 888
3.2	Localités traitées / de comparaison	59 / 238
3.4	Double différence (HC1) ; observations	0,3802 (0,0328) ; 2 866
3.6	Double différence placebo (HC1)	0,0129 (0,0277)
3.7	Effets fixes de localité et d'année (HC1)	0,3800 (0,0265)
3.8	Erreurs-types groupées : question 3.4 / question 3.7	0,0442 / 0,0467

Annexe B — Glossaire

2SLS
Doubles moindres carrés : on prédit le régresseur endogène à l'aide des instruments et des contrôles, puis on utilise cette prédiction dans l'équation d'intérêt. Fonction `ivreg()`.

anti_join
Fonction de `dplyr` qui renvoie les lignes d'une table sans correspondant dans une autre. Sert à repérer les communes présentes dans un seul fichier.

Biais d'atténuation
Biais vers zéro d'un coefficient quand le régresseur est mesuré avec une erreur aléatoire.

Biais de sélection
Biais qui apparaît quand les groupes comparés se sont formés selon des caractéristiques liées au résultat.

Biais de variable omise
Biais d'un coefficient quand on oublie une variable qui influence y et qui est corrélée au régresseur. Signe = (effet de la variable omise sur y) × (son lien avec le régresseur).

Catégorie de référence
La catégorie pour laquelle on ne met pas d'indicatrice. Tous les coefficients d'indicatrices mesurent un écart par rapport à elle.

Causalité inverse
Situation où c'est y qui influence x, et non (seulement) l'inverse.

Centrage
Soustraire une constante à un régresseur pour déplacer son point zéro. Ne change pas les pentes, mais rend interprétables la constante et les indicatrices.

Code INS
Code à cinq chiffres qui identifie chaque commune belge. C'est la clé qui permet de fusionner les deux fichiers de la partie 1.

Coefficient
Nombre estimé qui mesure de combien la variable dépendante change quand un régresseur augmente d'une unité, les autres régresseurs restant fixes.

Coefficient d'asymétrie
Mesure du déséquilibre entre les deux queues d'une distribution : nul si elle est symétrique, positif si la queue de droite est plus longue, négatif si c'est celle de gauche.

Colinéarité parfaite
Situation où un régresseur est une combinaison exacte des autres. Les MCO n'ont alors pas de solution unique, et R renvoie `NA` pour un coefficient.

Compliers
Individus dont le traitement dépend de l'instrument : ici, les mères qui ont un troisième enfant parce que les deux premiers sont de même sexe, et pas sinon.

Constante
Valeur prédite de y quand tous les régresseurs valent zéro. Notée `(Intercept)` dans R. Souvent sans interprétation concrète.

Contrefactuel
Ce qui serait arrivé au groupe traité s'il n'avait pas été traité. On ne l'observe jamais ; toute la méthode consiste à l'approcher.

Degrés de liberté
Paramètre d'une loi de test. Pour un khi-deux : le nombre de restrictions testées. Pour Sargan : nombre d'instruments moins nombre de variables endogènes.

Double différence
Différence, entre le groupe traité et le groupe de comparaison, de leurs évolutions avant-après.

Écart interquartile
Différence entre le troisième quartile (p75) et le premier (p25). Mesure la dispersion de la moitié centrale des observations.

Effets fixes
Une constante propre à chaque unité (localité) ou à chaque période (année). Absorbent tout ce qui ne varie pas dans le temps, ou tout ce qui est commun à une année.

Élasticité
Variation en pourcentage de y associée à une variation de 1 % de x. C'est la pente d'un modèle log-log.

Endogène
Se dit d'un régresseur corrélé au terme d'erreur. Son coefficient MCO est biaisé. Causes : variable omise, causalité inverse, erreur de mesure.

Erreur de mesure
Écart entre la valeur observée d'une variable et sa vraie valeur. Sur y : ajoute du bruit. Sur x : tire le coefficient vers zéro.

Erreur-type
Mesure de l'imprécision d'une estimation : de combien elle varierait d'un échantillon à l'autre. Plus elle est petite, plus l'estimation est précise.

Erreurs-types groupées
Erreurs-types qui autorisent les erreurs d'un même groupe (une même localité) à être corrélées entre elles. Dans R : `vcovCL()`.

Erreurs-types robustes HC1
Erreurs-types valables même en cas d'hétéroscédasticité. HC1 est la version de White multipliée par n/(n – k). Dans R : `vcovHC(m, type = "HC1")`.

Estimateur de Wald
Avec un instrument binaire : forme réduite divisée par première étape.

Exogène
Se dit d'un régresseur sans lien avec le terme d'erreur : $E(u \mid x) = 0$. Condition pour que son coefficient ne soit pas biaisé.

F de première étape
Statistique qui teste que les coefficients des instruments sont nuls dans la première étape. Avec un seul instrument, F = t².

Facteur de confusion
Variable qui agit à la fois sur la cause supposée et sur le résultat, et crée une association sans lien causal.

Forme fonctionnelle
Choix de mettre ou non la variable dépendante et les régresseurs en logarithme (niveau-niveau, log-log, log-niveau, niveau-log). Chaque forme impose une relation différente.

Forme réduite
Régression directe du résultat sur l'instrument. Mesure l'effet total de l'instrument sur le résultat.

Hétéroscédasticité
Situation où la variance du terme d'erreur dépend des observations. Les coefficients MCO restent sans biais, mais les erreurs-types classiques sont fausses.

Homoscédasticité
Hypothèse selon laquelle la variance du terme d'erreur est la même pour toutes les observations.

Hypothèse nulle
L'affirmation qu'un test met à l'épreuve, par exemple « le coefficient vaut zéro ». On la rejette si les données la rendent trop peu plausible ; ne pas la rejeter ne la prouve pas.

Indépendance
Condition selon laquelle l'instrument est « comme tiré au sort », sans lien avec les caractéristiques des individus.

Indicatrice
Variable qui vaut 1 si l'observation appartient à une catégorie, 0 sinon.

Instrument
Variable qui fait varier le régresseur endogène sans être liée au terme d'erreur. Permet d'isoler une variation « propre » du régresseur.

Instrument faible
Instrument qui fait très peu varier le régresseur endogène. L'estimation devient imprécise et peu fiable. Repère usuel : F de première étape inférieur à 10.

Interaction
Produit de deux régresseurs. Son coefficient mesure de combien l'effet de l'un change selon la valeur de l'autre (une pente différente par région, par exemple).

Intervalle de confiance
Plage de valeurs plausibles pour le vrai coefficient : estimation ± 1,96 × erreur-type pour un niveau de 95 %.

LATE
Effet moyen du traitement chez les « compliers » : c'est ce que mesure la VI quand l'effet diffère d'un individu à l'autre.

Logarithme
Fonction qui transforme les multiplications en additions. Une différence de logarithmes est approximativement une variation en pourcentage. `log()` dans R.

Loi du khi-deux
Loi suivie sous H_0 par les statistiques de plusieurs tests du travail (Breusch-Pagan, Sargan). Dépend d'un nombre de degrés de liberté.

Marge extensive
Marge extensive : participer ou non (travailler ou pas, être éclairé ou pas). Marge intensive : combien, parmi ceux qui participent.

Mauvais contrôle
Variable qui est elle-même une conséquence du régresseur d'intérêt (ou de y). La contrôler fausse l'interprétation.

MCO
Moindres carrés ordinaires : méthode qui choisit la droite (ou le plan) rendant la somme des carrés des résidus la plus petite possible. Fonction `lm()` dans R.

Médiane
Valeur qui partage les observations en deux moitiés égales. Peu sensible aux valeurs extrêmes, contrairement à la moyenne.

Modèle de probabilité linéaire
Régression linéaire dont la variable dépendante vaut 0 ou 1. Les coefficients se lisent en points de probabilité.

Moindres carrés pondérés
Variante des MCO qui donne plus de poids aux observations les plus précises. Plus efficace que les MCO en présence d'hétéroscédasticité de forme connue.

Monotonie
Hypothèse selon laquelle l'instrument pousse tout le monde dans le même sens (personne ne fait l'inverse). Nécessaire pour interpréter la VI comme un effet local.

Observation
Une ligne du tableau de données : une commune, une mère, une localité observée une année donnée.

p-valeur
Probabilité d'obtenir une statistique au moins aussi extrême que celle observée si l'hypothèse nulle était vraie. Petite p-valeur : les données contredisent H_0.

Panel
Données où les mêmes unités sont observées à plusieurs dates. Dans la partie 3, 574 localités suivies chaque année.

Pertinence
Première condition d'un instrument : il doit réellement faire varier le régresseur endogène. Se vérifie avec la première étape.

Placebo
Estimation refaite là où il ne devrait y avoir aucun effet (une fausse date de traitement, par exemple). Un « effet » placebo signale un problème.

Première étape
Régression du régresseur endogène sur l'instrument (et les contrôles). Mesure la force de l'instrument.

Puissance d'un test
Capacité d'un test à rejeter H_0 quand elle est fausse. Un test peu puissant laisse passer des écarts réels : son non-rejet n'est pas une preuve.

R^2
Part de la variance de la variable dépendante expliquée par le modèle, entre 0 et 1. Ne se compare qu'entre modèles ayant la même variable dépendante.

Régresseur
Une variable placée à droite du `~`, qui sert à expliquer la variable dépendante.

Résidu
Écart entre la valeur observée et la valeur prédite par le modèle estimé. C'est l'estimation du terme d'erreur, observation par observation.

Restriction d'exclusion
Condition selon laquelle l'instrument n'agit sur le résultat que par l'intermédiaire du régresseur endogène. Ne se teste pas directement.

Semi-élasticité
Variation en pourcentage de y associée à une hausse d'une unité de x. C'est 100 fois la pente d'un modèle log-niveau.

Significatif
Se dit d'un coefficient dont on rejette qu'il soit nul, à un seuil donné (5 % en général). Ne dit rien de l'importance pratique de l'effet.

Statistique t
Coefficient divisé par son erreur-type. Indique à combien d'erreurs-types de zéro se trouve l'estimation. Au-delà de 1,96 en valeur absolue : significatif à 5 %.

Suridentification
Situation où il y a plus d'instruments que de variables endogènes. On peut alors tester si les instruments donnent des réponses compatibles (test de Sargan ou test J).

Tendances parallèles
Hypothèse centrale de la double différence : sans traitement, les deux groupes auraient évolué de la même façon.

Terme d'erreur
Tout ce qui fait varier y en dehors des régresseurs du modèle. On ne l'observe pas. Les hypothèses importantes portent sur lui.

Test de Breusch-Pagan
Test d'homoscédasticité : on régresse les résidus au carré sur des variables, et $n \times R^2$ suit un khi-deux si la variance est constante.

Test de Hausman
Test qui compare les MCO et la VI pour savoir si le régresseur est réellement endogène. Suppose que les instruments sont valides.

TWFE
Régression avec à la fois des effets fixes d'unité et des effets fixes de période.

Unité statistique
Ce que représente une ligne du tableau. Partie 1 : une commune en 2023. Partie 2 : une mère. Partie 3 : une localité une année donnée.

Valeur ajustée
Valeur de y prédite par le modèle estimé pour une observation. Valeur observée = valeur ajustée + résidu.

Variable de contrôle
Variable ajoutée au modèle pour tenir constant un facteur qui influence y et qui est lié au régresseur d'intérêt.

Variable dépendante
La variable qu'on cherche à expliquer, notée y, à gauche du `~` dans une formule R.